

고부담 읽기 평가의 DIF(차별문항기능) 분석

-계열 선택에 따른 배경지식이 읽기 평가 결과에 영향을 미치는가?-

오 규 설*

< 次 例 >

- I. 서론
- II. 이론적 배경
- III. 연구 방법
- IV. 분석 결과
- V. 결론

I. 서론

수능 국어 영역의 난이도가 언론의 도마에 오르고(구무서, 2018; 서영표, 2015), 시험의 난이도와 타당도에 대한 논란이 지속되고 있다. 논란의 중심에는 이른바 비문학 영역으로 불리는 독서 문항이 있다. 독서 문항은 인문, 사회, 과학기술 영역에서 1,500 ~ 3,000자 내외의 정보 텍스트와 읽기 문항이 테스트렛(testlet) 형식으로 구성된다.

정보 텍스트를 읽는 능력을 평가하는 문항은 본질적으로 정보 텍스트의 내용과 구조에 영향을 받게 된다. 문제는 수능 국어의 독서 문항에 포함된 텍스트의 정보가 특정 전문 영역에 치우치는 데서

* 근화여자고등학교 교사

나타난다. 대학 수학 능력을 평가하는 시험이니만큼 전문적인 정보와 용어를 포함한 복잡도가 높은 텍스트를 활용하는 것은 문제가 아니다. 그러나 특정 영역에 속한 정보는 피험자의 배경지식에 따라 텍스트의 이해에 차이를 나타낼 수 있다. 읽기 능력에 영향을 미치는 여러 요인 가운데 배경지식이 미치는 영향은 절대적이다 (Bachman & Palmer, 2010; Hirsch, 2003; Kendeou & Van Den Broek, 2007; Marzano, 2004).

현재의 2015 개정 교육과정에 따른 수능 체제에서 학생들은 자신의 희망 진로 또는 전공에 따라 선택과목을 이수하고, 수능에서 탐구 영역 중 2과목을 선택한다.¹⁾ 교육과정의 취지와 달리 일선 현장에서는 여전히 문·이과의 경로대로 교육과정을 이수한 학생들이 다수이다. 인문사회 계열 학생들은 사회 교과 중심의 교육과정을 이수하고, 자연과학 및 공학 계열 학생들은 과학 교과 중심의 교육과정을 이수하는 것이다. 이에 따라 수능을 치르는 시점에서 응시자의 희망 전공 계열에 따라 배경지식이 다르게 구성되고, 이는 수능 국어 영역의 독서 문항 점수를 체계적으로 편향시킬 수 있다.

특정 교육과정을 이수한 학생 집단에게 독서 문항이 유리하거나 불리하다면 이는 평가 공정성(fairness) 측면에서 심각한 문제를 야기할 수 있다. 고부담 시험에서 공정성은 다양한 맥락을 포함하는 광의의 개념이다. American Educational Research Association,

1) 2023년 기준 수능 국어 영역에 응시하는 다수의 수험생은 2015 개정 교육과정을 이수한다. 이 교육과정은 이른바 ‘문·이과 통합형 교육과정’으로 문·이과의 구분 없이 모든 학생이 배우는 ‘공동과목’을 도입하고 통합사회 및 통합과학 과목을 신설하는 한편, 선택과목을 확대해 학습자가 자신의 희망 전공과 진로 또는 관심사에 따라 과목을 선택하여 개별화 교육과정을 구성할 수 있도록 하였다(교육부, 2015). 또한 개정 취지에 따라 2022학년도부터 대입제도를 개편하여, 사회·과학탐구 영역에서 계열 구분 없이 최대 2과목을 선택하도록 하였다(교육부, 2019).

American Psychological Association, & National Council on Measurement in Education (2014)는 공정성을 피험자에 대한 공정하고 공평한 대우, 측정 편향의 제거, 측정된 구인(construct)에 대한 접근, 시험 점수 해석의 타당성의 네 측면에서 논의한다. 평가 공정성을 위협하는 주된 요인은 측정의 편향이다(AERA, APA & NCME, 2014, p. 49). 이는 피험자의 하위 집단간 문항 반응의 차이를 식별하는 차별문항기능(Differential Item Functioning, DIF)의 개념으로 분석할 수 있다(Camilli, 2006, p. 226; Holland & Wainer, 1993). 특히 언어 평가는 피험자의 언어 능력과 텍스트, 문항, 맥락 등의 상호작용이 발생하므로, 언어 평가에서 발생하는 측정 편향은 시험 점수의 공정하고 타당한 해석에 장애가 될 수 있다(AERA, APA, & NCME, 2014, p. 53).

따라서 이 연구는 한국의 대학수학능력시험(이하 수능) 모의평가 국어 영역 독서 문항의 DIF를 분석하여 그 양상과 원인을 탐색하는 것을 목적으로 한다. 이를 위해 우선 읽기 능력과 배경지식의 관계에 대한 논의와 DIF의 개념을 검토한 뒤, 수능 모의평가 국어 영역의 독서 문항을 대상으로 DIF 분석을 시행한다. 이를 토대로 DIF 발생의 원인을 탐색하고, 대안을 논의하고자 한다.

II. 이론적 배경

1. 읽기 능력과 배경지식의 관계

학습자의 읽기 능력은 다양한 하위 구인들로 구성되어 있다. 인지

심리학의 관점에서는 인간의 기억과 기억된 정보에 따른 인지 처리를 정보 처리의 전제로 본다. 숙련된 독자는 장기기억에 저장된 어휘 정보를 토대로 단어의 재인과 장기기억에의 접근이 빠르고(Frederiksen, 1982; Perfetti, 1985), 읽기 과정에 대한 접근 중 하나인 스키마 모형에 따르면 텍스트의 해석에 독자의 지식이 중요하게 작용한다(Goodman, 1967; Rumelhart, 1980). 이러한 맥락에서 제시된 읽기 행위를 설명하는 지배적 패러다임인 구성-통합 모형(construction-integration model, Kintsch, 1998)에서는 학습자의 읽기 행위에서 이루어지는 이해가 표면적 텍스트의 표면 구조로부터 학습자의 장기기억에 저장된 배경지식과의 통합을 통해 상황 모형을 형성한다고 본다. 따라서 배경지식의 부재는 텍스트 이해의 유의미한 상황 모형을 구성하지 못하게 한다(Hirsch, 2003, p. 17). 또한 Bachman & Palmer (2010)의 언어 사용 모형에서도 언어 사용의 하위 요소에 주제적 지식이 있다고 보아 언어 사용에 영향을 미치는 지식의 역할에 주목한다.²⁾

배경지식이 읽기에 미치는 영향은 명료하다. 배경지식은 기본적인 이해의 속도를 높이고 작업 기억을 자유롭게 연결하여 언어 사용의 유창성을 향상시키고, 텍스트에 포함된 새로운 정보를 독자의 이전 학습 정보와 신속하게 연결지어 텍스트의 이해를 심화시킨다(de Groot, 1965; Hirsch, 2003, p. 13).

학습의 도구로 기능하는 읽기 행위의 특성에 따라 배경지식은 읽기뿐만 아니라 학업 성취에도 영향을 미친다. Marzano (2004, p. 127)에 따르면 특정 주제에 대한 개별 학습자의 배경지식과 새로운

2) Bachman & Palmer (2010)의 언어 사용 모형은 언어 사용의 하위 요소를 개인의 속성과 언어 능력으로 구분하는데 개인의 속성(individual attributes)에 주제적 지식, 정서적 스키마, 인지적 전략, 개인적 속성(personal attributes)이 있다고 본다.

정보의 학습 간에 보고된 평균 상관은 .66으로 나타났다. 또한 학문적 배경지식은 학교에서의 학습을 넘어 직업 및 사회경제적 지위(SES)와도 관련 있는 것으로 나타났다(Hofstetter, Sticht, & Hofstetter, 1999; Marzano, 2004). 한편 배경지식은 특정 주제 영역의 텍스트 이해에 영향을 미친다. Kendeou & Van Den Broek (2007)는 과학 텍스트의 이해에 배경지식(사전 지식)과 텍스트 구조가 미치는 영향을 실험하여 텍스트에 대한 독자의 기억이 배경지식의 영향을 받는다는 것을 밝혔다. Smith, Snow, Serry, & Hammond (2021)에서는 초등학생의 독해력에 배경지식이 미치는 영향을 살펴, 미숙한 독자가 배경지식을 활용하여 낮은 읽기 능력을 일부 보상하고 있음을 밝혔다. 이와 같이 장기기억 혹은 배경지식(주제적 지식)이 읽기와 이해에 영향을 미친다는 가설은 읽기 연구의 지난한 역사 속에서 이론적·경험적으로 논의되어 왔다.

2. 읽기 평가에서의 DIF

차별 문항 기능(DIF)은 의도하지 않은 요인에 의해 시험의 하위 집단 간 문항 반응에 차이가 나타나는지를 분석하는 통계적 방법이다(Bond & Fox, 2015; Ferne & Rupp, 2007; Zumbo, 2007). 이를테면 읽기 평가에서 성별, 지역, 배경지식 등 의도하지 않은 요인으로 인해 하위 집단에 따라 특정 문항에 대해 차별적 반응이 나타나는 것을 말한다. 이는 읽기 능력 외의 요인으로 인해 한 집단이 다른 집단에 비해 체계적으로 유리하거나 불리할 수 있다는 것을 말하며, 동일한 언어 능력을 가진 학생들이 읽기 능력의 구인 외 요인으로 인해 평가에서 다른 점수를 받을 수 있다는 것을 의미한다(Raquel, 2019, p. 103).

하위 집단 간 체계적인 편향이 발생하면, 집단 간 난이도 추정치와 능력 모수 추정치가 진점수와 다르게 나타날 수 있다. 이로 인해 평가 결과의 해석과 활용이 부정확해질 수 있고(Karami & Salmani Nodoushan, 2011), 시험의 공정성과 평가 타당도를 위협할 수 있다(Bachman, 2005; Raquel, 2019).

DIF 연구는 언어 평가 연구 분야를 중심으로 활발하게 전개되었다. 1980년대에 ETS에서는 언어 평가의 집단 간 점수 차이가 측정하고자 하는 구인에 대한 실제 능력 차이에서 비롯된 것인지로 조사하였다(Zieky, 2011). 읽기 평가의 경우 텍스트의 독해에 관여할 수 있는 여러 요인들에 대한 연구가 수행되었다. 이를테면 성별의 DIF를 탐색한 PIRLS의 연구(Mullis, Martin, Kennedy, & Foy, 2007)나 학년 요인의 DIF를 탐색한 연구(Koo, Becker & Kim, 2014), 학문적 요인의 DIF를 탐색한 연구(Pae, 2004) 등이 있다.

탐색적인 DIF 분석은 데이터에 기반하여 하위 집단간 문항 정보 및 능력 모수의 통계적 차이를 검증하거나 문항의 측정 차원을 판별한다(Song, Cheng, & Klinger, 2015, p. 100). 탐색적 접근은 하위 집단간 차별 문항을 통계적 방법으로 식별하는 단계와 DIF의 원인을 분석하는 검토 단계로 나뉜다(Gierl, 2005). 통계적 식별 단계에서는 다양한 DIF 분석 도구에 따라 차별 문항을 식별한다. 다음으로 검토 단계에서 교과 전문가가 특정 하위 집단 간의 차별적 수행에 기여하는 요인을 해석한다(Douglas, Roussos, & Stout, 1996). 탐색적 접근은 연령, 성별, 사용 언어, 배경지식 등 관측 변수를 활용하여 하위 집단 점수와 모델이 예측한 점수 간의 차이를 중심으로 이루어진다(Carlson & von Davier, 2017; Raquel, 2019). 또한 탐색적 접근에서는 다양한 통계적 이론에 기반한 DIF 분석 기법을 활용하여 DIF 식별의 경험적 증거로 활용된다. 관측 변수를 활용한 탐색적

DIF 분석 방법에는 Mantel-Haenszel, Logistic-Regression, Dichotomous Rasch Model, Simultaneous Item Bias Test, Lord's Chi-square Test 등이 있다.³⁾

첫째, DIF 분석에 널리 활용되는 Mantel-Haenszel(MH, Holland & Thayer, 1988; Mantel, 1963; Mantel & Haenszel, 1959)은 이분형 검사 문항에 사용되는 비모수 검정으로(NAEP, 2009),⁴⁾ 개별 문항과 응답 범주 내에서 총 문항 점수인 일치 기준(matching criterion)에 따라 하위 집단의 일치된 피험자 비율을 비교한다. 이를 토대로 두 하위 집단의 정답 확률이 동일하다는 통계적 가설을 검정하며, 참조 집단과 초점 집단의 난이도 차이를 나타내는 Mantel-Haenszel 공통 승산비(common odds ratio)를 추정한다.⁵⁾ 특정 문항에 대한 추정치가 양수값을 나타내면 해당 문항이 초점 집단이 참조 집단에 비해 더 쉬웠음을 의미한다.

둘째, MH와 함께 자주 활용되는 Logistic-Regression(Log-R, 로지스틱 회귀, Swaminathan & Rogers, 1990)은 관찰된 총시험 점수와 같은 조건 변수, 집단 변수, 조건 변수와 집단 변수의 상호작용을 분석하여 문항 정보를 추정한 뒤 변수 간 회귀 계수가 통계적으로 0과 유의하게 다를 경우 해당 문항이 DIF를 나타낸다고 본다.

셋째, Dichotomous Rasch Model(Wind & Hua, 2022)을 활용한 DIF 분석은 특수한 형태의 1모수 IRT 모형인 Rasch Model을 활용

3) 반면 잠재 변수를 활용한 방법, 즉 잠재 계층 분석을 이용한 DIF 분석에서는 응시자의 답변 간의 질적 차이를 바탕으로 DIF 그룹을 식별한다(e.g., Zhang & Roussos, 2009).

4) MH에 대한 논의는 NAEP (2009)를 참조하였다.

5) 전통적 시험 설계에서 시험 설계자가 의도한 집단을 참조 그룹(reference group)이라고 하고, 동일 시험에서 불리한 위치에 있을 것이라고 생각하는 집단을 초점 그룹(focal group)이라고 한다(Holland & Thayer, 1988).

하여 하위 집단간 문항 난이도를 비교한다. 이를 위해 개선된 Wald test(Cai, 2012)를 활용하여 하위 집단별 문항 난이도를 추정한다. 이때 집단에 따라 통계적으로 유의한 수준의 문항 난이도 차이를 보이는 특정 문항이 나타날 경우 DIF를 나타내는 것으로 본다. Rasch Model에 기반한 DIF의 경우 평가 영역의 일차원성을 전제로 하여, 이분 모형을 활용하여 학습자 개인의 능력 모수를 통제하여 문항 정보를 추정하고 이를 하위 집단별로 비교하여 DIF를 식별한다(Linacre & Wright, 1987). Rasch 모형 방식의 장점은 균일한 DIF 외에도 비균일한 경우에도 DIF를 식별 가능하다는 데 있다(Linacre, 2018).

넷째, Simultaneous Item Bias Test(SIBTEST, 동시 문항 편향 테스트, Shealy & Stout, 1993)는 문항에 대한 초점 집단과 참조 집단의 성과를 비교하기 위해 선형 회귀 수정 방법(linear regression based correction method)을 활용해, 표준화 평균 차 척도를 활용하여(Dorans & Kulick, 1986) 추정한 β 와 효과 크기를 추정한다.⁶⁾ 이를 토대로 β 추정치가 0과 유의하게 다르고, 효과 크기의 절댓값이 .25 이상인 경우를 DIF로 식별한다. 총점에 대한 비교를 통해 집단간 비교 가능성을 확립하는 MH 방법에 비해 선형 회귀 수정 방법을 사용하는 SIBTEST는 극단적인 DIF가 발생하는 문항에 대해 제1종 오류를 통제한다는 점에서 이점이 있다(Roussos & Stout, 1996).

다섯째, Lord's Chi-square Test(Lord, 1980)는 문항 난이도, 변별도, 집단 등 매개변수를 활용해 하위 집단의 유의성 검정을 수행한다. 특히 purifying test라는 절차를 통해 시험이 여러 하위 집단에

6) SIBTEST에 대한 논의는 NAEP (2008)를 참조하였다.

결쳐 동일한 구인을 측정하는지 확인하는데, 하위 집단별 매개변수의 차이에 대한 유의성 검정과 가설 검정을 통해 집단 간 차별 기능을 분석한다.

III. 연구 방법

이 연구는 2022년 6월 시행된 수능 모의평가의 국어 영역의 독서 영역을 대상으로 DIF 분석을 수행하였다. 데이터는 A 지역의 일반계 고등학교 2개교에서 시행된 독서 문항 17개에 대한 응답값(N=325)을 수집하였다.⁷⁾ 하위 집단은 모의 수능 탐구 영역 응시 과목에 따라 인문사회 계열(N=146)과 자연과학 계열(N=179)로 나누었으며, 통합 선택 응답자(N=23)는 자연과학 계열로 코딩하였다.

본 연구에서는 앞서 제시한 Mantel-Haenszel, Logistic-Regression, Dichotomous Rasch Model, Simultaneous Item Bias Test, Lord's Chi-square Test를 활용하여 탐색적 DIF 분석을 수행하였다. 고부담 읽기 평가의 DIF를 분석하기 위해 탐색적인 접근을 사용하는 까닭은 비모수 검정인 MH, 일차원 IRT 분석인 Dichotomous Rasch Model과 Lord's Chi-square test, 다차원 IRT 분석인 SIBTEST 등 다양한 조건 하에서 데이터의 DIF를 탐색하기 위함이다. 무엇보다 매 시험의 모집단 데이터는 고정되지 않고, 정규성이나 일차원성이 일관되게 전제되지 않기 때문에 다양한 방식의 DIF 분석 방법을 활용하는 탐색적 접근 방식이 일반적으로

7) 피험자의 성별은 남자 193명, 여자 132명이며, 개인식별정보를 삭제한 데이터를 수집하여 분석을 실행하였다.

활용된다.

본 연구에서 시행한 탐색적 DIF 분석은 다음과 같은 분석 도구를 활용하였다. 우선 LR, MH, SIBTEST, Lord’s Chi-square test의 분석에는 difR(Magis, Béland, Tuerlinckx, De Boeck, 2010)를 사용하였다. 그리고 Dichotomous Rasch Model의 분석에는 eRm(Debelak & Koller, 2020)과 TAM(Robitzsch, Kiefer & Wu, 2022) 패키지를 사용하였다. 탐색적 분석은 Google colab(R. version 4.3.2) 환경에서 수행하였고, 이후 검토 단계에서 개별 문항의 DIF 특성에 대해 분석하였다.

IV. 분석 결과

먼저 이분형 라쉬 모형(dichotomous Rasch model)을 활용하여 17개 문항에 대한 문항 난이도(θ)와 문항 용이도(easiness, β)를 추정하였다.

<표 1> 문항 난이도(θ) 추정

Item	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
Estimate	-3.25	-2.38	-1.45	-0.07	-0.46	1.02	0.43	0.54	0.38	0.54	0.43	0.30	2.90	1.20	0.58	-0.20
S. E	0.22	0.16	0.13	0.12	0.12	0.14	0.13	0.13	0.12	0.13	0.13	0.12	0.27	0.15	0.13	0.12
Lower CI	-3.68	-2.69	-1.69	-0.30	-0.69	0.75	0.18	0.29	0.14	0.29	0.18	0.06	2.38	0.91	0.33	-0.43
Upper CI	-2.83	-2.07	-1.20	0.16	-0.23	1.30	0.67	0.79	0.62	0.79	0.67	0.54	3.42	1.49	0.83	0.03

<표 2> 문항 응이도(β) 추정

Item	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
Estimate	0.50	3.25	2.38	1.45	0.07	0.46	-1.02	-0.43	-0.54	-0.38	-0.54	-0.43	-0.30	-2.90	-1.20	-0.58	0.20
S. E	0.12	0.22	0.16	0.13	0.12	0.12	0.14	0.13	0.13	0.12	0.13	0.13	0.12	0.27	0.15	0.13	0.12
Lower CI	0.27	2.83	2.07	1.20	-0.16	0.23	-1.30	-0.67	-0.79	-0.62	-0.79	-0.67	-0.54	-3.42	-1.49	-0.83	-0.03
Upper CI	0.73	3.68	2.69	1.69	0.30	0.69	-0.75	-0.18	-0.29	-0.14	-0.29	-0.18	-0.06	-2.38	-0.91	-0.33	0.43

문항 난이도 매개변수의 범위는 -3.25에서 2.89이며, 용이성 매개변수의 범위는 -3.42에서 3.67 나타났다.

이후 하위 집단별 문항 난이도의 통계적 유의성을 검토하기 위해 Wald test를 수행하였다.⁸⁾


<표 3> Wald test 분석 결과

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
z-statistic	0.21	-1.08	-1.09	0.56	0.76	1.25	0.92	0.48	-0.56	-1.16	-0.03	-1.86	0.84	-0.77	0.14	2.60	0.96
p-value	0.84	0.28	0.28	0.58	0.45	0.21	0.36	0.63	0.58	0.25	0.98	0.06	0.40	0.44	0.89	0.01	0.34

대부분의 문항에서 z-통계량과 p-값은 하위 집단 간에 통계적으로 유의한 차이를 보이지 않았으나, 16번 문항에서 유의한 차이($z = 2.60$, $p = 0.009$)가 나타났으며, 이는 하위 집단 간 문항 난이도에 차이가 있음을 시사한다.

하위 집단별 문항 난이도를 시각화하면 아래와 같다.

8) Wald test는 가설 검정 방식 중 하나로 무제약 추정치와 영가설 하의 추정값 사이의 가장 거리를 기반으로 통계적 매개변수의 제약을 평가하는 용도로 활용한다.




[그림 1] 하위 집단 간 문항 용이도 차이

위 그림에서 16번 문항이 집단 1, 즉 인문사회 계열 학습자에게 상대적으로 쉬웠음을 알 수 있다. 16번 문항은 경제학에서 사건의 효과를 평가하는 이중차분법에 대한 지문에서 새로운 자료에 적용하는 문항이다. 한편 자연과학 계열 집단에게 유리한 문항은 2번과 12번으로 나타났는데, 2번 문항은 독서 이론에 대한 지문에서 매튜 효과를 그래프로 제시한 문항이며, 12번 문항은 혈액의 응고와 순환에서 비타민 K의 중요성을 다룬 지문에서 비타민 K1과 K2의 개념을 묻는 문항이다.

다음으로 LR, MH, SIBTEST, Lord's Chi-square test를 수행하였다.


다음은 LR을 활용하여 DIF를 분석한 결과이다.



[그림 2] 로지스틱 회귀 DIF 분석 결과

로지스틱 회귀 분석 결과 다양한 DIF 수준이 나타났다. 특히 2번 문항이 통계적으로 유의한 DIF(statistic = 8.6371, p-value = 0.0133)를 나타냈으며, 나머지 문항은 통계적으로 유의한 DIF를 나타내지 않았다.


다음은 비모수 검정인 MH 분석 결과이다.



[그림 3] MH DIF 분석 결과


MH 분석 결과 승산비를 나타내는 AlphaMH은 특정 문항에서 초점 그룹의 선호를 나타내므로 해당 값이 큰 문항은 잠재적인 DIF 요인을 내포하고 있음을 알 수 있다. AlphaMH 값이 1보다 크게 나타난 문항은 2번(AlphaMH = 1.604), 3번(AlphaMH = 1.627), 12번(AlphaMH = 1.716), 14번(AlphaMH = 1.956)이었다. 그리고 MH Chisq가 유의수준 .05에서 통계적으로 유의한 DIF를 보인 문항은 없었지만, 12번과 16번이 근접한 분포를 보였다.

다음은 다차원 IRT인 SIBTEST 분석 결과이다.



[그림 4] SIBTEST DIF 분석 결과

SIBTEST DIF 분석 결과 DIF 유형을 균일한 DIF로 판단하였으며, 이는 문항 기능에 일관된 차이가 있음을 의미한다. 추정된 β 는 12번($\beta = 0.1069$, $p\text{-value} = 0.04$)에서 통계적으로 유의한 DIF가 식별되었다. 대조적으로 14번($\beta = 0.2331$, $p\text{-value} = 0.266$)은 상대적으로 반대 방향으로 효과 크기가 검출되었으나 통계적으로 유의한 결과를 나타내지는 않았다.



[그림 5] Lord's Chi-square Test 분석 결과

2PL 모형을 활용하여 분석한 Lord's Chi-square Test 결과 유의성에 대한 검출 임계값은 유의 수준 0.05에 해당하는 5.9915로 설정되었고, 이에 따라 DIF가 검출된 문항은 1, 2, 4, 6, 7, 8, 9, 10, 12, 13, 15번이었다. 특히 1, 4, 6번은 통계적으로 매우 유의한 수준($p < 0.001$)을 나타냈다.

이상의 결과를 종합하면 다음과 같다.

<표 4> 탐색적 DIF 분석 결과

분석 방법	식별 문항	식별 문항수
dichotomous Rasch model	16	1
LR	2	1
MH	12, 16	2
SIBTEST	12	1
Lord's Chi-square Test	1, 4, 6	3

12, 16번 문항이 공통적으로 2회 식별되었고, 1, 2, 4, 6번 문항이 1회 식별된 것을 확인할 수 있다. 복수의 통계적 방법에 의해 DIF가 식별된 문항은 해당 문항이 집단에 따라 차별적으로 기능하는 정도가 강하다는 것을 나타낸다. 또한 이는 하위 집단에 따라 특정 문항에 유불리가 발생하였다는 것을 지지하는 통계적 증거가 된다.

다음으로 DIF가 식별된 문항에 대한 검토를 통해 DIF의 발생 원인을 탐색하였다. 집단 간 비교를 위해 dichotomous Rasch model을 활용해 집단별 문항 난이도를 추정하였다.

<표 5> 집단간 문항 난이도 비교

item	Group 1(인문사회 계열)		Group 2(자연과학 계열)	
	xsi	se.xsi	xsi	se.xsi
1	0.06	0.17	-0.12	0.16
2	-2.48	0.30	-3.20	0.35
3	-1.65	0.22	-2.23	0.24
4	-0.95	0.19	-1.03	0.18
5	0.42	0.18	0.37	0.16
6	-0.03	0.17	0.04	0.16
7	1.46	0.21	1.50	0.19
8	0.95	0.19	0.84	0.17
9	1.21	0.20	0.84	0.17
10	1.13	0.20	0.62	0.17
11	1.13	0.20	0.90	0.17
12	1.29	0.20	0.59	0.17
13	0.78	0.18	0.76	0.17
14	3.76	0.51	3.09	0.33
15	1.75	0.23	1.58	0.20
16	0.81	0.18	1.25	0.18
17	0.27	0.17	0.27	0.16

12번 문항의 경우 혈액 응고 및 순화에 관여하는 비타민 K의 역할에 대한 과학 지문에 대해 비타민 K1과 K2에 대한 설명을 묻는 추론적 독해 문항이다. 인문사회 계열 집단($b = 1.292$)과 자연과학 계열 집단($b = 0.589$)의 난이도를 비교하면 자연과학 계열의 난이도가 낮게 추정된 것을 확인할 수 있다.

지문과 선지에는 ‘간세포’, ‘합성’, ‘표적 단백질’, ‘아미노산’, ‘활성화’ 등 생명과학 분야의 전문 어휘가 나타나는데, 이러한 어휘와 개념에 대한 배경지식을 가진 집단에서는 텍스트에 대한 독해가 원활

하게 이루어지리라 예상할 수 있다. 반면 특정 분야에 대한 배경지식이 없는 집단에서는 텍스트(지문)의 증거에 의존하여 개념을 추론하고 이해를 시도해야 하므로 텍스트의 독해에 요구되는 인지적 부담이 증가한다. 특히 10 ~ 13번은 과학 지문에 속한 세트 문항으로 13번을 제외하고 나머지 문항들은 집단 간 난이도 차가 발생한다는 점을 고려하면 이러한 난이도 차이는 배경지식이 독해에 미치는 여러 영향 가운데 이해의 정확도나 이해 속도와 관련되었음을 방증한다.

16번 문항은 정책 논의를 위해 사건의 효과를 평가하는 이중차분법에 대한 사회 지문에 대해, 지문의 내용을 <보기>에 제시된 새로운 사례의 내용에 적용하는 추론적 독해 문항이다. 이 문항에 대해 인문사회 계열 집단($b = 0.809$)보다 자연과학 계열 집단($b = 1.249$)의 난이도가 높게 추정되었다. 이 문항에는 시행집단, 비교집단, 정책의 시행 시점, 시행 전후의 효과 여부 등에 대한 이해가 요구되는데, 이는 행정·정치·경제학에서 주로 다루는 개념이다.

한편 한나라 초기의 사상과 조선 초기 진행된 고려 관련 역사서 편찬을 다룬 인문 지문에 포함된 4~8번의 경우 두 집단 간 난이도 차가 발생하지 않았다. 또한 사회 지문에 포함된 14~16번 문항의 경우 14, 15번은 인문사회 계열이 자연과학 계열에 비해 난이도가 높게 추정되었다.

이중차분법이나 비타민 K는 2015 개정 교육과정에 포함되지 않는 개념이다. 그러나 이를 설명하기 위해 지문에 기술되는 내용에는 특정 학문 분야와 밀접하게 관련된 개념들이 등장하고, 학습자는 자신이 선택한 교육과정 경로에 따라 구축된 배경지식을 활용하여 독해를 수행한다. 이는 보편적으로 상정하는 배경지식에 기대어 독해를 수행한다는 읽기 평가의 전제를 위반하는 것이며, 이러한 배경지식의 차이가 독해의 실행에 작용하여 읽기 평가 문항의 난이도에까

지 영향을 미친다고 볼 수 있다. 특히 현 교육과정 체제는 학습자 중심의 교육과정을 표방하여 개별 학습자가 일반·진로 선택 과목의 선택을 자유롭게 할 수 있으므로, 높은 수준의 학술적 텍스트 독해에 일반·진로 선택 과목의 이수 경로에 따른 배경지식의 차이가 영향을 미친다는 것은 평가 공정성 측면에서 문제가 될 수 있다.

요약하면 배경지식의 여부가 텍스트의 독해와 읽기 평가 문항의 답을 찾는 데에 미치는 영향이 주제 영역에 따라 다르게 나타난다고 볼 수 있다. 특히 과학 분야의 경우 배경지식이 독해와 문항 정답 여부에 미치는 영향이 큰 것으로 해석할 수 있다. 이는 과학 분야의 지식이 가진 개념의 정교함, 원리와 과정, 개념 간 인과 관계 등의 특수성에 기인한 것으로 보인다.

V. 결론

이 연구는 배경지식 변인이 읽기 평가의 DIF로 작용하는지를 분석하여 그 양상을 검토하고 원인을 탐색하였다. 탐색적 DIF 분석에 따르면 과학 분야의 지문에 포함된 문항이 DIF를 나타내는 것으로 식별되었으며, 그 원인을 과학 분야의 텍스트에 담긴 정보의 특성에 기인한 것으로 분석하였다.

평가의 DIF는 시험 점수의 공정하고 타당한 해석에 위협이 될 수 있다(AERA, APA, & NCME, 2014, p. 54). 읽기 평가의 경우 텍스트와 학습자의 읽기 구인 외에 여러 외적 요인이 개입할 여지가 많으므로 더욱 DIF의 식별에 민감하게 반응할 필요가 있다. 교육 전문가, 특히 평가의 설계와 개발에 참여하는 이들은 평가 도구의 품질을 개선하여 평가를 공정하게 만들 책임이 있으므로(Jencks &

Phillips, 1998), 읽기 평가의 설계자와 문항 개발자는 DIF 발생 요인을 고려하여 신중하게 읽기 평가를 개발할 필요가 있다.

읽기 평가의 DIF를 감소시키기 위한 제안 사항은 다음과 같다.

첫째, 배경지식 요인의 영향을 줄이는 문항을 개발해야 한다. 읽기 평가는 텍스트와 선지 요소가 문항의 질과 문항 난이도, 변별도와 같은 문항 정보에 직접적인 영향을 미친다. 따라서 텍스트의 주제와 내용을 선정할 때 배경지식에 따라 DIF가 발생하지 않도록 공통 교육과정 내의 주제와 내용에 한정하여 텍스트를 선정할 필요가 있다. 혹은 공통 교육과정 범위 내의 주제 영역 가운데 현실 세계의 이슈를 반영한 텍스트를 활용할 필요가 있다.

둘째, 읽기 능력에 직접적으로 관련되는 요인을 평가 문항 개발에 반영해야 한다. 배경지식과 같이 DIF를 유발하는 요인 외에, 정보의 효과적인 저장과 인출과 관련된 구인이나 텍스트 요인을 반영하여 문항을 개발할 필요가 있다. Kintsch (1998)의 구성-통합 모형에 따르면 학습자가 텍스트 표면의 정보를 자신의 사전지식에 통합하기 위한 작동 기억의 효율적 기능을 강조한다. 따라서 3,000자 내외의 제한된 텍스트 중심으로 지문을 개발하기보다는 평가 요소에 맞게 다양한 분량의 텍스트를 활용해야 한다. 이를테면 작동 기억의 수행을 측정하기 위해서는 읽기 전략과 같은 평가 요소를 활용할 수 있는데, 교양서 1개 절 분량의 텍스트(원고지 5~60매, 10,000~12,000자)를 지문으로 선정하여 읽기 전략과 독해 기능을 평가할 수 있다. 한편 주세형, 남가영(2015)에서는 수능 국어(언어) 영역의 과학 지문 특성을 분석하여 개념, 과정, 맥락, 문단 짜임 등의 기준으로 지문의 유형을 분류하였는데, 맥락과 문단 짜임과 같은 요소가 포함되지 않는 지문의 경우 적절하지 않다고 판단하였다. 이러한 텍스트적 장치는 과학 지식을 독자가 쉽게 받아들일 수 있게 하는 것으로, 배경지

식으로 인한 DIF의 발생 가능성을 줄일 수 있는 대안이 될 수 있다.

셋째, 지역, 연령, 사회문화적 지위 등 다양한 요인에 대한 읽기 평가의 DIF 연구가 지원되어야 한다. 한국 수능의 경우 수능 데이터가 공개되지 않는 것이 연구의 가장 큰 걸림돌이기 때문에, 관련 기관에서는 수능 데이터를 공개하여 평가 운영의 투명성과 공정성을 확보해야 할 것이다.

넷째, 읽기 평가 설계 단계에 DIF 검토 단계를 포함하여 평가 개발을 차원에서 공정성 확보를 위한 노력을 기울여야 한다. DIF 분석은 평가의 공정성과 타당도의 평가에서 필수적인 요소이다(Zwick, 2012, p. 22). 대단위 언어 평가 서비스를 운영하는 ETS는 이미 평가 개발 절차에 DIF 분석 단계를 포함하여 평가의 타당도와 공정성을 제고하기 위해 노력하고 있다(Schaeffer, Briel, & Fowles, 2001). 따라서 평가 개발 단계에서 언어 평가 전문가와 측정 전문가로 구성된 공정성 위원회의 DIF 검토를 거쳐야 하며, 평가 시행 후 사후 DIF 분석을 통해 차기 시험에서 개선할 수 있는 절차를 마련해야 한다.

이 연구는 고부담 읽기 평가인 수능 모의 평가의 국어 영역을 대상으로 DIF 분석을 수행하였다는 점에서 의의가 있다. 그러나 제한된 표본을 분석 대상으로 삼은 점, 읽기 평가의 DIF에 영향을 미치는 요인을 배경지식에 한정된 점은 연구의 한계라 할 수 있다.

평가 공정성의 확보는 국어교육 연구자들에 의해 개선될 수 있는 영역이다. 그 막중한 책무성을 안고 공론장에서 치열한 논의를 통해 보다 더 나은 시험을 개발하여 진일보한 고부담 평가를 시행할 수 있을 것이다.

참고 문헌

- 주세형, 남가영 (2015). 국어과 읽기 평가 맥락에서 과학 지문의 특성 연구. **교육과정평가연구**, 18(3), 313-342.
- American Educational Research Association(AERA), American Psychological Association(APA), & National Council on Measurement in Education(NCME) (2014). *Standards for educational and psychological testing*. Washington, DC: American Educational Research Association.
- Bachman, L. F. (2005). Building and supporting a case for test use. *Language Assessment Quarterly*, 2(1), 1-34.
- Bachman, L. F., & Palmer, A. S. (2010). *Language assessment in practice*. Oxford: Oxford University Press.
- Bond, T., & Fox, C. M. (2015). *Applying the Rasch model: Fundamental measurement in the human sciences*. New York, NY: Routledge.
- Cai, L. (2012). *flexMIRT: Flexible multilevel item factor analysis and test scoring* [Computer software]. Seattle, WA: Vector Psychometric Group, LLC.
- Camilli, G. (2006). Test fairness: In Brennan, R. L. (Ed.), *Educational measurement* (4th ed.) (pp. 220-256). Westport, CT: American Council on Education.
- Carlson, J. E., & von Davier, M. (2017). Item response theory. *Advancing human assessment: The methodological, psychological and policy contributions of ETS*, 133-178.
- de Groot, A. (1965). *Thought and Choice in Chess* (2nd ed.). The Hague: Mouton Publishers.
- Debelak, R., & Koller, I. (2020). Testing the local independence assumption of the Rasch model with Q 3-based nonparametric model tests. *Applied Psychological Measurement*, 44(2), 103-117.
- Dorans, N. J., & Kulick, E. (1986). Demonstrating the utility of the standardization approach to assessing unexpected differential item

- performance on the scholastic aptitude test. *Journal of Educational Measurement*, 23, 355-368.
- Douglas, J., Roussos, L., & Stout, W. (1996). Item-bundle DIF hypothesis testing: Identifying suspect bundles and assessing their differential functioning. *Journal of Educational Measurement*, 33, 465-484.
- Ferne, T., & Rupp, A. A. (2007). A synthesis of 15 years of research on DIF in language testing: Methodological advances, challenges, and recommendations. *Language Assessment Quarterly*, 4(2), 113-148.
- Frederiksen, J. R. (1982). A componential theory of reading skills and their interactions. *Center for the Study of Reading Technical Report: no. 227*, Champaign, IL: University of Illinois at Urbana-Champaign, Center for the Study of Reading.
- Gierl, M. J. (2005). Using dimensionality based DIF analyses to identify and interpret constructs that elicit group differences. *Educational Measurement: Issues and Practice*, 24(1), 3-14.
- Goodman, K. S. (1967). Reading: a psycholinguistic guessing game. *Journal of the Reading Specialist*, 6(1), 126-135.
- Hirsch, E. D. (2003). Reading comprehension requires knowledge of words and the world. *American educator*, 27(1), 10-13.
- Hofstetter, C. R., Sticht, T. G., & Hofstetter, C. H. (1999). Knowledge, literacy, and power. *Communication Research*, 26(1), 58-80.
- Holland, P. W., & Thayer, D. T. (1988). Differential item performance and the Mantel - Haenszel procedure. In H. Wainer & H. I. Braun (Eds.), *Test validity* (pp. 76-86). Hillsdale, NJ: Routledge.
- Holland, P. W., & Wainer, H. (1993). *Differential item functioning*. Hillsdale, NJ: Lawrence Erlbaum.
- Jencks, C., & Phillips, M. (1998). The black-white test score gap: Why it persists and what can be done. *The Brookings Review*, 16(2), 24-27.
- Karami, H., & Salmani Nodoushan, M. A. (2011). Differential item functioning:

- Current problems and future directions. *International Journal of Language Studies*, 5(3), 133-142.
- Kendeou, P., & Van Den Broek, P. (2007). The effects of prior knowledge and text structure on comprehension processes during reading of scientific texts. *Memory & cognition*, 35(7), 1567-1577.
- Kintsch, W. (1998). *Comprehension: A paradigm for cognition*. Cambridge: Cambridge University Press.
- Koo, J., Becker, B. J., & Kim, Y.-S. (2014). Examining differential item functioning trends for English language learners in a reading test: A meta-analytical approach. *Language Testing*, 31(1), 89-109.
- Linacre, J. M., & Wright, B. D. (1987). Item bias: Mantel-Haenszel and the Rasch model. *Memorandum No. 38*, Washington, D.C.: ERIC Clearinghouse.
- Lord, F. M. (1980). *Applications of item response theory to practical testing problems*. Hillsdale, NJ: Erlbaum.
- Magis, D., Béland, S., Tuerlinckx, F., & De Boeck, P. (2010). A general framework and an R package for the detection of dichotomous differential item functioning. *Behavior research methods*, 42(3), 847-862.
- Mantel, N. (1963). Chi-Square Tests With One Degree of Freedom: Extensions of the Mantel-Haenszel Procedure. *Journal of the American Statistical Association*, 58, 690 - 700.
- Mantel N., & Haenszel, W.M. (1959). Statistical Aspects of the Analysis of Data From Retrospective Studies of Disease. *Journal of the National Cancer Institute*, 22, 719 - 748.
- Marzano, R. J. (2004). *Building background knowledge for academic achievement: Research on what works in schools(1st ed.)*. Ascld.
- Mullis, I. V. S., Martin, M. O., Kennedy, A. M., & Foy, P. (2007). PIRLS 2006 International Report: IEA's Progress in *International Reading Literacy Study in primary schools in 40 countries*. MA: TIMSS & PIRLS International Study Center, Boston College.

- Pae, T.-I. (2004). DIF for examinees with different academic backgrounds. *Language Testing*, 21(1), 53-73.
- Perfetti, C. A. (1985). *Reading ability*. Oxford University Press.
- Raquel, M. (2019). The Rasch measurement approach to differential item functioning (DIF) analysis in language assessment research. *Quantitative data analysis for language assessment*, 1, 103-131.
- Robitzsch, A., Kiefer, T., & Wu, M. (2022). TAM: Test Analysis Modules. R package version 4.1-4.
- Roussos, L. A., & Stout, W. F. (1996). Simulation studies of the effects of small sample size and studied item parameters on SIBTEST and Mantel Haenszel type I error Performance. *Journal of Educational measurement*, 33(2), 215-230.
- Rumelhart, D. (1980). Schemata: The Building Blocks of Cognition. In R. Spiro, B. Bruce, & W. Brewer (Eds.), *Theoretical Issues in Reading Comprehension* (pp. 33-58). NJ: Erlbaum Associates.
- Schaeffer, G. A., Briel, J. B., Fowles, M. E., Boodoo, G., Braun, H., Lewis, C., & Thayer, D. (2001). Psychometric Evaluation of the New GRE® Writing Assessment. *ETS Research Report Series*, 2001(1), i-53.
- Shealy, R., & Stout, W. (1993). A model-based standardization approach that separates true bias/DIF from group ability differences and detects test bias/DIF as well as item bias/DIF. *Psychometrika*, 58(2), 159-194.
- Smith, R., Snow, P., Serry, T., & Hammond, L. (2021). The role of background knowledge in reading comprehension: A critical review. *Reading Psychology*, 42(3), 214-240.
- Song, X., Cheng, L., & Klinger, D. (2015). DIF investigations across groups of gender and academic background in a large-scale high-stakes language test. *Language Testing and Assessment*, 4(1), 97-124.
- Swaminathan H. & Rogers H. (1990). Detecting differential item functioning using logistic regression procedures. *Journal of Educational Measurement*.

274), 361-370.

- Wind, S., & Hua, C. (2022). *Rasch measurement theory analysis in R*. CRC Press.
- Zieky, M. J. (2011). The origins of procedures for using differential item functioning statistics at Educational Testing Service. In N. Dorans, & S. Sinharay (Eds.), *Looking back: Proceedings of a conference in honor of Paul W. Holland* (pp. 115-127). New York: Springer.
- Zumbo, B. D. (2007). Three generations of DIF analyses: Considering where it has been, where it is now, and where it is going. *Language assessment quarterly*, 42), 223-233.
- Zwick, R. (2012). A review of ETS differential item functioning assessment procedures: Flagging rules, minimum sample size requirements, and criterion refinement. *ETS Research Report Series*, 20121), i-30.
- 교육부 (2015. 09. 23.), **2015 개정 교육과정 총론 및 각론 확정·발표** [보도 자료], Retrieved from <https://www.moe.go.kr/boardCnts/viewRenew.do?boardID=294&boardSeq=60753&lev=0&searchType=null&statusYN=C&page=1&s=moe&m=020402&opType=N>
- 교육부 (2019. 08. 13.), **2022학년도 대학수학능력시험 기본계획 발표** [보도 자료], Retrieved from <https://www.moe.go.kr/boardCnts/viewRenew.do?boardID=294&boardSeq=78242&lev=0&searchType=null&statusYN=W&page=1&s=moe&m=020402&opType=N>
- 구무서 (2018. 11. 16.). “역대 최악 국어, 난이도 조절 실패”...교사·입시전문가 한목소리, **뉴스1**. Retrieved from https://mobile.news1.com/view.html?ar_id=NISX20181116_0000475622
- 서영표 (2015.11.16.). 수능 국어, 결국 ‘과학’에서 결판났다, **동아사이언스**, Retrieved from <https://www.dongascience.com/news.php?idx=8697>
- Linacre, J. M. (2018). DIF-DPF-bias-interactions concepts. *Help for Winsteps Rasch Measurement and Rasch Analysis Software*, Retrieved from <https://www.winsteps.com/winman/difconcepts.htm>
- NAEP (2009. March. 18). The Mantel-Haenszel Procedure, Retrieved from

https://nces.ed.gov/nationsreportcard/tdw/analysis/scaling_checks_dif_procedure_mh.aspx

NAEP (2008. July. 15). The SIBTEST Procedure, Retrieved from https://nces.ed.gov/nationsreportcard/tdw/analysis/scaling_checks_dif_procedure_sibtest.aspx

이 논문은 2023. 11. 15. 투고되었으며, 2023. 11. 24. 심사가 시작되어 2023. 12. 13. 심사가 완료되었고, 2023. 12. 16. 편집위원회 심의를 거쳐 게재가 확정되었음.

■ 국문초록

고부담 읽기 평가의 DIF(차별문항기능) 분석

—계열 선택에 따른 배경지식이 읽기 평가 결과에 영향을 미치는가?—

오규설

고부담 읽기 평가에서 공정성은 타당도와 더불어 핵심적인 요소이다. 특정 하위 집단에게 문항이 유리하거나 불리하다면 이는 동일한 읽기 능력을 가진 학생들의 점수가 달리 나타나게 되므로 공정성의 문제는 평가 결과의 타당한 해석에 장애가 될 수 있다. 하위 집단 간 문항 반응의 편향은 DIF(차별문항기능)을 통해 식별할 수 있다. 따라서 이 연구는 한국의 수능 모의평가 국어 영역의 독서 문항을 대상으로 DIF 분석을 시행하여 계열 선택에 따라 다른 배경지식을 가진 하위 집단의 DIF를 식별하였다. 이후 그 원인을 분석하고, DIF를 감소시키는 대응 방안을 제시하였다.

[주제어] DIF, 차별문항기능, 공정성, 읽기 평가, 수능 국어 영역, 배경지식

■ Abstract

Analysis of Differential Item Functioning in High-Stakes Reading Assessments:

Does Background Knowledge Based on Selection of Educational Curriculum
Majors Influence Reading Assessment Results?

Oh, Kyuseol

In high-stakes reading assessments, fairness is a critical component, along with validity. Suppose that an item is advantageous or disadvantageous to specific subgroups. In that case, it can lead to disparities in scores among students with the same reading ability, thus raising concerns about the fairness of the assessment and hindering valid interpretation of the results. Differential item functioning (DIF) can identify item bias among subgroups. Consequently, this study conducted a DIF analysis of the reading comprehension questions comprising the Korean SAT mock exams and identified DIF among subgroups with different background knowledge based on their chosen academic tracks. Subsequently, the study analyzed the causes of these differences, and this paper proposes measures to reduce DIF.

[Key words] DIF, Differential Item Functioning, Fairness, Reading Assessment, Korean SAT, Background Knowledge