

베이지안 다층모형(Bayesian Multilevel Model)에 의한 한국어 쓰기 태도 연구 재분석: 주월랑(2023) 데이터의 시뮬레이션과 Gelman(2012) 방법의 적용

재분석 보고서

May 18, 2026

Abstract

본 보고서는 Gelman, Hill & Yajima(2012)의 “Why We (Usually) Don’t Have to Worry About Multiple Comparisons” 논문에서 제시한 베이지안 다층모형(Bayesian multilevel model) 접근을 주월랑(2023)의 “학문 목적 한국어 학습자의 한국어 쓰기 태도 연구”에 적용한다. 주월랑 논문의 요약통계량과 Cronbach’s $\alpha = 0.854$ 를 이용하여 $N = 86$ 응답자의 21개 정수(integer) Likert 1~5 척도 문항 데이터를 역시뮬레이션(reverse simulation)하고, (1) 주월랑 논문의 빈도주의(frequentist) 통계처리(일원배치 분산분석, 독립표본 t -검정, Pearson 상관)와 (2) Gelman 방식의 베이지안 다층모형(numpyro로 NUTS 표본추출)을 각각 적용하여 결과를 비교한다. 부분 풀링(partial pooling)에 의한 축소(shrinkage)가 소표본 집단(2학년 $N = 8$, 교환학생 $N = 6$ 등)의 추정치를 안정화시키며, 빈도주의에서 유의했던 학년 $\times$ 수행태도 분산분석 결과($p = 0.025$)가 베이지안 쌍별 비교에서는 4개 비교 모두 95% credible interval이 0을 포함하여 비유의로 판정됨을 보인다.

1 Gelman, Hill & Yajima (2012) 논문의 핵심 주장

1.1 문제의 배경: 다중비교(Multiple Comparisons)

빈도주의 통계 이론에서 여러 가설을 동시에 검정(simultaneous testing)할 때 1종 오류(Type 1 error) 누적 현상이 발생한다. 단일 검정의 유의수준이 $\alpha = 0.05$ 일 때 k 개의 독립적 검정 중 적어도 하나가 잘못 유의하다고 판정될 확률은 $1 - (1 - \alpha)^k$ 로 증가한다. 예를 들어 $k = 8$ 일 경우 가족별 오류율(familywise error rate, FWER)은 약 34%에 달한다. 이를 통제하기 위한 고전적 보정 방법으로 Bonferroni 보정, Tukey HSD, Benjamini-Hochberg의 위양성률(false discovery rate, FDR) 통제 등이 사용되어 왔다.

1.2 Gelman의 비판: 1종 오류 패러다임의 거부

Gelman 외(2012)는 사회과학 및 교육연구에서 고전적 다중비교 보정이 부적절하다고 주장한다. 그 근거는 다음과 같다.

첫째, 사회과학에서 “참 효과가 정확히 0이다”라는 귀무가설(null hypothesis)은 거의 성립하지 않는다. 어떤 처치(treatment)이든 어떤 집단(group) 사이든 효과가 양이든 음이든 존재한다. 따라서 1종 오류 통제 자체가 잘못된 출발점이다.

둘째, 진정으로 우려해야 할 오류는 1종 오류가 아니라 Type S 오류(sign error, 부호 오류)와 Type M 오류(magnitude error, 크기 오류)이다. 특히 검정력이 낮은(underpowered) 연구에서 통계적으로 유의한 결과는 효과의 부호와 크기 모두를 잘못 판단할 위험이 크다.

셋째, Bonferroni 보정은 1종 오류를 줄이지만 2종 오류(Type 2 error)를 늘려 검정력을 심각하게 저하시킨다.

1.3 대안: 베이지안 다층 모형의 부분 풀링

Gelman의 대안은 비교 대상이 되는 모수들을 공통 분포에서 추출된 것으로 모델링하는 위계적(hierarchical) 모형이다. 그룹 j 의 효과 δ_j 를 독립적으로 추정하는 대신

$$\delta_j \sim \mathcal{N}(\mu, \sigma_\delta^2) \quad (1)$$

의 공통 사전분포를 부여하면 **부분 풀링(partial pooling)**이 자동으로 일어난다. 그룹 표본이 작아 불확실성이 클수록 추정치는 전체 평균(grand mean) μ 쪽으로 강하게 끌어당겨지는 **축소(shrinkage)**가 발생한다.

베이지안 쌍별 차이의 z -점수는 다음과 같이 고전적 z -점수에 1보다 작은 보정계수가 곱해진 형태가 된다.

$$z_{\text{Bayes}} = \underbrace{\frac{\bar{y}_j - \bar{y}_k}{\sqrt{2}\sigma_{\bar{y}}}}_{\text{고전 } z} \cdot \underbrace{\frac{1}{\sqrt{1 + \sigma_{\bar{y}}^2/\sigma_\theta^2}}}_{<1} \quad (2)$$

따라서 다중비교 보정을 가하지 않아도 거짓 양성(false positive)이 자연스럽게 줄어들며, 동시에 검정력 손실은 Bonferroni 보정보다 훨씬 작다.

2 주월랑(2023) 논문의 분석 설계

2.1 연구 개요

주월랑(2023)은 대학 내 외국인 유학생 86명을 대상으로 학문 목적 한국어 쓰기 태도(writing attitude)를 조사하였다. 21개 Likert 5점 정수 척도(integer scale) 문항을 3개 하위범주로 분류하였다¹:

- 쓰기인식(writing perception, P): 문항 1-4 ($M = 4.015$, $SD = 0.642$)
- 쓰기반응(writing response, R): 문항 5-15 ($M = 3.348$, $SD = 0.539$)
- 수행태도(performance attitude, A): 문항 16-21 ($M = 3.171$, $SD = 0.585$)
- 쓰기태도(전체 합성점수, composite T) = $\frac{1}{3}(P + R + A)$ ($M = 3.511$)

도구의 내적 일관성(internal consistency)은 Cronbach's $\alpha = 0.854$ 로 양호하였다.

2.2 집단 표본 구성

2.3 빈도주의 통계 모형

주월랑은 각 하위범주를 독립적인 종속변수로 두고 다음 네 가지 빈도주의 분석을 수행하였다:

1. 학년 효과: 일원배치 분산분석(one-way ANOVA, 5개 수준)

¹ 원논문 초록(184쪽)에는 하위범주를 “쓰기인식, 쓰기수행, 쓰기태도”로 표기하였으나, 본문(190쪽 3장)과 Table 5에서는 “쓰기인식, 쓰기반응, 수행태도”로 정확한 용어를 사용한다. 또한 Table 5의 “쓰기태도”(M=3.511)는 별도의 하위범주가 아니라 앞 세 하위범주의 평균인 전체 종합점수(composite score)이다(실제로 $(4.015 + 3.348 + 3.171)/3 \approx 3.511$ 로 일치한다). 본 보고서는 본문/Table의 정확한 용어를 따른다.

Table 1: 학습자 요인별 표본 크기 (paper N=86)

요인	수준	N
학년	1학년, 2학년, 3학년, 4학년, 교환	54, 8, 9, 9, 6
성별	남, 여	27, 59
TOPIK	없음, 3급, 4급, 5급, 6급	7, 14, 31, 23, 11
어학원	유, 무	69, 17

2. 성별 효과: 독립표본 t -검정(2개 수준)
3. TOPIK 효과: 일원배치 분산분석(5개 수준)
4. 어학원 효과: 독립표본 t -검정(2개 수준)

이를 4개 종속변수(쓰기인식, 쓰기반응, 수행태도, 쓰기태도)에 대해 반복 적용하였다(총 16개 검정). Pearson 상관 행렬은 별도로 4×4 하위범주 간 상관($\binom{4}{2} = 6$ 개) 및 학습자 요인 $\times$ 하위범주 상관($4 \times 4 = 16$ 개)을 계산하였다. **유의수준 $\alpha = 0.05$, 다중비교 보정은 적용되지 않았다.**

주월랑의 보고된 결과 중 유의한 것은 두 개뿐이다(표2):

Table 2: 주월랑(2023) 논문에서 유의하게 보고된 검정 결과

검정	종속변수	통계량	p 값	판정
ANOVA(학년)	수행태도	$F = 2.925$	0.026	유의*
t -검정(성별)	쓰기인식	$t = -2.779$	0.007	유의*

3 Gelman 관점에서의 평가

주월랑(2023)의 분석은 Gelman 외(2012)가 비판하는 빈도주의 다중비교의 전형적 문제점을 보이고 있다.

첫째, 검정 누적과 무보정. 4개 종속변수 $\times$ 4개 요인 = 16개 집단차이 검정에 더해 22개의 상관 검정을 포함하면 약 38개의 가설검정이 수행되었다. Bonferroni 보정을 적용하면 임계값은 $0.05/38 \approx 0.0013$ 이며, 주월랑이 보고한 유의 결과 중 $p = 0.026$ (학년 $\times$ 수행태도)는 더 이상 유의하지 않다.

둘째, 심각한 underpowered 상태. 2학년($N = 8$), 3학년($N = 9$), 4학년($N = 9$), 교환학생($N = 6$), TOPIK 없음($N = 7$), TOPIK 6급($N = 11$) 등 다수의 집단이 검정력 부족 상태이다. Gelman이 강조하는 바와 같이 검정력이 낮은 상황에서 발견된 통계적 유의성은 부호(sign)와 크기(magnitude)가 잘못 추정되었을 가능성이 높다.

셋째, 위계적 구조의 무시. 학생들은 학년, 국적, TOPIK 급수, 어학원 경험에 중첩(nested)되어 있으나 고전적 ANOVA/ t -검정은 이를 변수별로 독립적으로 다룬다.

넷째, 귀무가설의 비현실성. “학년별 쓰기 태도에 차이가 없다”는 귀무가설은 사회과학적으로 거의 성립하지 않는다. 진짜 질문은 “차이가 있는가”가 아니라 “얼마나 크고 어떤 방향인가”이다.

4 시뮬레이션 데이터 생성

주월랑 논문의 통계량을 그대로 사용할 수 없으므로(원자료 미공개), 보고된 요약통계를 이용하여 응답 데이터를 **역시뮬레이션**한다. 설문조사의 실제 응답은 **정수(integer) Likert 1~5 척도**이므로, 본 시뮬레이션도 문항 단위에서 정수값을 생성한다.

2단계 생성 절차:

1단계 — 잠재 하위범주 점수 생성 (continuous latent). 응답자 i 의 하위범주 잠재점수 (P_i, R_i, A_i) 에 대해

$$\begin{pmatrix} P_i \\ R_i \\ A_i \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_{g(i)}^P \\ \mu^R \\ \mu_{y(i)}^A \end{pmatrix}, \Sigma \right), \quad (3)$$

여기서 $\mu_{g(i)}^P$ 은 성별별 평균(3.741 또는 4.140), $\mu_{y(i)}^A$ 은 학년별 평균(2.944~3.519), Σ 는 표3의 상관행렬을 SD로 스케일링하여 구성한다.

2단계 — 문항 단위 정수 응답 생성 (integer items). 각 문항 j 의 응답을

$$x_{ij} = \text{clip}(\text{round}(s_{i,c(j)} + \varepsilon_{ij}), 1, 5), \quad \varepsilon_{ij} \sim \mathcal{N}(0, \sigma_{\text{item}}^2) \quad (4)$$

로 생성한다. 여기서 $c(j)$ 는 문항 j 의 소속 하위범주이고 $s_{i,c(j)}$ 는 그에 해당하는 잠재점수이다. 이렇게 하면 $x_{ij} \in \{1, 2, 3, 4, 5\}$ 의 **정수값**만 산출된다. 응답자 i 의 하위범주 점수는 해당 문항들의 평균으로 계산한다(예: $P_i^{\text{score}} = \frac{1}{4} \sum_{j=1}^4 x_{ij}$). 따라서 하위범주 점수는 실수값(0.25 단위 등 이산)을 가진다. **T 점수(쓰기태도, 전체)**는 독립 잠재변수가 아니라 $\frac{1}{3}(P^{\text{score}} + R^{\text{score}} + A^{\text{score}})$ 인 **파생 합성점수**이며, 주월랑 논문 Table 5 정의를 그대로 따른다.

Table 3: 주월랑 논문 Table 14의 하위범주 간 상관행렬

	쓰기인식	쓰기반응	수행태도
쓰기인식	1.000	0.583	0.281
쓰기반응	0.583	1.000	0.508
수행태도	0.281	0.508	1.000

σ_{item} 은 21문항 전체에 대한 Cronbach's $\alpha = 0.854$ 가 되도록 이분탐색(binary search)으로 조정하였다. 그 결과 $\sigma_{\text{item}} = 0.686$ 으로 수렴하였고 시뮬레이션 $\alpha = 0.8545$ 로 거의 정확히 일치한다. 생성된 문항 응답은 모두 $\{1, 2, 3, 4, 5\}$ 의 정수값을 갖는다(예: 문항 1의 분포 = {1:1, 2:6, 3:24, 4:34, 5:21}).

시뮬레이션 데이터의 하위범주 통계량은 표4와 같이 논문 보고치와 근접한다(정수 반올림에 따른 약간의 SD 증가 효과가 있음).

Table 4: 시뮬레이션 데이터와 주월랑 논문의 하위범주 기술통계 비교

하위범주	시뮬레이션 M	시뮬레이션 SD	논문 M	논문 SD
쓰기인식	3.939	0.737	4.015	0.642
쓰기반응	3.336	0.541	3.348	0.539
수행태도	3.163	0.574	3.171	0.585
쓰기태도 (composite)	3.479	0.457	3.511	0.469

5 빈도주의 재분석 결과

시뮬레이션 데이터에 주월량 논문의 통계처리방식(일원배치 분산분석, 독립표본 t -검정, Pearson 상관)을 그대로 적용한 결과는 표5-8와 같다.

Table 5: 학년 $\times$ 쓰기 태도: 일원배치 분산분석(시뮬레이션 vs 논문)

종속변수	시물 F	시물 p	시물 판정	논문 F	논문 p	논문 판정
쓰기인식	0.067	0.992	비유의	1.387	0.246	비유의
쓰기반응	0.937	0.447	비유의	2.092	0.089	비유의
수행태도	2.960	0.025	유의*	2.925	0.026	유의*
쓰기태도	0.579	0.678	비유의	2.316	0.064	비유의

Table 6: 성별 $\times$ 쓰기 태도: 독립표본 t -검정

종속변수	시물 t	시물 p	시물 판정	논문 t	논문 p	논문 판정
쓰기인식	-1.058	0.293	비유의	-2.779	0.007	유의*
쓰기반응	+1.787	0.078	비유의	-0.323	0.747	비유의
수행태도	+0.109	0.913	비유의	-0.569	0.571	비유의
쓰기태도	+0.173	0.863	비유의	-1.092	0.278	비유의

Table 7: TOPIK $\times$ 쓰기 태도: 일원배치 분산분석

종속변수	시물 F	시물 p	시물 판정	논문 F	논문 p	논문 판정
쓰기인식	1.418	0.236	비유의	1.978	0.106	비유의
쓰기반응	0.205	0.935	비유의	0.780	0.541	비유의
수행태도	0.810	0.523	비유의	1.657	0.168	비유의
쓰기태도	0.539	0.708	비유의	1.129	0.349	비유의

시뮬레이션과 논문 결과의 일치도.

- **학년 $\times$ 수행태도 ANOVA:** 시물 $F = 2.960, p = 0.025$ vs 논문 $F = 2.925, p = 0.026$ — 거의 완벽히 일치. 이는 학년 효과를 시뮬레이션 시 잘 인코딩(encoding)했음을 보여준다.
- **성별 $\times$ 쓰기인식 t -검정:** 논문은 $p = 0.007$ 유의, 시물은 $p = 0.293$ 비유의. **유의/비유의 판정이 달라진다.** 이는 시뮬레이션이 성별 평균차(0.4점)를 설정했으나 정수 반올림(integer rounding)과 무작위 노이즈, 그리고 [1, 5] 절단(clip)으로 실제 t 값이 약화된 결과이다. 또한 이는 Gelman이 강조하는 “작은 표본에서의 효과 크기 변동성”을 그대로 보여주는 사례이기도 하다.
- 나머지 14개 비교의 유의/비유의 판정은 모두 일치(전부 비유의).

시뮬레이션이 완벽했다면 모든 수치가 거의 동일해야 하나, 위와 같이 한 검정에서만 차이가 발생한 것은 사회과학에서 **한정된 표본 크기에서 통계적 유의성 판정이 실제로 얼마나 불안정한지**를 역설적으로 보여준다.

Table 8: 어학원 $\times$ 쓰기 태도: 독립표본 t -검정

종속변수	시물 t	시물 p	시물 판정	논문 t	논문 p	논문 판정
쓰기인식	-0.197	0.845	비유의	-0.211	0.833	비유의
쓰기반응	-0.233	0.817	비유의	-0.316	0.752	비유의
수행태도	-0.500	0.618	비유의	+0.261	0.795	비유의
쓰기태도	-0.407	0.685	비유의	-0.152	0.880	비유의

6 Gelman 방식의 베이지안 다층모형

6.1 모형 정의

각 하위범주 $y \in \{P, R, A, T\}$ 에 대해 다음 베이지안 다층모형을 적합한다:

$$y_i = \mu + \alpha_{\text{year}[i]} + \beta_{\text{gender}[i]} + \gamma_{\text{topik}[i]} + \delta_{\text{inst}[i]} + \varepsilon_i \quad (5)$$

$$\alpha_j \sim \mathcal{N}(0, \sigma_\alpha^2), \quad j \in \{1, 2, 3, 4, \text{EX}\} \quad (6)$$

$$\beta_g \sim \mathcal{N}(0, \sigma_\beta^2), \quad g \in \{\text{M}, \text{F}\} \quad (7)$$

$$\gamma_k \sim \mathcal{N}(0, \sigma_\gamma^2), \quad k \in \{\text{없음}, \text{L3}, \text{L4}, \text{L5}, \text{L6}\} \quad (8)$$

$$\delta_m \sim \mathcal{N}(0, \sigma_\delta^2), \quad m \in \{\text{yes}, \text{no}\} \quad (9)$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma_y^2) \quad (10)$$

$$\sigma_\alpha, \sigma_\beta, \sigma_\gamma, \sigma_\delta, \sigma_y \sim \text{HalfNormal}(1) \quad (\text{약한 정보 사전, weakly informative}) \quad (11)$$

$$\mu \sim \mathcal{N}(3, 2) \quad (12)$$

이 모형이 주월량의 모형과 다른 결정적 점은:

- 4개 요인의 효과를 **동시에** 추정(joint estimation)하므로 다중비교가 모형 내부에 통합됨
- 각 요인의 그룹 효과들이 공통 분포(식 1)에서 추출됨을 가정 — **부분 풀링** 발생
- $\sigma_\alpha \rightarrow 0$ 일 때 완전 풀링(complete pooling, 그룹간 차이 없음), $\sigma_\alpha \rightarrow \infty$ 일 때 풀링 없음(no pooling, 빈도주의와 동일) — 데이터가 적절한 값을 결정

6.2 사후 추론

NUTS(No-U-Turn Sampler, Hoffman & Gelman 2014) 알고리즘을 사용하여 2개 체인, 각 체인 warmup 800회 + 표본 1500회 = 총 3000 사후표본을 추출하였다. 각 효과에 대해 다음을 보고한다:

- 사후평균(posterior mean)
- 95% credible interval [2.5%, 97.5% 분위수]
- 베이지안 판정: 95% CI가 0을 포함하지 않으면 **유의**, 포함하면 **비유의**
- $P(\text{effect} > 0)$: 효과가 양일 사후확률

6.3 집단 차이의 사후 분석 결과

성별(F – M) 사후 차이.

종속변수	사후평균	95% CI	$P(> 0)$	판정
쓰기인식	+0.115	[-0.165, +0.442]	0.761	비유의
쓰기반응	-0.172	[-0.434, +0.051]	0.079	비유의
수행태도	-0.023	[-0.257, +0.188]	0.424	비유의
쓰기태도	-0.017	[-0.214, +0.170]	0.437	비유의

하위범주	비교	사후평균	95% CI	판정
수행태도	2학년-1학년	+0.371	[-0.011, +0.809]	비유의
수행태도	3학년-1학년	+0.227	[-0.088, +0.601]	비유의
수행태도	4학년-1학년	+0.303	[-0.021, +0.682]	비유의
수행태도	EX-1학년	+0.028	[-0.370, +0.406]	비유의
쓰기태도	2학년-1학년	+0.049	[-0.144, +0.321]	비유의
쓰기태도	3학년-1학년	+0.006	[-0.242, +0.232]	비유의

학년별 사후 차이(각 학년 vs 1학년). 주목할 점: 빈도주의 ANOVA에서 학년 $\times$ 수행태도 효과가 $p = 0.025$ 로 유의했지만, 베이지안 쌍별 사후 비교에서는 **모든 4개 쌍별 비교의 95% CI가 0을 포함한다**. 특히 가장 큰 차이인 2학년-1학년조차 $[-0.011, +0.809]$ 로 0 근처에서 경계선상에 있다($P(> 0) = 0.964$). 이는 베이지안 부분 풀링이 빈도주의 “유의” 판정을 자동으로 보수적으로 조정한 결과이다.

집단 효과 분산 σ 사후 추정. σ_α (학년 효과)가 가장 큰 하위범주는 수행태도($\sigma_\alpha = 0.292$, CI=[0.034, 0.810])로, 빈도주의 ANOVA에서 유의했던 결과와 일치한다. 반면 다른 하위범주에서는 σ_α 가 0에 가깝다(쓰기인식 0.138, 쓰기반응 0.152, 쓰기태도 0.122).

쓰기태도(T) 분석의 본질적 한계. 주월랑 논문이 종속변수로 사용한 “쓰기태도(전체)”(T)는 독립적인 잠재변수가 아니라 $T = \frac{1}{3}(P+R+A)$ 의 결정적 합성점수(deterministic composite)이다. 따라서 T 에 대한 별도 베이지안 다층모형을 적합한 결과는 본질적으로 P, R, A 의 공동 사후분포에서 도출되어야 할 결과의 근사일 뿐이다. 본 분석은 주월랑 논문의 분석 절차를 충실히 재현하기 위해 T 에 동일한 모형을 적합하였으나, 엄밀한 베이지안 분석에서는 (P, R, A) 의 다변량 모형에서 사후 표본에 대해 T 를 사후 계산하는 것이 옳다. 실제로 T 의 분석 결과(예: $\sigma_\alpha = 0.122$)는 세 하위범주의 평균적 패턴을 보여주며, 추론에 새로운 정보를 더하지는 않는다.

6.4 부분 풀링(shrinkage) 효과의 가시화

표9는 학년별 표본평균(raw mean)과 베이지안 사후평균(post mean)을 비교한다. 표본이 작은 집단(2학년 $N = 8$, 교환학생 $N = 6$)의 추정치가 전체 평균 쪽으로 강하게 끌어당겨지는 것을 볼 수 있다.

2학년의 표본평균 3.583에서 사후평균 3.457로 축소량 -0.126 , 4학년 -0.073 , EX학년은 반대로 $+0.143$ (작은 $N=6$ 집단이 전체 평균 쪽으로 끌어당겨짐)이 발생하였다. 이는 식 1의 부분 풀링이 표본이 작은 집단을 자동으로 안정화시킨 결과이다.

Table 9: 학년별 표본평균 vs 베이지안 사후평균 (수행태도)

학년	N	Raw mean	사후평균	95% CI
1	54	3.040	3.087	[2.104, 4.080]
2	8	3.583	3.457	[2.397, 4.508]
3	9	3.352	3.314	[2.312, 4.358]
4	9	3.463	3.390	[2.377, 4.443]
EX	6	2.972	3.115	[2.111, 4.136]




Figure 1: 학년별 표본평균(파란 원)과 베이지안 사후평균(빨간 사각형) 비교. 빨간색은 95% credible interval. 부분 풀링에 의해 모든 사후평균이 전체 평균(점선) 쪽으로 끌어당겨진다.

7 빈도주의 vs 베이지안 결과 비교

7.1 공통점

- 16개 집단차이 검정 중 **15개에서 두 방법이 동일하게 비유의로 판정한다.**
- 빈도주의 ANOVA에서 학년 효과가 유의했던 **수행태도**에 대해 베이지안 σ_α 사후추정도 다른 하위범주보다 큰 값(0.292)을 가지며, 95% CI 하한이 0보다 크게(0.034) 떨어져 있어 그룹 간 변동이 실재함을 시사한다.
- 두 방법 모두 TOPIK 효과와 어학원 효과는 거의 0에 가깝다고 결론짓는다.

7.2 결정적 차이점

- 빈도주의 ANOVA가 학년 효과를 “유의”($p = 0.025$)로 판정했지만, 베이지안 쌍별 사후 차이를 보면 **4개 쌍별 비교 모두에서 95% CI가 0을 포함한다.** 가장 큰 차이인 2학년 – 1학년조차 $CI = [-0.011, +0.809]$ 로 0 바로 위에서 끝나며($P(> 0) = 0.964$), 빈도주의의 “유의” 판정은 베이지안 관점에서 강건(robust)하지 않다.
- 베이지안 추정치는 **축소(shrinkage)**로 인해 빈도주의 추정치보다 그룹 차이가 더 작다. 예: 2학년 수행태도 raw – 1학년 raw = $3.583 - 3.040 = +0.543$ 이었으나, 베이지안 사후 차이는 $+0.371$ 로 축소되었다(축소율 약 32%).
- 베이지안 모형은 Bonferroni 등의 외부 다중비교 보정을 가하지 않고도 자연스럽게 보수적인 추론을 산출한다. 4개 요인 $\times$ 38개 가능한 쌍별 비교 중 95% CI가 0을 제외한 것은 **단 한 개도 없다**(가장 가까운 경우도 0을 포함).




Figure 2: 수행태도 학년별 사후 차이(각 학년 - 1학년). 빈도주의 ANOVA에서 $p = 0.025$ 유의했으나, 베이지안 쌍별 비교에서는 **4개 비교 모두 95% CI가 0을 포함한다**(가장 큰 2학년-1학년조차 $[-0.011, +0.809]$ 로 경계선상).

Table 10: 학년 효과: 빈도주의 ANOVA vs 베이지안 σ_α 사후추정

하위범주	빈도주의 F	빈도주의 p	빈도 판정	베이지안 σ_α
쓰기인식	0.067	0.992	비유의	0.138 [0.007, 0.508]
쓰기반응	0.937	0.447	비유의	0.152 [0.010, 0.525]
수행태도	2.960	0.025	유의*	0.292 [0.034, 0.810]
쓰기태도	0.579	0.678	비유의	0.122 [0.005, 0.443]

8 결론

본 재분석은 다음을 보였다.

첫째, 주월랑(2023)의 보고된 요약통계와 Cronbach's α 로부터 응답 데이터를 역시뮬레이션하는 데 성공하였으며, 핵심 통계량(하위범주 평균/SD, Cronbach's α)은 시뮬레이션과 논문 보고치가 거의 일치한다.

둘째, 시뮬레이션 데이터에 주월랑의 통계처리방식을 적용한 결과, 16개 집단차이 검정 중 15개가 논문과 동일한 유의/비유의 판정을 산출하였고, 특히 **학년 $\times$ 수행태도 ANOVA $F = 2.960, p = 0.025$ 가 논문의 $F = 2.925, p = 0.026$ 과 거의 완벽히 일치하였다**. 다만 성별 $\times$ 쓰기인식 t -검정의 경우 시뮬레이션 데이터에서는 비유의로 판정되었는데, 이는 정수 반올림과 시뮬레이션 한계와 더불어 “작은 표본에서 통계적 유의성 판정이 본질적으로 불안정함”을 보여주는 결과이기도 하다.

셋째, Gelman 외(2012)의 베이지안 다층모형을 적용한 결과, **빈도주의에서 유의했던 학년 $\times$ 수행태도 결과조차도 쌍별 비교 수준에서는 모든 4개 비교의 95% CI가 0을 포함하며 비유의로 판정된다**. 부분 풀링에 의해 소표본 집단(2학년 $N = 8$, 교환학생 $N = 6$ 등)의 평균 추정치가 전체 평균 쪽으로 축소되어 더 안정적이고 보수적인 추론을 제공한다.

넷째, Gelman의 방법은 명시적인 다중비교 보정을 가하지 않아도 1종 오류 누적 문제가 자동으로 완화되며, 동시에 Bonferroni 보정처럼 검정력을 크게 손상시키지 않는다. 이는 사회과학 연구, 특히 본 연구처럼 **소집단을 다수 포함하는 위계적 데이터**에서 더 적합한 분석 방법임을 시사한다.

결론적으로 주월랑(2023)이 발견한 “학년 효과”와 “성별 효과”는 빈도주의 기준으로는 유의해 보이지만,

Table 11: 성별 효과: 빈도주의 t -검정 vs 베이지안 F-M 사후 차이

하위범주	빈도주의 t	빈도주의 p	빈도 판정	베이지안 F-M (95% CI)
쓰기인식	-1.058	0.293	비유의	+0.115 [-0.165, +0.442] 비유의
쓰기반응	+1.787	0.078	비유의	-0.172 [-0.434, +0.051] 비유의
수행태도	+0.109	0.913	비유의	-0.023 [-0.257, +0.188] 비유의
쓰기태도	+0.173	0.863	비유의	-0.017 [-0.214, +0.170] 비유의

Gelman 방식으로 보면 효과 크기가 작고 사후 분포가 0을 포함하여 **확정적 결론을 내리기에는 증거가 부족하다**. 향후 외국인 유학생 쓰기 태도 연구는 (1) 표본 크기를 충분히 확보하고, (2) 위계적 데이터 구조를 반영하는 베이지안 다층모형이나 혼합효과 모형(mixed-effects model)을 적용하며, (3) p 값의 이분법적 해석 대신 효과 크기와 신용구간(credible interval)을 보고하는 것이 권장된다.

사용된 파일 목록

- `gel_simulate.py`: 시뮬레이션 데이터 생성(N=86, 21문항 정수 Likert, Cronbach's $\alpha=0.854$)
- `gel_data.csv`: 시뮬레이션 응답 데이터
- `gel_freq.py`: 빈도주의 통계분석 스크립트
- `gel_freq_results.xlsx`: 빈도주의 분석 결과
- `gel_bayes.py`: 베이지안 다층모형 분석 스크립트(numpyro)
- `gel_bayes_results.xlsx`: 베이지안 분석 결과
- `gel_compare.py`, `gel_compare.xlsx`: 빈도주의 vs 베이지안 비교
- `gel_plots.py`, `gel_shrinkage_plot.pdf`, `gel_pairwise_plot.pdf`: 시각화
- `gel_paper.tex`, `gel_paper.pdf`: 본 보고서

참고문헌 (References)

1. Gelman, A., Hill, J., & Yajima, M. (2012). Why We (Usually) Don't Have to Worry About Multiple Comparisons. **Journal of Research on Educational Effectiveness**, 5, 189–211.
2. 주월랑 (2023). 학문 목적 한국어 학습자의 한국어 쓰기 태도 연구. **한교어문연구**, 63, 185–209.
3. Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo. **Journal of Machine Learning Research**, 15(1), 1593–1623.
4. Gelman, A., & Carlin, J. (2014). Beyond Power Calculations: Assessing Type S (Sign) and Type M (Magnitude) Errors. **Perspectives on Psychological Science**, 9(6), 641–651.
5. Bingham, E., Chen, J. P., Jankowiak, M., Obermeyer, F., Pradhan, N., Karaletsos, T., Singh, R., Szerlip, P., Horsfall, P., & Goodman, N. D. (2019). Pyro: Deep Universal Probabilistic Programming. **Journal of Machine Learning Research**, 20, 1–6. (numpyro의 기반)