

베이지안 다층모형(Bayesian Multilevel Model) 왜, 어떻게, 무엇이 좋은가

Gelman, Hill & Yajima (2012) 와 주월랑(2023) 사례를 중심으로

재분석 강의자료

- 빈도주의 검정(t-test, ANOVA)의 **한계** 이해
- 다중비교(multiple comparisons) 문제와 Bonferroni 보정의 **대가**
- 베이지안 다층모형의 **기본 아이디어**: “효과들이 정규분포를 따른다”
- t-test와 ANOVA가 다층모형의 **특수 경우**임을 이해
- 부분 풀링(partial pooling)의 직관과 **Type M 오류** 완화
- Python(numpyro) 으로 **10줄 안에** 다층모형 적합하기

도입 — 동전 두 개 이야기

두 친구가 각자 동전을 던졌습니다.

친구 A

- 동전을 **10번** 던졌다
- 그 중 **9번** 앞면
- $\hat{p} = 0.9$
- 양측 p값 $\approx 0.022 < 0.05$ **유의**

친구 B

- 동전을 **1000번** 던졌다
- 그 중 **540번** 앞면
- $\hat{p} = 0.54$
- 양측 p값 $\approx 0.011 < 0.05$ **유의**

둘 다 “유의”이지만, 두 사람의 결론을 똑같이 믿어야 할까?

Type M 오류 — 효과 크기의 과장

만약 진짜 동전이 약간만 편향($p_{\text{true}} = 0.55$)이라면?

	친구 A (9/10)	친구 B (540/1000)
참 편향 $ p - 0.5 $	0.05	0.05
추정 편향 $ \hat{p} - 0.5 $	0.40	0.04
과장 비율	8 배	0.8 배
95% 신뢰구간	[0.71, 1.00] (매우 넓은)	[0.51, 0.57] (좁고 신뢰)

- 친구 A의 “유의” 결과는 **Type M 오류(magnitude error)**의 전형
- 검정력 부족(underpowered) 연구에서 “유의”로 나온 결과는 효과 크기를 **체계적으로 과장**
- Gelman & Carlin (2014): “승자의 저주(winner's curse)”

다중비교 문제 — 검정을 많이 하면?

유의수준 $\alpha = 0.05$ 로 독립적 검정 k 개를 수행한다고 하자.

적어도 하나가 “유의”로 잘못 판정될 확률(가족별 오류율, FWER):

$$\text{FWER} = 1 - (1 - \alpha)^k$$

k (검정 수)	FWER	의미
1	5%	정상
5	23%	우려
8	34%	심각
20	64%	매우 심각
38 (주월랑)	86%	거의 확실히 거짓 양성

검정을 많이 할수록 “우연한 유의”가 보장된다.

임계값을 α/k 로 낮춘다 (즉 더 보수적으로 판단).

문제

- 1종 오류는 줄어들지만 **2종 오류(검정력 손실)**가 커짐
- 진짜 효과도 “비유의”로 놓쳐버림
- 사회과학에서 “효과가 정확히 0”이라는 귀무가설이 **비현실적**

Gelman의 핵심 주장:

“We don’t (usually) have to worry about multiple comparisons.”

— Gelman, Hill & Yajima (2012)

근거: **다층모형(multilevel model)**이 다중비교 문제를 자동으로 해결.

$$y_i = \mu + \alpha_{\text{group}[i]} + \varepsilon_i$$
$$\alpha_g \sim \mathcal{N}(0, \sigma_\alpha^2), \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_y^2)$$

해석:

- μ : 전체 평균(grand mean)
- α_g : 그룹 g의 효과(전체평균에서 벗어난 편차)
- “그룹 효과들이 정규분포를 따른다”는 가정 — 핵심!
- σ_α : 그룹들 사이의 변동 정도 (데이터로부터 추정)
- σ_y : 그룹 내 개인차

이 단순한 식 하나가 t-test, ANOVA, 사후비교를 모두 포괄한다.

σ_α 가 결정하는 세 가지 체제(regime)

σ_α 값	모형 행동	빈도주의 대응
0 (또는 매우 작음)	완전 풀링(complete pooling) 모든 $\alpha_g = 0$	그룹 차이 무시 (H_0 채택)
∞ (또는 매우 큼)	풀링 없음(no pooling) 각 α_g 독립 추정	각 그룹 독립 추정 (전통적 t-test/ANOVA)
데이터로 추정	부분 풀링(partial pooling) 작은 표본은 평균 쪽으로 끌어당김	없음(베이지안 고유)

핵심: σ_α 를 데이터로부터 추정한다는 점이 다층모형의 위력.

두 그룹 비교를 다층모형으로 표현:

$$y_i = \mu + \alpha_{g[i]} + \varepsilon_i, \quad g \in \{1, 2\}$$

$\sigma_\alpha \rightarrow \infty$ 극한에서 사후분포:

$$\alpha_1 - \alpha_2 \mid y \sim \mathcal{N}\left(\bar{y}_1 - \bar{y}_2, \sigma_y^2(1/n_1 + 1/n_2)\right)$$

이 식은 빈도주의 t-검정의 표본분포와 완전히 동일.

빈도주의 t-검정	베이지안 다층모형
t 통계량	$\alpha_1 - \alpha_2$ 의 사후평균/사후 SD
양측 p값	$2 \cdot \min P(\alpha_1 \geq \alpha_2 \mid y)$
95% 신뢰구간 (CI)	95% 신용구간 (credible interval)

ANOVA 대응 — 같은 식, 더 많은 그룹

K개 그룹 비교:

$$y_i = \mu + \alpha_{g[i]} + \varepsilon_i, \quad g \in \{1, 2, \dots, K\}$$

빈도주의 ANOVA F-통계량 $\approx$ “ $\sigma_\alpha^2 / \sigma_y^2$ 가 얼마나 큰가”

$$F \approx 1 + \frac{n \cdot \sigma_\alpha^2}{\sigma_y^2}$$

빈도주의 ANOVA	베이지안 다층모형
F 통계량	$\sigma_\alpha^2 / \sigma_y^2$ 의 사후분포
F 유의	σ_α^2 의 95% CI가 0 멀리 떨어짐
사후비교(post-hoc, Tukey)	모든 $\alpha_j - \alpha_k$ 의 공동 사후분포
Bonferroni 보정	불필요 (부분 풀링이 자동 처리)

한 번 적합 → 모든 비교 동시 처리.

사례연구: 주월랑(2023) 한국어 쓰기 태도 연구

연구 설계:

- 외국인 유학생 $N = 86$
- 21개 Likert 5점 정수 척도 문항 → 3개 하위범주
 - 쓰기인식(P, 문항 1–4)
 - 쓰기반응(R, 문항 5–15)
 - 수행태도(A, 문항 16–21)
- Cronbach's $\alpha = 0.854$

집단 표본 — 매우 불균형:

요인	표본크기
학년 (5개 집단)	54, 8, 9, 9, 6
성별 (2개)	27, 59
TOPIK (5개)	7, 14, 31, 23, 11
어학원 (2개)	69, 17

빈도주의 분석 — 주월량의 방법

주월량은 4개 종속변수에 대해 각각:

- 학년 효과: **ANOVA** (5개 수준)
- 성별 효과: **t-검정** (2개 수준)
- TOPIK 효과: **ANOVA** (5개 수준)
- 어학원 효과: **t-검정** (2개 수준)

+ Pearson 상관 22개 $\Rightarrow$ **총 약 38개 검정**, 다중비교 보정 없음.

유의하게 나온 결과는 **단 2개**:

검정	종속변수	p값
ANOVA(학년)	수행태도	0.026
t-검정(성별)	쓰기인식	0.007

38번 던져 2번 “유의”. 우연일까, 실재일까?

모형:

$$y_i = \mu + \alpha_{\text{year}[i]} + \beta_{\text{gender}[i]} + \gamma_{\text{topik}[i]} + \delta_{\text{inst}[i]} + \varepsilon_i$$

$$\alpha_j, \beta_g, \gamma_k, \delta_m \sim \mathcal{N}(0, \sigma^2), \quad \sigma. \sim \text{HalfNormal}(1)$$


수행태도의 학년별 사후 차이 (가장 강하게 보이던 효과):

비교	사후 차이 (95% CI)	판정
2학년 - 1학년	+0.371 [-0.011, +0.809]	비유의
3학년 - 1학년	+0.227 [-0.088, +0.601]	비유의
4학년 - 1학년	+0.303 [-0.021, +0.682]	비유의
EX - 1학년	+0.028 [-0.370, +0.406]	비유의

빈도주의의 “유의”가 베이지안에서는 모두 0을 포함.

부분 풀링 효과 — 수행태도 학년별 평균

학년별 표본평균 vs 베이지안 사후평균 — 부분 풀링(shrinkage) 효과



- 파란 원: 표본평균(raw mean) — 풀링 없음
- 빨간 사각형: 사후평균(posterior mean) — 부분 풀링 후
- 작은 표본 집단(2학년 $N = 8$, 교환학생 $N = 6$)이 전체 평균 쪽으로 끌어당겨짐

Q: “효과들이 정규분포를 따른다”는 가정과 사전분포 선택이 자의적이지 않은가?

A: Gelman의 처방은 **약한 정보 사전분포(weakly informative prior, WIP):**

- 비현실적 값만 배제, 데이터가 결정하도록 둬
- 예: $\sigma_{\alpha} \sim \text{HalfNormal}(1)$ (Likert 1–5 척도용)
- $\text{Inverse Gamma}(\epsilon, \epsilon)$ 같은 “무정보”는 피할 것 (Gelman 2006)

사실 빈도주의도 암묵적 사전분포를 사용:

- “평탄(flat) 사전분포”라는 매우 강한 가정을 인식 없이 사용
- 베이지안 WIP가 더 명시적이고 더 합리적

민감도 분석(sensitivity analysis): 여러 사전분포로 재실행 후 결론 안정성 확인.

코드 한 컷 — numpyro 로 10줄

```
import numpyro, numpyro.distributions as dist
from numpyro.infer import MCMC, NUTS

def model(year_idx, y):
    mu          = numpyro.sample('mu', dist.Normal(3, 2))
    sigma_a     = numpyro.sample('sigma_a', dist.HalfNormal(1.0))
    sigma_y     = numpyro.sample('sigma_y', dist.HalfNormal(1.0))
    alpha       = numpyro.sample('alpha',
                                  dist.Normal(0, sigma_a).expand([5]))
    numpyro.sample('y', dist.Normal(mu + alpha[year_idx], sigma_y), obs=y)

mcmc = MCMC(NUTS(model), num_warmup=500, num_samples=2000)
mcmc.run(jax.random.PRNGKey(0), year_idx=jnp.array(idx), y=jnp.array(scores))
```

사후표본에서 추출:

● $\alpha_i - \alpha_i$: t-test 대응

빈도주의 vs 베이지안 — 핵심 비교표

구분	빈도주의	베이지안 다층모형
2그룹 비교	t-검정 (개별 식)	$\alpha_1 - \alpha_2$ 사후
K그룹 비교	ANOVA + 사후비교 (별도)	σ_α 사후 + 쌍별 사후
다중비교 보정	Bonferroni, FDR 등 (외부)	부분 풀링이 자동 처리
효과 크기	별도 계산 (Cohen's d 등)	사후분포에서 직접
불확실성	95% CI (간접 해석)	95% 신용구간 (직접 해석)
작은 표본 안정성	불안정 (Type M 오류)	축소(shrinkage)로 안정
모형 수	검정마다 다른 식	한 식, 한 적합

베이지안 다층모형은 빈도주의 검정들의 일반화(generalization)이다.

- 1 **빈도주의 검정은 다층모형의 특수 경우** — 사전분포 평탄($\sigma_\alpha \rightarrow \infty$) 극한
- 2 **한 모형으로 모든 것** — t-test, ANOVA, 사후비교, 효과크기, 다중비교 보정 동시 처리
- 3 **부분 풀링이 자동 보정** — Bonferroni 불필요, 검정력 보존
- 4 **사전분포는 약점 아닌 명시적 도구** — 정규화(regularization)로 재해석
- 5 **코딩이 단순** — numpyro 10줄, lmer 1줄

핵심 논문:

- Gelman, A., Hill, J., & Yajima, M. (2012). Why We (Usually) Don't Have to Worry About Multiple Comparisons. *J. Research on Educational Effectiveness*, 5, 189–211.
- Gelman, A., & Carlin, J. (2014). Beyond Power Calculations: Type S and Type M Errors. *Perspectives on Psychological Science*, 9(6), 641–651.
- Gelman, A. (2006). Prior distributions for variance parameters in hierarchical models. *Bayesian Analysis*, 1(3), 515–533.

교재:

- Gelman & Hill (2007). *Data Analysis Using Regression and Multilevel/Hierarchical Models*.
- McElreath, R. (2020). *Statistical Rethinking* (2nd ed.).

소프트웨어:

- `jupyter` (Python), `brms` / `rstanarm` (R), `Stan` (C++/C)

질문?

다층모형으로 한 단계 더 깊은 추론을

“Don’t worry (much) about multiple comparisons.”

– Gelman, Hill & Yajima (2012)