

L2 한국어 쓰기 채점자의 편향과 인지 처리 과정에 대한 고찰

- 주장하는 글을 중심으로 -

김 춘 영
(경희대학교 박사 수료)

〈 차 례 〉

- | | |
|-----------|------------|
| 1. 서론 | 4. 분석 결과 |
| 2. 이론적 배경 | 5. 논의 및 결론 |
| 3. 연구 방법 | <참고문헌> |

〈국문 요약〉

본 연구는 L2 한국어 쓰기 중 주장하는 글쓰기 평가에서 채점자가 보이는 편향과 인지 처리 과정을 분석하고, 채점의 타당성과 일관성의 증진 방안에 대한 논의를 주요 목적으로 한다. 이를 위해 L2 한국어 쓰기 채점자 10명이 한국어 학습자 15명의 주장하는 글쓰기를 완전 교차 채점한 후, 그 결과를 라쉬 모형에 근거한 FACETS 프로그램을 통해 분석하고, 채점 과정을 사료 구술한 자료를 전사하여 인지 처리 단계별 수행 행동을 중심으로 채점자 프로토콜 분석을 실시하였다.

주요 연구 결과는 다음과 같다. 첫째, 주장하는 글쓰기 평가에서의 채점자 편향을 분석한 결과, 교육 경력이나 채점 경험에 따라 채점의 안정화 전략과 채점자의 편향 양상이 다르게 나타났다. 또한 텍스트의 난이도와 과제의 완료 여부 등이 채점 편향에 영향을 미치는 주요 원인임을 알 수 있었다. 둘째, 주장하는 글쓰기 평가의 채점자 인지 처리 과정 분석 결과, 텍스트 이미지 형성하기, 해석하기, 평가적 읽기, 점수 결정하기의 4개 단계에서 타당성 높은 채점자와 그렇지 않은 채점자 간의 인지 처리 양상

과 하위 정보 처리 행동의 차이를 확인할 수 있었다.

◎ 주제어: L2 한국어 주장하는 글 쓰기 평가, 채점자 인지 편향, 정보처리 과정, 다국면 라슈 모형, 채점 타당성 및 일관성

1. 서론

현대 언어 교육에서의 패러다임 변화가 의사소통 중심으로 전환되면서 L2 언어 평가 방식 역시 학습자의 실제적인 언어 수행 능력을 중점적으로 평가하는 방향으로 변화하고 있다(Bachman & Palmer, 2010; McNamara, 1996). 이러한 변화로 인해 기존의 간접 평가 방식에서 벗어나 학습자의 표현 능력을 직접 평가할 수 있는 방식이 채택되고 있고 최근에는 특정 상황 맥락 속에서 과제 수행 능숙도를 관찰하는 방향으로 평가가 발전하고 있다. L2 언어 교육의 이러한 과제 수행 중심 평가는 쓰기와 말하기 교육 분야에서 특히 중요한 평가 방식으로 자리 잡았다.

이와 같은 변화는 L2 한국어 교육에도 반영되고 있다. 예컨대, 한국어 능력시험(이하 TOPIK)의 초기 쓰기 영역 문항은 주로 쓰기에 관한 지식을 측정하는 데 중점을 두었으나, 현재는 수험자의 실제적 언어 숙달도를 평가하는 방향으로 전환되었다(서유남, 2003; 이해영, 2004; 김정숙 외, 2005). 이러한 변화는 한국어 교육기관의 교육과정에도 영향을 미쳐, 대부분의 교육 현장에서 학습자의 의사소통 능력을 직접 평가하는 방식으로 쓰기와 말하기 평가가 이루어지고 있다. 이제 L2 한국어 평가의 목적도 다양한 상황 맥락 안에서 학습자의 실제적인 언어 수행 능력을 정확히 추론하는 것으로 방향이 변화하였다.

이러한 직접 평가 방식은 학습자의 의사소통 능력을 교사가 직접 평가할 수 있는 장점을 가지지만, 평가 과정에서 채점자의 주관성이 개입되기 때문에 채점의 타당도와 신뢰성 확보 문제가 제기될 수 있다. 실제로 Linacre(1989)는 수행 평가에서 채점 과제와 채점자의 점수 차이가 전체

점수의 1/3에서 2/3에 이르며, 이는 학생 능력으로 인한 점수 차이와 유사한 비중을 차지한다고 주장한 바 있다. Eckes(2012) 연구에서도 채점자가 수험자의 쓰기 텍스트를 채점하는 과정에서 주관적인 판단을 완전히 배제할 수 없으며, 이는 평가 결과에 대한 타당도 측면에서의 문제 발생 가능성이 커질 수 있음을 지적하기도 하였다.

이러한 채점자 타당도와 관련하여 가장 빈번하게 제기되는 문제는 채점자의 주관적 경향에 따른 평가 결과 왜곡 현상인 채점 편향이다(장소영·신동일, 2009). 한국어 교육 분야에서도 채점 편향의 원인을 규명하고자 하는 연구가 늘어나고 있으며, 이를 방지하기 위하여 채점 기준의 명확한 설정, 채점자 간의 일관된 채점 훈련, 다중 채점자의 평가를 종합하는 방법, 그리고 통계적 분석을 통한 편향 탐지 및 보정 등이 제안되고 있다(강민석, 2015; 김수현, 2019). 그러나 이 또한 채점자의 역량이나 개인적 태도 등에 의존하는 경향이 커서, 채점 편향 그 자체를 확인하여 그 문제를 직접적으로 다루는 데에는 한계가 있다.

따라서 L2 한국어 쓰기 채점 편향을 최소화하고, 채점의 공정성과 신뢰성을 제고하기 위해서는 편향의 주체인 채점자에 대한 면밀한 분석이 선행되어야 할 필요가 있다. 이와 함께 쓰기 채점 과정도 문제를 해결하는 일종의 의사 결정 과정이므로 채점 결과 분석과 더불어 인지적 관점의 논의가 필수적으로 보완될 필요가 있음을 피력하는 연구도 많아지고 있다(박종임, 2014; 박지수, 2021; Jia & Zhang, 2023). 즉, L2 한국어 쓰기 채점자가 평가 과정에서 어떤 인지적 판단 및 그에 따른 부담을 경험하는지, 또는 어떤 전략을 활용하여 평가 기준을 적용하고 점수를 산출하는지에 대한 논의는 필수적으로 이루어져야 할 것이다.

특히 최근 L2 한국어 쓰기 채점을 위한 자동 채점 기술이 도입되면서 인간 채점자의 한계를 보완하려는 노력이 이어지고 있지만, 자동 채점 시스템 역시 우수한 채점자의 인지적 판단 과정을 기반으로 설계되고 있다(김승주, 2021; 남미정·원미진, 2022). 따라서 L2 한국어 쓰기 채점의 신뢰성과 타당성을 증진하여 L2 한국어 평가 체계의 안정성 증진을 도모하

고, 나아가 자동 채점 기술의 기반을 강화하고 신뢰도를 높이기 위해서라도 채점자가 쓰기 채점 시 보이는 편향의 발생 여부 및 양상을 확인하고, 이와 관련한 인지 과정의 탐구는 중요한 연구 주제로 다루어져야 한다.

이에 본고에서는 다음의 두 가지 연구 질문을 바탕으로 L2 한국어 쓰기 채점자에 대한 고찰을 진행하였다.

<연구 질문>

1. L2 한국어 채점자의 주장하는 글쓰기 평가에서 나타나는 채점 편향의 양상은 어떠한가?
2. L2 한국어 채점자의 주장하는 글쓰기 평가의 편향과 관련하여 발생하는 인지적 처리 과정은 어떠한가?

2. 이론적 배경

2.1. 주장하는 글쓰기와 평가

최근 한국어 글쓰기 교육은 장르 기반 교육을 중심으로 이루어지고 있다. 장르는 담화 공동체가 세계를 바라보고 그 안에서 언어를 구조화하는 방식을 보여주어 담화 공동체 안에서 효율적인 의사소통의 도구로 활용될 수 있다는 장점을 지닌다(김해미, 2020; 오세영, 2018). 즉, 학습자는 특정 담화 공동체 내에서 통용되는 장르적 규칙을 습득하고, 이를 통해 보다 효율적이고 목적에 맞는 글쓰기를 할 수 있게 된다. 요즘 대학에서 학문적으로 한국어를 배우는 학습자들은 학업이나 전문 분야로의 진출을 목적으로 다양한 학술적 글쓰기 능력을 요구받고 있는데, 그중에서 특히 주목받는 장르는 ‘주장하는 글’이다. ‘주장하는 글’은 TOPIK 쓰기 평가에서는 가장 높은 쓰기 숙달도를 측정하기 위한 문항으로 출제되고 있으며, 논리적 전개를 돕는 연결어와 근거 제시 방식, ‘서론-본론-결론’의 구조와 함께 학술적 표현 방식과 실증성을 담보하는 문장 구성 능력과 같

은 ‘장르적 지식’을 요구한다. 따라서 ‘주장하는 글’을 평가하는 채점자는 기본 쓰기 평가와 관련한 지식과 더불어 장르가 가지는 특정 구인까지를 매우 복잡하게 고려하여 세심한 채점을 할 필요가 있다(최혜민, 2011). 그러나 이러한 복잡한 장르적 특성은 채점자에게 높은 인지적 부담을 초래할 수 있다. 윤나영(2023)의 연구에서도 논설문 채점의 경우 다른 장르의 글쓰기에 비해 다른 종류의 편향이 나타날 가능성이 있음을 시사하고 있으며, 최혜민(2011)과 백유진·박영민(2021)에서도 글 유형에 따라 채점 특성이 달라질 수 있음을 피력하고 있다.

2.2. 채점자의 편향 연구

채점 편향은 채점자가 수험자의 쓰기 텍스트를 평가할 때 주관적 인지적 요인에 의해 평가 결과가 왜곡되는 현상으로, 다양한 형태로 나타난다(Eckes, 2012). 주요 유형에는 보상적 편향, 중앙 집중 편향, 후광 효과, 대비 효과, 순서 편향 등이 있다. 보상적 편향은 특정 채점 기준에서 관대하게 평가하는 경우, 다른 기준에서 엄격히 평가하려는 경향으로 나타나며(신동일, 2001), 중앙 집중 편향은 중간 점수를 선호하여 극단적인 점수를 피하는 경향을 보인다. 후광 효과는 텍스트의 일부 요소가 전체 평가에 영향을 미쳐, 예를 들어 서론이 훌륭하면 본문과 결론까지 과대 평가되는 현상이다. 대비 효과와 순서 효과는 다른 수험자의 텍스트와 비교해 평가하는 경향으로, 채점 순서에 따라 평가가 달라질 수 있는 문제를 일으킨다(Lumley & McNamara, 1995).


수험자와 채점자 특성에 따른 편향도 발생할 수 있다. 수험자 특성 편향(Test-taker Characteristic Bias)은 채점자가 수험자의 성별, 인종, 사회적 배경 등 특정 인구 통계적 특성에 의해 무의식적으로 영향을 받아 점수를 부여하는 경우 발생한다. 이러한 편향은 평가의 공정성을 심각하게 저해할 수 있기 때문에 채점을 할 때에는 수험자를 익명 처리한 후에 채점을 하는 것이 공정하다고 할 수 있다.

채점자 특성과 관련된 편향 유형으로는 채점 경력, 채점 훈련 경험 유무에 따라 채점 편향이 나타날 수 있다. 강민석(2015)은 한국어 교사를 대상으로 쓰기 채점에 나타나는 채점 편향을 분석한바, 전체 일관성 수준이 ‘부적합’인 채점자 부류가 특정 텍스트나 채점 기준에 높은 채점 편향을 보였는데, 이는 채점자의 경력이 가장 큰 배경이 되었다. 채점자 특성과 관련한 또 다른 편향 유형은 채점자의 감정 상태나 신체 상태와 같은 개인적 요인으로 채점에 영향을 주는 경우이다. 이런 채점자의 정서적 편향(Emotional Bias)은 채점자의 감정 상태가 채점 결과에 영향을 미치는 경우로, Lumley & McNamara(1995)는 채점 시간에 따라 채점자의 엄격성이 유의한 변화를 나타냈다고 밝히고 있다. 즉 채점자가 피로하거나 스트레스를 받는 상태에서는 채점자가 엄격성을 일관되게 유지하는 데에 어려움이 있다고 설명하였다.

2.3. 채점자의 인지 과정 연구

정보 처리 과정 이론에 따르면, 채점자는 평가 과정에서 텍스트를 읽고 이해하며 점수를 부여하는 일련의 인지적 단계를 거친다. 이 과정은 감각 등록기, 단기 기억, 작업 기억, 장기 기억의 저장소를 거쳐 주의, 시연, 인출의 과정을 포함한다(Atkinson & Shiffrin, 1968). 쓰기 채점에서는 채점자의 인지적 부담이 크므로 채점자의 인지적 처리 과정을 이해하는 것이 중요하다. Freedman & Calfee(1983)의 모델에 따르면 채점자는 텍스트를 읽고 심리적 표상, 즉 텍스트 이미지를 형성하여 채점 과정에 영향을 미친다.

Wolfe(2005)는 Freedman & Calfee(1983)의 채점자의 인지 처리모형을 채점 프레임워크와 글 프레임워크의 개념으로 설명한다. 채점자의 인지 처리 과정은 ‘해석’, ‘평가’, ‘정당화’의 세 가지 단계로 구분되며, 채점자는 텍스트 이미지를 평가 기준과 비교하여 점수를 부여하고 최종적으로 확정한다.



[그림 1] Wolfe의 채점자 인지 처리 모형(Wolfe, 2005:40)

쓰기 평가에서 읽기 과정은 채점자가 가장 많은 정보를 처리하는 과정으로, 평가적 읽기는 채점자가 텍스트를 이상적인 기준에 따라 평가하는 활동이다(Crisp, 2012; Cumming, 1990). Cumming(1990)은 전문 채점자와 초보 채점자의 평가 과정에서 해석 전략과 판단 전략이 다르다고 하였으며, 예를 들어 전문 채점자는 내용, 수사적 조직, 언어적 특징 등 다양한 측면에 동시에 주의를 기울이면서 채점을 수행하는 경향이 있었다. 또한 채점 기준을 고려하거나 채점 기준 간에 나타날 수 있는 상호작용에 유의하며 채점을 수행하는 정보 처리 행동을 보였다.

Crisp(2012)에 따르면, 채점자는 읽기 과정 중 정서적 반응을 보이거나 사회적 상호작용을 상상하기도 한다. 채점자는 텍스트 이미지 형성, 텍스트 비교, 점수 조정 등의 정보를 처리하며 구체적인 텍스트 특징을 평가에 반영한다. 점수 결정 과정은 채점자가 텍스트 이미지를 점수로 변환하는 단계로, 주관적 판단을 구체적인 점수로 표현하는 과정이다. Milanovic et al.(1996)의 인지 과정 모델에서는 채점자가 전체 인상을 형성한 후 평가 기준을 적용하고 점수를 수정하는 회귀적 과정이 포함된다.

점수 수정은 채점자가 텍스트를 다시 읽고 가점 요인 또는 감점 요인을 재발견하여 점수를 재검토할 때 발생한다. 이는 채점 기준 해석이 변경되거나, 특정 기준에서 관대성 또는 엄격성을 재평가하는 경우 나타난다(Sakyi, 2000). 이러한 점수 수정 행동은 채점자 간 일관된 척도 활용

의 필요성을 제기하며, 채점자의 심리적 부담을 높일 수 있다. 채점자의 인지적 편향과 정보 처리 과정은 L2 쓰기 평가의 타당성과 신뢰도에 중요한 영향을 미친다. 편향을 최소화하고 일관된 채점을 보장하기 위해서는 채점 기준의 명확화, 채점자 훈련 및 편향 통제 방안이 필요하다 (Crisp, 2012; Cumming, 1990).

3. 연구 방법

본 연구는 L2 한국어 쓰기 평가에서 채점자의 인지적 편향과 정보 처리 과정을 탐구하기 위해 혼합 연구 방법론을 적용하였다. 수렴적 설계를 통해 양적 데이터와 질적 데이터를 동시에 수집하여 상호 보완적 해석을 시도하였으며, 설명적 순차 설계를 통해 양적 분석 후 질적 분석을 수행하여 결과를 심층적으로 해석하였다. 이러한 설계를 통해 채점자 간 신뢰도와 편향 요인, 인지 과정의 차이를 구체적으로 이해하고자 하였다.

3.1. 연구 대상

본 연구의 대상은 현재 외국인을 대상으로 한국어를 가르치고 있으면서, 모어와 한국어 교육 경험 수준 등 배경이 다른 L2 한국어 교원 10명이다. 먼저 원어민 채점자는 6명, 비원어민 채점자는 4명이 참여하였다. 평균 교육 경력은 4.7년이었으며, 채점 경험은 어학당과 학부 수업을 기준으로 중간, 기말시험 등의 채점에 참여한 경력이 있었다. 교원자격증 보유 현황은 1급 1명, 2급 8명, 미소지 1명으로 나타났으며, 자격증 미소지자는 해당 분야 박사학위 소지자로 교육 경력과 전문성을 고려하여 연구에 참여하였다. 한국어 평가와 관련된 경험을 확인한 결과, 평가론 수강 경험이 있는 교원은 9명, 채점자 훈련 경험이 있는 교원은 2명으로 나타났다. 평가론 미 수강 교원 1명도 채점자 훈련 경험이 있어, 모든 참여

자가 평가론적 기본지식을 보유하고 있었다. 채점자 훈련을 경험한 교원들은 세종학당재단에서 진행된 훈련에 참여한 것으로 확인되었다. 구체적인 채점자 정보는 다음의 <표 1>과 같다.

<표 1> 채점자 정보

채점자	국적	교육 경력(년)	채점 경험 (1학기당 평균 횟수)	한국어 교원 자격증	근무 기관	평가론 이수	채점자 훈련
R1	한국	1년 미만	없음	2급	프리랜서	유	무
R2	한국	1년 미만	없음	2급	프리랜서	유	무
R3	한국	10년	30회	2급	어학당	유	무
R4	한국	2년	없음	2급	학원	유	무
R5	한국	5년	6회	1급	학부/어학당	유	유(2회)
R6	한국	3년	2회	2급	어학당	유	무
R7	베트남	8년	5회	2급	학부	유	무
R8	중국	1년 미만	없음	2급	프리랜서	유	무
R9	태국	9년	5회	2급	학부	유	무
R10	인도네시아	10년	2회	없음	학부	무	유(2회)

3.2. 연구 도구

연구 도구는 경기도 소재 대학 부설 한국어 교육기관에서 L2 한국어 학습자로 한국어를 학습하고 있는 중급 수준 이상의 수험자 15명을 대상으로 수집한 주장하는 글 15편이다. 주제는 ‘긍정적 사고의 영향’이었으며 쓰기 주요 과제는 ‘긍정적인 생각이 삶에 주는 영향과 이유를 제시하라.’였으며 분량 제한은 250자 이상이었다. 과제 작성은 글씨체와 국적 정보를 배제함으로써 평가의 공정성과 신뢰도를 확보하기 위하여 워드프로세서로 제작성하였다. [그림 2]와 [그림 3]은 실제 수험자의 예시 글과 채점자들에게 모범 답안으로 제공한 글이다.

세월로 우리의 힘으로 성공할 수 있다는 긍정적인 생각은 생명을 자각
사람의 몸과/이어서 우리 삶에 큰 영향을 끼치는 의미가 있다/첫째
자기 계획을 얻는 것이 가능하다. 긍정적인 생각을 새기는 사람은 모든
초월하기 위해서 무엇을 놓지 않아서 자기 계발에 점점 빠지게 된다.
두 번 세 번 연습에 어떤 사람은 긍정적인 생각은 자기가(는) 하지만
앞으로 성공하지 못한다 그 생각에 무한한 삶에 여러 번에 도움이 될 것
같다/두 대각적으로 그런 생각을 새기는 사람은 다른 사람들에게
좋은 긍정적인 가치들을 준다. 그런 사람들은 자신이 '계발한 사람'이
다른 사람들에게도 행복, 지식, 성공 아이디어를 전해주는 것이 중요하다.

[그림 2] 실제 수험자 예시 글

자신의 힘으로 성공할 수 있다는 긍정적인 생각은 우리의 삶에 큰 영향을 미친다. 이러한 사고는 자존감과 자신감을 높여 주며, 도전하는 자세를 갖게 한다. 또한 어려움에 처했을 때 포기하지 않고 계속 목표를 향해 나아갈 수 있도록 도와준다.

왜냐하면 긍정적인 생각은 실패를 두려워하지 않도록 도와주기 때문이다. 이는 실패를 성장의 기회로 생각하고, 자기계발을 통해 더 큰 목표를 이루는 힘이 될 수 있다.

결론적으로, 긍정적인 사고는 도전 정신과 자신감을 키우고, 실패를 극복할 수 있는 원동력이 되어 더 나은 삶을 살게 하는 중요한 요소다.(303자)

[그림 3] 모범 답안

기본적인 채점 자료의 특징과 평균 점수에 대한 구체적인 정보는 다음 <표 2>와 같다.

<표 2> 채점 자료 정보

수험자	글의 완료 여부	글자 수(자)	평균 점수(점)
S1	완료	323	13
S2	완료	195	9.5
S3	완료	284	13.6
S4	완료	315	14.4
S5	완료	249	11.6
S6	완료	262	12.3
S7	완료	330	10.3
S8	완료	299	10.9

S9	완료	392	14.1
S10	미완	63	4
S11	완료	277	8.4
S12	완료	289	10.7
S13	미완	94	3.7
S14	완료	393	11.8
S15	미완	165	8.3

수험자가 제출한 15개의 주장하는 글쓰기에 대한 채점 방식은 분석적 채점 방식을 채택하였으며, 모든 채점자가 모든 글에 대해 완전 교차 채점하도록 하였다. TOPIK II의 채점 기준으로 설정된 내용 및 과제 수행, 글의 전개 구조, 언어 사용의 세 가지 평가 항목을 설정했다. 다만 TOPIK에서 제시하고 있는 척도는 너무 광범위하여 채점자의 인지적 부담을 일으킬 수 있어, 평가의 세부적인 차이를 명확히 구분하면서 채점자의 다양한 반응을 확인할 수 있는 6점 Likert식 척도로 수정하여 사용하였다. 구체적인 채점 기준은 <표 3>과 같다.

<표 3> 채점 기준표

평가 범주	세부 내용	채점 척도
내용 및 과제 수행	-주어진 과제를 충실히 수행하였는가? -주제와 관련된 내용으로 구성하였는가? -주어진 내용을 풍부하고 다양하게 표현하였는가?	6·5·4·3·2·1
글의 전개 구조	-시작과 마무리를 적절하게 구성하였는가? -내용 전개의 긴밀성이 있는가? -내용의 전환에 따라 문단을 적절히 구성하였는가?	6·5·4·3·2·1
언어 사용	-문법과 어휘를 다양하고 풍부하게 사용하며 적절한 문법 과 어휘를 선택하여 사용하였는가? -문법, 어휘, 맞춤법 등의 사용이 정확한가? -글의 목적과 기능에 따라 격식에 맞게 글을 썼는가?	6·5·4·3·2·1

이와 함께 채점자를 대상으로 채점 인지 과정 분석을 위해 사고 구술 자료를 수집하였으며, 채점자가 답안을 읽으며 떠오르는 생각을 구술한

내용을 수집하였다. 실험 중에는 온라인 화상 시스템을 이용하여 채점 과정과 사고 구술 과정을 녹화하였으며, 채점자들이 집중할 수 있는 환경을 조성하였다. 텍스트 유형별로 수집된 사고 구술 자료는 네이버 클로바노트를 통해 전사 및 검토하였다. 수집한 사고 구술 자료는 <표 4>의 분석 틀을 토대로 정리하고, 교육 경력 5년 이상의 동료 연구자 1인이 교차 검토하는 과정을 거쳤다.

<표 4> 채점자 사고 구술 분석용 틀

채점 과정	정보처리 행동	부호화
A. 텍스트 이미지 형성하기	1. 과제 확인하기	A1
	2. 채점 기준 확인하기	A2
	3. 채점 기준별 하위 요소 설정하기	A3
	4. 모범 답안 확인하기	A4
	5. 외적 요소 고려하기	A5
	6. 채점 계획하기	A6
	7. 예상하기	A7
B. 해석하기	1. 훑어 읽기	B1
	2. 반복 읽기	B2
	3. 문맥 파악하기	B3
	4. 요약하기	B4
	5. 오류 찾기	B5
	6. 오류 수정하기	B6
	7. 주제 찾기	B7
C. 평가적 읽기	1. 논평하기	C1
	2. 채점 근거 제시하기	C2
	3. 개선 방안 제안하기	C3
	4. 다른 채점 기준의 개입	C4
	5. 상황식 읽기/하향식 읽기	C5+/C5-
	6. 개인적 반응	C6
D. 점수 결정하기	1. 다른 텍스트와 비교하기	D1
	2. 가점 요인 찾기	D2
	3. 감점 요인 찾기	D3
	4. 점수 부여하기(읽기 중/읽은 후)	D4
	5. 점수 수정하기	D5

3.3. 분석 방법

수집한 자료는 다음과 같은 과정을 통해 분석 및 처리되었다. 첫째, 채점자의 채점 경향과 편향을 분석하기 위해 분석적 채점 방식을 적용하여 수집한 채점 결과를 다국면 라쉬 모형을 활용한 프로그램 FACETS를 사용하여 통계 분석하였다. 라쉬 모형은 채점자의 엄격성, 일관성, 채점 기준의 곤란도 등을 평가하여 채점 신뢰도를 높이는 데 유용하다. 각 채점자의 일관성은 Wright & Linacre(1994)에서 권장하는 적합도 범위인 0.6~1.4를 기준으로 하였으며, 채점 편향은 Bias/Interaction Reports와 t 값(± 2), p 값($p < 0.05$) 등을 통해 통계적으로 유의미한지를 판단하였다. 둘째, 사고 구술 도구를 통해 수집한 자료는 채점 과정에서 채점자들이 산출한 사고 구술 프로토콜은 내용분석(content analysis) 방법을 통해 분석하였다. 분석 범주와 단위는 선행 연구(Crisp, 2012; Cumming, 1990; Wolfe, 2005)를 바탕으로 설정하였으며, 예비 실험에서 일부 범주를 추가하여 최종 프로토콜 틀을 완성하였다. 프로토콜 분석 절차는 연구 주제와 표집 대상을 결정한 후, 각 단계에서 나타나는 정보 처리 행동을 코딩하고 분석하였다.

4. 분석 결과

4.1. 편향 분석

본 연구는 L2 한국어 쓰기 평가에서 채점자들이 보이는 편향을 파악하기 위해 다국면 라쉬 모형을 적용하여 채점자별 엄격성과 일관성, 채점자 간 편향 크기, 채점자와 텍스트 간 이상치, 그리고 채점자와 채점 기준 간의 편향 크기를 검토하였다.

4.1.1. 채점자의 엄격성과 일관성

채점자들의 엄격성과 일관성을 검토한 결과, <표 5>와 같이 채점자 간 엄격성 차이가 나타났다. 신뢰도 분석에 따르면, R7은 엄격성 지수(logits)가 2.31로 가장 높은 반면, R1은 -1.11로 가장 관대한 채점자로 나타났다. 또한 경력이 많은 채점자들 사이에서도 부적합이나 과적합 경향이 나타났다.

<표 5> 신뢰도 분석

채점자	엄격성 지수	내적합 지수	외적합 지수	판정
*R1	-1.11	*.59	*.59	관-과
R2	.11	.95	1.09	엄-적
R3	-.34	.71	.76	관-적
R4	-.65	.97	.92	관-적
R5	.21	1.05	.96	엄-적
*R6	.11	1.17	*1.85	엄-부
R7	2.31	.96	.87	엄-적
R8	.68	.93	.82	엄-적
*R9	-.15	*.51	*.55	관-과
*R10	.68	*1.78	*1.58	엄-부

$\chi^2(9) = 207.6, p < .001, RS = .96$

4.1.2. 채점자와 수험자 텍스트 간 편향 크기 검증 결과

각 채점자가 수험자 텍스트에 대해 차별적인 편향을 보였는지 확인하기 위해 편향 크기를 분석한 결과는 <표 6>과 같다. 총 17쌍의 편향이 나타났고 모형의 예측보다 관대한 채점 경향이 더 많았다. 채점자별로는 일관성이 가장 낮은 채점자였던 R10의 채점 편향이 자주 보고되었으며 주로 초반과 후반의 글에 편향을 보였다. 채점자 간 편향이 가장 자주 나타난 글을 S14였다. S14의 텍스트는 가장 글자 수가 많은 특징이 있었다. 채점 편향의 크기가 가장 컸던 글은 S12(t=3.06)로 편향의 양상이 극단적인 R5와 R10의 점수 차는 5배나 차이를 보였다.

<표 6> 채점자와 수험자 텍스트 간 상관관계

rater	examinee	Observed Score	Expected Score	<i>t</i>	Prob.
5	12	16	10.65	3.09	0.0907
8	11	12	7.11	3.09	0.0909
7	5	11	6.55	2.9	0.101
10	1	17	11.98	2.73	0.1123
10	14	15	10.65	2.64	0.1185
10	2	12	8.21	2.36	0.1421
3	14	17	13.07	2.29	0.1488
6	10	6	3.88	2.21	0.1573
8	12	13	9.46	2.18	0.1608
10	8	13	9.68	2.06	0.1761
4	14	17	13.72	2.02	0.181
9	9	12	14.87	-2.1	0.1708
4	15	6	10.23	-2.51	0.129
2	14	8	12.03	-2.54	0.1266
6	14	8	12.03	-2.54	0.1266
10	12	3	9.46	-2.55	0.1256
3	4	12	15.47	-2.65	0.1178

S12

있는 사람 말들은 부정적인 사람은
비가 온 날이 미끄럽게 날이지만 긍정
적인 사람은 비가 온 날이 시원한 날
이라고 한다. 그래서 긍정적인 생각이
있는 사람이 어떤 상황 있는데 좋은
것도 볼 수 있다. 반대로 부정적인 사람
들이 남은 것을 볼 수 있을 것이다.
이 생각이 어떻게 사형이 많이 나타날
것이다 자신의 힘으로 성공할 수 있다
는 긍정적인 생각이 싫으면 어렵게 상
황을 극복한 앞으로 힘이 있을 것 같
다 하지만 부정적인 생각이 항상 있으
면 우리가 쉽게 자신의 하고 싶은 것
을 뛰어날 것이다.
그래서 좋은 생활 싶은 앞으로 힘으
로 성공하고 긍정적인 생각하게 된다.
(28 9 자)

S14

하늘은 스스로 돕는 자를 돕는다는 옛
말이 있다. 이 옛 말은 기적과 같이
대단한 것은 아니라 할 지라도 우리가
인생에서 스스로 이루어 내는 작은 성
공들은 그것을 할 수 있다는 자신의
신념에서 비롯 된 노력의 결과라고 한
다. 왜냐하면 인생에서 태어났을 때 조
원한 사람이 없다. 사실은 성공하기 위
해서 우리는 시시각각 최고 노력해야
한다. 예를들어 공부할 때 너무 힘들지
만 "우리 할 수 있다" 는 생각하면
우리 성공할 수 있다. 우리의 삶에 긍
정적인 생각이 자신감이 있어서 자신의
힘으로 성공할 수 있다. 밀려거나 인관
하도 똑같다. 우리 긍정적인 생각하는다
면야 우리 성공할 수 있다. 인생에서
태어났을 때 성공한 사람 없다. 왜냐하
면 그 사람들을 긍정적인 생각하고 최
고 노력하기 때문이다. 그 사람들을 성
공하고 생복할 수 있다. (39 3 자)

[그림 4] 채점 편향이 나타난 글

4.1.3. 채점자와 텍스트 간 이상치 검증 결과

이상치 검증을 통해 모형의 예상과 실제 채점 결과 간에 유의미한 차이를 보이는 이상치를 확인한 결과는 <표 7>과 같다. 채점자 R6가 S10과 S13 텍스트의 언어 사용 항목에서 지나치게 높은 점수를 부여하여 관대한 편향이 나타났다. 이상치 결과는 채점 신뢰도를 저하하게 만드는 주요 원인이기 때문에 반드시 확인해야 할 필요가 있다. S10과 S13 텍스트는 모두 과제가 미 완료되어 문항이 요구하는 글자 수에서 매우 미달하는 수준의 글이었다.

<표 7> 이상치 정보


채점자	텍스트	채점 항목	기대 점수 (Exp.)	관찰 점수 (Obs.)	잔차 (Resd)	표준화 잔차 (StRes)
R6	S13	언어 사용	1.1	3	1.9	5.1
R6	S10	언어 사용	1.2	3	1.8	4.1

4.1.4. 채점자와 채점 기준 간 편향 크기 검증 결과

10명의 채점자와 채점 기준 간의 편향 분석 결과에 따르면 전체 채점 신뢰도 결과와 상관없이 대부분 채점자가 채점 기준을 적용할 때 일관성을 유지하는 데 매우 어려움을 겪은 것을 확인할 수 있다. <표 8>을 보면 2명의 채점자를 제외하고 모두 하나 이상의 구인에서 편향이 나타났다. 과적합이 부적합보다 많은 비중을 차지하였으며, 비교적 교육 경력이 있는 채점자들에게서 부적합이 나타났다. [그림 5]를 살펴보면 R6의 경우 다른 채점자들과의 이질적 채점 경향이 확인되는데, 이런 편향의 원인은 채점 기준에 대한 해석과 적용에 대한 인지적 처리 과정 분석을 통해 확인할 필요성이 있다.

<표 8> 채점 기준별 편향 크기와 일관성 검증 결과

rater	factor	bias size	infit MnSq	outfit MnSq	판정
*R1	language	-0.27	0.8	0.8	엄-적
	writing	0.31	0.4	0.4	관-과
	performance	0.02	0.5	0.5	관-과
*R2	language	0.26	0.4	0.7	관-과
	writing	0.06	1.1	1.2	관-적
	performance	-0.32	1.2	1.2	엄-적
*R3	language	-0.1	0.5	0.5	엄-과
	writing	-0.1	0.8	0.8	엄-적
	performance	0.14	0.8	1	관-적
*R4	language	-0.21	0.4	0.3	엄-과
	writing	0.1	1	1	관-적
	performance	0.14	1.6	1.4	관-부
R5	language	-0.02	0.6	0.6	엄-적
	writing	-0.04	1.2	1.1	엄-적
	performance	0.07	1.3	1.2	관-적
*R6	language	0.85	1.3	1.8	관-부
	writing	-0.23	1	1.1	엄-적
	performance	-0.61	0.6	0.6	엄-적
R7	language	-0.01	1.3	1.1	엄-적
	writing	-0.41	1	0.9	엄-적
	performance	0.33	0.6	0.6	관-적
*R8	language	-0.42	0.4	0.4	엄-과
	writing	0.05	0.8	0.7	관-적
	performance	0.35	1.4	1.2	관-적
*R9	language	-0.19	0.3	0.3	엄-과
	writing	0.29	0.4	0.5	관-과
	performance	-0.09	0.7	0.8	엄-적
*R10	language	0.07	1.3	1.2	관-적
	writing	-0.04	1.7	1.5	엄-부
	performance	-0.04	2.3	2	엄-부



[그림 5] 채점 기준 간 편향 분석

4.2. 인지 과정 분석

본 연구에서는 L2 한국어 쓰기 평가에서 채점자가 텍스트를 평가하는 인지적 과정을 Freedman & Calfee(1983)과 Wolfe(2005)가 제안한 채점자의 인지 과정 모형에서 제안하는 네 가지 주요 단계인 텍스트 이미지 형성하기, 해석하기, 평가적 읽기, 점수 결정하기로 나누어 분석하였다. 각 단계에서 채점자가 텍스트를 인지하고 평가하는 구체적인 정보 처리 행동을 관찰하였으며, 이를 통해 채점의 신뢰도에 영향을 미치는 요인을 분석하였다.

4.2.1. 텍스트 이미지 형성하기 단계 분석

‘텍스트 이미지 형성하기’ 단계는 채점자가 과제와 관련된 이상적인 텍스트 이미지를 형성하는 단계로, 이는 이후 평가 판단에 중요한 역할을 하였다. 이 과정에서 채점자들은 문항과 채점 기준을 확인하고, 모범 답안을 참조하며, 채점자의 배경지식 등을 활용하여 이상적인 텍스트 이미지를 형성하였다. 사고 구술 프로토콜을 분석한 결과에 따르면 경험이 많은 채점자일수록 다양한 정보처리 행동이 나타났다. <표 9>에 제시한

것과 같이, 먼저 과제와 채점 기준 확인, 하위 요소 설정하기는 전 채점자에게서 공통하여 나타났다. 모범 답안을 참조하거나 문단의 구성이나 문체, 분량, 띄어쓰기 등의 외적 요인을 고려하는 채점자는 일부만 확인이 되었다. 또한 수험자의 수준을 예상하는 행동과 그 수준을 척도 구간별로 어떻게 구분할 수 있는지를 고려하기도 하였다. 이처럼 채점자들은 채점 관련 다양한 정보를 심상의 텍스트 이미지에 담은 후, 이후 채점 단계에서 실제 평가하는 텍스트와 비교하는 과정을 반복함으로써 더욱 선명한 텍스트 이미지를 형성하는 것을 알 수 있었다.

<표 9> 텍스트 이미지 형성하기의 정보 처리 행동 출현 여부

채점자	A1	A2	A3	A4	A5	A6	A7
	과제 확인	기준 확인	하위 요소	모범 답안	외적 요인	계획 하기	예상 하기
R1	○	○	○	×	○	○	×
R2	○	○	○	×	×	×	×
R3	○	○	○	×	×	○	×
R4	○	○	○	○	○	×	×
R5	○	○	○	○	○	○	×
R6	○	○	○	○	○	○	○
R7	○	○	○	×	×	○	×
R8	○	○	○	○	○	×	×
R9	○	○	○	×	×	×	×
R10	○	○	○	×	×	×	×
행동 산출율	10 22.2%	10 22.2%	10 22.2%	4 8.9%	5 11.1%	5 11.1%	1 2.2%

4.2.2. 해석하기 단계 분석

‘해석하기’ 단계에서 채점자들은 수험자의 텍스트를 실제로 읽으며 맥락을 파악하고, 텍스트의 오류와 수준을 판단하였다. <표 10>에 제시한 것과 같이, 훑어 읽기, 반복 읽기, 오류 찾기는 모든 채점자에게서 빈번

하게 나타났으며, 이러한 행동은 전체적인 내용 이해와 세부 오류 인지에 도움을 주었다. 특징적인 것은 ‘요약하기’는 비원어민 채점자들 사이에서는 나타나지 않았으며, ‘주제 찾기’에 더 집중하는 경향을 보였다.

<표 10> 해석하기의 채점자 프로토콜 산출 수

채점자	B1	B2	B3	B4	B5	B6	B7	B8
	흠여 읽기	반복 읽기	문맥 파악	요약 하기	오류 찾기	오류 수정	주제 찾기	수준 파악
R1	○	○	○	○	○	○	○	×
R2	○	○	○	○	○	×	×	×
R3	○	○	○	○	○	○	○	○
R4	○	×	○	×	○	○	○	×
R5	○	○	○	○	○	×	○	○
R6	○	○	○	×	○	×	×	○
R7	○	×	×	×	○	×	○	○
R8	○	×	○	×	○	×	○	×
R9	○	○	○	×	○	○	×	×
R10	○	○	○	×	○	×	×	×
행동 산출율	10	7	9	4	10	4	5	4
	18.9%	13.2%	17%	7.5%	18.9%	7.5%	9.4%	7.5%

4.2.3. 평가적 읽기 단계 분석

‘평가적 읽기’ 단계에서 채점자들은 해석된 텍스트 이미지를 기준에 대조하여 평가하고, 논평하기, 채점 근거 제시하기, 개선 방안 제안하기 등의 행동을 수행하였다. <표 11>에 제시한 것과 같이, 이 단계에서 경험이 많은 채점자들은 상향식 접근과 하향식 접근방식을 혼합하여 텍스트를 평가하였다. 상향식 접근은 세부 항목을 독립적으로 평가하며, 하향식 접근은 전체적 인상에서 출발하여 세부 요소로 내려가는 방식으로 이루어

어졌다. 또한 경험이 부족한 채점자들은 채점 분량만을 채점 근거로 삼거나 채점 구인별 세부 요인을 축소하여 판단하는 특징을 보였다.

<표 11> 평가적 읽기의 채점자 프로토콜 산출 수

채점자	C1	C2	C3	C4	C5+	C5-	C6
	논평하기	채점 근거	개선 방안	개입	상향식	하향식	개인 반응
R1	○	○	○	○	○	○	○
R2	×	○	○	○	○	×	○
R3	○	○	○	○	○	○	×
R4	×	○	×	×	○	×	×
R5	○	○	○	○	×	○	×
R6	○	○	×	×	○	○	○
R7	○	○	×	×	×	○	×
R8	×	○	○	×	○	×	○
R9	×	○	×	×	○	×	×
R10	○	○	×	×	○	○	×
행동 산출율	6	10	5	4	8	6	4
	12.8%	21.3%	10.6%	8.5%	17%	12.8%	8.5%

4.2.4. 점수 결정하기 단계 분석

‘채점 결정하기’ 단계에서 채점자들은 텍스트 평가 후 최종 점수를 부여하고 필요에 따라 조정하였다. <표 12>에 제시한 것과 같이, 점수 결정 시 채점자들은 비교하기, 가점 요인 찾기, 감점 요인 찾기 등의 행동을 통해 점수의 타당성을 확인하였다. 특히 감점 요인에 민감하게 반응하는 경향이 있었으며, 이를 통해 점수를 조정하거나 수정하기도 하였다. 경험이 풍부한 채점자들은 평가의 일관성을 높이기 위해 이전 평가와 비교하는 행동을 보였으나, 일부 경험이 적은 채점자들은 회귀적 비교 과정에서 기준 혼란을 겪거나 자신감 부족을 나타냈다.

<표 12> 채점 결정하기 단계의 채점자 프로토콜 산출 여부

채점자	D1	D2	D3	D4+	D4-	D5
	비교	가점	감점	점수 부여 (읽기 중)	점수 부여 (읽기 후)	점수 수정
R1	○	○	○	○	○	×
R2	×	○	○	×	○	×
R3	×	○	○	×	○	○
R4	×	×	○	×	○	×
R5	○	○	○	×	○	×
R6	○	×	○	×	○	×
R7	×	×	○	○	○	×
R8	○	○	×	×	○	×
R9	×	○	○	×	○	×
R10	×	×	○	×	○	×
행동 산출율	4	6	9	2	10	1
	12.5%	18.8%	28.1%	6.3%	31.3%	3.1%

5. 논의 및 결론

본 연구는 L2 한국어 주장하는 글쓰기 평가에서 채점자들이 보이는 인지적 편향과 인지 처리 과정을 탐구하는 것을 목적으로 한다. 이를 위해 L2 한국어 쓰기 채점자 10명에게 한국어 학습자 15명이 작성한 주장하는 글쓰기를 채점한 결과를 라슈 모형에 근거한 FACETS 프로그램을 통해 분석하고, 채점 과정을 사고 구술한 자료를 모두 전사하여 정보 처리 단계와 수행 행동을 중심으로 채점자 프로토콜 분석을 수행하였다. 이를 통해 도출한 본 연구의 결과 및 그에 따른 논의점은 다음과 같다.

첫째, 주장하는 글쓰기 평가에서 나타난 L2 한국어 채점자의 편향을 확인하기 위해 다국면 라슈 모형을 활용한 분석 결과, 교육 경력이나 채점 경험이 많을수록 채점자의 신뢰도가 반드시 높아지는 것은 아니라는

점이 발견되었다. 이는 채점 경력과 채점 신뢰도 간의 상관관계를 강조한 Kondo-Brown(2002), Eckes(2012)의 연구와 상반된 연구 결과였다. 다만 백유진(2020)에서는 전문 채점자를 판단할 때 전체 채점 일관성 결과만을 참고해서는 안 되며, 채점 편향 결과를 참고할 필요가 있음을 밝히고 있다. 채점 기준 편향 분석 결과, 대다수 채점자가 세 가지 채점 구인을 일관되게 적용하는 데 문제점이 발생했다. 채점의 변별이 나타나지 않는 과적합 경향이 자주 나타났으며, 한 가지 구인에만 의존하는 보상 편향을 보였다. 경력 채점자들 채점 경험이 없는 채점자들에 비해 두 가지 이상의 구인에서 엄격성을 보였으나 부적합 경향이 나타났다. 이러한 결과는 숙련도별로 채점 구인의 세부 근거를 설정하는 데 차이를 보인다는 김동수(2014)의 의견과 일부 맥락을 같이 한다. 채점 근거를 다양하게 제시한다는 점은 평가의 환류 효과를 생각할 때 매우 장려되어야 할 사항이지만, 지나치게 세부 요인이 많아지면 채점자의 인지적 부담을 일으킨다는 부정적 영향이 있다. 또한 채점 편향이 나타나는 텍스트의 특징을 살피고 채점자 간 협의의 과정을 거칠 필요가 있다. 특히 분석적 채점 방식이 독립 구인별 채점이기에는 하나 전체 글의 인상과 균형을 맞추지 않으면 신뢰도에 영향을 미친다. 따라서 채점 기준별 세부 요소를 다양하게 확인하되, 그 세부 요소들을 종합하여 수준을 판단하는 채점자 훈련이 보완될 필요가 있음을 시사한다.

이와 함께 채점자들이 수험자의 텍스트에서 고려하는 것은 텍스트의 분량과 과제의 난이도였다. 먼저 텍스트 분량이 너무 길거나 짧은 글에 대한 채점 편향이 두드러지게 나타났다. 또한 주장하는 글쓰기의 경우 관대한 편향이 더 자주 발생할 수 있음을 확인하였다. 채점자들은 사후 인터뷰에서 ‘긍정적인 생각이 삶에 미치는 영향’이라는 주제가 다소 추상적이기 때문에 난이도가 높다고 밝혔는데, 이는 Weigle(2002)의 연구에서 나타난 난이도가 높은 과제에 대한 채점자의 무의식적 보상을 한다는 연구 결과와 유사하다. 최혜민(2011)에서는 텍스트 유형에 따라 채점 기준을 다르게 마련할 필요성을 제기하였는데, 이는 텍스트의 장르적 특징

에 따라 글을 쓰는 목적과 내용 및 형식 등에 차이가 있기 때문이라고 밝히고 있다. 따라서 이런 채점자 편향을 방지 혹은 최소화하기 위해서는 채점자들로 하여금 분량에 의한 인상적 채점 및 보상적 편향에 대한 인지 증진과 함께 특히 난이도가 높은 주장하는 글쓰기와 같은 유형의 채점에 대한 독립적 채점 기준 마련이 필요하다고 할 수 있다.

둘째, 이러한 인지적 편향 발생에 대한 심도 있는 논의를 위해 L2 한국어 채점자의 주장하는 글쓰기 평가에서의 인지 처리 과정을 선행 연구에서 제시한 인지 처리 과정을 바탕으로 ‘텍스트 이미지 형성하기-해석하기-평가적 읽기-점수 결정하기’의 네 가지 단계로 구분하여 분석한 결과는 다음과 같다. 먼저, ‘텍스트 이미지 형성하기’ 단계에서는 주장하는 글의 채점과 관련된 다양한 정보를 담아 이상적인 텍스트 이미지를 형성하는 심상의 작업이 진행되었다. 경험이 풍부한 채점자들은 채점과 관련된 내면화된 정보를 바탕으로 글의 형식과 내용, 문체, 글의 수준까지 다양한 정보가 담긴 심상의 텍스트 이미지와 실제 채점하는 텍스트를 비교하면서 종합적인 채점이 가능했지만, 경험이 부족한 채점자들은 텍스트 이미지에 담긴 정보가 적기 때문에 채점 과정을 반복하거나 부분적이고 소극적인 채점 경향을 보였다. Lumley(2005)에서는 채점 초기에 형성된 직관적 이미지가 채점 전반에 영향을 미친다고 보고하였으며, 장미(2020)에서는 이 과정을 자기 강화 전략으로 설명하고 채점의 일관성 유지와 자동적 인지 처리에 도움을 준다고 밝히고 있다. 이를 통해 채점자의 보상적 편향이나 후광 효과는 텍스트 이미지를 형성하는 첫 단계에서부터 발생할 가능성이 큼을 알 수 있었다.

‘해석하기’ 단계에서는 오류 찾기, 주제 찾기, 요약하기 등의 행동이 관찰되었다. 특히 경험이 많은 채점자들은 텍스트의 맥락과 의미를 풍부하게 해석하려는 경향이 있었으나, 경험이 부족한 채점자들은 어휘와 문법의 오류와 같은 텍스트의 외적 요인에 집중하고 충분히 수험자의 텍스트를 이해하려는 인지적 노력이 부족하였다. 또한 지나친 오류 수정으로 인해 수험자 텍스트의 수준을 파악하기 어렵게 만들기도 하였다.

Cumming(1990)에서도 숙련된 채점자들과 초보 채점자 사이에는 수험자의 텍스트를 이해하거나 판단하는 전략에 차이가 있음을 밝히고 있다. 이런 인지 처리 과정의 차이는 수험자 텍스트의 세부 특징을 잘못 판단하게 하거나 특정 채점 기준 편향의 주요 원인이 될 수 있음을 확인할 수 있었다. 또한 원어민과 비원어민의 ‘해석하기’의 인지적 처리 양상에 차이가 있음을 확인하였다. 이는 향후 채점자 훈련에 있어 채점자의 모어와 같은 배경 요인을 고려할 필요가 있음을 시사한다.

‘평가적 읽기’ 단계에서는 점수를 부여하기 전에 텍스트와 채점 기준을 비교하면서 채점의 근거를 찾기 위한 다양한 정보 처리 행동이 관찰되었다. 이때 경험이 적은 채점자들은 상향식 접근방식을 통해 채점 근거를 확인하였으며, Wolfe(2005)의 연구 결과와 일부 다른 점은 경험이 풍부한 채점자들은 상향식, 하향식 접근방식을 모두 사용하여 전반적인 글의 인상과 세부 채점 요소들을 종합하는 과정을 거치는 것으로 나타났다. 이는 채점 기준 편향 결과와 연관하여 봤을 때 경험이 많은 채점자들의 부적합 편향을 방지할 수 있는 주요 정보 처리 행동임을 확인할 수 있었다.

‘점수 결정하기’ 단계는 텍스트의 수준을 변별하여 최종 의사결정을 내리는 단계로 다른 텍스트와 비교하기, 가점/감점 요인 확인하기, 점수 점검하기 등의 정보 처리 행동이 관찰되었다. 이와 같은 채점 단계는 선형적으로 나타나는 절차가 아니라 모두 순환되는 구조이며, 최종 점수를 결정하기 전까지는 앞의 단계로 계속 회귀될 수 있는 특징을 가지고 있었다. 하지만 경험이 부족한 채점자들 사이에서는 결정된 채점 결과에 의문을 가지고 이상적인 텍스트 이미지를 기준으로 비교하는 채점 과정이 아닌 채점 자료 간의 비교를 통해 점수를 조정하고, 이전의 정보 처리 단계로 채점 회귀가 반복적으로 나타나는 특징이 있었다. 이인혜(2014)에서는 평가에 대한 자기 효능감이 떨어지는 채점자들 사이에서 중앙집중화 편향과 과적합 경향이 나타날 수 있음을 확인한 바 있다. 즉, 이와 같은 인지적 처리 과정에 나타나는 잘못된 정보 처리 행동이 채점 편향의 원인으로 사료할 수 있다.

상기 내용을 토대로 내린 본 연구의 결론은 다음과 같다. 먼저 채점자들의 인지 처리 방식에 근거하여 표준화된 채점 절차를 마련하고 채점 단계별 전략 훈련을 고려할 필요가 있다. 이때 경험 수준이나 채점자 배경 요인에 따른 맞춤형 피드백을 제공하는 것이 효과적일 수 있다. 또한 채점자 훈련 과정에서 채점 기준의 명확한 이해와 상향식, 하향식 접근 방식의 내면화를 강조할 필요가 있다. 이를 통해 채점자들이 주관적 편향을 줄이고 공정한 평가를 수행할 수 있도록 정기적인 채점 평가와 상호 피드백을 제공하는 것이 바람직하다. 마지막으로 채점 결과에 영향을 미치는 텍스트의 특징이나 텍스트 난이도, 분량, 채점 순서와 같은 채점 환경 요인에 의해 채점 결과가 편향되지 않도록 주지시키고, 텍스트 유형에 따른 채점 가이드라인에 대한 재검토와 보완이 필요하다.

본 연구의 제한점 및 그에 따른 후속 연구에 대한 제언은 다음과 같다. 본 연구는 L2 한국어 주장하는 글쓰기 평가에서 채점자의 인지적 편향과 처리 과정을 분석하였으나, 몇 가지 한계가 있다. 첫째, 채점자 표본이 10명으로 제한되어 일반화의 한계가 있다. 둘째, 주장하는 글쓰기라는 특정 텍스트 유형에만 초점을 맞추고 있어 향후 다른 장르의 연구가 보완될 필요가 있다. 셋째, 사고 구술 자료 수집 과정이 실제 채점 환경과 차이가 있어 자연스러운 채점 행동이 완전히 반영되지 않았을 가능성이 있다. 그럼에도 불구하고 본 연구는 지금까지 잘 주목하지 않았던 실제적인 채점자의 인지 처리 과정을 탐색함으로써 채점 편향의 원인을 다각도로 모색해 볼 수 있었다. 이를 통해 채점 경험이 신뢰도를 보장하지 않음을 확인하였으며 주장하는 글쓰기 채점에서 채점자가 주목하는 텍스트의 특징을 규명하고 이에 따른 채점 기준의 명확화와 단계적 인지 전략 훈련의 구체적 방안을 제안하였다는 점에 의의가 있다고 할 수 있다. 향후 연구에서는 다양한 과제 유형과 채점자의 배경을 고려한 추가적인 편향 요인을 탐색하고, 이를 보완할 교육적 방안을 제시하는 연구가 진행되어야 할 필요가 있다고 사료한다.

참고문헌

- 강민석(2015), 「다국면 라쉬 모형을 통한 한국어 쓰기 평가에서의 채점 경향 연구」, 고려대학교 석사학위논문.
- 김동수(2014), 「사고구술법을 통한 한국어 쓰기 평가자의 숙련도별 평가 과정 연구」, 고려대학교 석사학위논문.
- 김수현(2019), 「한국어 학습자의 쓰기 수행 평가에 대한 신뢰도 연구」, 경희대학교 석사학위논문.
- 김승주(2021), 「교실 단위 작문 평가에서 활용 가능한 작문 자동 채점 프로그램의 설계 방안에 대한 연구 -인공지능적 설계 접근과 채점자의 인지 부하 요인을 고려하여-」, 『청람어문교육』 83, 청람어문교육학회, 157~203쪽.
- 김정숙·최은규·김유정(2005), 「한국어 능력 시험의 개선 방안 연구(Ⅱ) -평가 문항 유형을 중심으로-」, 『한국어 교육』 16(2), 국제한국어교육학회, 91~108쪽.
- 김해미(2020), 「장르 특성을 활용한 주장하는 글쓰기 교육 연구」, 『어문론집』 81, 중앙어문학회, 335~374쪽.
- 남미정·원미진(2022), 「한국어 쓰기 자동 채점을 위한 언어 자질 탐색 연구」, 『언어사실과 관점』 57, 연세대학교 언어정보연구원, 9~32쪽.
- 박종임(2014), 「작문 채점에서의 인지적 과정 모형에 대한 이론적 고찰」, 『청람어문교육』 52, 청람어문교육학회, 57~85쪽.
- 박지수(2021), 「한국어 쓰기 평가의 채점자 요인 연구」, 서울대학교 석사학위논문.
- 백유진·박영민(2021), 「글 유형에 따른 예비국어교사의 평가 특성 분석」, 『교원교육』, 37(2), 한국교원대학교 교육연구원, 163~183쪽.
- 서유남(2003), 「한국어능력시험 쓰기 평가 개선방안 연구」, 경희대학교 석사학위논문.
- 신동일(2001), 「채점 경향 분석을 위한 Rasch 측정모형 적용 연구」, 『외국어교육』 8(1), 한국외국어교육학회, 249~272쪽.
- 오세영(2018), 「대학생 필자의 학문적 글쓰기 과정에 나타난 장르 인식과 글쓰기 변형의 상관 분석 연구」, 『우리말글』 76, 우리말글학회, 61~107쪽.
- 윤나영(2023), 「한국어 쓰기 평가에서의 채점 편향 분석 연구 -논설문에서의 찬반 입장을 중심으로-」, 『언어와 문화』 19(3), 한국언어문화교육학회, 225~253쪽.
- 이인혜(2014), 「한국어 교사의 쓰기 평가 효능감과 평가 특성 연구」, 『이중언어학』 56, 이중언어학회, 231~266쪽.
- 이해영(2004), 「국어 시험의 현황과 개선 방안: 한국어능력시험의 현황과 개선 방안」, 『국어교육학연구』 20, 국어교육학회, 197~235쪽.

- 장미(2020), 「논설문 채점 진행에 따른 국어교사의 채점 전략 변화 분석」, 한국교원대학교 박사학위논문.
- 장소영·신동일(2009), 『언어교육평가 연구를 위한 FACETS 프로그램』, 글로벌콘텐츠.
- 최혜민(2011), 「텍스트 종류에 따른 한국어 쓰기의 내용 평가 기준 연구 -설명문, 논설문, 감상문을 중심으로-」, 『한성어문학』 30, 한성대학교 한성어문학회, 218~252쪽.
- Atkinson, R. C. & Shiffrin, R. M.(1968), Human memory: A proposed system and its control processes, *Psychology of Learning and Motivation* 2, 89-195.
- Bachman, L. F. & Palmer, A. S.(2010), *Language assessment in practice* (2nd ed.), Oxford: Oxford University Press.
- Crisp, V.(2012), An investigation of rater cognition in the assessment of projects, *Educational Measurement: Issues and Practice* 31(3), 10-20.
- Cumming, A.(1990), Expertise in evaluating second language compositions, *Language Testing* 7(1), 31-51.
- Eckes, T.(2012), Operational rater types in writing assessment: Linking rater cognition to rater behavior, *Language Assessment Quarterly* 9(3), 270-292.
- Freedman, S. W. & Calfee, R. C.(1983), Holistic assessment of writing: Experimental design and cognitive theory, In P. Mosenthal, L. Tamor and S. A. Walmsley (Eds.), *Research on writing: Principles and methods* (pp. 75-98), Longman.
- Jia, W. & Zhang, P.(2023), Rater cognitive processes in integrated writing tasks: From the perspective of problem-solving, *Language Testing in Asia* 13(1), 50.
- Kondo-Brown, K.(2002), A FACETS analysis of rater bias in measuring Japanese second language writing performance, *Language Testing* 19(1), 3-31.
- Linacre, J. M.(1989), *Many-facet Rasch measurement*, Chicago: MESA Press.
- Lumley, T. & McNamara, T. F.(1995), Rater characteristics and rater bias: Implications for training, *Language testing* 12(1), 54-71.
- Lumley, T. (2005). *Assessing second language writing: The rater's perspective* (Vol. 3). P. Lang.

- McNamara, T.(1996), *Measuring second language performance*, London: Longman.
- Milanovic, M., Saville, N., & Shuhong, S.(1996), A study of the decision-making behaviour of composition markers, In M. Milanovic and N. Saville (Eds.), *Performance testing, cognition and assessment: Selected papers from the 15th Language Testing Research Colloquium* (pp. 92-114), Cambridge University Press.
- Sakya, A. A.(2000), Validation of holistic scoring for ESL writing assessment: How raters evaluate composition, In A. J. Kunnan (Ed.), *Fairness and validation in language assessment: Selected papers from the 19th Language Testing Research Colloquium* (pp. 129-152), Cambridge University Press.
- Weigle, S. C.(2002), *Assessing writing*, Cambridge: Cambridge University Press.
- Wolfe, E. W.(2005), Uncovering Rater's cognitive processing and focus using think-aloud protocols. *Journal of Writing Assessment* 2(1), 37-56.
- Wright, B. D. & Linacre, J. M.(1994), *The Rasch model as a foundation for the Lexile framework* (Unpublished manuscript).

□ 김춘영

- ✿ 소 속: 경희대학교 외국어대학 국제한국언어문화학과
- ✿ 주 소: [17104] 경기 용인시 기흥구 덕영대로 1732, 외국어대학관
- ✿ 전자우편: kiroro04@khu.ac.kr

- ◎ 논문접수: 2024년 11월 23일
- ◎ 논문심사: 2024년 12월 17일
- ◎ 게재결정: 2024년 12월 19일

<Abstract>

An Examination of Bias and Cognitive Processing in L2 Korean Writing Raters – Focusing on Argumentative Writing –

Kim, Chun-young
(Kyung Hee University)

This study aims to analyze the biases and cognitive processing of raters in evaluating argumentative writing in L2 Korean writing and to discuss strategies for enhancing the validity and consistency of scoring. To achieve this, 10 raters of L2 Korean writing performed a fully crossed evaluation of argumentative essays written by 15 Korean language learners. The results were analyzed using the FACETS program based on the Rasch model, and the raters' think-aloud protocols during the scoring process were transcribed and analyzed, focusing on their cognitive processing stages and specific actions.

The main findings of the study are as follows:

First, an analysis of rater bias in evaluating argumentative writing revealed that stabilization strategies and bias patterns varied depending on the raters' teaching experience and scoring background. Additionally, factors such as the difficulty level of the text and the completeness of the task were identified as key contributors to scoring bias.

Second, an analysis of the cognitive processing stages of raters in evaluating argumentative writing identified differences in the cognitive processing patterns and sub-level information processing behaviors between raters with high validity in scoring and those with lower validity. The cognitive processing stages were categorized into four phases: forming a text image, interpreting, evaluative reading, and making a scoring decision.

This study provides insights into the underlying causes of scoring biases and proposes strategies for improving the validity of rater evaluations in L2 Korean argumentative writing.

Keywords: L2 Korean Argumentative Writing Assessment, Rater Cognitive Bias, Information Processing, Many-Facet Rasch Model, Scoring Validity and Consistency