

Analysis of Text Factors Influencing Korean Writing Assessment

Chun Young Kim
Kyung Hee University

This study examines the factors influencing Korean writing assessment by analyzing the correlation between text type, text length, text proficiency level, and scoring bias using a FACETS analysis based on the Many-Facet Rasch Model (MFRM). The findings are as follows: First, rater severity varied according to text type. Additionally, specific scoring criteria garnered more attention from raters depending on the text type. However, raters encountered challenges in consistently applying multiple scoring constructs, particularly for argumentative and narrative texts. Second, argumentative and expository texts exhibited a greater dispersion in scoring tendencies among raters, while narrative texts displayed relatively less scoring bias. Moreover, an analysis of texts with a high frequency of scoring bias within each text type revealed that key scoring criteria or contrasting characteristics considered important for each text type could significantly contribute to scoring bias. Finally, although scoring bias was more prominent in longer texts overall, this effect was especially noticeable in argumentative texts, where longer submissions tended to receive a lenient compensatory bias. The frequency of scoring bias also varied by text proficiency level, with different ranges of bias occurring depending on the text type.

Keywords Korean Writing Assessment, Scoring Bias, Many-Facet Rasch Model (MFRM), Text Type, Text Length, Text Proficiency Level/한국어 쓰기 평가, 채점 편향, 다국면 라쉬 모형, 텍스트 유형, 텍스트 분량, 텍스트 수준

한국어 쓰기 채점에 영향을 미치는 텍스트 요인 분석

김춘영(경희대학교)

I. 서론

현대의 언어 평가는 기존의 규범적이고 획일적인 접근에서 벗어나, 실제 언어 사용 맥락을 반영한 과제를 통해 학습자의 수행 능력을 관찰하는 방향으로 발전하고 있다. 특히 이러한 과제 수행 중심 평가는 쓰기와 말하기 교육에서 중요한 평가 방식으로 자리 잡으며, 학습자의 실질적인 의사소통 능력을 평가하는 데 중점을 두고 있다.

L2 한국어 쓰기 평가도 이러한 현대 언어 평가의 흐름을 반영하여 학습자의 실제적이고 유의미한 쓰기 능력을 평가하는 방향으로 나아가고 있다. 단순히 문법적 정확성이나 어휘 사용에만 초점을 맞추기보다는, 학습자가 특정 글 쓰기 맥락에서 효과적으로 생각을 조직하고 내용을 표현하는지를 중점적으로 평가한다. 이런 직접 평가 방식은 학습자의 언어 능력을 보다 세심하게 측정하고 다양한 교육적 피드백을 제공한다는 점에서 매우 유용한 평가 방식이지만 채점 과정에서 필연적으로 교사의 주관적 판단이 개입한다는 점에서 다양한 논의가 제기되고 있다.

쓰기 채점의 주요 영향 요인으로 주목하고 있는 것은 채점자 요인, 채점 기준이나 채점 방식, 텍스트 요인 등으로 구분할 수 있다. 채점자 요인으로는 채점자의 원어민 여부, 채점 경험, 교육 경력, 채점 신념과 같은 세부 요인이 채점 결과의 차이를 유발하는지에 대한 연구를 진행해 왔다(강민석, 2014; 정지윤, 2017; 강은혜, 김은실, 2021; 박지수, 2021). 이와 같은 연구는 채점자 훈련의 중요성을 강조하고 채점자 요인에 따라 채점자 훈련의 내용을 달리할 필요성을 제기하였다. 채점 기준이나 채점 방식에 따른 채점 영향 요인 분석 연구는 총체적 채점과 분석적 채점과 같은 주요 채점 방식이 채점 신뢰도에 어떤 영향을 미치는지에 주목하였다(이인혜, 2012; 김수현, 김영주, 2018). 또한 채점 기준의 명확성이 채점 신뢰도에 영향을 미치는 주요 요인임을 피력한 연구도 활발히 이루어졌다(이지연, 2007; 이인혜, 2014; 김정숙, 안수현, 2017). 이와 함께 쓰기 채점에서 주요하게 다루어야 하는 채점 영향 요인은 채점의 실제적인 대상이 되는 텍스트라고 할 수 있다. 학습자가 생성하는 다양한 텍스트에는 학습자 개별의 글쓰기 특성과 더불어 과제가 요구하는 장르적, 수사적 특성 등이 포함되어 있다. 정형적인 글쓰기 흐름을 보이는 텍스트가 있는가 하면 전혀 예측하지 못한 특징을 가진 텍스트도 있다. 또한 모어가 아닌

목표어로 작성된 텍스트는 오류를 포함하고 있다는 특징도 있다. 따라서 이런 텍스트를 독자의 입장에서 해석하는 채점자들은 텍스트에 나타나는 특징에 따라 더욱 복잡한 판단 과정을 거치기도 한다. 이와 같은 이독성(readability)의 문제는 채점 결과에 강한 영향력을 발휘할 수밖에 없다(Wolfe et al., 2016). 따라서 채점의 타당도를 높이기 위해서는 채점자 간에 분산적 특성이 나타나는 텍스트의 특징에 주목할 필요가 있다. 하지만 한국어 평가 연구에서 채점자가 텍스트에서 주목하는 요소가 무엇인지 텍스트 유형 간에 나타나는 채점자들의 차이는 무엇인지에 대한 구체적인 분석이 부족하며, 이를 다룬 실증연구도 제한적이다. 최근에는 텍스트의 특징을 자동으로 추출하여 채점 결과를 산출하는 자동채점 연구가 활발해지고 있지만, 채점 결과를 신뢰하기 위해서는 먼저 인간 채점자들이 텍스트에서 주목하는 요인이 무엇인지 밝혀져야 AI 자동채점의 결과와 비교 분석이 가능할 것이다.

따라서 본고에서는 한국어 쓰기 교육 과정에서 자주 다루어지는 주장하는 글, 설명하는 글, 서사적인 글 세 가지 텍스트 유형과 텍스트의 개별적 특징인 분량과 수준을 분석하여 한국어 쓰기 채점에 영향을 미치는 텍스트 요인을 규명하고자 한다. 이를 통해 한국어 쓰기 평가에서 실제적인 채점자 훈련을 비롯하여 AI 자동채점 연구까지 연구 범위를 확장하기 위한 기초 연구로서 시사점을 제시하고자 한다.

- 1) 텍스트 유형(주장하는 글, 설명하는 글, 서사적인 글)은 쓰기 채점의 엄격성과 일관성에 어떤 영향을 미치는가?
- 2) 채점 편향이 나타나는 텍스트의 특징은 무엇인가?
- 3) 채점 편향에 영향을 미치는 텍스트의 분량과 수준은 어떠한가?

II. 이론적 배경

1. 채점 편향

쓰기 평가에서 채점의 일관성은 평가의 타당성과 신뢰성을 확보하는 핵심 요소이다. 채점 일관성은 채점자가 텍스트의 수준을 적절히 변별하며 일관된 엄격성을 유지하는지에 따라 판단된다. 만약 채점자가 텍스트의 수준을 제대로 변별하지 못하고 유사한 점수를 반복적으로 부여한다면 이는 ‘과적합’으로, 수준이 낮은 글에 과하게 높은 점수를 부여하여 수험자의 능력을 잘못 추정하면 ‘부적합’으로 판별될 수 있다. 채점 일관성을 연구하는 것은 평가 결과의 신뢰도를 높이고, 채점자가 평가 기준을 얼마나 안정적으로 적용하는지를 점검하는 데 중요한 역할을 한다. 또한, 채점자의 훈련 및 피드백 과정에서 일관

성을 유지하도록 지도하는 데 유용한 근거를 제공하며, 평가의 공정성을 높이는 데 기여할 수 있다. 그러나 채점 일관성은 평균적인 채점 경향을 기준으로 분석되므로, 개별 텍스트나 채점 기준과의 관계를 충분히 설명하기 어렵다는 한계를 지닌다.

따라서 한국어 쓰기 채점에 영향을 미치는 요인을 더욱 세밀하게 분석하기 위해서는 채점자 간 혹은 채점자 개인의 반복적 채점 과정에서 나타나는 분산적 채점 경향에 주목할 필요가 있다. 이런 채점의 분산적 특성을 채점자 편향이라고 한다. 다시 말하면 채점자 편향은 특정 텍스트나 채점 기준에서 채점자가 기준 범위를 벗어나 극단적으로 관대하거나 엄격한 점수를 부여하는 현상을 의미한다(신동일, 장소영, 2009). 이는 평가의 신뢰성을 저해하는 주요 요인으로 작용할 수 있다. 선행연구에 따르면 채점 편향이 자주 발생할수록 채점자의 평가가 ‘부적합’으로 판정될 가능성이 높은 것으로 알려져 있다. 또한 채점 일관성이 ‘적합’한 채점자에게서도 편향이 나타날 수 있음이 보고되었다(박영민, 최숙기, 2011; 강민석, 2014). 따라서 본고에서는 이런 채점 편향 연구를 통해 채점자들이 특정 텍스트를 평가하는 과정에서 겪는 어려움을 이해하는 데 중요한 단서를 탐색해 보고, 채점 과정에서 평가 차이를 유발하는 텍스트 요인을 규명하는 데 연구 목적을 두고자 한다.

2. 쓰기 채점과 텍스트 요인

쓰기 평가에서 텍스트 요인은 채점자의 판단에 영향을 미치는 주요 변수로 작용하며, 채점 결과의 차이를 유발하는 요인으로 연구되어 왔다(Freedman & Calfee, 1983). 그러나 한국어 교육에서는 이에 대한 연구가 부족하며, 주로 국어 교육 및 해외 연구에서 관련 논의가 이루어져 왔다. 텍스트 요인은 크게 쓰기 평가 문항과 관련된 요인으로 쓰기 과제, 글의 목적, 글의 장르 등과 수험자가 작성한 답안의 개별 텍스트 특징에 해당하는 주제, 난이도, 길이, 구성, 손글씨 등으로 구분할 수 있으며, 이러한 요인은 채점자의 채점 편향에 영향을 미칠 수 있다(Weigle, 1999).

특히 텍스트 유형은 채점자의 평가 방식과 채점의 엄격성에 영향을 미칠 수 있다. 기존 연구에서는 개별 텍스트 유형에 대한 분석이 많았으나, 유형 간 채점 차이를 비교한 연구는 상대적으로 부족하다(백유진, 2021). 선행연구에 따르면 논설문과 설명문처럼 텍스트 유형이 다르면 채점자의 인식 차이로 인해 평가 편향이 발생할 가능성이 있다. 예를 들어, 국어 교사들은 논설문보다 설명문을 더 관대하게 평가하는 경향을 보이며, 조직 요소에서 점수 차이가 두드러진다는 연구 결과가 있다(박영민, 최숙기, 2010). 또한, 논설문과 서사문을 비교한 연구에서도 논설문이 더 엄격하게 평가되는 경향이 확인되었다(박종임, 2013). 이는 서사문이 보다 자유로운 형식을 띠기 때문에 채점자들이 명

확한 기준을 적용하는 데 어려움을 겪을 수 있음을 시사한다.

텍스트의 수준 또한 채점자의 평가 일관성에 영향을 미칠 수 있다. 기존 연구에서는 수준이 높은 과제에 대해 채점자가 무의식적으로 보상하는 경향이 있음을 보고한 바 있으며(Weigle, 2002), 난도가 높아질수록 채점자 간 일관성이 떨어지는 현상이 나타난다고 분석되었다. 이는 어려운 텍스트에 대한 채점자의 판단이 더 주관적일 가능성이 있음을 의미한다. 텍스트의 길이, 완성도, 어휘 수준 등도 채점의 어려움을 증가시키는 요인으로 작용할 수 있다. Weigle(1999)는 극단적으로 짧거나 긴 텍스트, 미완성된 텍스트가 채점자의 평가를 어렵게 만들 수 있다고 지적하였으며, 국내 연구에서도 텍스트 분량, 어휘의 다양성, 논증 구조가 평가의 곤란도를 높이는 요인임이 밝혀졌다(이슬기, 2019; 윤금준, 2021). 특히, 논설문의 경우 텍스트 수준이 극단적으로 낮거나 높을수록 채점 편향이 높아지는 경향이 확인되었다(백유진, 2020). 이러한 연구들은 채점자가 텍스트 특성에 따라 평가 기준을 일관되게 적용하지 못할 가능성이 있음을 시사한다.

이러한 채점 편향을 줄이기 위해서는 채점 기준의 조정과 채점자 간 협의 과정이 필요하다는 연구가 제안되었다(김지영, 2022). 특히, 텍스트 유형별로 다른 평가 기준을 마련하는 것이 필요하며, 채점자 간 합의를 통해 텍스트 해석의 차이를 줄이면 채점 일관성을 높일 수 있다는 점이 강조되고 있다(최혜민, 2011; 백유진, 2021; 윤나영, 2023).

한편, 최근 자동 채점 연구가 활성화되면서 텍스트 특성 분석이 더욱 중요해지고 있다. 기계 학습 기반 자동 채점에서는 인간 채점자와의 평가 결과 비교뿐만 아니라, 텍스트의 다양한 특성을 정량적으로 분석하는 과정이 필수적이다. 따라서 자동 채점을 위해서는 텍스트의 다양한 채점 요소를 밝혀내는 것이 중요한 연구 과제이다. Foltz et al.(2013)은 어휘 다양성, 구두점 사용, 문장 길이, 응결성 표지 등 42개 특성(feature)을 자동 채점의 주요 요인으로 제시하였다. 또한, Wolfe, Song & Jiao(2016)는 어휘의 다양성, 문장 길이 등 11가지 요인을 분석하여 채점이 어려운 텍스트의 특성을 규명하였다. 하지만 한국어 교육 분야에서는 아직 자동 채점에 적용할 수 있는 채점 자질에 대한 정보가 부족하다고 할 수 있다(남미정, 원미진, 2022).

최근에는 대규모 언어 모델(LLM, Large Language Model) 기반 자동 채점 기술이 발전하면서, 텍스트 특성 분석의 적용 범위도 더욱 확장되고 있다. 특히, ChatGPT와 같은 생성형 인공지능은 자동 채점 시스템의 보조 도구로 활용되면서 평가 과정에 미치는 영향을 연구하는 사례가 증가하고 있다(신동광 외, 2023). 하지만 이러한 AI 기반 자동 채점이 인간 채점자의 직관적 판단과 평가 기준을 완전히 대체할 수 있는지에 대한 논의도 이어지고 있다(김승주, 2021). 이러한 연구들은 쓰기 채점에서 텍스트 요인의 중요성을 부각하며, 향후 연구에서 이를 보다 체계적으로 분석할 필요성을 제기하고 있다.

III. 연구 방법

1. 연구 대상

1) 채점 자료

텍스트 요인이 쓰기 채점에 미치는 영향을 살펴보기 위해 경기도 소재 대학 부설 한국어 교육기관과 학부에서 한국어를 학습하고 있는 초·중급 수준의 한국어 학습자 50명의 쓰기 채점 자료를 수집하였다. 최종 수집된 채점 자료는 주장하는 글 15편, 설명하는 글 20편, 서사적인 글 15편으로 구성되었다. 구체적인 쓰기 과제 정보는 표 1과 같다.

표 1
쓰기 과제

텍스트 유형	주제	내용
주장하는 글	긍정적인 사고가 삶에 미치는 영향	1. 긍정적인 생각이 우리의 삶에 주는 영향은 무엇이라고 생각합니까? 2. 그렇게 생각하는 이유는 무엇입니까? 3. 250자 이상 쓰십시오.
설명하는 글	돈을 절약하는 방법	1. 생활비를 아끼는 방법에는 어떤 것이 있습니까? 2. 알뜰하게 쇼핑하는 방법에는 어떤 것이 있습니까? 3. 300자 이상 쓰십시오.
서사적인 글	기억에 남는 여행지	1. 여행지에서 무엇을 했습니까?(2가지 이상) 2. 그 여행지가 특별하게 기억에 남는 이유는 무엇입니까? 3. 300자 이상 쓰십시오.

채점자들에게 제공된 수험자 쓰기 자료는 글씨체로 인한 후광 효과를 통제하기 위해 워드 프로세서로 작성되었다(김인숙, 2015). 또한 수험자의 국적이 노출되지 않도록 이름 대신 텍스트 번호를 부여하였다. 또한 수험자가 작성한 글의 분량을 확인할 수 있도록 글자 수 정보를 제공하였다. 구체적인 채점 자료 정보는 다음 표 2와 같다.

표 2

채점 자료 정보

주장하는 글				설명하는 글				서사적인 글			
수험 자	글자 수	평균 점수	logit	수험 자	글자 수	평균 점수	logit	수험 자	글자 수	평균 점수	logit
S1	323	13	1.23	S1	371	13.1	0.47	S1	529	15.1	1.02
S2	195	9.5	-0.29	S2	333	10.7	-0.79	S2	370	13.4	0.14
S3	284	13.6	1.53	S3	259	11	-0.64	S3	275	11	-0.95
S4	315	14.4	1.95	S4	356	12.6	0.2	S4	667	15.2	1.08
S5	249	11.6	0.6	S5	279	9.4	-1.49	S5	349	15.9	1.54
S6	262	12.3	0.91	S6	291	13	0.41	S6	320	9.8	-1.5
S7	330	10.3	0.04	S7	350	14.7	1.39	S7	251	9.2	-1.79
S8	299	10.9	0.3	S8	670	14.7	1.39	S8	318	12	-0.5
S9	392	14.1	1.78	S9	368	13.2	0.52	S9	256	11.6	-0.68
S10	63	4	-3.47	S10	314	12.5	0.15	S10	295	13	-0.05
S11	277	8.4	-0.77	S11	225	8.2	-2.2	S11	265	9	-1.88
S12	289	10.7	0.21	S12	442	12.6	0.2	S12	245	13.8	0.33
S13	94	3.7	-3.9	S13	330	11.7	-0.27	S13	303	14	0.43
S14	393	11.8	0.69	S14	264	9.3	-1.55	S14	462	15.8	1.47
S15	165	8.3	-0.81	S15	388	12.1	-0.06	S15	311	15.6	1.33
				S16	456	12.4	0.09				
				S17	425	13.5	0.68				
				S18	492	15.7	2.1				
				S19	260	10.8	-0.74				
				S20	322	12.5	0.15				
평균	262	10.44		평균	359	12.19		평균	347	12.96	

2) 채점자

L2 한국어 수험자의 서사적인 글, 설명하는 글, 주장하는 글을 채점하는 과정에서 나타나는 채점 경향을 분석하기 위해 한국어 교원 10명을 연구 대상으로 선정하였다. 10명의 교원은 모두 한국어 평가론 과목을 이수하여 평가 원리와 채점 방식과 관련된 기본 지식을 잘 숙지하고 있었으며, 실제 쓰기 평가에 관심이 높은 채점자들로 모집하였다. 초중등 교육기관이나 대학 부설 어학당 및 학부, 다문화센터와 같은 정식 교육기관 소속이 아닌 채점자들은 봉사 기관이나 사설 기관에서 쓰기 교육과 평가를 담당할 경험에 있는 채점자들이었다. 채점자 훈련 경험에 있는 교원은 2명이었으며, 모두 세종학당재단에서 실시한 채점자 교육을 각각 2회씩 이수한 것으로 확인되었다. 구체적인 10명의 채점자 연구 대상에 관한 설명은 다음의 표 4와 같다.

표 3
채점자 정보

채점자	교육 경력(년)	교육 기관	*채점 경력 (1학기당 평균 횟수)	채점자 훈련	한국어 평가론 과목 이수 여부
R1	1년 미만	프리랜서	없음	무	유
R2	1년 미만	프리랜서	없음	무	유
R3	10년	어학당	30회	무	유
R4	2년	학원	없음	무	유
R5	5년	어학당, 대학(학부)	6회	유(2회)	유
R6	3년	어학당	2회	무	유
R7	8년	대학(학부)	5회	무	유
R8	1년 미만	프리랜서	없음	무	유
R9	9년	대학(학부)	5회	무	유
R10	10년	대학(학부)	2회	유(2회)	유

2. 검사 도구

수험자가 제출한 50편의 텍스트는 분석적 채점 방식으로 평가하였으며, 모든 채점자가 50편의 텍스트를 완전 교차 채점하도록 하였다. 분석적 채점 방식은 글의 내용, 조직, 표현과 같은 여러 요소를 독립적으로 평가하는 방식으로 전체적인 글의 인상을 바탕으로 채점하는 총괄적 채점 방식에 비해 수험자의 능력을 더 명확하게 변별할 수 있는 것으로 알려져 있다(김정숙, 2010; 김수현, 김영주, 2018). 분석적 채점을 위해 TOPIK II의 채점 기준인 ‘내용 및 과제 수행’, ‘글의 전개 구조’, ‘언어 사용’을 세 가지 평가 항목으로 설정하였다. 채점 척도는 6점 Likert식 척도로 결정하였다. TOPIK 홈페이지에서 확인할 수 있는 채점 척도는 54번 작문을 기준으로 항목별로 최대 13점 척도인데 이는 너무 광범위하여 채점자의 인지적 부담을 일으킬 수 있다. 또한 보통 홀수 척도는 중간 점수로 집중될 가능성이 있으며, 4점 척도는 구간이 넓어 세밀한 채점 변별이 어려울 수 있다. 이에 평가의 세부적인 차이를 명확히 구분하면서 채점자의 다양한 반응을 확인할 수 있도록 6점 척도로 수정하여 사용하였다. 구체적인 채점 기준은 표 3과 같다.

표 4
채점 기준표

평가 범주	세부 내용	채점 척도
내용 및 과제 수행	-주어진 과제를 충실히 수행하였는가? -주제와 관련된 내용으로 구성하였는가? -주어진 내용을 풍부하고 다양하게 표현하였는가?	6·5·4·3·2·1
글의 전개 구조	-시작과 마무리를 적절하게 구성하였는가? -내용 전개의 긴밀성이 있는가? -내용의 전환에 따라 문단을 적절히 구성하였는가? -문법과 어휘를 다양하고 풍부하게 사용하며 적절한 문 법과 어휘를 선택하여 사용하였는가?	6·5·4·3·2·1
언어 사용	-문법, 어휘, 맞춤법 등의 사용이 정확한가? -글의 목적과 기능에 따라 격식에 맞게 글을 썼는가?	6·5·4·3·2·1

3. 분석 방법

본 연구는 텍스트 유형, 텍스트 분량, 텍스트 수준이 한국어 쓰기 채점에서 채점자의 엄격성, 일관성, 채점 편향에 미치는 영향을 분석하는 것을 목적으로 한다. 이를 위해 다국면 Rasch 모형을 적용하는데, 이 모형은 채점자, 평가 기준, 과제 난이도 등 다양한 요인의 영향을 동시에 분석할 수 있는 확장된 개념의 Rasch 모형으로(Linacre, 1989), 채점자의 엄격성 및 관대함, 일관성, 특정 텍스트와 채점 기준에 대한 편향을 추정하기 가장 적합한 통계 모형이다. 본 연구의 분석에는 다국면 Rasch 모형을 기반으로 설계된 Facets 프로그램을 이용하여 분석을 진행하였다(신동일, 장소영, 2009). 먼저 수집된 데이터들이 다국면 Rasch 모형 분석에 적합한지 모형 적합도를 확인하였다.




그림 1
모형 적합도

모형 적합도 분석 결과 주장하는 글, 설명하는 글, 서사적인 글의 데이터 관찰치는 문항특성곡선의 95% 신뢰구간 안에 포함되는 것으로 나타나 다국면

Rasch 모형 분석에 적합함을 확인하였다.

텍스트 유형별로 채점 경향을 살피기 위해서는 채점자들이 부여한 점수를 logit 값으로 변환한 Measure 값으로 확인할 수 있다. 양수(+)로 나타나면 엄격한 채점, 음수(-)로 나타나면 관대한 채점으로 판단할 수 있다. 단, 채점자의 엄격성은 채점자 고유의 성향이기에 때문에 신뢰도를 판단하는 기준은 아니다. 채점자의 엄격성이 일관되게 유지되었는지가 채점의 신뢰도와 관련된다고 할 수 있다. 채점의 일관성은 표 5의 Wright & Linacre(1994) 에서 권장하는 적합도 범위를 참고하였다. 본 연구에서는 등급척도를 사용한 채점을 진행하였기 때문에 적합도 참고 범위를 0.6~1.4를 기준으로 하였다. 참고 범위 기준으로 0.6 미만의 경우에는 과적합으로 판단되는데, 이는 관찰된 값이 모형의 예측과 지나치게 일치하는 경우로 채점자들이 모든 텍스트에 대해 비슷한 점수를 주어 변별력 없는 채점 경향을 말한다. 참고 기준 1.4를 초과하는 경우는 부적합으로 판정되며, 이는 텍스트의 수준을 잘못 판단하여 높은 능력의 수험자에 대해서 낮은 점수를 주거나 낮은 능력의 수험자에게 높은 점수를 주는 경우를 말한다.

표 5
Wright & Linacre의 평가 유형에 따른 적합도 범위

평가의 유형	적합도 범위
교부담 다지선다형 평가	0.8~1.2
일반적인 다지선다형 평가	0.7~1.3
등급척도	0.6~1.4
임상적 관찰	0.5~1.7
합의가 권장되는 판정	0.4~1.2

채점 편향은 FACETS 결과 테이블 중 Bias/Interaction Reports와 t -값(± 2), p -값($p < 0.05$) 등을 통해 통계적으로 유의미한지를 판단하였다. Bias size는 Measure 값이 0에 가까울수록 편향이 나타나지 않았다고 해석할 수 있다. 양의 편향이 나타나면 관대한 채점 편향으로 판단하며, 음의 편향이 나타나면 엄격한 편향이 나타났다고 해석된다. 채점자와 텍스트의 편향이 전체 평균을 기준으로 t -값이 절대값 2를 넘어서는 경우에는 채점 편향이 통계적으로 유의미한 수준이므로 이를 통해 채점 타당도를 저해하는 원인을 모색할 수 있다. p -값은 이런 통계적 차이가 우연에 의한 것인지를 판단하는 기준이 될 수 있는데, 평가와 채점이 1회만 실시되고 해당 평가에서 수험자가 우연에 의해 유·불리한 채점을 받았을 경우에도 채점 타당도의 문제가 될 수 있다는 점에서 본고에서는 t -값을 기준으로 채점 편향의 특징을 살피고자 하였다. 또한 FACETS 프로

그림에서는 잔차값을 기준으로 unexpected response 혹은 이상치(outlier) 결과 table을 통해 비신뢰성 검증 정보를 제공하는데, 이를 통해서도 채점자의 편향을 확인할 수 있다. t -값이 채점자 전체의 평균을 기준으로 하는 반면, 잔차값 정보는 개인 채점자의 엄격성 평균을 기준으로 하여 제공되는 정보이다. 잔차값은 표준화한 값이 절대값 2를 초과한 경우 통계적으로 유의미하다고 판단할 수 있다.

텍스트의 분량과 수준이 채점 결과에 미치는 결과를 분석하기 위해서 텍스트의 분량과 텍스트의 수준을 구분하는 작업을 하였다. 먼저 텍스트의 분량은 과제가 요구하는 글자 수를 기준으로 하여, 5개의 구간(140%이상, 120~140%, 100~120%, 80~100%, 80% 이하)으로 텍스트를 구분하였다. 텍스트의 내적 특징인 개별 수준은 평균 점수보다 FACETS에서 제공하는 measure값이 보다 정확한 측정치이므로 이 logit 값을 기준으로 4개(1.0 이상, 1.0~0.0, 0.0~-1.0, -1.0 이하)의 수준으로 구분하였다. 채점자와 텍스트 간에 나타나는 채점 편향 결과를 참고하여 텍스트 분량과 텍스트의 수준에 따라 채점 편향이 나타난 빈도 분석을 통해 채점과의 상관관계를 확인하였다.

IV. 분석 결과

1. 텍스트 유형별 엄격성과 일관성

1) 채점자의 엄격성과 일관성

텍스트 유형별 채점자의 엄격성과 일관성을 살펴본 결과, 주장하는 글이 가장 엄격한 채점 경향을 보였다. 설명하는 글과 서사적인 글은 전체적으로 관대한 채점 경향이 강했다. 채점자 간의 채점 편차가 가장 큰 텍스트 유형은 설명하는 글로 카이제곱 값(χ^2)이 413.3으로 데이터 변동성이 가장 컸던 것으로 나타났다. 이는 설명하는 글에서 R7만이 극단적인 엄격성을 보였기 때문인 것으로 해석된다. 채점자 간 편차는 세 유형 중 서사적인 글이 가장 적었다. 다만 채점자별 채점 일관성을 살펴보면 주장하는 글과 서사적인 글에서 10명의 채점자 중 4명의 채점자가 과적합과 부적합이 보고되어 쓰기 채점 과정에서 일관성을 유지하기 어려웠던 것으로 나타났다.




그림 2
텍스트 유형별 채점자의 엄격성 변화

표 6
채점자별 엄격성과 일관성 분석 결과

채점자	주장하는 글			설명하는 글			서사적인 글		
	엄격성 지수	내적합 지수	외적합 지수	엄격성 지수	내적합 지수	외적합 지수	엄격성 지수	내적합 지수	외적합 지수
R1	-1.11	*.59	*.59	-.67	.61	.60	-.36	1.04	1.01
R2	.11	.95	1.09	-.52	1.11	1.08	-1.23	.73	.80
R3	-.34	.71	.76	-1.91	1.12	1.19	-1.20	*1.72	*1.58
R4	-.65	.97	.92	-1.91	.92	.90	-1.37	.72	.70
R5	.21	1.05	.96	-1.66	1.07	1.05	-1.30	*1.55	*1.44
R6	.11	1.17	*1.85	-2.28	1.19	1.18	-2.31	.87	.90
R7	2.31	.96	.87	1.39	*1.42	*1.44	-.45	1.26	1.27
R8	.68	.93	.82	-.57	*.55	*.55	-.74	*.59	*.58
R9	-.15	*.51	*.55	-2.46	1.08	1.09	-2.19	.87	.89
R10	.68	*1.78	*1.58	-.20	1.02	.99	-1.23	*.58	*.64
$\chi^2(9) = 207.6, p < .001, RS = .96$ $\chi^2(9) = 413.3, p < .001, RS = .98$ $\chi^2(9) = 100.8, p < .001, RS = .91$									

2) 채점 기준별 엄격성과 일관성

텍스트 유형에 따라 채점 기준의 엄격성이 다르게 적용되는지 확인한 결과, 전체적으로 모든 텍스트 유형에서 ‘언어 사용’ 기준이 가장 엄격하게 채점된 반면 ‘내용 및 과제 수행’ 기준은 상대적으로 관대하게 채점된 경향이 나타났다. 채점 기준별로 살펴보면, ‘언어 사용’ 기준은 서사적인 글(.88)에서 다른 두 유형에 비해 현저히 엄격하게 채점되었으며, 설명하는 글(.51), 주장하는 글(.36)의 순서로 엄격성이 나타났다. ‘글의 전개 구조’ 기준의 경우, 설명하는 글(.05)에서 가장 엄격하게 적용되었고, 주장하는 글(-.04), 서사적인 글(-.29)의 순서였다. ‘내용 및 과제 수행’ 기준은 모든 텍스트 유형에서 전반적으로 비슷

한 관대성을 보였으나, 상대적으로 주장하는 글(-.32)에서 덜 관대하게 채점되는 경향을 확인할 수 있었다.

특히, 채점자 간 변동성에 대한 통계 분석 결과 서사적인 글의 데이터 변동성이 $\chi^2(2)=119.2, p<.001, RS=.97$ 로 가장 크게 나타났다. 이는 서사적인 글에서 채점자들이 ‘언어 사용’ 기준(내적합 1.03, 외적합 1.00)을 유독 엄격하게 적용한 것이 주요 원인으로 판단된다. 이러한 결과는 채점자들 사이에 서사적인 글 유형에 대한 평가 기준의 이해와 적용 방식에서 상당한 차이가 존재함을 시사하며, 개별 채점자의 일관성에 대해서도 좀 더 면밀한 분석이 필요하다는 점을 보여준다. 또한, 주장하는 글의 변동성은 $\chi^2(2)=23.0, p<.001, RS=.87$ 이었고, 설명하는 글은 $\chi^2(2)=69.4, p<.001, RS=.96$ 로 나타났다. 세 유형 모두 통계적으로 유의미한 변동성을 보였으나, 서사적인 글이 특히 두드러졌다. 다만, 이 결과는 전체 엄격성 평균을 기준으로 추정된 것이므로 구체적인 채점 기준 정보를 확인하려면 개별 채점자의 채점 기준에 대한 엄격성과 일관성을 분석할 필요가 있다.

표 7
채점 기준별 엄격성과 일관성 분석 결과

	주장하는 글			설명하는 글			서사적인 글		
채점 기준	엄격성	내적합	외적합	엄격성	내적합	외적합	엄격성	내적합	외적합
언어 사용	.36	.75	.97	.51	.81	.82	.88	1.03	1.00
글의 전개 구조	-.04	.98	.92	.05	1.11	1.16	-.29	.83	.85
내용 및 과제	-.32	1.19	1.10	-.56	1.06	1.03	-.59	1.14	1.09
	$\chi^2(2) = 23.0, p < .001, RS = .87$			$\chi^2(2) = 69.4, p < .001, RS = .96$			$\chi^2(2) = 119.2, p < .001, RS = .97$		

표 8에서 표 10까지의 분석 결과에 따르면, 다수의 채점자들이 채점 기준별로 서로 다른 엄격성과 일관성을 나타내는 경향을 보였다. 특히 여러 채점자에게서 하나 이상의 채점 기준이 과적합 또는 부적합으로 나타나, 채점 기준 적용에 상당한 어려움이 있었음을 확인할 수 있다.

주장하는 글에서 R10은 전체 채점 결과에서는 적합 판정을 받았으나, 개별 채점 기준별 분석에서는 내용 및 과제 수행(performance) 기준에서 과도한 부적합(*infit MnSq 2.3, outfit MnSq 2.0*)을 나타냈다. 서사적인 글에서는 R3이 내용 및 과제 수행(performance) 기준에서 현저히 높은 부적합(*infit MnSq 2.4*)을 보였다. 반면 설명하는 글의 경우에도 일부 채점자들이 특정 채점 기준에서 상대적으로 더 엄격하거나 관대한 편차를 보이는 등 일관되지 않은 결과가 나

타났다.

이러한 결과는 채점자들이 세 가지 채점 기준을 고르게 적용하지 못하고 특정 채점 기준에만 집중하거나 의존하여 채점했을 가능성을 시사한다. 채점 기준별로 뚜렷하게 나타난 개별 채점자의 부적합 사례는 채점 기준에 대한 이해나 적용 방식이 채점자마다 상당히 상이했음을 보여준다.

표 8
주장하는 글의 채점 기준별 엄격성과 일관성

rater	factor	measure	infit MnSq	outfit MnSq
R1	language	-0.83	0.8	0.8
	writing	-1.41	0.4	0.4
	performance	-1.13	0.5	0.5
R2	language	-0.15	0.4	0.7
	writing	0.06	1.1	1.2
	performance	0.43	1.2	1.2
R3	language	-0.24	0.5	0.5
	writing	-0.24	0.8	0.8
	performance	-0.57	0.8	1
R4	language	-0.44	0.4	0.3
	writing	-0.75	1	1
	performance	-0.79	1.6	1.4
R5	language	0.23	0.6	0.6
	writing	0.25	1.2	1.1
	performance	0.14	1.3	1.2
R6	language	-0.73	1.3	1.8
	writing	0.34	1	1.1
	performance	0.72	0.6	0.6
R7	language	2.32	1.3	1.1
	writing	2.72	1	0.9
	performance	1.98	0.6	0.6
R8	language	1.1	0.4	0.4
	writing	0.63	0.8	0.7
	performance	0.34	1.4	1.2
R9	language	0.04	0.3	0.3
	writing	-0.44	0.4	0.5
	performance	-0.06	0.7	0.8
R10	language	0.61	1.3	1.2
	writing	0.72	1.7	1.5
	performance	0.72	2.3	2

표 9
설명하는 글의 채점 기준별 엄격성과 일관성

rater	factor	measure	infit MnSq	outfit MnSq
R1	language	-0.65	0.8	0.8
	writing	-0.72	0.6	0.6
	performance	-0.65	0.4	0.4
R2	language	-1.19	0.7	0.7
	writing	-0.18	1.4	1.4
	performance	-0.19	0.8	0.7
R3	language	-1.5	1.2	1.3
	writing	-2.22	1	1.3
	performance	-2.06	1	0.9
R4	language	-1.8	0.5	0.5
	writing	-1.97	0.6	0.6
	performance	-1.97	1.8	1.6
R5	language	-1.57	0.8	0.8
	writing	-1.89	1.3	1.3
	performance	-1.53	1	1
R6	language	-3.14	0.9	0.9
	writing	-1.81	1.1	1.1
	performance	-1.88	1.1	1.1
R7	language	1.8	0.8	0.7
	writing	2.15	1.6	1.8
	performance	0.51	1.1	1.1
R8	language	-0.49	0.3	0.3
	writing	-0.95	0.3	0.3
	performance	-0.26	0.8	0.8
R9	language	-2.19	0.7	0.7
	writing	-2.77	1.8	1.8
	performance	-2.47	0.7	0.7
R10	language	0	0.5	0.5
	writing	-0.26	1.3	1.2
	performance	-0.34	1.2	1.2

표 10
서사적인 글의 채점 기준별 엄격성과 일관성

rater	factor	measure	infit MnSq	outfit MnSq
R1	language	-0.21	1.6	1.4
	writing	-0.26	0.5	0.5
	performance	-0.62	1.1	1
R2	language	-1.61	0.7	0.6
	writing	-1.23	0.6	0.6
	performance	-0.82	0.6	0.8
R3	language	-0.11	0.6	0.6
	writing	-1.66	1.6	1.5
	performance	-2.11	2.4	1.6
R4	language	-1.8	0.6	0.6
	writing	-1.23	0.3	0.4
	performance	-1.03	0.9	0.9
R5	language	-1.61	1.7	1.7
	writing	-1.23	1.5	1.4
	performance	-1.03	1.2	1.1
R6	language	-2.71	0.8	0.8
	writing	-2.02	0.8	0.8
	performance	-2.11	0.8	0.8
R7	language	0.09	1.1	1
	writing	-0.07	0.9	0.9
	performance	-1.47	1	1
R8	language	-1.05	0.5	0.5
	writing	-0.93	0.3	0.3
	performance	-1.47	0.6	0.6
R9	language	-1.89	0.7	0.7
	writing	-2.71	0.9	1.1
	performance	-2.11	0.9	0.9
R10	language	-1.51	0.5	0.5
	writing	-1.23	0.7	0.8
	performance	-0.93	0.4	0.4

표 11은 텍스트 유형과 채점 기준별 일관성을 비교 분석한 결과를 제시한 것이다. 텍스트 유형별 일관성 문제 사례는 주장하는 글(12건), 설명하는 글(7

건), 서사적인 글(11건) 순서로 나타났으며, 특히 주장하는 글과 서사적인 글에서 채점자들이 기준을 일관되게 유지하는 데 어려움을 경험한 것으로 나타났다. 전체 30건의 과·부적합 사례 중 과적합이 19건(63%)으로 과반을 넘었으며, 이는 채점자들이 텍스트 간의 수준을 충분히 변별하지 않고 유사한 점수를 부여했음을 시사한다. 또한, 과·부적합 사례들은 대부분 채점 기준 적용 시 관대하게 평가하는 경향을 보여, 채점 판단이 명확하지 않고 점수를 부여하는 과정에서 모호성을 경험한 것으로 판단된다.

구체적으로 텍스트 유형별로 보면, 주장하는 글에서는 특히 ‘언어 사용’기준에서 6건(과적합 5건, 부적합 1건)으로 가장 많은 사례가 나타나, 채점자들이 언어적 요소 평가에서 상당히 어려움을 겪었음을 알 수 있다. 서사적인 글에서는 ‘글의 전개 구조’(5건)와 ‘언어 사용’(4건)기준 모두에서 문제가 두드러졌으며 상대적으로 설명하는 글에서는 일관성 문제가 적었으나, 여전히 언어 사용에서 일부 과적합 현상이 나타나 텍스트 수준의 변별에 어려움이 존재함을 보여준다.

표 11
텍스트 유형별 채점 기준 일관성 비교

채점 기준 텍스트 유형별 일관성	주장하는 글		설명하는 글		서사적인 글	
	과적합	부적합	과적합	부적합	과적합	부적합
language	5	1	3	0	2	2
writing	2	1	1	1	3	2
performance	1	2	1	1	1	1
소계(건)	8	4	5	2	6	5
총합(건)	12		7		11	

2. 채점 편향 분석 결과

1) 텍스트 유형별 채점 편향

전체 텍스트 유형별 채점자와 텍스트 간 상관관계 분석 결과에 따르면 주장하는 글과 설명하는 글에서 각각 17쌍의 채점 편향이 보고되었으며, 서사적인 글은 다른 두 유형의 텍스트보다는 적은 9쌍의 채점 편향이 보고되었다. 먼저 주장하는 글에 나타난 채점 편향을 구체적으로 살펴보면 전체 채점 편향 결과 중 모형이 기대한 예상치보다 지나치게 관대한 채점 경향이 12쌍으로 나타났다. 가장 많은 채점 편향이 나타난 텍스트는 S14번으로 채점자 간 분산적 특징이 두드러진 것으로 나타났다. 이 텍스트의 경우 가장 관대한 채점을 보인 채점자(R10)와 가장 엄격한 채점을 한 채점자(R6) 간 점수 차이는

7점으로 그 차이가 매우 컸다. S14의 텍스트에 대해 5명의 채점자에게서 채점 편향이 나타났으며 관대한 편향이 3명(R3, R4, R10), 엄격한 편향이 2명(R2, R6)이 보고되었다.

표 12
주장하는 글

rater	examinee	Observed Score	Expected Score	<i>t</i>	<i>Prob.</i>
5	12	16	10.65	3.09	0.0907
8	11	12	7.11	3.09	0.0909
7	5	11	6.55	2.9	0.101
10	1	17	11.98	2.73	0.1123
10	14	15	10.65	2.64	0.1185
10	2	12	8.21	2.36	0.1421
3	14	17	13.07	2.29	0.1488
6	10	6	3.88	2.21	0.1573
8	12	13	9.46	2.18	0.1608
10	8	13	9.68	2.06	0.1761
4	14	17	13.72	2.02	0.181
9	9	12	14.87	-2.1	0.1708
4	15	6	10.23	-2.51	0.129
2	14	8	12.03	-2.54	0.1266
6	14	8	12.03	-2.54	0.1266
10	12	3	9.46	-2.55	0.1256
3	4	12	15.47	-2.65	0.1178




그림 3
주장하는 글의 채점 편향 크기(bias size)

설명하는 글에서는 주장하는 글과 비슷한 결과가 보고되었는데 11쌍의 관대한 채점 편향과 6쌍의 엄격한 채점 편향이 나타나, 설명하는 글에서도 관대

한 채점 편향이 다소 많은 것으로 나타났다. 가장 채점 편향이 많이 나타난 텍스트는 S19의 텍스트였다. R4, R7, R10의 채점자에게서 채점 편향이 나타났으며, R7은 관대하게 R4, R10은 평균보다 엄격하게 채점한 것으로 보고되었다.

표 13
설명하는 글

rater	examinee	Observed Score	Expected Score	t	Prob.
10	6	16	11.24	2.97	0.0973
7	19	10	6.58	2.97	0.097
7	3	10	6.72	2.83	0.1057
3	2	16	12.27	2.39	0.1395
4	13	17	13.34	2.22	0.1562
1	20	15	11.66	2.22	0.1569
5	10	18	13.69	2.08	0.1732
5	4	17	13.79	2.02	0.1807
9	5	15	11.97	2.02	0.1806
6	2	10	13.04	-2.08	0.1736
5	11	6	8.99	-2.22	0.1563
10	19	6	8.99	-2.23	0.156
4	19	9	12.38	-2.27	0.1507
10	3	6	9.18	-2.34	0.1444
9	17	13	15.97	-2.4	0.1382
3	18	14	16.92	-2.82	0.106
7	12	4	7.9	-2.95	0.0982




그림 4
설명하는 글의 채점 편향 크기(bias size)

서사적인 글에서는 다른 두 유형의 채점과는 달리 엄격한 채점이 높은 비중을 차지하였다. 총 9쌍의 채점 편향 보고 중 관대한 채점은 R1과 R3 2건뿐

이였으며, 나머지 7건의 경우는 모두 엄격한 채점 경향을 보였다. 채점 편향이 많았던 S6의 텍스트에 대해서는 R1, R3, R5가 부여한 점수가 평균보다 다소 엄격하거나 관대하게 채점된 것으로 나타났다.

표 14
서사적인 글

rater	examinee	Observed Score	Expected Score	<i>t</i>	<i>Prob.</i>
1	6	11	7.97	2.18	0.1616
3	11	12	8.88	2.15	0.1644
5	3	8	11.12	-2.05	0.1766
1	15	11	14.12	-2.1	0.1701
7	11	4	7.42	-2.15	0.1645
5	7	6	9.29	-2.25	0.1528
10	5	13	16.01	-2.4	0.1384
5	6	6	9.89	-2.62	0.1197
3	6	5	9.67	-3.02	0.0942




그림 5
서사적인 글의 채점 편향 크기(bias size)

다음 그림 6은 각 텍스트 유형별로 채점 편향의 빈도가 가장 높게 나타난 텍스트의 실제 사례이다.

하루는 스스로 동년자를 동년다는 옛 말이 있다. 이 옛 말은 기차와 같이 매단한 것은 아니라 할 지라도 우리가 인생에서 스스로 이루어 내는 작은 성 공들은 그것을 할 수 있다는 자신의 신념에서 비롯 된 노력의 결과라고 한 다. 왜냐하면 인생에서 태어났을 때 조 물한 사람이 없다. 사실은 성공하기 위 해서 우리는 시시각각 최고 노력해야 한다. 예를들어 공부할 때 너무 힘들거 면 "우리 할 수 있다"는 생각하면 우리 성공할 수 있다. 우리의 삶에 공 정적인 생각이 자신감이 있어서 자신의 힘으로 성공할 수 있다. 일하거나 인관 하도 똑같다. 우리 긍정적인 생각하니까 면여 우리 성공할 수 있다. 인생에서 태어났을 때 성공한 사람 없다. 왜냐하 면 그 사람들을 긍정적인 생각하고 최 고 노력하기 때문이다. 그 사람들을 성 공하고 성복할 수 있다. (39 3 제)	지금 물건을 사는 방법이 있습니다. 그런데 물건을 싸게 사는 방법이 적습 니다. 그러므로 이 글을 싸게 사는 방법 이 소개합니다. 첫 번째는 음식을 싸게 사는 방법입 니다. 보통 시장에 가서 음식을 삽니다 시장에서 사는 것이 편이점에서 사는 것보다 더 싼니다. 그러므로 제가 시장 에 자주 갑니다. 두 번째는 옷이나 산발하고 다른 물 건을 싸게 사는 방법입니다. 제가 자주 인터넷으로 삽니다. 할인이 많고 쿠폰 때문에 자주 인터넷으로 삽니다. 마지막 돈이 많이 있으면 어디에서 사도 삽니다. (25 9 제)	저는 1년 전에 중국에서 여행했어요 한국 수업 끝나면 친구와 함께 같이 중국에 가요. 저는 중국 음식이 관심이 있습니 다. 그래서 친구와 같이 식당에 많이 많이 가요. 저는 백화 때문에 시간이 많아요. 그 래서 우기 많이 전수 가요. 중국 옷 정말 유명해요. 중국옷 그리고 중국 사 람들이 모도 좋아해요. 저는 중국 옷을 관심이 많습니 다. 그래서 우리 친구와 함께 같이 옷가게 가고 싶어요. 많이 옷을 사요. 중국 사람들이 많아요. 우리 식당에 사치들 많아요. 다음 한기 시간이 이시 면 우리 중국에 가고 싶어요. 저는 중 국 음식 좋아해요. 그리고 옷을 좋아해 요. 중국에 활동 정말 재미있어요. 하지 만 할들이요. (32 0 제)
--	---	--

<주장하는 글 S14>

<설명하는 글 S19>

<서사적인 글 S6>

그림 6
채점 편향 빈도가 높은 텍스트 실제 사례

2) 비신뢰성 검증 결과

FACETS 프로그램에서 산출된 이상치 정보를 통해 텍스트 유형별로 총 4건의 채점자의 비신뢰성 검증 결과를 확인하였다. 비신뢰성 검증 결과는 개별 채점에서 평균 엄격성과 비교했을 때 동떨어진 결과로 개별 채점자의 분산성을 확인할 수 있다. 자세한 분석 결과는 표 15와 같다.

주장하는 글에서는 S10, S13의 텍스트에 대해 채점자 R6가 언어 사용 기준에서 관대한 채점 편향이 나타났음을 보고하고 있다. S10과 S13은 텍스트의 분량이 과제 요구 기준보다 매우 부족한 특징을 보였다. R6의 경우 ‘언어 사용’ 기준에서 엄격한 채점 경향을 보였는데, 분량이 매우 부족한 글에 대해 오히려 관대한 채점을 한 것이 채점 일관성에 부정적인 영향을 미친 것으로 나타났다. 설명하는 글에서는 S18의 텍스트에서 채점자 R3가 글의 전개 구조에서 엄격한 채점 편향이 나타났다. S18의 텍스트는 텍스트의 분량이 많고, 수준이 가장 높은 텍스트 특징을 보였다. R3는 서사적인 글에서도 S6의 텍스트에 대해 내용 및 과제 수행에서 엄격한 채점 편향이 나타났는데, S6는 텍스트의 분량은 적정 수준이지만 텍스트 수준이 매우 낮은 것으로 나타났다. 즉 텍스트의 분량과 텍스트의 수준에서 극단적인 특징을 가진 텍스트에 대해 채점 편향이 나타난 것을 알 수 있었다.

표 15
비신뢰성 검증 정보

유형	채점자	텍스트	채점 기준	기대 점수 (Exp.)	관찰 점수 (Obs.)	잔차 (Resd)	표준화 잔차 (StRes)
주장하는 글	R6	S13	언어 사용	1.1	3	1.9	5.1
	R6	S10	언어 사용	1.2	3	1.8	4.1
설명하는 글	R3	S18	글의 전개 구조	5.6	4	-1.6	-3
서사적인 글	R3	S6	내용 및 과제 수행	3.6	1	-2.6	-3

그림 7은 개별 채점자의 비신뢰성 검증 결과를 바탕으로 이상이 발견된 텍스트의 실제 사례이다. 4편의 텍스트 S6은 채점자 간 편향도 가장 높은 빈도로 나타난 텍스트였다. 실제 사례는 그림 6에 제시하였다.

스스로 노력하면 성공할 수 있다는 가치가 있다. 우리가 인생에서 얼마나 힘든 것을 지나친다. 그때 의지가 더 있 진다. (63 자)	<주장하는 글 S10>
현재 사회가 전전 발전하고 있다. 그 래서 인간이 필요한다 인간은 사람들이 만아서 알고 사귀하다. 사회에는 인간이 중심해야 한다. 우리는 매일 노력 해야 하면 성공을 할 수 있다. (94 자)	<주장하는 글 S13>
사람들은 돈을 아끼기 위해서 다양한 방법이 있어요 예를 들면 돈을 낭비하 지 않으면 돈을 절약할 수 있어요. 발 에서 나갈 때마다 물을 끄는 것이 중 요 방법이에요 그리고 물도 아껴 쓰려 면 필요할 때만 물을 써야 해요. 그것 이 자연에 좋은 것 같아요. 또한 쇼핑을 하면 필요없는 물건을 사지 않아요. 저는 어떻게 돈을 아껴쓰 는지 책을 읽어 보니까 새로운 방법을 알아봤어요 물건을 사기 전에 잘 일 동안 열심히 생각한다는 사실을 알았어 요. 잘 일 후에 그것을 아직도 사고 싶으면 그것을 살 수 있어요 그리고 사용하지 않은 물건을 버리거나 팔 수 도 있어요. 저는 그 방법을 실천하도록 노력해요. 일주일마다 생활비를 열심히 확인하는 게 좋아요. 생활비는 많으면 그것을 줄 이면 돼요.	<설명하는 글 S18>

그림 7
채점 편향 빈도가 높은 텍스트 실제

3. 텍스트 요인과 채점 편향 분석 결과

1) 텍스트의 분량과 채점 편향

텍스트 분량이 채점에 미치는 영향을 확인하기 위해 텍스트 분량별로 채점 편향이 나타나는 빈도를 확인하였다. 표 16에 따르면 전체적인 채점 편향 빈도는 텍스트의 분량이 적정 기준보다 길게 작성된 텍스트에 대한 편향 비율이 높은 것으로 나타났다. 하지만 텍스트 유형별로 살펴보면 주장하는 글에서는 글자 수가 과제의 요구 기준을 초과한 경우 편향 빈도가 높게 나타났다. 특히 적정 분량 기준보다 40%이상 초과하여 작성된 텍스트에 대해 채점자 간 분산적 특성이 가장 강하게 나타났으며, 관대한 채점 편향 비율이 높았다. 설명하는 글에서는 텍스트의 분량이 많을 때와 적을 때 비율이 비슷한 수준으로 나타나 분량에 따른 채점 편향은 두드러지지 않았다. 서사적인 글에서도 글의 분량에 대한 채점 편향의 빈도가 큰 차이를 보이지 않았다.

표 16
텍스트 분량별 채점 편향 빈도

유형	분량	텍스트	편향 빈도	비율(%)	편향성(엄/관)
주장하는 글	140% 이상 (350자 이상)	S9, S14	6	35.2	관(3)/엄(3)
	120%~140% 미만 (300~349자)	S1, S4, S7	2	11.8	관(1)/엄(1)
	100%~120% 미만 (250~299자)	S3, S6, S8, S11, S12	5	29.4	관(4)/엄(1)
	80%~100% 미만 (200~249자)	S5	1	5.89	관(1)
	80% 미만 (200자 미만)	S2, S15, S10, S13	3	17.6	관(2)/엄(1)
설명하는 글	140% 이상 (420자 이상)	S8, S12, S16, S17, S18	3	17.6	엄(3)
	120%~140% 미만 (360~419자)	S1, S9, S15	0	0	0
	100%~120% 미만 (300~359자)	S2, S4, S7, S10, S13, S20	6	35.3	관(2)/엄(5)
	80%~100% 미만 (240~299자)	S3, S5, S6, S14, S19	7	41.2	관(4)/엄(3)
	80% 미만 (180자 미만)	S11	1	5.9	엄(1)

서사적인 글	140% 이상 (420자 이상)	S1, S4, S14	0	0	
	120%~140% 미만 (360~419자)	S2	0	0	
	100%~120% 미만 (300~359자)	S5, S6, S8, S13, S15	5	55.6	엄(4)/관(1)
	80%~100% 미만 (240~299자)	S3, S7, S9, S10, S11, S12	4	44.4	엄(3)/관(1)
	80% 미만 (180자 미만)		0	0	




그림 8
텍스트 분량별 채점 편향 비율

2) 텍스트의 수준과 채점 편향

텍스트의 수준과 채점 편향의 빈도를 분석한 결과는 표 15와 같다. 먼저 주장하는 글에서는 텍스트의 수준이 0.0~1.0 사이일 때 채점 편향이 가장 빈도 높게 나타났으며 관대한 편향이 엄격한 편향보다 많았다. 설명하는 글에서는 평균보다 약간 낮은 -1.0~0.0 사이의 수준일 때 채점 편향이 가장 많이 보고되었다. 편향성은 엄격한 편향과 관대한 편향이 동일하게 나타났다. 서사적인 글에서는 -1.0 이하의 수준이 낮은 글에 대해 채점자의 편향이 두드러졌으며, 다른 두 유형에 비해 엄격한 편향이 주요하게 나타난 것을 알 수 있었다.

표 17

텍스트 수준별 채점 편향 빈도

유형	범위(logit)	텍스트	편향 빈도	비율(%)	편향성(관/업)
주장하는 글	1.0 이상	S1, S3, S4, S9	3	17.6	관(1)/업(2)
	0.0~1.0 미만	S5, S6, S7, S8, S12, S14	10	58.2	관(7)/업(3)
	-1.0~0.0 미만	S2, S11, S15	3	17.6	관(2)/업(1)
	-1.0 미만	S10, S13	1	5.9	관(1)
설명하는 글	1.0 이상	S7, S8, S18	1	5.9	업(1)
	0.0~1.0 미만	S1, S4, S6, S9, S10, S12, S16, S17, S20	6	35.3	관(4)/업(2)
	-1.0~0.0 미만	S2, S3, S13, S15, S19	8	47.1	관(4)/업(4)
	-1.0 미만	S5, S11, S14	2	11.8	관(1)/업(1)
서사적인 글	1.0 이상	S1, S4, S5, S14, S15	2	22.2	업(2)
	0.0~1.0 미만	S2, S12, S13	0	0	없음
	-1.0~0.0 미만	S3, S8, S9, S10	1	11.1	업(1)
	-1.0 미만	S6, S7, S11	6	66.7	관(2)/업(4)




그림 9

텍스트 수준별 채점 편향 비율

V. 논의

본 연구는 채점 결과에 영향을 미치는 텍스트 요인을 분석하기 위해 텍스트 유형, 텍스트 분량, 텍스트 수준을 변인으로 설정하고 다국면 Rasch 모형을 활용한 FACETS 프로그램 분석을 통해 채점자의 엄격성과 일관성, 채점 편향 간의 관계를 살펴보았다. 구체적인 연구 질문과 그에 대한 논의는 다음과 같다.

1) 텍스트 유형(주장하는 글, 설명하는 글, 서사적인 글)은 쓰기 채점의 엄격성과 일관성에 어떤 영향을 미치는가?

텍스트 유형에 따라 채점자의 엄격성과 일관성에 어떤 영향을 미치는지 이유를 분석한 결과, 텍스트 유형별로 채점자가 중요하게 고려하는 채점 기준이 다르며, 이는 텍스트의 목적과 특성이 채점 기준 적용 방식에 영향을 미치는기 때문인 것으로 판단된다.

먼저, 주장하는 글에서는 ‘내용 및 과제 수행’이 다른 텍스트 유형보다 엄격하게 채점되었으며, 설명하는 글에서는 ‘글의 전개 구조’, 서사적인 글에서는 ‘언어 사용’이 엄격성이 높게 나타났다. 이러한 차이는 채점자가 각 텍스트 유형에서 필수적으로 갖춰야 할 능력을 변별할 수 있도록 채점 기준의 중요도를 조정한 결과로 해석된다. 예를 들어, 주장하는 글의 경우 논리적 전개와 타당한 근거 제시가 중요하기 때문에 채점자는 수험자가 논증적 사고를 충분히 반영했는지에 초점을 맞출 수 있다. 따라서 ‘언어 사용’이나 ‘글의 전개 구조’에서 다소 미흡한 부분이 있어도 주요 논거의 충실성에 따라 평가가 이루어질 가능성이 크다. 반면, 서사적인 글은 구조적 자유도가 높은 특성을 가지므로, 채점자는 문법적 정확성과 표현력을 차별적인 채점 기준으로 설정할 가능성이 높다. 설명하는 글의 경우는 정보 전달의 명확성이 핵심 요소이므로 논증보다는 전개 방식과 조직력에 초점을 두어 채점이 이루어질 수 있다.

채점 일관성의 차이는 주로 채점자의 인지적 부담과 과제의 난도와 관련이 깊다고 사료된다. 난도가 가장 높은 과제였던 주장하는 글뿐만 아니라 가장 쉬운 과제였던 서사적인 글에서 일관성이 낮게 나타난 것은 채점자가 전체 글의 인상과 여러 평가 요소를 균형 있게 고려하기 어렵기 때문으로 분석된다(Lumley, 2005). 특히 서사적인 글에 나타난 채점 변동성은 채점자가 복잡한 과제를 다룰 때와 마찬가지로 단순한 과제에서 다양한 요소를 고려해야 할 때 변별 요소를 명확히 하기 어렵기 때문인 것으로 추정된다. 채점자들이 과적합을 보이는 경우가 높은 비중을 차지한 것 또한 텍스트의 난도가 높거나 평가 기준 적용이 어려울 때 채점자들이 대체로 관대한 점수를 부여하는 경향을 반영하는 것으로 보인다(Weigle, 2002; 신동일, 장소영, 2009). 즉, 평가 기준이 명확하게 적용되기 어려운 경우 채점자는 보수적인 점수 부여보다 상대적으로 관대한 채점 방식을 취할 가능성이 높은 것으로 보인다. 이처럼 채점 기준을 단순화하는 과정을 통해 채점자들은 채점 과정의 인지적 부담을 경감시키려는 것으로 판단된다.

향후 쓰기 평가 연구 및 교육 현장에서는 이러한 분석 결과를 반영하여 텍스트 유형별 평가 기준의 명확성을 높이고, 채점자의 인지적 부담을 줄일 수 있는 채점 훈련 프로그램을 개발할 필요가 있다. 특히, 채점자 교육에서 각 과제 유형별 채점 기준과 적용 사례를 구체적으로 안내하여 채점 기준 적용의

일관성을 높이고, 채점자 간 협의를 통해 평가 기준의 공유와 표준화를 유도하는 방안이 요구된다(최혜민, 2011; 윤나영, 2023). 또한, 최근 발전하고 있는 인공지능 기반 자동 채점 기술을 보조적으로 활용하여 인간 채점자의 평가 과정에서 일관성을 확보하고 편차를 줄이는 방안도 검토할 필요가 있다.

2) 채점 편향이 나타나는 텍스트의 특징은 무엇인가?

채점 편향이 나타난 글의 특성을 중심으로 채점자의 채점 과정에서 편향이 발생하는 요인을 분석한 결과, 채점 편향은 텍스트의 분량, 어휘의 정확성 및 수준, 문체의 일관성과 같은 구체적인 텍스트 특성과 밀접한 관련이 있었다.

구체적으로 주장하는 글에서 채점 편향이 가장 빈번히 나타난 S14번 텍스트는 393자로 과제 기준보다 길었으며, ‘신념’, ‘시시각각’, ‘비록’과 같은 고급 어휘와 표현을 잘 사용했으나, ‘행복’을 ‘생복’, ‘기적’을 ‘기작’으로 잘못 표기하는 등 기초적 어휘 오류가 혼재되었다. 이러한 특징은 텍스트가 지닌 고급 표현과 초급 수준의 오류가 동시에 나타나 채점자의 혼란을 초래하여 채점 편향을 유발한 것으로 추정된다. Weigle(2002)과 윤금준(2021)은 텍스트의 특성이 불균형하거나 모호할 때 채점자가 채점 기준을 일관되게 적용하지 못할 가능성을 지적한 바 있는데, 본 연구 결과 역시 어휘 수준의 불균형이 채점 편향과 밀접한 연관이 있음을 확인하였다. 이는 채점자 교육에서 텍스트 내 모순적인 요소를 평가할 때 명확한 기준과 구체적인 지침을 제공해야 한다는 실질적인 시사점으로 연결된다.

설명하는 글에서 채점 편향이 두드러졌던 S19번 텍스트는 분량이 295자로 과제 기준에 미치지 못했지만 ‘첫 번째’, ‘두 번째’, ‘마지막’등의 연결 표현으로 구조적 명료성을 보였다. 그러나 사용된 어휘가 ‘웃’, ‘신발’, ‘사다’ 등과 같이 초급 수준에서 벗어나지 못했다. 이로 인해 구조적으로는 준수하지만 어휘 수준의 단조로움 때문에 채점자가 어떤 채점 요소를 중점적으로 평가해야 할지 명확한 기준을 적용하지 못했다. 이는 백유진(2020)이 제기한 구조와 어휘 수준의 불균형이 채점의 어려움을 초래한다는 연구 결과를 지지하면서, 특히 어휘 수준과 구조의 균형을 맞추는 것이 채점자 교육에서 중요한 기준으로 제시되어야 한다는 점을 시사한다.

서사적인 글에서 편향이 많이 나타난 S6번 텍스트는 320자로 분량은 적절했으나 문체의 일관성이 부족했다. 실제 작성된 문장의 일부를 살펴보면 ‘...저는 박함 때문에 시간이 많아요. 그래서 우기 많이 전수 가요. 중국 못 정말 유명해요...’처럼 문장 구조가 매우 단순하고, ‘방학’을 ‘박함’으로 잘못 쓰는 등 기본적인 어휘 사용에서의 심각한 오류가 나타났다. 또한 과제의 주제였던 여행 경험과 관련성이 약하여 채점자들의 판단 기준을 혼란스럽게 했다. 선행연구(박종임, 2013; 백유진, 2021)에서는 서사적인 글에서 채점자의 판단이 주관

적이고 모호해질 가능성이 높다고 지적하고 있는데, 본 연구에서는 특히 서사적인 글의 문체 일관성과 어휘 정확성이 채점 편향을 유발하는 핵심 채점 요소임이 강조된다.

또한, 비신뢰성 검증 결과에서는 텍스트의 분량이 극단적으로 적거나 수준이 극단적으로 높거나 낮은 경우에도 채점자의 편향이 자주 발생했다. 예를 들어, 주장하는 글의 S10과 S13 텍스트는 분량이 매우 부족했지만 특정 채점자는 관대한 점수를 주었으며, 설명하는 글의 S18 텍스트는 높은 수준의 텍스트였음에도 엄격하게 평가된 사례가 나타났다. 이와 같은 결과는 텍스트의 극단적 특성 앞에서 채점자가 일관된 기준을 유지하기 어렵다는 기존 연구(Weigle, 1999)의 결과를 뒷받침하면서, 채점자 훈련 과정에서 극단적인 텍스트 사례를 통해 명확하고 세부적인 기준 적용 방법을 제시하는 교육적 접근이 필요하다고 사료한다.

3) 채점 편향에 영향을 미치는 텍스트의 분량과 수준은 어떠한가?

텍스트의 분량과 텍스트의 수준을 중심으로 두 가지 요인이 채점에 영향을 미치는지를 확인하였다. 먼저 텍스트의 분량과 채점 편향과의 영향 관계를 확인한 결과 전체 채점 결과에서는 텍스트 분량이 과제의 기준보다 많을 때 전체 41건의 채점 편향 중 34건이 나타나 65.8%를 차지하였다. 이와 같은 연구 결과는 텍스트의 분량이 많을수록 채점 편향이 두드러진다는 선행연구와 비슷한 결과이다(이슬기, 2019; 백유진, 2020; 윤금준, 2021). 다만 본고에서는 텍스트 유형별로 나누어 보았을 때에는 주장하는 글에서만 분량이 많은 글에 대해 채점 편향이 두드러지게 나타났고, 설명하는 글과 서사적인 글에서는 채점 편향의 비율이 차이가 크지 않았다. 또 텍스트 분량 수준이 ‘상’인 집단에서 엄격한 편향이 주로 보고되었다는 윤금준(2021)의 연구와는 달리 본고에서는 오히려 관대한 편향이 더 높은 비중을 차지하였다. 이는 주장하는 글의 주요 채점 기준인 ‘내용 및 과제 수행’에서 충분한 분량 자체가 높은 성취로 간주되어 보상적 채점이 이루어졌을 가능성을 시사한다(Weigle, 1999). 다만 설명하는 글과 서사적인 글에서는 주요 채점 기준이 각각 ‘글의 전개 구조’와 ‘언어 사용’으로 달랐기 때문에 텍스트의 분량이 주장하는 글보다 영향력을 발휘하지 못했을 것으로 추정할 수 있다.

텍스트의 내면적 특징을 모두 고려한 텍스트의 수준(수험자의 능력) 측정치인 logit값을 기준으로 텍스트의 수준과 채점 편향을 분석한 결과에 따르면 텍스트 유형에 따라 채점 편향이 나타나는 구간이 다른 것으로 나타났다. 주장하는 글에서는 평균보다 약간 높은 수준인 0.0~1.0 범위에서 관대한 채점 편향이 두드러졌다. 이는 채점자가 전반적으로 양호한 텍스트에서 세부적 오류보다는 긍정적 요소에 더 집중하여 평가했기 때문으로 추정된다. 즉, 수준

이 높을수록 채점자는 텍스트의 전반적인 완성도를 높게 평가하는 경향이 있어 세부적인 오류나 문제점에 대해 관대하게 반응한 것으로 보인다. 설명하는 글은 평균 이하의 수준(-1.0 이하)에서 관대한 채점과 엄격한 채점이 균형 있게 나타났는데, 이는 텍스트 수준이 명확하지 않을 때 채점자마다 서로 다른 평가 요소에 집중하여 다양한 판단을 내렸기 때문으로 분석된다. 마지막으로 서사적인 글의 경우에는 수준이 매우 낮은 텍스트(-1.0 이하)에서 엄격한 채점 편향이 두드러지게 나타났는데, 이는 서사적인 글의 자유로운 구조와 내용의 특성상, 수준이 현저히 낮으면 기초적인 언어적 오류가 두드러지게 드러나 채점자가 더 엄격하게 판단하게 되었기 때문으로 해석할 수 있다.

이러한 결과는 채점자 훈련 시 텍스트의 분량과 수준을 보다 구체적으로 반영한 채점 지침이 제공될 필요성을 시사한다. 특히 채점 과정에서 텍스트의 분량이 길거나 수준이 불명확할 경우 채점자가 겪는 인지적 혼란을 최소화할 수 있도록, 각 텍스트 유형의 특성을 구체적으로 반영한 훈련 자료와 세부적인 채점 기준이 마련되어야 할 것이다. 이를 통해 채점의 일관성과 신뢰성을 확보하고, 채점자의 평가 역량을 효과적으로 강화할 수 있을 것이다.

VI. 결론

쓰기 평가는 채점자의 주관에 관여하는 평가 방식이라는 점에서 채점자의 신뢰도가 평가의 타당도를 결정한다. 본고에서는 이런 쓰기 채점의 타당도에 영향을 미치는 주요 요인으로 텍스트에 주목하였다. 구체적으로는 텍스트의 유형, 분량, 수준이 채점자의 평가 방식이나 편향에 어떠한 영향을 미치는지를 살펴보았다. 주요 연구 결과를 요약하면 다음과 같다.

첫째, 텍스트 유형에 따라 비교했을 때 채점자가 상대적으로 엄격하게 평가하는 채점 기준이 달랐으며, 주장하는 글과 서사적인 글에서는 채점자 간 평가 결과의 차이가 크게 나타났다. 주장하는 글에서는 ‘내용 및 과제 수행’, 설명하는 글에서는 ‘글의 전개 구조’, 서사적인 글에서는 ‘언어 사용’이 가장 중요한 채점 기준으로 적용되었다. 이는 각 텍스트 유형이 요구하는 핵심 능력이 다르며, 이에 따라 채점자가 중요하게 고려하는 평가 요소가 달라지는 것을 의미한다. 다만, 채점 기준을 일관성 있게 적용하는 데에는 모든 채점자들이 어려움을 경험하는 것으로 나타났다. 또한, 주장하는 글과 서사적인 글에서는 채점자 간 평가 결과가 일관되지 않은 경향이 나타났는데, 다양한 요소를 동시에 고려하는 과정에서 채점자들은 인지 부담을 덜기 위해 채점 기준을 단순화하거나 채점 기준 간의 개입으로 판단 기준이 다르게 적용되었기 때문으로 해석된다.

둘째, 채점 편향은 텍스트의 분량, 어휘 수준, 문체 일관성과 같은 요인과 밀접한 관련이 있었다. 주장하는 글에서는 논리적 구성이 뛰어난 고급 어휘를

사용한 텍스트라도 기초적인 어휘 오류가 포함될 경우 채점자 간 평가 결과가 불안정해졌다. 설명하는 글에서는 구조적 명료성이 있었으나 어휘 수준이 낮은 경우 채점자마다 평가 기준 적용 방식이 달라지는 경향이 나타났다. 서사적인 글에서는 문체의 일관성이 부족하거나 과제 주제와의 관련성이 약한 경우 채점자의 판단이 흔들리는 현상이 두드러졌다. 또한, 텍스트의 분량이 극단적으로 적거나 텍스트 수준이 지나치게 높거나 낮을 때도 채점자의 채점 기준 적용이 일관되지 않은 사례가 확인되었다.

셋째, 텍스트의 분량과 수준이 채점자의 채점 방식에 영향을 미치는 요인으로 작용하였다. 주장하는 글에서는 텍스트의 분량이 많을수록 관대한 채점이 이루어지는 경향이 나타났으며, 서사적인 글에서는 수준이 낮을수록 엄격한 채점이 이루어졌다. 이는 텍스트 유형별로 특정 분량이나 수준에서 채점 편향이 발생할 가능성이 높음을 시사한다. 따라서 채점자 협의를 통해 이러한 경향을 반영한 채점 기준을 보다 명확히 설정할 필요가 있다. 또한, 채점자 훈련에서는 편향이 발생하는 구간의 텍스트를 교육용 채점 자료로 활용함으로써, 채점자의 기준 적용을 일관되게 하고 보다 효과적인 훈련을 제공할 수 있을 것이다.

다만 본 연구는 참여한 채점자의 수가 제한적이어서 결과를 일반화하기에는 한계를 지닌다. 향후 채점자 규모를 확장하고 텍스트 사례를 다양화한다면 텍스트 요인이 채점 타당도에 미치는 영향에 대해 보다 심층적인 연구 결과를 도출할 수 있을 것으로 기대된다.

참고문헌

- 강민석. (2014). 다국면 표집 모형을 통한 한국어 쓰기 평가에서의 채점 경향 연구 [석사학위논문. 고려대학교]. RISS. <https://www.riss.kr/link?id=T13692597>
- 강승혜, 김은실. (2021). 채점자 경력 요인 및 작문 평가방식이 평가 결과에 미치는 영향-한국어 작문 평가를 중심으로. *작문연구*, 49, 129-157.
- 김수현, 김영주. (2018). 한국어 학습자의 쓰기 수행 평가 신뢰도 분석-다국면 라쉬 모형을 사용하여. *한국어 의미학*, 61, 1-31.
- 김승주. (2021). 교실 단위 작문 평가에서 활용 가능한 작문 자동 채점 프로그램의 설계 방안에 대한 연구-인지공학적 설계 접근과 채점자의 인지 부하 요인을 고려하여. *청람어문교육*, 83, 157-203.
- 김인숙. (2015). 손글씨쓰기 평가와 컴퓨터쓰기 평가의 차이 분석 : 중학생 논설문 평가를 중심으로 [석사학위논문, 한국교원대학교]. RISS. <https://www.riss.kr/link?id=T13717334>
- 김지영. (2022). 한국어 쓰기 평가에서 채점자 간 협의 과정이 채점자 신뢰도에 미치는 영향 연구 [박사학위논문, 서울대학교 대학원]. RISS. <https://www.riss.kr/link?id=T16547487>
- 김정숙. (2010). 한국어 쓰기 능력 평가 방안-종합적 채점과 분석적 채점 결과를 중심으로. *이중언어학*, 43, 81-99.
- 김정숙, 안수현. (2017). 한국어능력시험(TOPIK) 쓰기 평가의 채점 특성 연구. *한국어 교육*, 28(1), 173-196.
- 남미정, 원미진. (2022). 한국어 쓰기 자동 채점을 위한 언어 자질 탐색 연구. *언어사실과 관점*, 57, 9-32.
- 박영민, 최숙기. (2010). Rasch 모형을 활용한 국어교사의 쓰기 평가 특성 분석: 중학생 설명문 쓰기 평가를 중심으로. *국어교육학연구*, 37, 367-391.
- 박영민, 최숙기. (2011). 논설문 평가에 나타난 국어교사의 평가 특성 및 편향 분석. *교육과정평가연구*, 14(1), 201-228.
- 박종임. (2013). 국어교사의 쓰기 평가 특성 연구 [박사학위논문, 한국교원대학교]. RISS. <https://www.riss.kr/link?id=T13091676>
- 박지수. (2021). 한국어 쓰기 평가의 채점자 요인 연구 [석사학위논문. 서울대학교]. RISS. <https://www.riss.kr/link?id=T15959240>
- 백유진. (2020). 논설문 채점에 나타난 국어 교사의 채점 편향의 특성 분석-텍스트 특징에 따른 채점 편향 분석을 중심으로. *청람어문교육*, 76, 67-101.
- 백유진. (2021). 국어 교사의 사고 구술 분석을 통한 학생 논설문 채점 편향의 원인 탐색 [박사학위논문. 한국교원대학교]. RISS.

<https://www.riss.kr/link?id=T15786656>

- 신동광, 이용상, 정혜경. (2023). 내용중심 영어 교수 학습의 도구로서 ChatGPT의 활용 가능성 탐색. *영어교과교육*, 22(1), 171-192.
- 신동일, 장소영. (2009). 언어교육평가 연구를 위한 FACETS프로그램. 글로벌콘텐츠.
- 윤금준. (2021). 국어교사의 채점 편향에 영향을 미치는 글의 특징 분석. *새국어교육*, 129, 301-338.
- 윤나영. (2023). 한국어 쓰기 평가에서의 채점 편향 분석 연구-논설문에서의 찬반 입장을 중심으로. *언어와 문화*, 19(3), 225-253.
- 이슬기. (2019). 작문 채점의 분산적 특징에 대한 글 요인 분석. *새국어교육*, 119, 281-314.
- 이인혜. (2012). 한국어 쓰기 평가의 채점 방식에 따른 채점자 신뢰도 연구: 종합적 채점 및 분석적 채점을 중심으로 [석사학위논문. 고려대학교]. RISS. <https://www.riss.kr/link?id=T12708103>
- 이인혜. (2014). 한국어 교사의 쓰기 평가 효능감과 평가 특성 연구. *이중언어학*, 56, 231-266.
- 이지연. (2007). 영어 교사들의 주관적 평가 방법에 따른 영작문 평가시 평가 항목의 타당도. *응용언어학*, 23(1), 147-171.
- 이지연. (2023). 한국어 학습자의 학술적 데이터 설명문 쓰기 연구 [박사학위논문. 서울대학교]. RISS. <https://www.riss.kr/link?id=T16865782>
- 정지윤(2017). 한국어 쓰기 평가의 영향 요인에 대한 교차분류 다층분석 [석사학위논문. 연세대학교]. RISS. <https://www.riss.kr/link?id=T14451314>
- 최혜민. (2011). 텍스트 종류에 따른 한국어 쓰기의 내용 평가 기준 연구-설명문, 논설문, 감상문을 중심으로. *한성어문학*, 30, 218-252.
- Foltz, P. W., Streeter, L. A., Lochbaum, K. E., & Landauer, T. K. (2013). Implementation and applications of the intelligent essay assessor. In *Handbook of automated essay evaluation*. 68-88. Routledge.
- Freedman, S. W., & Calfee, R. C. (1983). Holistic assessment of writing: Experimental design and cognitive theory. *Research on writing: Principles and methods*, 75-98.
- Linacre, J. M.(1989). *Many-Facet Rasch Measurement*. IL: MESA Press.
- Lumley, T. (2005). *Assessing second language writing: The rater's perspective* (Vol. 3). Lang.
- Weigle, S. C.(1999). Investigating rater/prompt interactions in writing assessment: Quantitative and qualitative approaches. *Assessing Writing*, 6(2), 145-178.
- Weigle, S. C.(2002). *Assessing Writing*. Cambridge: Cambridge University Press. 정희모, 김성숙, 유혜령, 서수현 역(2017). 쓰기 평가. 서울: 글로벌콘텐츠.

Wolfe, E. W., Song, T., & Jiao, H. (2016). Features of difficult-to-score essays. *Assessing Writing*, 27, 1-10.

Wright, B. D., Linacre, J. M.(1994). The Rasch model as a foundation for the Lexile Framework. *Unpublished manuscript*.

저자 소개

김춘영은 경희대학교 글로벌한국학과 강사로 외국어로서의 한국어교육과 한국어평가에 관심을 두고 있다.

저자 주소

김춘영
경희대학교 국제한국언어문화학과
17104 경기도 용인시 기흥구 덕영대로 1732 외국어대학
이메일: kiroro04@khu.ac.kr

논문 투고일자: 2025년 01월 31일
심사 접수일자: 2025년 03월 05일
게재 확정일자: 2025년 03월 21일