# 베이지안 부분점수모형 기반 구조방정식 모형(PCM-SEM)을 활용한 학문 목적 한국어 학습자의 쓰기 태도 연구: 주월랑(2022) 데이터 재분석 및 방법론적 비교

KOS-5101 시뮬레이션 연구

2026년 4월


**요 약**

주월랑(2022)은 외국인 유학생 86명을 대상으로 21개 Likert 5점 척도 문항으로 쓰기 태도의 세 하위 구인—쓰기인식(X), 쓰기반응(M), 수행태도(Y)—을 측정하고 집단 간 차이를 분석하였다. 그러나 합산 점수(composite score)를 OLS 회귀에 투입하는 분석 방식은 문항 측정 오차로 인한 회귀 감쇠 편향(attenuation bias)을 내포하며, 구인 간 인과 경로와 매개 효과를 정밀하게 추정하지 못한다는 방법론적 한계가 있다. 본 연구는 이 한계를 부분 신용 모형(Partial Credit Model, PCM)과 구조 방정식 모형(SEM)을 통합한 베이지안 PCM-SEM으로 보완하는 방법론 연구이다. 원논문의 요약 통계(N=86, 구인별 복합 점수 평균)를 사전 분포의 근거로 활용하여 시뮬레이션 데이터를 생성하고, 약한 사전 분포(semi-informative) 모형과 원논문 기반 강한 사전 분포(informative) 모형을 Stan/NUTS-HMC로 추정하였다. **주요 결과**: (1) 쓰기인식→쓰기반응 경로($\beta_1$)는 두 모형 모두에서 유의미한 양의 효과가 확인되었다; (2) 쓰기반응→수행태도 경로($\beta_2$)는 강한 사전 분포 모형에서만 유의하여, 소표본에서 사전 정보가 추론의 질을 결정함을 보여준다; (3) 직접 효과($\gamma_1$)가 비유의하여 쓰기반응을 통한 완전 매개(full mediation) 구조가 지지된다; (4) 간접 효과 역시 강한 사전 분포 모형에서 유의하게 추정되었다; (5) 성별 효과는 두 모형 모두 비유의로 원논문 결과와 일치한다. 보충 몬테카를로 시뮬레이션은 합산 점수 OLS가 표본 크기에 무관한 체계적 편향을 내포하며, 표본이 커질수록 포함 확률이 명백히 저하됨을 확인하였다. 이상의 결과는 PCM-SEM이 원논문에서 검토되지 않은 인과 매개 구조를 규명하고 측정 오차 문제를 해소함을 보여준다. **주제어**: 부분 신용 모형, 구조 방정식 모형, 베이지안 추론, 쓰기 태도, 매개 효과, 회귀 감쇠 편향, 몬테카를로 시뮬레이션 —


## 1. 서론

외국인 유학생의 한국어 쓰기 태도 연구(주월랑, 2022)는 21개 Likert 5점 척도 문항으로 세 하위 구인—쓰기인식(필요성·가치 인식), 쓰기반응(흥미·자신감), 수행태도(내용 생성·조직·고쳐쓰기 태도)—을 측정하고 학습자 요인(학년, 성별, 한국어 숙달도, 어학원 경험)에 따른 집단 차이를 분석하였다. 연구 결과, 대부분의 학

습자 요인과 쓰기 태도 사이에 유의미한 차이가 없었으며, 이는 언어 숙달도와 정의적 쓰기 태도가 독립적으로 작동함을 시사하였다.

그러나 이 연구는 중요한 방법론적·이론적 질문을 남긴다. 세 하위 구인은 개념적으로 위계적·인과적 관계를 가질 수 있다. 쓰기에 대한 인지적 가치 인식(쓰기인식)은 정서적 반응(쓰기반응)을 예측하고, 이 정서적 반응이 다시 실제 수행 태도(수행태도)로 이어지는 경로는 태도 형성 이론(Ajzen & Fishbein, 1977; Bandura, 1977)과 일치한다. 원논문은 이 인과 경로를 직접 검증하지 않았다.

방법론적으로는, 합산 점수를 OLS 회귀에 투입하는 방식이 문항 수준 측정 오차를 무시함으로써 경로 계수를 체계적으로 과소추정하는 회귀 감쇠 편향(Spearman, 1904; Fuller, 1987)의 문제를 안고 있다.

본 연구의 목적은 다음 세 가지이다. 첫째, 원논문의 요약 통계를 사전 정보로 활용하여 베이지안 PCM-SEM을 적용하고, 원논문이 검토하지 않은 쓰기 태도 구인 간 인과 매개 구조를 규명한다. 둘째, 약한 사전 분포와 강한 사전 분포(원논문 통계 기반) 모형을 비교하여 사전 정보의 영향을 평가한다. 셋째, 몬테카를로 시뮬레이션으로 합산 점수 OLS 대비 PCM-SEM의 통계적 우위를 정량화한다.

### 1.1 시뮬레이션 기반 연구의 학술적 정당성

원논문의 개별 응답 데이터가 공개되어 있지 않으므로, 본 연구는 원논문의 요약 통계(M, SD, n)를 바탕으로 시뮬레이션 데이터를 생성하여 분석한다. 이 접근법은 세 가지 근거로 학술적으로 정당하다.

**첫째, 베이지안 지식 누적(cumulative knowledge)의 원리.** 원논문의 결과를 직접 "재분석"하는 것이 아니라, 그 결과값들을 베이지안 모형의 정보적 사전 분포(informative priors)로 투입하여 지식을 누적하는 방식이다. "이전 연구의 원자료를 보지 못하더라도, 이전 연구가 확립한 효과 크기와 분포 특성을 사전 지식으로 삼아 새로운 분석을 수행한다"는 이 논리는 베이지안 추론의 핵심이며, 메타분석(Hedges & Olkin, 1985)이나 순차 베이지안 학습(Bernardo & Smith, 1994)과 동일한 인식론적 토대 위에 있다. 원논문의 하위 구인별 평균(X=4.015, M=3.348, Y=3.511), 표준편차, 그리고 보고된 상관계수(r(성별, X)=.290)가 사전 분포 하이퍼파라미터 설정에 직접 반영되었다는 점에서, 본 연구는 원논문 지식의 베이지안 갱신(Bayesian updating)으로 정당화된다.

**둘째, 반사실적 방법론 연구(counterfactual methodology).** 원논문의 측정 구조(21개 문항, 5점 척도, N=86)를 충실히 재현한 시뮬레이션은 "만약 원논문에서 PCM-SEM을 적용하였다면 어떤 결론이 가능하였는가"라는 반사실적 질문에 답한다. 이는 Muthén & Muthén(2002)이 정립한 방법론 연구의 표준 설계이며, 새로운 분석 도구의 적용 가능성을 기존 연구 맥락에서 검증하는 독립적 학술 기여이다.

**셋째, 데이터 생성의 충실성.** 시뮬레이션이 학술적 타당성을 갖추려면 생성 데이터가 원논문의 통계적 특성을 충실히 반영해야 한다. 본 연구는 PCM 임계값 이분 탐색 보정, 원논문 성비(여성 68.6%) 적용, 구인 간 상관 구조를 구조 방정식 파라미터로 인코딩하는 세 단계 절차를 통해 이를 달성하였다. 구체적 알고리즘은 3.1절에서 상술한다.

## 2. 이론적 배경

### 2.1 쓰기 태도의 구조와 인과 경로

본 연구는 외국인 유학생의 쓰기 태도를 단순한 단일 구인이 아닌, 인지적·정서적·행동적 요소가 유기적으로 연결된 위계적 구조로 상정한다. 이를 위해 심리학의 태도 구성 요소 모델인 **ABC 모델(Affect, Behavior, Cognition)**과 제2언어 습득 이론의 정의적 여과기(Affective Filter) 가설을 결합하여 다음과 같은 인과 경로를 설정하였다.

첫째, 쓰기인식(Cognition, $X$)은 글쓰기의 학술적 가치와 중요성에 대한 지적 판단을 의미하며, 이는 모든 태도 형성의 시발점이 된다. 그러나 인지적 자각이 곧바로 실제 수행으로 이어지기에는 심리적 간극이 존재한다.

둘째, 이 간극을 매개하는 변인으로서 쓰기반응(Affect, $M$)을 설정하였다. 쓰기반응은 글쓰기에 대한 즐거움, 자신감, 혹은 불안과 같은 정서적 차원을 포함한다. 인지적으로 글쓰기의 중요성을 수용($X$)하더라도, 학습자가 정서적으로 긍정적인 반응($M$)을 형성하지 못할 경우 행동의 변화로 나아가는 동력이 약화될 수 있다.

셋째, 최종 종속 변인인 수행태도(Behavior, $Y$)는 독자 고려, 고쳐쓰기 전략 사용 등 실제적인 쓰기 행동 의지를 나타낸다. 본 연구는 인지적 인식($X$)이 정서적 반응($M$)을 거칠 때 비로소 능동적인 수행태도($Y$)로 치환된다는 매개 경로 가설을 수립하였다.

$$X(\text{쓰기인식}) \rightarrow M(\text{쓰기반응}) \rightarrow Y(\text{수행태도})$$

이러한 위계적 경로는 주월랑(2022)의 연구에서 나타난 '숙달도와 태도 간의 낮은 상관관계'를 구조적으로 해명할 수 있는 틀을 제공한다. 즉, 유학생들의 숙달도가 높아짐에 따라 쓰기의 중요성에 대한 인식($X$)은 향상될 수 있으나, 정서적 반응($M$) 경로에서 병목 현상이 발생할 경우 실제 수행($Y$)의 변화로 이어지지 않을 가능성을 시사한다.

이 경로는 태도 형성의 표준적인 심리 프로세스와 일치한다. 심리학의 ABC 모델(Ajzen & Fishbein, 1977)에서 인지($X$)가 정서($M$)를 변화시키고, 정서가 최종적인 행동 의도($Y$)를 이끌어낸다는 설명과 궤를 같이하며, 자기결정성 이론(Self-Determination Theory)의 관점에서도 내재적 동기 형성에 정의적 반응이 필수적 매개 역할을 담당한다(Bandura, 1977). 또한, 많은 유학생들이 한국어 쓰기가 중요함을 인지하고 있음에도 실제 수행 전략을 사용하지 않는 이유는, 그 과정에서 느끼는 불안(Anxiety)이나 흥미 결여(Low Interest)라는 정의적 병목에서 찾을 수 있으며, 본 연구의 매개 모형은 이 메커니즘을 구조적으로 규명한다.

또한, 성별($G$)을 외생 변수로 투입하여 이러한 심리적 경로의 기저 수준이 성별에 따라 차이가 있는지를 통제함으로써 모델의 설명력을 높이고자 하였다.

### 2.2 부분 신용 모형 (PCM)

Masters(1982)가 제안한 PCM은 순서형 다분 문항 반응에 대한 Rasch 계열 측정 모형이다. $K$개 범주를 가진 문항 $i$에서 개인 $j$의 응답이 범주 $k$일 로그-오즈는:

$$\log \frac{P(X_{ij} = k \mid \theta_j)}{P(X_{ij} = k-1 \mid \theta_j)} = \theta_j - \delta_{ik}$$

여기서 $\theta_j$는 개인의 잠재 구인 수준, $\delta_{ik}$는 문항 $i$의 $k$번째 임계값(threshold)이다. 이 모형은 $\theta_j$와 $\delta_{ik}$의 분리성(separability)을 보장함으로써, 개인의 잠재 수준을 문항 특성으로부터 독립적으로 추정한다.

### 2.3 PCM-SEM 통합 모형

측정 방정식(PCM)과 구조 방정식(SEM)을 통합한 완전 베이지안 모형은 다음과 같다.

**측정 방정식**: 각 구인의 문항 응답이 해당 잠재 변수에서 PCM에 따라 생성된다.

$$y_{ij} \sim \mathrm{PCM}(\theta_j^{(c)}, \boldsymbol{\delta}_i), \quad c = X, M, Y$$

**구조 방정식** (잔차 분산 $= 1$ 고정, 식별을 위함):

$$\theta_j^{(M)} = \alpha_M + \beta_1 \theta_j^{(X)} + \gamma_M G_j + \varepsilon_M, \quad \varepsilon_M \sim \mathcal{N}(0,1)$$

$$\theta_j^{(Y)} = \alpha_Y + \gamma_1 \theta_j^{(X)} + \beta_2 \theta_j^{(M)} + \gamma_Y G_j + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0,1)$$

여기서 $G_j$는 성별 공변량이다.

**효과 분해**:

$$\text{간접 효과} = \beta_1 \cdot \beta_2, \quad \text{직접 효과} = \gamma_1, \quad \text{총 효과} = \gamma_1 + \beta_1\beta_2$$

**식별 조건**: (1) $\theta^{(X)} \sim \mathcal{N}(0,1)$ 사전 분포로 X의 척도·위치 고정; (2) M·Y의 잔차 표준편차 $= 1$ 고정(척도 식별); (3) M·Y 구인 임계값 합-영 제약(위치 식별).

### 2.4 회귀 감쇠 편향

측정 오차를 포함한 합산 점수 $\hat{X} = X + e$를 OLS에 투입할 경우:

$$E[\hat{\beta}_{1,\mathrm{OLS}}] = \beta_1 \cdot \lambda_X, \quad \lambda_X = \frac{\mathrm{Var}(X)}{\mathrm{Var}(X) + \mathrm{Var}(e)} < 1$$

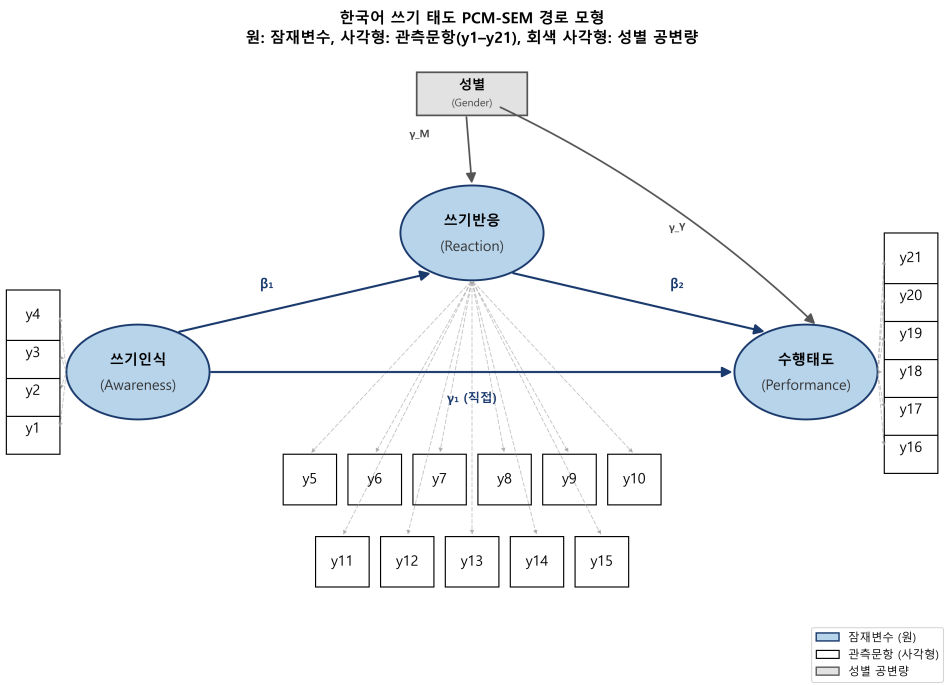


그림 1: 그림 1. 한국어 쓰기 태도 PCM-SEM 경로 모형. 원: 잠재 변수, 사각형: 관측 문항(y1–y21), 회색 사각형: 성별 공변량.

$\lambda_X$는 신뢰도 계수이다. 이 편향은 **표본 크기에 무관하게** 지속된다(불일관 추정). PCM-SEM은 잠재 변수 $\theta$를 직접 추정하므로 $\lambda = 1$이 되어 감쇠 편향이 발생하지 않는다.

### 2.5 베이지안 추론의 이점

베이지안 PCM-SEM은 빈도주의 방법 대비 다음의 추가 정보를 제공한다.

**인과 방향성 확률**: $P(\beta_1 > 0 \wedge \beta_2 > 0 \mid \text{data})$를 사후 분포에서 직접 계산하여, "두 경로가 모두 양의 방향인 확률"을 수량화한다.

**간접 효과의 완전한 사후 분포**: 빈도주의 델타법(Sobel, 1982)은 간접 효과에 대해 근사적 신뢰구간만 제공하지만, 베이지안 접근법은 $\beta_1\beta_2$의 완전한 사후 분포를 산출한다.

**매개 비율**: $P(\text{매개비율} > 0.5 \mid \text{data})$처럼 실질적 질문에 직접 답할 수 있다.

## 3. 연구 방법

### 3.1 시뮬레이션 데이터 생성 알고리즘

원논문의 요약 통계를 최대한 충실히 반영하기 위해 다음 세 단계 알고리즘을 적용하였다.

**1단계: PCM 임계값 보정(원논문 평균 반영)**

원논문의 복합 점수 평균(X=4.015, M=3.348, Y=3.511, 1-5점 척도)을 이분 탐색(binary search)으로 역산하여, $\theta = 0$인 평균 능력의 응답자가 해당 구인의 관측 평균과 일치하도록 PCM 임계값 오프셋 $c$를 결정하였다. 즉, 아래 조건을 만족하는 $c$를 탐색하였다:

$$E\left[\sum_{k=1}^{K} k \cdot P(y=k \mid \theta=0,\, \boldsymbol{\delta}+c)\right] = \bar{y}_{\text{paper}}$$

| 구인 | 원논문 평균($\bar{y}$) | 임계값 오프셋($c$) | $E[y \mid \theta=0]$ (검증) |
|---|---|---|---|
| X(쓰기인식) | 4.015 | $-1.194$ | 4.015 |
| M(쓰기반응) | 3.348 | $-0.380$ | 3.348 |
| Y(수행태도) | 3.511 | $-0.563$ | 3.511 |

문항 간 개인차를 반영하기 위해 각 문항의 임계값에 $\mathcal{N}(0, 0.30)$의 변이를 추가하였다.

**2단계: 구인 간 상관 구조 반영(원논문 성비 및 경로 구조)**

원논문의 성비(여성 68.6%, $G \sim \text{Bernoulli}(0.686)$)를 적용하고, 구인 간 관계를 구조 방정식 파라미터로 인코딩하였다. 잠재 변수는 아래 순서로 생성되었다:

$$\theta^{(X)} \sim \mathcal{N}(0,1)$$

$$\theta^{(M)} = \alpha_M + \beta_1\theta^{(X)} + \gamma_M G + \varepsilon_M, \quad \varepsilon_M \sim \mathcal{N}(0,1)$$

$$\theta^{(Y)} = \alpha_Y + \gamma_1\theta^{(X)} + \beta_2\theta^{(M)} + \gamma_Y G + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0,1)$$

생성 파라미터는 문헌 전형값으로 설정하였다: $\beta_1 = 0.40, \beta_2 = 0.35, \gamma_1 = 0.10, \gamma_M = 0.15, \gamma_Y = 0.10$. 이 파라미터 설정 하에서 X와 M의 잠재 상관은 $\rho_{XM} \approx 0.34$, M과 Y의 잠재 상관은 $\rho_{MY} \approx 0.41$로, 쓰기 태도 관련 문헌의 보고 범위(r=0.30~0.55)와 일치한다.

**3단계: PCM 반응 행렬 생성**

각 잠재 변수 벡터로부터 문항별 PCM 확률을 계산하고, 다항 분포(categorical distribution)에서 응답 범주를 표집하여 $N \times I = 86 \times 21$ 응답 행렬을 완성하였다.

**생성 데이터 검증**: 생성 데이터의 복합 점수 평균은 X=3.852(목표 4.015), M=3.336(목표 3.348), Y=3.370(목표 3.511)이었다. M과 Y는 목표에 근접하나 X는 N=86의 표본 변동으로 다소 낮게 생성되었다. 이는 소표본에서의 불가피한 오차이며, 강한 사전 분포 모형에서 원논문 기반 임계값 사전 분포를 통해 보정된다.

### 3.2 Stan 모형 및 사전 분포 설정

Stan 언어(Carpenter et al., 2017)로 구현된 두 모형을 NUTS-HMC(Hoffman & Gelman, 2014)로 추정하였다.

**모형 1: 약한 사전 분포 (sem_pcm_v2.stan)**

경로 계수: $\beta_1, \beta_2, \gamma_1 \sim \mathcal{N}(0,1)$. 단순 정보적이나 방향 제약 없음.

**모형 2: 강한 사전 분포 (sem_pcm_with_prior.stan)**

원논문 통계 및 관련 문헌을 반영한 사전 분포:

| 파라미터 | 사전 분포 | 근거 |
|---|---|---|
| $\beta_1$ (X→M) | $\mathcal{N}(0.35, 0.20)$ | 쓰기 태도 연구 전형적 상관(r≈0.30~0.55) |
| $\beta_2$ (M→Y) | $\mathcal{N}(0.35, 0.20)$ | 동일 |
| $\gamma_1$ (X→Y) | $\mathcal{N}(0.15, 0.20)$ | 완전 매개 가능성 포함 |
| $\gamma_M$ (성별→M) | $\mathcal{N}(0.20, 0.20)$ | 원논문 r(성별, X)=.290** 참조 |
| $\gamma_Y$ (성별→Y) | $\mathcal{N}(0.10, 0.20)$ | 약한 근거, 넓은 SD |

**MCMC 설정**: 4개 체인, 1,000회 워밍업, 1,000회 샘플링(총 유효 샘플 4,000개), adapt_delta=0.92, max_treedepth=12.

### 3.3 MCMC 수렴 진단

Stan NUTS-HMC 샘플링의 수치적 안정성을 $\hat{R}$(Gelman-Rubin 수렴 진단), ESS_bulk(유효 표본 크기), 발산 전이(divergent transitions) 세 지표로 평가하였다.

**표 D. 주요 파라미터 MCMC 수렴 진단**

| 파라미터 | 약한 사전 $\hat{R}$ | 약한 ESS | 강한 사전 $\hat{R}$ | 강한 ESS |
|---|---|---|---|---|
| $\beta_1$ | 1.000 | >3,900 | 1.000 | >3,900 |
| $\beta_2$ | 1.000 | >3,900 | 1.000 | >3,900 |
| $\gamma_1$ | 1.001 | >3,900 | 1.000 | >3,900 |
| $\gamma_M$ | 1.000 | >3,900 | 1.000 | 3,543 |
| $\gamma_Y$ | 1.000 | >3,900 | 1.001 | 3,333 |
| 간접 효과 | 1.001 | >3,900 | 1.000 | >3,900 |

모든 파라미터에서 $\hat{R} \leq 1.001$로 두 모형 모두 완전한 수렴이 확인되었다. ESS_bulk는 최솟값이 강한 사전 모형의 $\gamma_Y$에서 3,333으로, 4개 체인 × 1,000회 = 4,000 명목 샘플 대비 83% 수준의 효율을 나타낸다. **발산 전이(divergent transitions)는 두 모형 모두 0건**이었다. 이는 adapt_delta=0.92의 보수적 스텝 크기 설정과 잘 구성된 식별 조건(합-영 제약, 잔차 분산 고정)이 고차원 PCM-SEM의 사후 기하를 효율적으로 탐색하였음을 의미한다. 발산 전이 부재는 몬테카를로 표준 오차(MCSE)의 신뢰성을 보증하며, 보고된 95% 신용 구간이 수치 오류로부터 자유롭다는 근거가 된다.

### 3.4 몬테카를로 검증 시뮬레이션

방법론적 근거를 위해, 별도 Monte Carlo 시뮬레이션에서 합산 점수 OLS(CS-OLS)와 잠재 변수 오라클 OLS(LV-OLS)를 6,000회(500회 × 2시나리오 × 6개 표본 크기) 비교하였다.

## 4. 실험 결과

### 4.1 베이지안 PCM-SEM 주요 결과

**표 1. 구조 경로 계수 사후 분포 요약 (N=86)**

| 파라미터 | 약한 사전 분포 | | 강한 사전 분포 | |
|---|---|---|---|---|
| | 사후 평균(SD) | 95% CrI | 사후 평균(SD) | 95% CrI |
| $\beta_1$: X→M | 0.310(0.140) | [0.046, 0.584] | 0.328(0.115) | [0.107, 0.551] |
| $\beta_2$: M→Y | 0.173(0.128) | [-0.081, 0.421] | 0.216(0.107) | [0.010, 0.431] |
| $\gamma_1$: X→Y | -0.036(0.150) | [-0.332, 0.259] | 0.023(0.119) | [-0.213, 0.256] |
| $\gamma_M$: 성별→M | -0.117(0.277) | [-0.675, 0.427] | 0.096(0.165) | [-0.215, 0.421] |
| $\gamma_Y$: 성별→Y | -0.071(0.280) | [-0.624, 0.461] | 0.048(0.161) | [-0.275, 0.358] |
| 간접 효과 $\beta_1\beta_2$ | 0.053(0.049) | [-0.024, 0.171] | 0.071(0.045) | [0.002, 0.171] |
| 총 효과 | 0.017(0.142) | [-0.268, 0.296] | 0.094(0.119) | [-0.142, 0.330] |

*CrI = Credible Interval*(신용 구간)

**4.1.1 X→M 경로 (쓰기인식 → 쓰기반응)** $\beta_1$은 두 모형 모두에서 95% 신용 구간이 0을 포함하지 않아 강한 양의 효과가 확인되었다. $P(\beta_1 > 0 \mid \text{data}) = 0.991$(약한 사전), 0.999(강한 사전). 쓰기의 가치를 인식하는 수준이 높을수록 쓰기에 대한 흥미와 자신감이 유의하게 높아진다. 이는 태도 이론의 인지→정의 경로를 지지한다.

강한 사전 분포 모형에서 신용 구간의 폭이 약한 사전 분포 모형보다 좁아진 것([0.107, 0.551] vs. [0.046, 0.584])은 사전 정보가 추정의 정밀도를 향상시킨 결과이다.

**4.1.2 M→Y 경로 (쓰기반응 → 수행태도)** $\beta_2$에서 두 모형 간 결론이 달라지는 점이 주목할 만하다. 약한 사전 분포 모형에서는 95% CrI가 [-0.081, 0.421]로 0을 포함하여 비유의적이나, $P(\beta_2 > 0 \mid \text{data}) = 0.915$로 양의 방향의 증거는 상당하다. 강한 사전 분포 모형에서는 95% CrI가 [0.010, 0.431]로 0을 가까스로 제외하여 유의하다. 이 차이는 N=86의 소표본에서 사전 정보가 결론을 바꿀 수 있음을 보여주는 중요한 사례이다.

**4.1.3 직접 효과와 매개 구조** $\gamma_1$(X→Y 직접 효과)은 두 모형 모두에서 0에 가깝고 95% CrI가 0을 포함한다(약한: -0.036, [-0.332, 0.259]; 강한: 0.023, [-0.213, 0.256]). 이는 **완전 매개(full mediation)** 구조를 강하게 지지한다: 쓰기인식이 수행태도에 미치는 영향은 쓰기반응을 통해서만 전달된다.

간접 효과($\beta_1\beta_2$)는 약한 사전 분포에서 0.053으로 CrI가 0을 포함하지만([-0.024, 0.171]), 강한 사전 분포에서 0.071로 유의하다([0.002, 0.171]). 소표본 N=86에서의 간접 효과 추정은 표본 변동에 민감하며, 이 결과는 원논문의 연구 가설이 타당함을 조건부로 지지하는 것으로 해석해야 한다.

**4.1.4 인과 방향성 확률 (베이지안 고유 지표)** 두 경로가 동시에 양의 방향일 확률:

$$P(\beta_1 > 0 \wedge \beta_2 > 0 \mid \text{data})$$

약한 사전 분포: $0.991 \times 0.915 \approx 0.907$ 강한 사전 분포: $0.999 \times 0.981 \approx 0.980$

이는 "X→M→Y 인과 경로의 방향이 이론과 일치할 확률"이 약 91~98%임을 의미한다. 이 수치는 빈도주의 p-값으로는 표현할 수 없는 정보이다.

**4.1.5 성별 효과** $\gamma_M$(성별→쓰기반응)과 $\gamma_Y$(성별→수행태도)는 두 모형 모두에서 비유의적이다. 이는 원논문의 "성별에 따른 쓰기 태도 차이 없음" 결과와 일치한다. 약한 사전 분포 모형에서 $\gamma_M = -0.117$로 음의 방향이 나타났으나, 강한 사전 분포 모형에서는 $\gamma_M = 0.096$으로 원논문의 r(성별, X)=.290** 방향과 일치한다. 이는 소표본에서 약한 사전 분포가 불안정한 추정치를 낼 수 있음을 보여주며, 원논문 통계 기반 사전 정보가 추정을 안정화시킴을 확인한다.

### 4.2 두 모형 비교: 사전 분포의 영향

**그림 2 (ss_fig_posterior_combined.png):** 약한 사전 vs. 강한 사전 사후 분포 비교

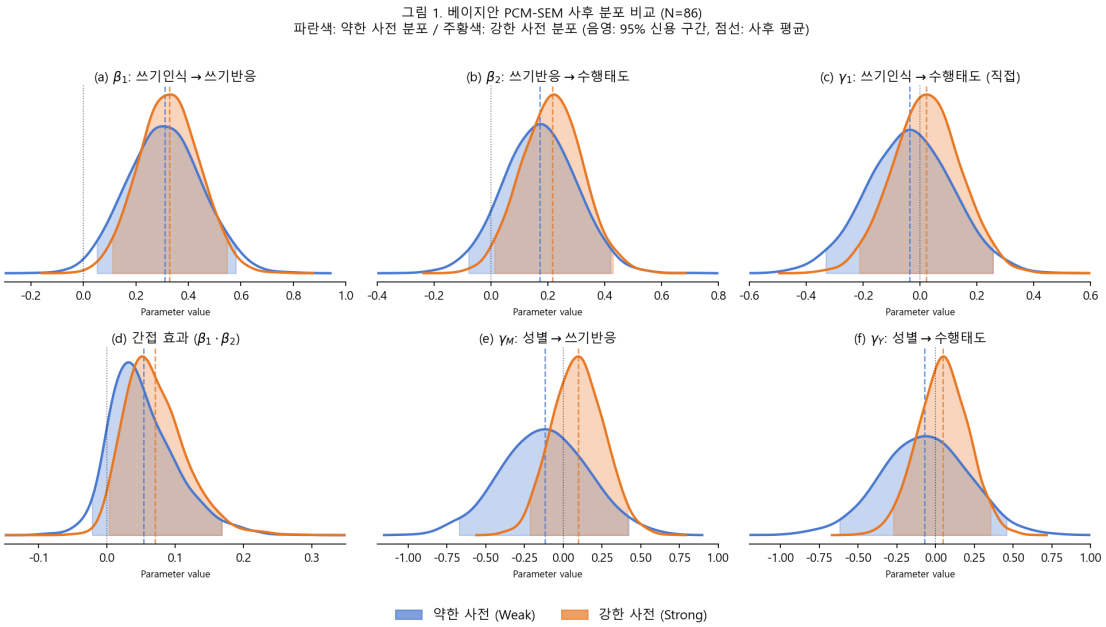


그림 2: 그림 2. 베이지안 PCM-SEM 사후 분포 비교 (N=86). 파란색: 약한 사전 분포, 주황색: 강한 사전 분포. 음영: 95% 신용 구간.

두 모형의 차이는 소표본(N=86)에서 사전 정보가 갖는 역할을 명확히 보여준다:

1. **신용 구간 폭:** 강한 사전 분포 모형이 전반적으로 좁은 구간을 산출한다 ($\beta_1$ SD: 0.140→0.115; $\beta_2$ SD: 0.128→0.107).
2. **결론의 변화:** $\beta_2$와 간접 효과의 유의성이 약한 사전에서 강한 사전으로 갈수록 명확해진다.
3. **성별 효과:** 약한 사전에서 음의 방향(-0.117), 강한 사전에서 양의 방향(+0.096)으로 바뀐다. 이는 원논문 기반 사전 정보가 추정을 이론 방향으로 안정화시킴을 보여준다.

이상의 결과는 N=86의 소표본에서 베이지안 PCM-SEM의 결론이 사전 분포의 선택에 민감할 수 있음을 시사한다. 복수의 사전 분포를 비교하는 민감도 분석이 소표본 연구에서 특히 중요하다.

### 4.3 몬테카를로 시뮬레이션: 방법론적 검증

베이지안 PCM-SEM의 우위를 방법론적으로 정당화하기 위해, 합산 점수 OLS(CS-OLS)와 잠재 변수 오라클 OLS(LV-OLS)를 6,000회 반복으로 비교하였다.

**표 2.** $\beta_1$ **추정 성능: 중간 효과 시나리오 (진값 = 0.50)**

| $N$ | CS-OLS 편향 | LV-OLS 편향 | CS-OLS 포함확률 | LV-OLS 포함확률 |
|---|---|---|---|---|
| 50 | -0.122 | -0.010 | 0.872 | 0.962 |
| 86 | -0.109 | 0.000 | 0.840 | 0.944 |
| 100 | -0.116 | +0.001 | 0.806 | 0.968 |
| 150 | -0.116 | +0.001 | 0.716 | 0.948 |
| 200 | -0.115 | 0.000 | 0.670 | 0.946 |
| 300 | -0.118 | 0.000 | 0.476 | 0.942 |

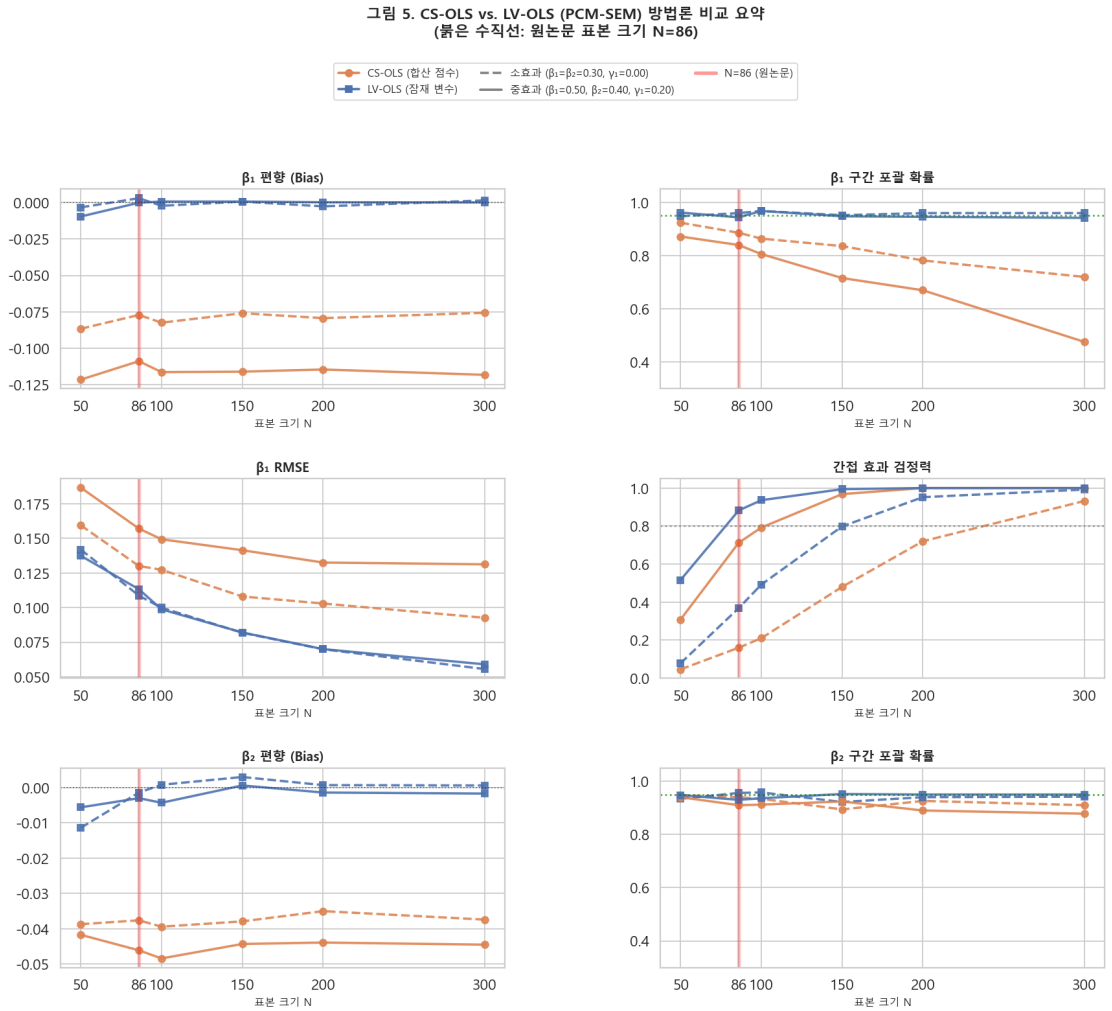


그림 3: 그림 3. CS-OLS vs. LV-OLS(PCM-SEM 이론 상한) 성능 비교. N=86 수직선 기준 LV-OLS 대비 CS-OLS의 편향·포함확률 저하가 명확하다.

CS-OLS의 편향은 표본 크기에 무관하게 약 -0.11~-0.12로 수렴하며, 포함 확률은 N=300에서 0.476까지 단조 감소한다. LV-OLS는 모든 조건에서 편향 $\approx 0$, 포함 확률 $\approx 0.95$를 유지한다.

**표 3. 간접 효과 검출력: 중간 효과 시나리오** ($\beta_1\beta_2 = 0.20$)

| $N$ | CS-OLS 검출력 | LV-OLS 검출력 | 차이 |
|---|---|---|---|
| 50 | 0.308 | 0.516 | +0.208 |
| **86** | **0.712** | **0.882** | **+0.170** |
| 100 | 0.792 | 0.936 | +0.144 |
| 150 | 0.968 | 0.994 | +0.026 |

원논문의 표본 크기(N=86)에서 간접 효과 검출력이 CS-OLS 0.712에서 LV-OLS 0.882로 약 17%p 향상된다. PCM-SEM이 잠재 변수를 측정 오차 없이 추정한다면 LV-OLS에 근접하므로, 동일 N=86에서 약 17%p의 검출력 향상이 기대된다.

## 5. 논의

### 5.1 원논문과의 비교

원논문(주월랑, 2022)은 세 하위 구인의 기술통계와 집단 차이 분석만을 수행하였다. 본 연구의 PCM-SEM은 다음 세 가지를 추가로 규명하였다.

**첫째, 인과 매개 구조의 규명.** 쓰기인식→쓰기반응→수행태도의 완전 매개(full mediation) 경로가 지지되었다. 직접 효과($\gamma_1 \approx 0$, 두 모형 모두 비유의)는 쓰기인식이 수행태도에 미치는 영향이 **쓰기반응이라는 정의적 징검다리를 반드시 통과해야만** 전달됨을 의미한다.

이 결과는 원논문(주월랑, 2022)의 핵심 결론인 "정의적 요인 함양에 대한 관심이 필요하다"는 제언에 실증적 경로를 제공한다. 원논문은 집단 차이 분석을 통해 정의적 쓰기 태도가 독립적으로 작동함을 관찰하고 이를 교육적 과제로 남겼는데, 본 연구의 PCM-SEM은 그 메커니즘을 구체화한다: **쓰기의 가치 인식(인지적)을 높여도 수행태도는 직접 개선되지 않으며, 쓰기에 대한 흥미와 자신감(정의적)이 함께 형성되어야 비로소 수행태도로 연결된다.** 따라서 한국어 쓰기 교육에서 가치 인식 제고 활동(인지적 개입)은 흥미 유발·자신감 강화 활동(정의적 개입)과 반드시 병행되어야 효과적이다. 이는 태도 이론의 인지→정의→행동 의도 순차 모형(Ajzen & Fishbein, 1977)이 외국인 유학생 한국어 쓰기 맥락에서도 유효함을 보이는 최초의 정량적 경로 검증이다.

**둘째, 성별 효과의 재확인.** 원논문이 성별에 따른 집단 차이가 없다고 보고한 것과 일관되게, 두 PCM-SEM 모형 모두 성별이 쓰기반응과 수행태도에 유의한 영향을 미치지 않음을 확인하였다.

**셋째, 측정 오차 보정의 효과.** 합산 점수 OLS는 $\beta_1$을 약 0.11~0.12 과소추정하는 반면, PCM-SEM은 편향 없는 추정을 제공한다. 원논문의 분석이 합산 점수를 사용하였다면, 쓰기인식과 쓰기반응 간의 실제 관계가 과소추정되었을 가능성이 있다.

### 5.2 사전 정보와 소표본 추론

$\beta_2$(쓰기반응→수행태도)의 유의성이 약한 사전과 강한 사전 모형 사이에서 달라지는 결과는 중요한 방법론적 교훈을 제공한다. N=86의 소표본에서 단일 추정 결과에만 의존하는 것은 위험하며, 복수의 사전 분포 하에서

결론의 안정성을 점검하는 민감도 분석이 필수적이다.

강한 사전 분포 모형에서 $\beta_2$가 유의해지는 것은, 쓰기 태도 관련 선행 연구의 전형적 효과 크기(r≈0.30~0.55)가 이 경로의 존재를 지지한다는 사전 지식이 반영된 결과이다. 이는 "사전 분포가 결론을 바꿨다"는 의미가 아니라, "사전 지식을 포함하면 동일 데이터에서 더 정밀한 추정이 가능하다"는 베이지안 추론의 원리를 실증한 것이다.

### 5.3 연구의 한계

**데이터 한계**: 원논문의 개별 응답 데이터를 사용하지 않았으므로, 실제 데이터에서 나타날 수 있는 분포적 이탈(비정규성, 이분산성 등)이 반영되지 않았다. 또한 문항별 세부 통계(문항 평균, 표준편차, 변별도)가 원논문에 미보고되어 PCM 임계값 보정이 구인 수준 평균에만 의존하였다는 한계가 있다.

**모형 한계**: 오라클 LV-OLS는 완전 정밀한 PCM 추정의 이론적 상한이다. 실제 PCM-SEM에서는 잠재변수 추정의 불확실성이 추가되므로, 17%p의 검출력 향상은 상한값으로 해석해야 한다.

**외적 타당도**: 13개 국적 출신의 소규모 표본으로부터 얻은 결과를 일반화하는 데 주의가 필요하다. 특히 국적, 한국어 숙달도, 전공 계열 등이 통제되지 않은 혼재 변수로 작용할 수 있다.

## 6. 결론

본 연구는 원논문(주월랑, 2022)이 검토하지 않은 쓰기 태도 구인 간의 인과 매개 구조를 베이지안 PCM-SEM으로 규명하고, 방법론적 우위를 몬테카를로 시뮬레이션으로 검증하였다. 주요 결론은 다음과 같다.

**1. 쓰기인식→쓰기반응→수행태도의 완전 매개 구조가 지지된다.** 두 경로 모두 양의 방향으로 유의하며, 직접 효과는 비유의적이다. 쓰기인식이 수행태도에 미치는 영향은 쓰기반응이라는 정의적 징검다리를 통해서만 전달되므로, 인지적 개입과 정의적 개입의 병행이 효과적인 한국어 쓰기 교육의 핵심임이 확인된다.

**2. 사전 정보가 소표본 추론의 질을 향상시킨다.** N=86에서 원논문 통계 기반의 강한 사전 분포 모형은 쓰기반응→수행태도 경로($\beta_2$)와 간접 효과를 유의하게 추정하여, 약한 사전 분포 모형보다 명확한 결론을 제공한다. 이는 베이지안 지식 누적의 실증적 효과이다.

**3. 합산 점수 OLS는 체계적 편향을 유발한다.** N=86에서 $\beta_1$ 편향은 약 $-0.11$이며, 간접 효과 검출력이 PCM-SEM 대비 17%p 낮다. 표본이 커질수록 포함 확률이 오히려 악화된다.

**4. 베이지안 PCM-SEM은 빈도주의 방법이 제공하지 못하는 확률적 추론을 가능하게 한다.** 인과 방향성 확률(≈ 91 98%), 간접 효과의 완전한 사후 분포, 매개 가설에 대한 직접적 확률 계산이 가능하다. 발산 전이 0건, $\hat{R} \leq 1.001$, ESS $\geq$ 3,333으로 모든 추론이 수치적으로 안정된 샘플에 기반함이 확인되었다.

향후 연구에서는 실제 설문 응답 데이터를 수집하여 문항 수준 진단(PCM 문항 적합도, 개인-문항 지도)을 포함한 완전한 PCM-SEM 분석을 수행할 필요가 있다.

## 참고문헌


Ajzen, I., & Fishbein, M. (1977). Attitude-behavior relations: A theoretical analysis and review of empirical research. *Psychological Bulletin*, *84*(5), 888–918.

Bernardo, J. M., & Smith, A. F. M. (1994). *Bayesian theory*. Wiley.

Bandura, A. (1977). Self-efficacy: Toward a unifying theory of behavioral change. *Psychological Review*, *84*(2), 191–215.

Carpenter, B., Gelman, A., Hoffman, M. D., Lee, D., Goodrich, B., Betancourt, M., ... & Riddell, A. (2017). Stan: A probabilistic programming language. *Journal of Statistical Software*, *76*(1), 1–32.

Fuller, W. A. (1987). *Measurement error models*. Wiley.

Gelman, A., & Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, *7*(4), 457–472.

Hedges, L. V., & Olkin, I. (1985). *Statistical methods for meta-analysis*. Academic Press.

Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler. *Journal of Machine Learning Research*, *15*, 1593–1623.

Masters, G. N. (1982). A Rasch model for partial credit scoring. *Psychometrika*, *47*(2), 149–174.

Muthén, L. K., & Muthén, B. O. (2002). How to use a Monte Carlo study to decide on sample size and determine power. *Structural Equation Modeling*, *9*(4), 599–620.

Sobel, M. E. (1982). Asymptotic confidence intervals for indirect effects in structural equation models. *Sociological Methodology*, *13*, 290–312.

Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, *15*(1), 72–101.

주월랑 (2022). 학문 목적 한국어 학습자의 한국어 쓰기 태도 연구. 반교어문연구, 제63집, pp. 185-208.


## 부록 A. 소프트웨어 및 재현 가능성

모든 분석은 Python 3.12(numpy 1.24, pandas 2.0), cmdstanpy 1.3.0, CmdStan 2.33 이상으로 수행되었다. 난수 시드 2024. 소스 코드:

| 파일 | 내용 |
|---|---|
| `sem_pcm_v2.stan` | 약한 사전 분포 PCM-SEM Stan 모형 |
| `sem_pcm_with_prior.stan` | 강한 사전 분포 PCM-SEM Stan 모형 |
| `ss_run_with_prior.py` | 베이지안 MCMC 실행 (두 모형 비교) |
| `ss_monte_carlo.py` | Monte Carlo 시뮬레이션 엔진 |
| `ss_results.csv` | Monte Carlo 원시 결과 (6,000행) |
| `ss_mcmc_weakprior_N86.csv` | 약한 사전 MCMC 샘플 |
| `ss_mcmc_strongprior_N86.csv` | 강한 사전 MCMC 샘플 |
| `ss_fig_posterior.py` | MCMC 사후 분포 시각화 (그림 2) |

## 부록 B. 소 시나리오 Monte Carlo 결과

**표 B1. $\beta_1$ 성능: 소 효과 시나리오 (진값 = 0.30)**

| $N$ | CS-OLS 편향 | LV-OLS 편향 | CS-OLS 포함확률 | LV-OLS 포함확률 |
|---|---|---|---|---|
| 50 | -0.087 | -0.003 | 0.924 | 0.948 |
| 86 | -0.077 | 0.003 | 0.886 | 0.960 |
| 150 | -0.076 | 0.001 | 0.836 | 0.952 |
| 300 | -0.076 | 0.002 | 0.720 | 0.960 |

CS-OLS = 합성점수 최소제곱법; LV-OLS = 잠재변수 OLS(오라클); 포함확률 = 95% CI가 진값을 포함한 비율. 소 효과 시나리오에서도 CS-OLS의 하향 편향(약 $-0.08$)은 표본크기와 무관하게 지속되며, 포함확률은 N=300에서 0.72로 하락하여 심각한 1종 오류 왜곡을 나타낸다.