creative commons

COMMONS DEED

저작자표시-동일조건변경허락 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.
- 이 저작물을 영리 목적으로 이용할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

동일조건변경허락. 귀하가 이 저작물을 개작, 변형 또는 가공했을 경우에는, 이 저작물과 동일한 이용허락조건하에서만 배포할 수 있습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

인하대학교
INHA UNIVERSITY

교육학 석사 학위 논문

다분 문항 검사에서 설명적 부분점수모형과 머신러닝 모형 간의 문항 난도 추정 정확성 비교

Comparison of Polytomous Item Difficulty Estimation Accuracy Between Explanatory Partial Credit Model and Machine Learning Models

2025년 2월

인하대학교 대학원

교육학과(교육학 전공)

이 하 늘

인하대학교
INHA UNIVERSITY

교육학 석사 학위 논문

다분 문항 검사에서 설명적 부분점수모형과 머신러닝 모형 간의 문항 난도 추정 정확성 비교

Comparison of Polytomous Item Difficulty Estimation Accuracy Between Explanatory Partial Credit Model and Machine Learning Models

2025년 2월

지도교수 이 용 상

이 논문을 석사학위논문으로 제출함

인하대학교
INHA UNIVERSITY

이 논문을 이하늘의 석사학위논문으로 인정함.

2024년 12월

주심 (인)

부심 (인)

위원 (인)

인하대학교
INHA UNIVERSITY

목 차

국 문 요 약 ····· vi

Ⅰ. 서론 ····· 1
1. 연구 필요성 및 목적 ····· 1
2. 연구 문제 ····· 4

Ⅱ. 이론적 배경 ····· 5
1. 다분문항반응모형 ····· 5
1) 등급반응모형 ····· 6
2) 부분점수모형 ····· 9
2. 설명적 문항반응모형 ····· 11
1) 선형 로지스틱 검사 모형 ····· 12
2) 설명적 부분점수모형 ····· 14
3. 머신러닝 모형 ····· 16
1) 결정 트리 모형 ····· 18
2) 랜덤 포레스트 모형 ····· 20
3) 그래디언트 부스팅 모형 ····· 22

인하대학교
INHA UNIVERSITY

Ⅲ. 연구 방법 ····· 24
1. 분석 자료 ····· 24
2. 분석 방법 ····· 28
1) 설명적 부분점수모형 ····· 28
2) 머신러닝 모형 ····· 28
3. 평가 준거 ····· 31
1) 모수 추정치와 실제 모수 간 상관 ····· 31
2) 평균제곱오차 ····· 32

Ⅳ. 연구 결과 ····· 33
1. 모형별 문항 난도 추정 결과 ····· 33
1) 부분점수모형 ····· 33
2) 설명적 부분점수모형 ····· 35
3) 랜덤 포레스트 모형 ····· 39
4) 그래디언트 부스팅 모형 ····· 43
3. 모형별 문항 난도 추정 정확성 비교 ····· 46
1) 머신러닝 모형과 설명적 부분점수모형의 추정 정확성 비교 ····· 46

Ⅴ. 결론 및 논의 ····· 49
1. 연구 결과 및 논의 ····· 49
2. 제언 ····· 51

인하대학교
INHA UNIVERSITY

참 고 문 헌 ····· 52
ABSTRACT ····· 60

인하대학교
INHA UNIVERSITY

표 목 차

<표 3.1.1> 언어적 공격성 데이터 구조 ····· 25
<표 3.1.2> 언어적 공격성 문항 데이터 ····· 26
<표 3.2.1> 머신러닝 모형의 하이퍼파라미터 요소 및 범위 ····· 30
<표 3.2.2> 각 머신러닝 모형의 하이퍼파라미터 선정 결과 ····· 30
<표 4.1.1> 부분점수모형의 문항별 단계 난도 ····· 34
<표 4.1.2> 설명적 부분점수모형의 문항 특성 효과 ····· 36
<표 4.1.3> 설명적 부분점수모형의 문항별 단계 난도 ····· 38
<표 4.1.4> 설명적 부분점수모형과 부분점수모형의 모형 적합도 ····· 39
<표 4.1.5> 랜덤 포레스트 모형의 문항별 단계 난도 ····· 41
<표 4.1.6> 그래디언트 부스팅 모형의 문항별 단계 난도 ····· 44
<표 4.2.1> 모형별 단계 난도 추정치와 실제 난도 간 상관 ····· 46
<표 4.2.2> 모형별 단계 난도 추정치의 평균제곱오차 ····· 47

인하대학교
INHA UNIVERSITY

그 림 목 차

[그림 2.1.1] 문항반응범주특성곡선 예시 ····· 7
[그림 2.1.2] 경계특성곡선 예시 ····· 7
[그림 2.3.1] 지도학습의 과정 ····· 17
[그림 2.3.2] 결정 트리의 구조 ····· 19
[그림 2.3.3] 랜덤 포레스트 모형의 알고리즘 ····· 21
[그림 2.3.4] 그래디언트 부스팅 결정 트리의 구조 ····· 23
[그림 4.1.1] 랜덤 포레스트 모형의 문항별 단계 난도 추정치 변화 ····· 40
[그림 4.1.2] 랜덤 포레스트 모형의 단계 난도 추정치 분포 ····· 42
[그림 4.1.3] 그래디언트 부스팅 모형의 문항별 단계 난도 추정치 변화 ····· 43
[그림 4.1.4] 그래디언트 부스팅 모형의 단계 난도 추정치 분포 ····· 45
[그림 4.2.1] 모형별 단계 난도 추정치와 실제 난도 간 상관 ····· 47
[그림 4.2.2] 모형별 단계 난도 추정치의 평균제곱오차 ····· 48

인하대학교
INHA UNIVERSITY

국 문 요 약

학생들의 학습 결과를 보다 정확히 평가하고 예측하기 위해 피험자의 배경 요인 및 문항 관련 특성을 활용한 평가 결과를 제시하는 것의 필요한만큼, 피험자 및 문항에 관한 정보를 활용하여 평가 결과를 분석하는 방법에 관한 연구와 관련 모형의 개발이 지속적으로 이루어지고 있다. 특히, 설명적 문항반응모형(explanatory item response model, EIRM)은 피험자 및 문항의 특성, 각 특성 간의 상호작용 효과를 모형에 포함하여 데이터를 분석함으로써 평가 결과에 대해 종합적으로 해석할 수 있도록 한다는 측면에서 활용성이 높다고 할 수 있다. 한편, 머신러닝(machine learning)은 효율적이고 정확한 예측 알고리즘의 데이터 기반 접근법으로서 문항 난도 및 피험자 응답 등과 같은 교육 평가 분야의 데이터를 분석하는 데에도 활용될 가능성이 있다. 이에 따라, 최근에는 머신러닝 모형과 문항반응모형을 결합하거나, 추정 결과를 비교하는 등의 연구도 이루어지고 있으나, 주로 이분 문항 유형 검사 상황을 가정하고 있으며, 설명적 문항반응모형 및 머신러닝 모형 간의 추정 정확성을 비교한 연구는 상대적으로 제한적이라고 할 수 있다.

이에 본 연구는 다분 문항으로 구성된 검사에서 설명적 부분점수모형(step difficulty explanatory linear partial credit model)과 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅)의 문항 난도 추정 정확성을 분석 및 비교하고자 하였다. 본 연구를 통해 다분 문항 반응 데이터를 기반으로 문항 난도를 예측하는 데 있어 두 접근 방식의 성능을 평가하고, 각 모형의 장단점을 파악하고자 하였다. 이를 위해 본 연구에서는 언어적 공격성(verbal aggression) 검사 데이터를 분석에 활용하였으며, 문항 난도 추정치와 실제 문항 난도 간의 상관(correlation)과 평균제곱오차(mean squared error, MSE)를 산출하여 두 모형 간의 추정 정확성을 비교하였다.

인하대학교
INHA UNIVERSITY

이에 따른 연구 결과는 다음과 같다. 먼저, 설명적 부분점수모형과 랜덤 포레스트 모형, 그래디언트 부스팅 모형의 문항별 단계 난도 추정치와 실제 단계 난도 간의 상관계수를 분석한 결과, 전반적으로 1단계와 2단계 난도에서 모든 모형의 상관계수가 0.9 이상으로 높은 것으로 나타났다. 또한, 설명적 부분점수모형과 랜덤 포레스트 모형, 그래디언트 부스팅 모형의 문항별 단계 난도 추정 정확성을 파악하기 위해 각 모형의 평균제곱오차를 비교한 결과, 1단계와 2단계 난도에서 모든 모형의 평균제곱오차가 0.2 미만으로 낮게 나타났다. 이는 머신러닝 모형과 설명적 부분점수모형의 예측 정확성이 우수하고 추정 오차가 적다는 것을 의미한다. 설명적 부분점수모형의 경우, 기존 부분점수모형에 비해 추정한 문항 모수의 개수가 적었음에도 불구하고 높은 추정 정확성을 보였다는 점에서 문항 수가 적은 경우에도 비교적 정확하게 문항 난도를 추정할 수 있다는 가능성이 있다고 할 수 있다.

본 연구를 통해 다분 문항으로 구성된 검사 상황에서 문항 난도를 추정하고 예측하는 데 있어서 설명적 문항반응모형과 머신러닝 모형의 활용 가능성을 탐색하고 예측 정확성을 비교함으로써, 다분 문항 검사 조건에서 문항 난도를 예측하고 추정하는 데 있어서 적합한 모형을 선택하는 데 도움을 줄 수 있을 것이다.

주제어: 다분문항반응모형, 설명적 문항반응모형, 설명적 부분점수모형, 머신러닝

인하대학교
INHA UNIVERSITY

Ⅰ. 서론

1. 연구 필요성 및 목적

교육평가는 학생들의 지식, 기술, 능력을 체계적으로 평가하여 교수 및 학습을 개선하기 위한 더 나은 방법을 찾는 과정이라 할 수 있다. 그러나 실제 교육 환경은 학교, 지역, 강의 방식 등 다양한 요인에 의해 달라지며, 이러한 차이를 평가 문항에 반영하는 것은 쉽지 않다(Jiao & Lissitz, 2020). 특히, 다양한 검사 상황과 피험자 특성을 충분히 고려하지 않고 실시된 평가는 그 결과를 해석하는 데 있어서 제한적인 피드백을 제공할 가능성이 높다. 따라서, 학생들의 학습 결과를 보다 정확히 평가하고 예측하며 교육 실천을 개선하고 발전시키기 위해서는 맥락을 고려한 평가(context-aware assessment)가 필요하다. 이러한 평가에서는 피험자의 성별, 연령, 주거 지역, 사전 지식 수준 등의 배경 요인과 문항 형식과 측정 영역, 지문의 길이 등과 같은 문항 관련 특성을 활용하여 평가 결과의 정확성과 활용성을 제고할 수 있다. 이러한 접근법은 교육 평가의 주요한 과제로 자리 잡고 있으며, 피험자 및 문항에 관한 정보를 활용하여 평가 결과를 분석하는 방법에 관한 연구와 관련 모형의 개발이 지속적으로 이루어지고 있다.

이러한 측면에서 문항반응이론(item response theory, IRT)은 개인의 능력과 문항 특성을 비선형 통계 모형으로 통합하여 평가 데이터를 분석하는 강력한 도구이자 이론으로서 자리잡고 있다(Kim & Wilson, 2020). 특히, 설명적 문항반응모형(explanatory item response model, EIRM; De Boeck & Wilson, 2004)은 개인과 문항의 특성뿐만 아니라 이들의 상호작용을 모형에 포함함으로써 평가 데이터를 더 풍부하게 설명할 수 있다. 대표적인 설명적 IRT 모형으로는 선형 로지스틱 검사 모형(linear logistic test model, LLTM; Fisher, 1973)이 있으며, 이 모형은 Rasch 모형의 문항 난도를 문항 특성을 설명하는 변수의 가

인하대학교
INHA UNIVERSITY

중치 합으로 분해하여 설명한다(Embretson & Reise, 2000).

LLTM 모형은 문항 설계, 문항 내용, 문항 형식 등을 문항 특성으로 통합하여 문항 난도에 미치는 영향을 설명하는 데 유용하며, 진단적 피드백을 제공하고 검사 설계를 개선하는 데 활용될 수 있다. 이에 따라, 문항 특성과 형식, 문항 위치가 문항 난도에 미치는 효과, 자동 문항 생성을 위한 인지적 조작과 같이 LLTM 모형을 활용한 연구(Baghaei & Kubinger, 2015; Embretson & Reise, 2000; Hecht et al., 2015; Kim & Wilson, 2020; Loe et al., 2018; Poinstingl, 2009; Rief, 2012; Rose et al., 2019)가 다양하게 이루어지고 있으나, 주로 이분 문항 데이터를 분석하는 데에 집중된 경향이 있어 다분 문항 데이터를 분석하는 데 LLTM 계열의 모형을 활용한 연구는 부족한 상황이다.

한편, 머신러닝(machine learning)은 효율적이고 정확한 예측 알고리즘을 제공하는 데이터 기반 접근법으로, 문항의 난도와 피험자의 응답 등을 예측하는 데 있어서도 활용될 가능성이 있다(Shmueli, 2010). 특히, 지도 학습(supervised learning) 모형은 피험자와 문항 간의 상호작용 데이터를 기반으로 새로운 관찰값을 예측하는 데 활용될 수 있다(Witten et al., 2011). 이에 따라, 최근에는 머신러닝 모형과 문항반응모형 간의 방법론적 연결을 시도하는 연구도 활발히 진행되고 있다. 예를 들어, Bergner et al. (2012)은 다차원 문항반응모형이 협업 필터링 알고리즘의 특정 사례로 간주될 수 있음을 보였고, Pliakos et al. (2019)은 문항반응모형을 통해 추정된 피험자의 능력과 문항 난도를 머신러닝 모형에 통합한 하이브리드 접근법을 제안했다. 또한, Gonzalez(2020)는 문항반응모형과 머신러닝 모형 간의 비교를 통해 머신러닝 모형이 문항반응모형을 기반으로 한 심리·측정적 접근방식과 유사한 예측 정확도를 보일 수 있음을 보고한 바 있다.

그러나 기존의 연구들은 주로 이분 문항으로 구성된 검사 상황을 가정하고 있으며 문항 난도 추정에 있어, 피험자 및 문항 관련 배경 정보를 고려한 설명적 문항반응모형을 활용한 연구는 상대적으로 적은 편이다. 더불어, 머신러닝 모형을 활용하여 다분 문항 데이터를 분석하고 추정 정확성을 확인하며,

인하대학교
INHA UNIVERSITY

설명적 문항반응모형과의 정확성을 비교한 연구 또한 제한적이라고 할 수 있다. 앞서 밝혔듯, 최근 머신러닝 모형과 문항반응모형을 결합하거나 교육 평가 상황에서 피험자의 응답을 예측하는 데 있어서 머신러닝 모형을 사용하는 등의 연구가 이루어지고 있다. 이러한 점을 고려할 때, 실제 검사 상황에서 빈번하게 사용되는 다분 문항 유형의 검사에서 머신러닝 모형과 문항반응모형의 문항 난도 추정 정확성을 파악하고 이를 비교하는 연구가 필요하다고 할 수 있다. 이에 본 연구는 다분 문항 검사에서 머신러닝 모형과 설명적 문항반응모형을 활용하여 문항 난도의 추정 정확성을 탐구하고자 하였다. 구체적으로, 머신러닝 모형 중에서 지도 학습(supervised learning) 모형에 해당하는 랜덤 포레스트(random forest) 모형과 그래디언트 부스팅(gradient boosting) 모형을 적용하였으며, 설명적 문항반응모형 중에서 다분 문항에 대한 응답 반응을 분석하는 데 적절한 설명적 부분점수모형(step difficulty explanatory linear partial credit model; Kim & Wilson, 2020)을 활용하여 문항 난도를 추정하였다. 이때, 머신러닝 모형이 문항 난도를 예측하기 위한 훈련 과정에서 제공할 데이터를 확보하고 머신러닝 모형과 설명적 부분점수모형의 추정 정확성을 비교할 수 있는 기준을 마련하기 위해 기존의 부분점수모형(partial credit model, PCM; Masters, 1982)을 활용하여 문항 및 단계 난도를 추정하였다. 이렇게 부분점수모형으로 추정한 문항 난도를 참값(true value)으로 상정하여 설명적 부분점수모형과 머신러닝 모형의 문항 난도 추정 정확성을 파악하고자 하였다. 더불어, 부분점수모형과 설명적 부분점수모형의 문항 난도 추정 결과를 비교하여 다분 문항에 대한 설명적 부분점수모형의 유용성을 확인하고자 하였다.

이를 위해 본 연구에서는 언어적 공격성(verbal aggression) 검사 데이터(Vansteelandt & Van Mechelen, 2001)를 분석에 활용하였으며, 문항 난도 추정치와 실제 문항 난도 간의 상관(correlation)과 평균제곱오차(mean squared error, MSE)를 산출하여 두 모형 간의 추정 정확성을 비교하였다. 본 연구를 통해 다분 문항으로 구성된 검사 상황에서 문항 난도를 추정하고 예측하는 데 있어서 설명적 문항반응모형과 머신러닝 모형의 활용 가능성을 탐색하고 예측 정확성을 비교함으로써, 다분 문항 검사 조건에서 문항 난도를 예측하고 추정

인하대학교
INHA UNIVERSITY

하는 데 있어서 적합한 모형을 선택하는 데 도움을 줄 수 있을 것으로 생각된다. 또한, 이는 추후 자동 문항 생성 기법을 활용하여 생성된 문항에 대해 기존 문항 데이터를 기반으로 문항 난도를 미리 파악하는 데 있어서 활용될 수 있다는 점에서 의의가 있다.

2. 연구 문제

본 연구는 다분 문항으로 구성된 검사에서 머신러닝 모형과 설명적 문항반응모형 간의 문항 난도 추정 정확성을 파악하고 비교하는 것을 목적으로 하고 있다. 이를 위해 머신러닝 모형 중에서는 랜덤 포레스트 모형과 그래디언트 부스팅 모형, 설명적 문항반응모형 중에서는 설명적 부분점수모형을 선정하여 언어적 공격성 데이터의 문항 난도를 추정하였으며 이를 비교하였다. 이에 따른 연구 문제는 다음과 같다.

연구 문제 1. 다분 문항으로 구성된 검사에서 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅)과 설명적 부분점수모형의 문항 난도 추정치와 실제 문항 난도 간의 상관은 어떠한가?

연구 문제 2. 다분 문항 검사에서 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅)과 설명적 부분점수모형 간 문항 난도 추정치의 평균제곱오차는 어떠한가?

인하대학교
INHA UNIVERSITY

Ⅱ. 이론적 배경

1. 다분문항반응모형

이분문항반응모형에서 각 문항에 대한 응답 데이터를 정답(1) 또는 오답(0)으로 구분하여 분석하는 것과 달리, 다분문항반응모형(polytomous item response model)은 문항의 응답 범주가 3개 이상일 때도 분석이 가능한 모형이다. 보편적으로 리커르트 척도, 평정 척도 등을 사용한 다분 문항으로 검사를 구성하는 심리측정 분야에서는 이러한 다분문항반응모형에 관한 연구가 많이 이루어지고 있다(강태훈, 김명연, 2012; 강태훈, 심혜진, 2015; Cole et al., 2019). 일반적으로 이분문항반응모형보다 다분문항반응모형을 사용하여 모수를 추정했을 때, 더 넓은 범위의 문항 정보와 정확한 추정 결과를 얻을 수 있으며 분석 결과를 통해 보다 상세한 진단적 정보를 피험자에게 제공할 수 있다(Bejar, 1977; Masters, 1988; Ostini & Nering, 2006).

다분문항반응모형은 문항 반응 범주 확률의 모형화 차이에 따라 '차이의 모형(difference model), 나눔의 모형(divided-by-total model)' 으로 구분할 수 있다(Thissen & Steinberg, 1986). 차이의 모형은 범주반응확률을 산출하기 위해 누적문항반응범주확률의 차를 활용하는 모형으로, 등급반응모형(graded response model, GRM; Samejima, 1969)이 대표적이다. 나눔의 모형은 범주반응확률을 산출하기 위해 인접한 범주반응에 대한 로짓(adjacent-categories logit; Masters & Wright, 1997)을 사용하는 모형으로 평정척도모형(rating scale model, RSM; Andrich, 1978)과 부분점수모형(partial credit model, PCM; Masters, 1982), 일반화부분점수모형(generalized partial credit model, GPCM; Muraki, 1992)가 대표적이다. 두 모형은 실제 검사 상황에서 빈번하게 활용되지만, 문항반응범주에 대한 확률화 과정의 차이가 있어 피험자가 각 문항의 범주에 응답할 확률을 해석하는 방식이 다르다고 할 수 있다.

인하대학교
INHA UNIVERSITY

1) 등급반응모형

등급반응모형(graded response model, GRM; Samejima, 1969)은 Lord & Novick(1968)의 2모수 정규 오자이브 모형에서 착안하여, Thurstone의 연속적 동간법(method of successive intervals)을 확장한 것으로 피험자의 문항에 대한 반응을 여러 개로 분류된 경계의 개념으로 해석한다(DeMars, 2010). 등급반응모형은 서열화된 여러 개의 응답 범주로 이루어진 문항을 다룰 수 있으며, 태도 및 심리검사, 선호도 검사와 같은 심리학 분야에서도 널리 사용된다(박정, 2001).

등급반응모형에서는 피험자 능력 수준의 모든 범위에서 문항 i의 응답 범주 k에 대한 피험자의 응답 확률 $P_k(\theta_j)$을 구할 수 있으며, 각 능력 수준에 대한 $P_k(\theta_j)$를 연결하면 [그림 2.1.1]과 같은 문항반응범주특성곡선(item response category characteristic curve)이 도출된다(성태제, 1997). 이러한 문항반응범주특성곡선은 피험자의 능력 수준에 따라 각 문항의 범주에 응답할 확률을 나타내는 곡선으로, 특정 능력 수준을 기준으로 했을 때 각 범주에 응답할 확률을 모두 합하면 1.0이 되는 것을 알 수 있다.

[그림 2.1.2]와 같은 경계특성곡선(boundary characteristic curve)은 피험자가 각 응답 범주에 응답할 확률을 나타낸 것으로, 다분 문항에서 피험자의 응답을 채점할 때 활용될 수 있다. [그림 2.1.2]에서 $P_3{}^*(\theta)$는 세 번째 응답 범주($k=3$)와 네 번째 응답 범주($k=4$)를 구분하는 경계특성곡선으로, $P_3{}^*(\theta)$ 이하의 확률은 네 번째 응답 범주에 대한 응답 확률을 나타낸다. 또한, $P_2{}^*(\theta)$는 두 번째 응답 범주($k=2$)와 세 번째 응답 범주($k=3$)를 구분하는 경계특성곡선을 나타낸 것으로, 이때 세 번째 응답 범주에 응답할 확률은 $P_2{}^*(\theta)$와 $P_3{}^*(\theta)$ 사이의 확률이다. 즉, 등급반응모형에서는 경계특성곡선을 이용하여 각 범주에 응답할 확률을 구하며, 서로 이웃하고 있는 경계특성곡선의 차이를 이

인하대학교
INHA UNIVERSITY

용하여 각 경계특성곡선 사이에 위치한 응답 범주의 응답확률을 산출한다.

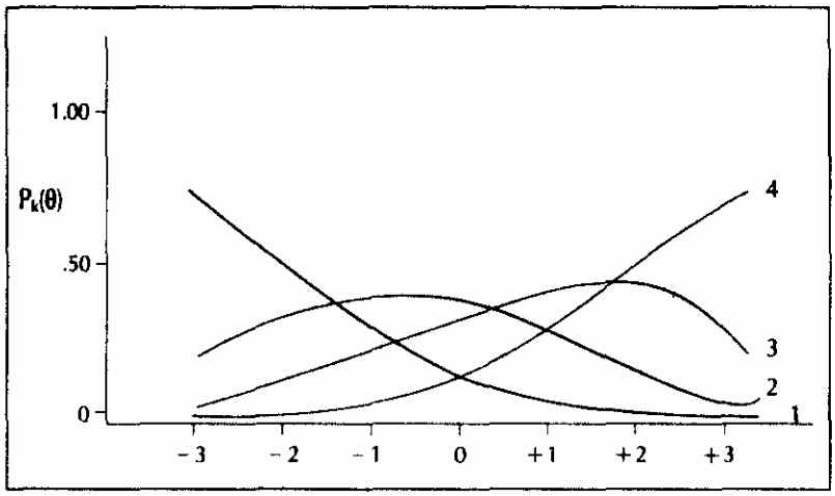

[그림 2.1.1] 문항반응범주특성곡선 예시 (출처: 성태제, 1997)

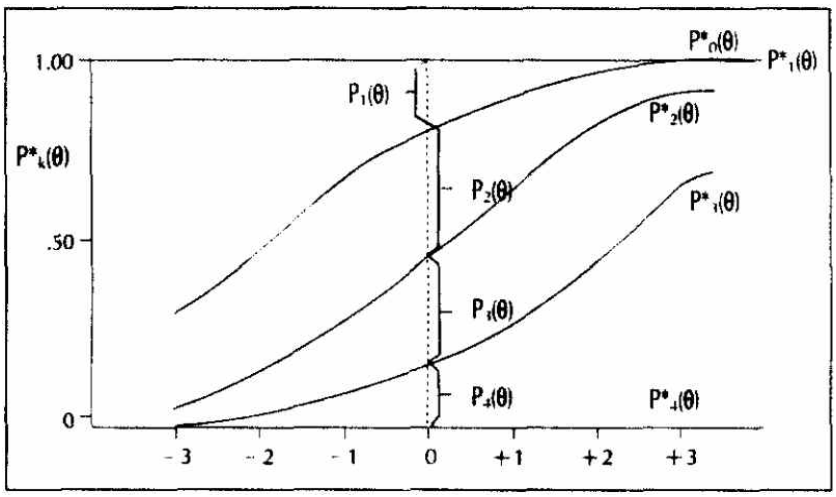

[그림 2.1.2] 경계특성곡선 예시 (출처: 성태제, 1997)

인하대학교
INHA UNIVERSITY

이러한 원리를 일반식으로 나타내면 다음의 식(2.1.1)과 같다:

$$\log[\frac{P(x_i \geq k)}{P(x_i < k)}] = D\alpha_i(\theta_j - \beta_{ik}) \tag{2.1.1}$$

식(2.1.1)에서 θ_j는 피험자 j의 능력 모수인 θ(theta)를 나타내며, α_i는 문항 i의 변별도, β_{ik}는 문항 i의 응답 범주 k의 난도, D는 로지스틱 모형을 정규 오자이브 모형으로 변환하는 데 사용되는 척도 요인(scaling factor)으로써 약 1.7의 값이다. 이때, α_i는 각 문항의 모든 범주에서 동일하다고 가정하며, β_{ik}는 각 문항의 응답 범주에 응답할 확률이 0.5일 때의 능력 모수의 값을 의미하며 연속적 서열성을 지닌다. 즉, 각 문항의 응답 범주 k의 난도는 응답 범주 $k-1$의 난도보다 항상 높은 값이어야 한다. 이를 식으로 나타내면 다음의 식(2.1.2)과 같다.

$$\beta_{ik} > \beta_{ik-1} > \ldots > \beta_{i1} \tag{2.1.2}$$

이러한 특성을 반영하여 등급반응모형에서 문항 i에 대해 m개의 응답 범주 중에서 k 이상의 범주에 응답할 확률은 식(2.1.3)과 같다.

$$P^*_{ik}(\theta_j) = P(x_i \geq k|\theta) = \begin{cases} 1 & k=1 \\ \dfrac{\exp[D\alpha_i(\theta_j - \beta_{ik})]}{1+\exp[D\alpha_i(\theta_j - \beta_{ik})]} & 2 \leq k \leq m_i \\ 0 & k > m \end{cases} \tag{2.1.3}$$

이는 문항 i에 대해 피험자가 k 이상의 범주에 응답할 확률이기 때문에, 특정 범주 k에 응답할 확률인 $P_{ik}(\theta_j)$은 인접한 두 범주의 응답 확률 간의 차이를 이용하여 다음의 식(2.1.4)와 식(2.1.5)로 나타낼 수 있다.

인하대학교
INHA UNIVERSITY

$$P_{ik}(\theta) = P(x_i = k|\theta) = P^*_{ik}(\theta_j) - P^*_{ik+1}(\theta_j) \tag{2.1.4}$$

$$P_{ik}(\theta_j) = \frac{\exp[D\alpha_i(\theta_j - \beta_{ik})]}{1+\exp[D\alpha_i(\theta_j - \beta_{ik})]} - \frac{\exp[D\alpha_i(\theta_j - \beta_{ik+1})]}{1+\exp[D\alpha_i(\theta_j - \beta_{ik+1})]} \tag{2.1.5}$$

2) 부분점수모형

부분점수모형(partial credit model, PCM; Masters, 1982)은 Rasch(1960)의 이분문항모형을 확장한 것으로, 세 개 이상의 응답 범주를 가진 다분 문항 모수를 추정할 수 있다. 부분점수모형은 앞서 소개한 등급반응모형과 달리, 인접범주로짓(adjacent category logits)에 기반하므로 피험자가 문항 i에서 인접한 두 응답 범주 중에서 특정 응답 범주 k에 응답할 조건부 확률을 구하는 방식으로 응답 확률을 산출한다(박정, 2001). 부분점수모형은 Rasch 계열의 모형을 확장한 것이므로, 모든 문항에 대해 변별도 α_i를 상정하지 않으며, 이는 변별도를 상수 1로 고정한 것과 같다. 또한, 부분점수모형에서 β_{ik}는 문항 i에서 응답 범주 k에 해당하는 점수를 받는 것에 대한 난도를 의미하며 이는 단계 모수(step parameter) 또는 단계 난도(step difficulty)라고 표현된다(강태훈, 김명연, 2012; 박정, 2001). 부분점수모형에서 능력수준 θ의 피험자 j가 문항 i에서 특정 응답 범주 k에 응답할 확률은 다음 식(2.1.6)과 같다.

$$P_{ik}(\theta_j) = \frac{\exp[\sum_{v=0}^{k}(\theta_j - b_{iv})]}{\sum_{c=0}^{m_i}\exp[\sum_{v=0}^{c}(\theta_j - b_{iv})]} \quad , \quad k = 1,2,\ldots,m_i \tag{2.1.6}$$

인하대학교
INHA UNIVERSITY

식(2.1.6)에서 θ_j는 피험자 j의 능력 모수인 θ를 나타내며, b_{iv}는 문항 i의 단계 난도로 응답 범주 v와 $v-1$에 응답할 확률이 동일해지는 지점의 위치모수, m_i는 응답 범주의 수($k=1,2,\ldots,m_i$)를 나타낸다. 이때, 단계 난도는 인접한 응답 범주의 교차 지점이기 때문에 단계 난도의 개수는 m_i-1개라고 할 수 있다. 예컨대, $m_i=5$인 경우에는 단계 난도가 총 네 개라고 할 수 있다.

이러한 Masters(1982)의 부분점수모형에서 각 문항의 변별도를 추정할 수 있도록 확장한 모형은 일반화부분점수모형(generalized partial credit model, GPCM; Muraki, 1992)이다. 일반화부분점수모형은 부분점수모형과 달리, 각 문항의 변별도를 추정함으로써 문항 특성에 대해 상세한 정보를 제공할 수 있고 등급반응모형에서 가정하는 응답 범주 난도의 서열성을 가정하지 않기 때문에 다양한 평가 상황에서 활용된다(박정, 2001; Muraki & Muraki, 2016). 일반화부분점수모형에서 능력수준 θ의 피험자 j가 문항 i에서 특정 응답 범주 k에 응답할 확률은 다음 식(2.1.7)과 같다.

$$P_{ik}(\theta_j)=\frac{\exp[\sum_{v=0}^{k}D\alpha_i(\theta_j-\beta_{ik})]}{\sum_{c=0}^{m_i}\exp[\sum_{k=0}^{c}D\alpha_i(\theta_j-\beta_{ik})]} \tag{2.1.7}$$

식(2.1.7)에서 θ_j는 피험자 j의 능력 모수인 θ를 나타내며, α_i는 문항 i의 변별도, β_{ik}는 문항 i의 응답 범주 k의 단계 난도이다. 일반화부분점수모형에서 단계 난도 β_{ik}는 등급반응모형에서와 달리, 서열성을 가지 않으며 문항 난도(β_i)와 응답 범주 난도(δ_k)로 분해되며 이는 식(2.1.8)과 같다.

$$\beta_{ik}=\beta_i-\delta_k\ ,\ \sum_{k=1}^{m}\delta_k=0 \tag{2.1.8}$$

인하대학교
INHA UNIVERSITY

식(2.1.8)에서 응답 범주 난도(δ_k)는 문항 i의 각 단계와 비교했을 때 k 단계의 상대적인 난도를 나타낸다(Embretson & Reise, 2000; Masters, 1982). 이처럼 단계 난도를 문항 난도와 응답 범주 난도로 분리할 경우, 검사를 구성하는 각 문항의 난도를 서로 비교할 수 있다.

2. 설명적 문항반응모형

De Boeck & Wilson(2004)은 기존의 문항반응모형이 수험자의 반응 데이터를 기반으로 수험자와 문항 모수를 추정하는 데 초점을 두었다면, 이를 확장하여 수험자와 문항에 관한 추가적인 배경 정보를 통합적으로 분석할 수 있는 설명적 문항반응모형(explanatory item response model, EIRM)의 틀을 제안하였다. 설명적 문항반응모형은 문항 및 피험자에 관련된 다양한 속성이 Rasch 문항 난도에 미치는 효과를 분석하는 데 주로 사용된다(김 선, 반제천, 2024; Cho et al., 2017; Embretson & Wetzel, 1987; Fischer & Formann, 1982; Kim & Wilson, 2020; Park et al., 2022). 이러한 설명적 문항반응모형의 핵심은 일반화된 선형·비선형 혼합 모형(generalized linear·non-linear mixed models)을 활용하여 피험자의 문항 반응 데이터를 분석하면서 피험자와 관련된 배경 요인과 문항 특성, 그리고 이 두 가지 요소의 상호작용을 동시에 고려할 수 있다는 점이다. 이러한 접근은 기존의 총점 또는 부분 점수를 기반으로 한 분석과 차별화되며, 이분(binary) 문항과 다분(polytomous) 문항 반응을 종속변수로 직접 모형링할 수 있다는 데 이점이 있다(최세일, 2017).

설명적 문항반응모형은 단순 선형 결합을 포함한 Rasch 모형에서부터 설명변수 간의 상호작용 효과(interaction effect)를 포함하는 비선형(nonlinear) 모형에 이르기까지 폭넓게 적용될 수 있다. 더 나아가, 혼합효과모형(mixed-effect model)으로서의 특성을 활용하여 문항 반응 데이터가 갖는 계층적 구조를 명시적으로 모형화할 수 있으며, 동일한 인지적 특성을 측정하는 문항 그룹을 반복측정(repeated measure)으로 분석하는 것도 가능하다. 대표적

인하대학교
INHA UNIVERSITY

인 설명적 문항반응모형으로는 선형 로지스틱 검사 모형(linear logistic test model, LLTM; Fisher, 1973)이 있으며, 본 연구에서 사용한 다분 라쉬 모형이 다분 문항 설명적 문항반응모형으로 확장된 모형인 설명적 부분점수모형(step difficulty explanatory linear partial credit model, LPCM; Kim & Wilson, 2020)이 있다.

1) 선형 로지스틱 검사 모형

선형 로지스틱 검사 모형(linear logistic test model, LLTM; Fisher, 1973)은 기본적으로 라쉬 모형(Rasch model)을 확장한 모형으로, 라쉬 모형의 문항 난도를 문항 속성들의 가중합으로 설명한다(Embretson & Reise, 2000). 기본 라쉬 모형은 다음의 식(2.2.1)과 같다.

$$P(y_{ij}=1|\theta_j, b_i)=\frac{\exp(\theta_j-b_i)}{1+\exp(\theta_j-b_i)} \tag{2.2.1}$$

식(2.2.1)에서 θ_j는 피험자 j의 능력 모수인 θ를 나타내며, 문항 i의 난도가 b_i일 때 피험자가 정답할 확률을 의미한다. LLTM 모형은 라쉬 모형에서 문항 난도에 영향을 미치는 문항 특성(item property)을 사전 정의하여 이러한 문항 특성으로 문항 난도를 예측하여 문항 특성과 난도 간 관계를 설명하고자 한다. 이러한 LLTM 모형의 통계적 모형은 다음의 식(2.2.2)로 설명할 수 있다.

$$\ln\left(\frac{P_{ij}(\theta_j)}{1-P_{ij}(\theta_j)}\right)=\eta_{ij}=\theta_j-b_j=\theta_j-(\mu+\sum_{m=1}^{M}q_{im}X_{im}) \tag{2.2.2}$$

식(2.2.2)에서 η_{ij}는 문항 i에 대한 피험자 j의 정답확률을 로짓으로 나타낸 것으로, μ는 문항을 나타내는 특성이 모두 중심화, 혹은 효과 코딩(effect

인하대학교
INHA UNIVERSITY

coding)되었을 때의 전체 평균이다(Cho et al., 2017). X_{im}은 문항 i의 문항 특성 변수 $m(m=1,2,...,M)$을 나타내며, 문항 i가 문항 특성 m을 가지고 있으면 1, 그렇지 않으면 0의 값으로 표현된다. q_{im}은 문항 특성 m의 회귀 가중치로, 문항 특성의 수는 문항의 수보다 적어야 하므로 $M \leq$ (문항의 수) -1 이어야 한다.

한편, LLTM 모형이 기반으로 하는 라쉬 모형은 문항 반응 자료의 기댓값인 확률을 로짓 함수로 선형 변환하여 표현하므로 일반선형모형이라고 할 수 있으며, 선형 부분 중에서 피험자의 능력을 무선 변수(random variables)로 포함하므로 혼합모형이라고 할 수 있다(De Boeck et al., 2011). 이에 따라, 라쉬 모형과 더불어 LLTM 모형에 대해 일반선형혼합모형(generalized linear mixed model, GLMM)의 방식으로 접근할 수 있다. 라쉬 모형과 LLTM 모형을 GLMM의 방식으로 접근하면 보다 다양한 분석이 가능하며, LLTM 모형을 GLMM의 접근 방식으로 표현하면 식(2.2.3)으로 나타낼 수 있다(De Boeck & Wilson, 2004).

$$\eta_{ij} = \theta_j + (\mu + \sum_{m=1}^{M} \beta_m X_{im}) \tag{2.2.3}$$

식(2.2.3)에서 θ_j와 $(\mu + \sum_{m=1}^{M} \beta_m X_{im})$의 결합이 +로 이루어진 것은 라쉬모형을 GLMM으로 설명할 경우, 문항 모수가 문항 난도(item difficulty)가 아닌 문항 용이도(item easiness)로 추정되기 때문이다. 따라서, GLMM을 사용할 때 LLTM 모형의 회귀계수 β_m은 문항 난도가 아닌 문항 용이도로, 이 값이 클수록 해당 문항이 평균적으로 쉽고 값이 작을수록 문항이 평균적으로 어렵다는 것을 의미한다(김 선, 반제천, 2024).

LLTM 모형에서는 각 문항 난도를 문항 특성과 문항 특성들의 효과로 설명하고자 하며, 문항 특성 간 상호작용을 나타내는 항을 독립변수로 사용할 수

인하대학교
INHA UNIVERSITY

있다. 즉, LLTM 모형은 문항을 고정 효과로 설정하여 무선 효과를 고려하지 않으므로 문항의 난도가 사전에 구성된 몇 가지의 문항 특성에 의해 완벽하게 예측될 수 있다고 가정한다(Janssen et al., 2004). 이러한 가정은 LLTM 모형의 가장 대표적인 특징이라고 할 수 있는데, 이러한 특성 때문에 현실적으로 문항 특성과 문항 난도와의 관계를 규명하는 데에는 한계가 있다. 실제 평가가 이루어지는 상황에서는 검사 문항의 난도에 영향을 미치는 요소가 무수히 많을 수 밖에 없기 때문에 모형의 설계자가 임의적으로 사전에 구성한 문항 특성에 포함된 독립변수들로 문항 난도의 분산을 완전히 설명한다고 가정하는 것은 비현실적이라고 볼 수 있다. 이러한 LLTM 모형의 한계를 보완하기 위해 문항 특성에 포함된 독립변수로 설명할 수 없는 문항 난도 분산의 잔차, 즉 오차를 포함한 LLTM-R(linear logistic test model with random effects; Janssen et al., 2004) 모형이 도출되었다. LLTM-R 모형은 문항 모수와 문항 특성의 효과, 문항의 무선 효과를 함께 추정하여 문항 특성들과 문항 난도와의 관계를 보다 현실적으로 파악할 수 있다는 이점이 있다.

2) 설명적 부분점수모형

먼저, 다변량 일반화 선형 혼합 모형(multivariate generalized linear mixed model, MGLMM; Hartzel et al., 2001) 프레임워크에서 모형을 설계하는 행렬(design matrix)에 포함될 수 있는 문항 반응 데이터의 문항 측면에 대한 설명변수(예측 변수)에는 세 가지 유형이 있다(Rijmen et al., 2003; Tuerlinckx & Wang, 2004). 문항 설명 변수(item predictors)는 문항에 따라 값이 달라지지만, 각 문항의 단계(step)에서는 고정되어 동일한 경우를 의미하며 단계 설명 변수(step predictors)는 각 문항의 단계에 따라 값이 달라지지만, 모든 문항에 대해서는 값이 동일한 경우를 말한다. 또한, 문항-단계 상호작용 변수(item-by-step predictors)는 모든 문항과 단계에서 값이 달라지지만, 모든 피험자에 대해서는 값이 동일한 경우를 의미한다.

인하대학교
INHA UNIVERSITY

기존의 부분점수모형에서는 모형의 설명 변수인 문항-단계 상호작용 변수에 대해 각 문항의 단계별 난도를 나타내는 변수로 간주하며, 문항 난도 및 피험자의 능력에 대한 개인 간의 차이를 모형링한다. 그러나, LLTM 모형의 접근법을 적용한 설명적 부분점수모형(Kim & Wilson, 2020)에서 모형의 설명 변수들은 단순히 문항 및 단계 난도를 추정하는 데 그치지 않고, 다분 문항의 특성에 대해 설명하는 변수로서 사용된다. 설명적 부분점수모형에서는 문항의 특성이 설명할 수 있는 변수를 고려하여 모형의 각 문항 설명 변수, 단계 설명 변수, 문항-단계 상호작용 변수에 포함시킨다. 예를 들어, 읽기 문항에서 지문의 길이나 지문의 내용과 같이 각 문항의 고유한 특성에 대해 설명할 수 있다고 간주되는 문항 특성은 모형에 문항 설명 변수로 포함된다. 이와 마찬가지로, 채점 기준이나 성취 수준과 같이 각 문항의 단계 난도를 설명할 수 있다고 생각되는 문항 특성은 단계 설명 변수로써 모형에 포함될 수 있다.

이러한 설명적 부분점수모형에서 각 문항 i의 단계 $m(m=1,\ldots,M_i)$에 대한 단계 난도 δ'_{im}은 문항-단계 상호작용 변수와의 가중치 합으로 분해된다. 이는 아래의 식(2.2.4)와 같으며, 이를 통해 설명적 부분점수모형을 다음의 식(2.2.5)와 같이 나타낼 수 있다.

$$\delta'_{im} = \sum_{k=0}^{K} \omega_{km} x_{ik}\,,\ k=0,\ldots,K \tag{2.2.4}$$

$$\eta_{pim} = \ln \frac{\Pr(y_{pi}=m|\theta_p)}{\Pr(y_{pi}=m-1|\theta_p)} = \theta_p - \sum_{k=0}^{K} \omega_{km} x_{ik} \tag{2.2.5}$$

식(2.2.5)에서 $\theta_p \sim N(0,\sigma_\theta^2)$, $\eta_{pi0}=0$, $\omega_{k0}=0$을 가정하며, x_{ik}는 문항 i의 문항 특성 k의 값을 나타낸다. x_{i0}의 경우에는 모든 문항에 대해 1의 값을 나타내는 상수 문항 설명 변수이며, ω_{0m}은 $x_{ik}=0$인 모든 문항의 m번째 단계 난도이다.

인하대학교
INHA UNIVERSITY

문항 특성을 나타내는 x_{ik}은 각 문항의 인접 범주 로짓에 확장되어 문항-단계 상호작용 변수로 포함될 수 있다(Zheng et al, 2007).

설명적 부분점수모형은 선형 부분점수모형(linear partial credit model, LPCM; Fischer & Ponocny, 1994)의 변형된 모형으로서, 단계 난도 모수에 선형 제약을 부과하여 문항-단계 상호작용 변수의 값에서 모수를 추정하였다. 기존의 선형 부분점수모형과 달리, 설명적 부분점수모형에서는 정규화 상수(normalization)를 포함하지 않았으며 문항-단계 상호작용 변수 ω_{km}를 사용한다. 따라서, 이 모형에서는 문항 특성의 효과를 단계별로 추정할 수 있어, 단계 난도에 대한 문항 특성의 효과를 각 단계에 따라 해석할 수 있다.

응답 범주가 3개인 다분 문항 1개에 대해 설명적 부분점수모형이 적용되는 예시를 표현하자면 다음의 식(2.2.6)과 같다. 식(2.2.6)에서 ω_{01}, ω_{02}은 상수이고 문항 특성 효과 ω_{X1}, ω_{X2}는 각 응답 범주에 대한 단계 난도로 추정된다.

$$\begin{aligned} &when\ m=0, \eta_{p10}=0 \\ &when\ m=1, \eta_{p10}+\eta_{p11}=0+(\theta_p-\omega_{01}-\omega_{X1})=\theta_p-\omega_{01}-\omega_{X1}, \text{ and} \\ &when\ m=2, \eta_{p10}+\eta_{p11}+\eta_{p12}=0+(\theta_p-\omega_{01}-\omega_{X1})+(\theta_p-\omega_{02}-\omega_{X2}) \\ &=2\theta_p-\omega_{01}-\omega_{02}-\omega_{X1}-\omega_{X2} \end{aligned} \quad (2.2.6)$$

3. 머신러닝 모형

머신러닝(machine learning)은 데이터를 보다 효율적으로 처리하고 학습시키기 위해 활용되는 기술로, 데이터가 주어졌을 때 중요한 정보를 추출하거나 이를 해석하는 것이 어려운 상황이 발생할 수 있는데 이러한 경우에 머신러닝 모형이 적용된다. 최근에는 방대한 데이터셋을 활용할 수 있어, 머신러닝의 중요성과 수요는 급격히 증가하고 있으며, 다양한 산업 분야에서 이를 활용하여 유용한 데이터를 추출하고 문제를 해결하는 데 기여하고 있다.

머신러닝의 주요 목적은 기계를 명시적으로 프로그래밍하지 않고도 데이터

인하대학교
INHA UNIVERSITY

로부터 추출한 정보를 기반으로 기계가 스스로 학습하는 방법을 탐구하는 데 중점을 둔다. 머신러닝과 관련된 연구를 통해 수많은 수학자와 프로그래머들이 방대한 데이터를 다뤄야 하는 문제를 해결하기 위한 다양한 접근법을 개발해왔다. 머신러닝의 궁극적인 목표는 데이터를 통해 패턴을 인식하고, 이를 바탕으로 이전에 경험하지 못한 문제를 해결할 수 있는 방법을 도출하는 데 있다(Carleo et al., 2019).

머신러닝 모형은 다양한 알고리즘을 통해 데이터 문제를 해결할 수 있으나, 특정 문제를 해결하는 데 있어 항상 적합한 이른바 '만능 알고리즘(one-size-fits-all)'은 존재하지 않는다(Wolpert & Macready, 1997). 따라서, 어떠한 문제를 해결하는 데 있어서 적절한 알고리즘은 문제의 성격, 데이터 내 변수의 개수, 적합한 모형 유형 등 다양한 요소에 따라 결정해야 한다.

이러한 머신러닝은 학습 방식에 따라 지도 학습(supervised learning)과 비지도 학습(unsupervised learning)으로 구분된다. 먼저, 지도 학습은 입력 데이터와 출력 데이터 간의 관계를 학습하는 과정으로써 입력 데이터를 출력 데이터로 매핑하는 함수를 학습한다. 지도 학습에서의 입력 데이터는 레이블(label)이 지정된 훈련 데이터(training data)와 테스트 데이터(test data)로 구분된다. 지도학습 모형은 입력된 훈련 데이터에서 일정한 패턴을 학습한 후, 이를 테스트 데이터에 적용하여 예측(prediction) 또는 분류(classification) 작업을 수행하는 알고리즘으로 구현되며 이는 [그림 2.3.1]과 같다.

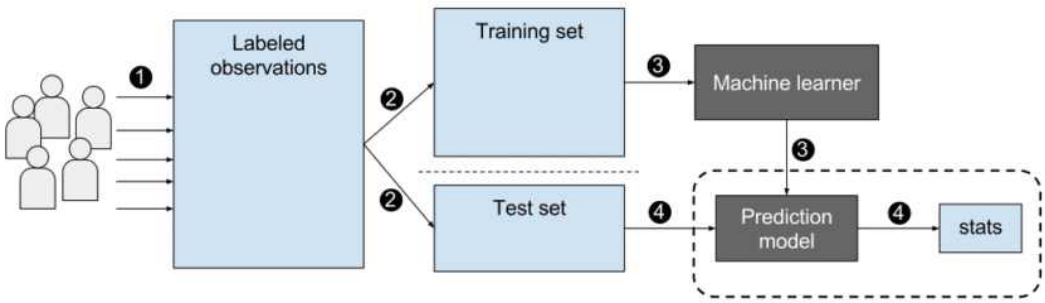

[그림 2.3.1] 지도학습의 과정 (출처: NVIDIA Korea, 2018)

인하대학교
INHA UNIVERSITY

반면, 비지도 학습은 입력 데이터의 레이블이 없는 상태에서 데이터를 분석하는 것으로, 마치 교사가 없는 상태에서 학생 스스로 학습하는 것과 같다. 이러한 알고리즘은 데이터를 스스로 탐구하며, 데이터에서 특징(features)을 학습함으로써 새로운 데이터를 분류하여 해당되는 클래스(class)를 인식한다. 비지도 방식의 머신러닝 모형은 주로 클러스터링(clustering)과 특징 축소(feature reduction)와 같은 작업에 활용된다.

1) 결정 트리 모형

결정 트리(decision tree)는 데이터를 분석하여 트리 형태의 모형을 구축하는 기법으로, 노드(node)와 이를 연결하는 엣지(edge)로 구성된다(Breiman et al., 2017; Quinlan, 1986). 결정 트리 모형은 분류(classification)와 회귀 분석(regression)에 모두 사용될 수 있기 때문에 CART(classification and regression tree)라고도 한다. 결정 트리 모형의 첫 번째 노드는 루트 노드(root node)라고 하며, 이는 전체 훈련 데이터 전체를 포함한다. 트리의 루트에서 시작하여 각 노드는 주어진 분할 기준(splitting criterion)에 따라 분할되며, 최종적으로 리프 노드(leaf)에 도달한다. 리프 노드는 출력층이 없는 노드로, 각 리프에 포함된 샘플에 해당하는 레이블은 동일한 리프에 도달한 새로운 샘플의 예측 레이블로 사용된다. 아래의 [그림 2.3.2]는 결정 트리의 예시 구조를 보여준다.

인하대학교
INHA UNIVERSITY

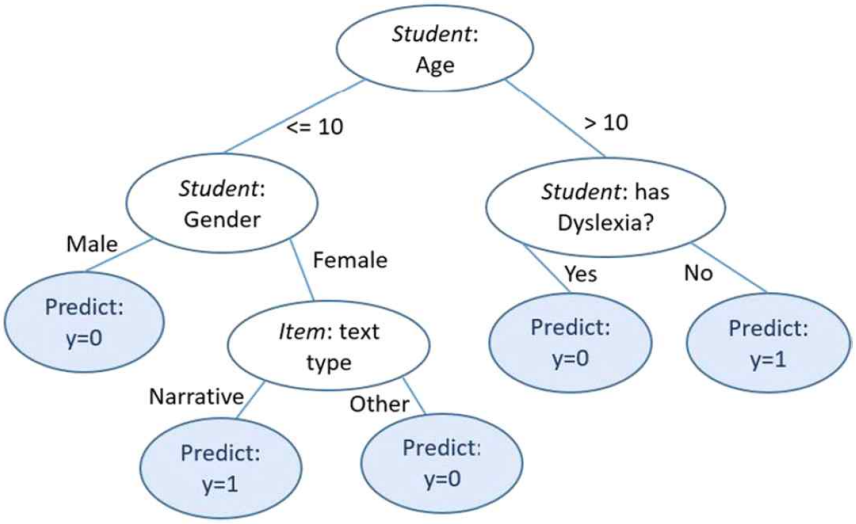

[그림 2.3.2] 결정 트리의 구조 (출처: Park et al., 2023)

결정 트리 모형에서는 주로 다수결 규칙(majority rule)에 따라 라벨링(labeling)을 진행한다. 즉, 리프 내에서 가장 많이 나타나는 레이블을 해당 리프에 속하는 새로운 샘플의 예측값으로 사용하는 것이다. 이러한 결정 트리는 모형의 확장과 분석 결과 해석이 용이하다는 점에서 다양한 분야에 활용되고 있으나, 예측의 불안정성과 과적합(overfitting) 문제의 우려가 있다. 이러한 한계로 인해 결정 트리 모형은 상대적으로 성능이 약한 분류기로 간주되기도 하며, 이를 극복하기 위한 방법으로 앙상블 학습(ensemble learning)을 활용할 수 있다(Fernández-Delgado et al., 2014).

앙상블 학습은 분류기(classifier)나 회귀 모형(regressor)와 같은 다수의 모형을 생성하고 이를 전략적으로 결합하여 특정 문제를 해결하는 기법이다. 앙상블 학습 기법은 주로 모형의 성능을 향상시키거나, 낮은 성능의 모형이 선택될 가능성을 줄이기 위해 사용되며, 앙상블 학습은 모형이 내린 결정에 대한 신뢰도 할당(confidence assignment), 최적의 특징 선택(optimal feature selection), 데이터 융합(data fusion), 점진적 학습(incremental learning), 비정상

인하대학교
INHA UNIVERSITY

적 학습(non-stationary learning), 오류 수정 등과 같은 다양한 응용 분야에서 활용된다.

앙상블 학습은 다수의 결정 트리를 구축한 뒤, 이들의 결과를 결합하여 최종 출력을 생성하는 방식으로 작동하며, 각 트리는 새로운 샘플의 최종 예측을 수행한다. 본 연구는 이러한 앙상블 학습 기반의 머신러닝 모형 중에서 랜덤 포레스트(random forest; Breiman, 2001) 모형과 그래디언트 부스팅(gradient boosting; Friedman, 2001; Chen & Guestrin, 2016) 모형을 활용하여 다분 문항 데이터에서 문항 난도에 대한 예측을 실시하였다.

2) 랜덤 포레스트 모형

랜덤 포레스트 모형(random forest)은 여러 개의 결정 트리를 결합한 앙상블 머신러닝 모형로, 트리 간의 다양성을 보장할 수 있다는 점이 중요한 이점이다. 이러한 다양성은 훈련 데이터의 부트스트랩(bootstrap)과 데이터의 특징 또는 배경 정보를 무작위로 선택하는 과정을 통해 이루어진다.

구체적으로, 랜덤 포레스트 모형을 구성하는 각 결정 트리는 훈련 데이터 세트의 무작위 하위 집합을 기반으로 구축된다. 즉, 각 노드에서 분할할 때 무작위로 설명변수를 선택함으로써 결정 트리의 다양성을 높이면서 모형 간의 상관을 감소시킨다(한정아, 2023). 또한, 각 트리의 노드는 무작위로 선택된 특징의 하위 집합에서 가장 적합한 기준을 계산하여 분할되며, 이 과정은 트리 간의 다양성을 더욱 증가시킨다. 최종적으로, 랜덤 포레스트는 개별 결정 트리의 예측값을 평균화하여 최종 예측값을 산출하는데 이러한 방식은 기존 트리 기반 학습의 장점인 확장성과 계산 효율성을 보장한다.

랜덤 포레스트 모형의 핵심적인 메커니즘은 [그림 2.3.2]에 제시된 결정 트리 구조를 기반으로 하며, 이러한 결정 트리는 주어진 데이터를 특정 기준에 따라 반복적으로 두 그룹으로 나누는 방식으로 작동하며, 이러한 과정은 트리의

인하대학교
INHA UNIVERSITY

최대 깊이나 노드 내의 데이터 수와 같이 사전에 정해진 정지 조건이 충족될 때까지 계속된다. [그림 2.3.3]은 이러한 랜덤 포레스트 모형의 알고리즘을 시각화한 예시로, 랜덤 포레스트의 데이터 분할 과정을 보여준다(Schonlau & Zou, 2020).

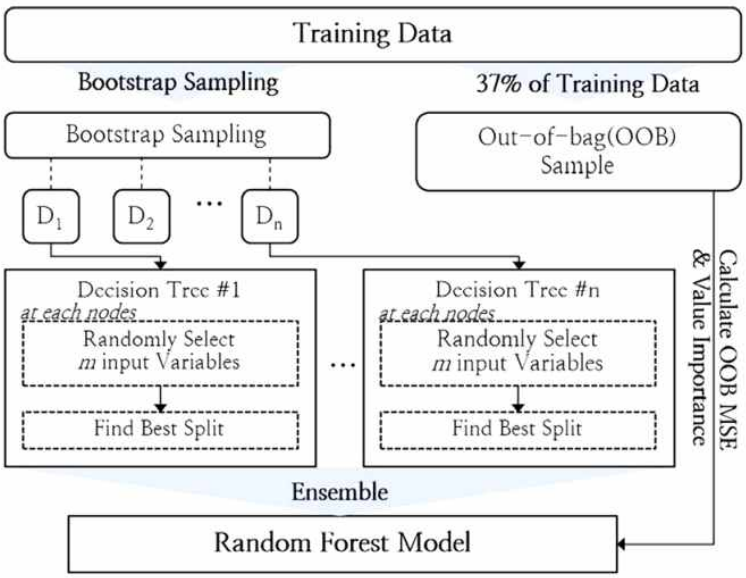

[그림 2.3.3] 랜덤 포레스트 모형의 알고리즘 (출처: 이지혜, 강동수, 2021)

Breiman(2001)의 연구에 따르면, 랜덤 포레스트는 단일 결정 트리보다 높은 예측 성능을 나타내며, 이는 부트스트랩 샘플링과 무작위 특징 선택으로 인해 모형의 일반화 능력이 향상되고 이상치(outlier)에 크게 영향을 받지 않기 때문이라고 설명하였다. 더불어, 랜덤 포레스트에 속한 각 결정 트리는 독립적으로 예측을 수행하고, 이를 병렬 처리할 수 있으므로 대규모 데이터에서도 빠르고 효율적인 예측이 가능하다는 장점이 있다(김길재, 김병주, 2024).

인하대학교
INHA UNIVERSITY

3) 그래디언트 부스팅 모형

그래디언트 부스팅 모형(gradient boosting)은 Friedman(2001)이 제안한 기법으로, 앙상블 학습 방법 중 하나인 부스팅(boosting)을 통해 여러 학습기를 순차적으로 결합하여 앙상블 모형을 구성한다. 부스팅은 비교적 부정확하고 약한 학습기(weak learner)를 다수 묶어 보다 정확하고 강한 학습기(strong learner)를 만드는 방식이다. 이때, 약한 학습기는 진분류(true classification)와 낮은 상관을 보이는 분류기를 의미하며, 강한 학습기는 진분류와 높은 상관성을 가진 분류기를 말한다. 부스팅은 편향(bias)과 분산(variance)을 줄이고 모형의 일반화 성능을 향상시키는 데 사용되는 앙상블 학습 기술이다. 이 과정에서 첫 번째 학습 모형이 예측을 수행한 뒤, 그 과정에서 발생한 예측 오류를 보완하는 새로운 학습 모형을 순차적으로 추가함으로써 강한 학습기를 구축하게 된다(허주성 외, 2018).

구체적으로, 그래디언트 부스팅 모형은 이전 학습 결과를 기반으로 샘플의 가중치를 조정하며, 이를 통해 예측 오류를 교정하고 모형의 성능을 점진적으로 향상시킨다(장필식, 2022). 이 과정을 여러 번 반복하여 다수의 트리를 구축하며, 최종 예측값은 각 트리의 예측값에 가중치를 부여한 합으로 계산된다. 이때, 약한 학습기는 일반적으로 예측 성능이 뛰어나지 않은 간단한 모형을 지칭하며, 그래디언트 부스팅 모형에는 결정 트리 모형이 주로 사용된다. 그래디언트 부스팅을 통해 구축한 모형은 예측 성능이 우수하다는 장점이 있지만, 대규모 데이터셋에 대해서는 훈련 시간이 길다는 단점도 지닌다(장필식, 2022). 아래의 [그림 2.3.4]는 이러한 그래디언트 부스팅 결정 트리 구조의 예시를 보여준다.

인하대학교
INHA UNIVERSITY

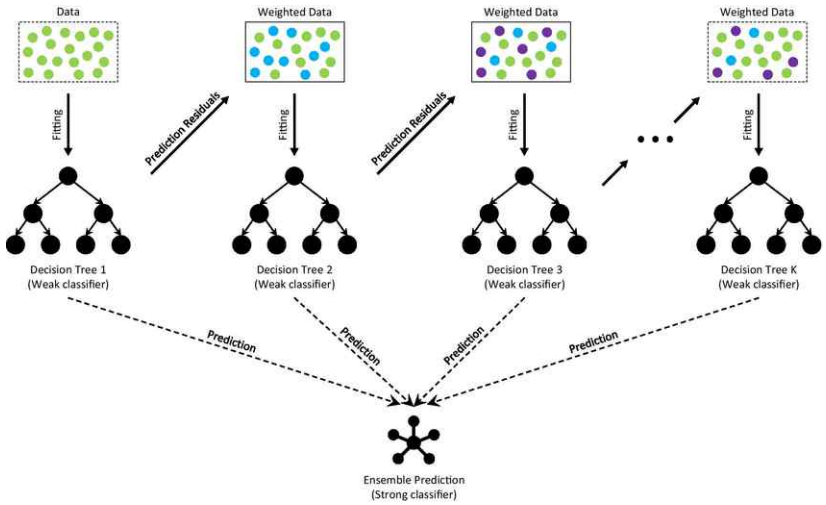

[그림 2.3.4] 그래디언트 부스팅 결정 트리의 구조 (출처: Deng, et al., 2021)

특히, 그래디언트 부스팅의 변형 기법인 익스트림 그래디언트 부스팅(extreme gradient boosting, XGBoost; Chen, 2015)은 높은 예측 성능과 빠른 실행 속도로 인해 머신러닝 커뮤니티에서 널리 사용되며 높은 평가를 받고 있다. XGBoost는 그래디언트 부스팅과 동일한 구조를 기반으로 하지만, 추가된 정규화 항(regularization term)을 통해 모형의 복잡도가 증가할 때 벌점을 부과함으로써 과적합을 방지하고 모형의 성능을 더욱 향상시킨다(문지영, 조명근, 2023).

인하대학교
INHA UNIVERSITY

Ⅲ. 연구 방법

1. 분석 자료

본 연구는 다분 문항 유형의 검사에서 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅)과 설명적 문항반응모형 간 문항 난도 추정 정확성을 비교하는 데에 목적을 두고 있다. 이를 위해 본 연구에서는 언어적 공격성(verbal aggression; Vansteelandt & Van Mechelen, 2001) 데이터를 활용하였다. 해당 데이터는 벨기에 소재 대학의 심리학과 1학년 학생 316명을 대상으로 수집되었으며, 좌절감을 유발하는(frustrating) 상황에서 언어적으로 공격적인 반응의 정도를 측정하는 24개의 문항으로 구성되어 있다. 해당 데이터에서 모든 문항은 좌절감을 유발하는 상황에 대한 언어적 공격 반응을 묘사하고 있으며, 각 문항에 대한 응답은 '아니요(0), 아마도(1), 예(2)'의 척도로 구성되어 있다.

언어적 공격성 데이터에서 각 문항은 두 가지의 상황 유형(situation type)에 해당하는 상황과 각 상황에 대한 행동 방식(behavior mode)과 행동 유형(behavior type)을 결합하여 구성되었다. 해당 데이터에서 설정한 상황 유형은 '타인을 질책하는 상황(other-to-blame)'과 '자신을 탓하는 상황(self-to-blame)'이며, 각 상황에 대한 행동 방식은 언어적으로 공격적인 행동을 '하고 싶음(want)'과 '실제로 행함(do)'으로 구분되어 있다. 또한, 각 상황에 대한 행동 유형은 언어적 공격성의 정도에 따라 '욕설(curse)'과 '꾸짖음(scold)', '고함(shout)'으로 구분되어 있다. 이러한 언어적 공격성 데이터의 구조는 다음의 <표 3.1.1>과 같이 나타낼 수 있다.

인하대학교
INHA UNIVERSITY

<표 3.1.1> 언어적 공격성 데이터 구조

문항 번호	상황 (situations)	행동 방식 (behavier mode)		상황 유형 (situation type)		행동 유형 (behavier type)		
		Want	Do	Other-to-blame	Self-to-blame	Curse	Scold	Shout
1	버스가 정류장에서 나를 지나친다. (A bus fails to stop for me.)	1	0	1	0	1	0	0
2		1	0	1	0	0	1	0
3		1	0	1	0	0	0	1
4	직원이 잘못된 정보를 주어서 기차를 놓친다. (I miss a train because the clerk gave me faulty information.)	1	0	1	0	1	0	0
5		1	0	1	0	0	1	0
6		1	0	1	0	0	0	1
7	내가 가게에 들어가려고 하니, 영업시간이 종료된다. (The grocery store closes just as I am about to enter.)	1	0	0	1	1	0	0
8		1	0	0	1	0	1	0
9		1	0	0	1	0	0	1
10	마지막 동전을 사용했는데, 전화 연결이 끊긴다. (The operator disconnects me when I used up my last 10 cents for a call.)	1	0	0	1	1	0	0
11		1	0	0	1	0	1	0
12		1	0	0	1	0	0	1
13	버스가 정류장에서 나를 지나친다. (A bus fails to stop for me.)	0	1	1	0	1	0	0
14		0	1	1	0	0	1	0
15		0	1	1	0	0	0	1
16	직원이 잘못된 정보를 주어서 기차를 놓친다. (I miss a train because the clerk gave me faulty information.)	0	1	1	0	1	0	0
17		0	1	1	0	0	1	0
18		0	1	1	0	0	0	1
19	내가 가게에 들어가려고 하니, 영업시간이 종료된다. (The grocery store closes just as I am about to enter.)	0	1	0	1	1	0	0
20		0	1	0	1	0	1	0
21		0	1	0	1	0	0	1
22	마지막 동전을 사용했는데, 전화 연결이 끊긴다. (The operator disconnects me when I used up my last 10 cents for a call.)	0	1	0	1	1	0	0
23		0	1	0	1	0	1	0
24		0	1	0	1	0	0	1

<표 3.1.1>에서 볼 수 있듯이, 응답자는 제시된 각 상황에 대한 2가지의 행동 방식, 3가지의 행동 유형에 대한 의향을 선택하며, 총 4개의 상황에 대해 응답하게 되어 있다. 다음의 <표 3.1.2>는 이러한 언어적 공격성 데이터 구조

인하대학교
INHA UNIVERSITY

에 따라, 응답자에게 제시된 검사 문항과 해당 문항의 행동 방식 및 상황 유형, 응답 양식을 정리한 것이다.

<표 3.1.2> 언어적 공격성 문항 데이터

번호	문항 내용	행동 방식	상황 유형	응답 양식
1	버스가 정류장에서 나를 지나친다. 나는 욕설을 하고 싶을 것이다. (A bus fails to stop for me. I would want to curse.)	Want	Other-to-blame	아니오 (0) 아마도 (1) 예 (2)
2	버스가 정류장에서 나를 지나친다. 나는 꾸짖고 싶을 것이다. (A bus fails to stop for me. I would want to scold.)			
3	버스가 정류장에서 나를 지나친다. 나는 고함을 지르고 싶을 것이다. (A bus fails to stop for me. I would want to shout.)			
4	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 욕설을 하고 싶을 것이다. (I miss a train because the clerk gave me faulty information. I would want to curse.)			
5	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 꾸짖고 싶을 것이다. (I miss a train because the clerk gave me faulty information. I would want to scold.)			
6	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 고함을 지르고 싶을 것이다. (I miss a train because the clerk gave me faulty information. I would want to shout.)			
7	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 욕설을 하고 싶을 것이다. (The grocery store closes just as I am about to enter. I would want to curse.)		Self-to-blame	
8	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 꾸짖고 싶을 것이다. (The grocery store closes just as I am about to enter. I would want to scold.)			
9	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 고함을 지르고 싶을 것이다. (The grocery store closes just as I am about to enter. I would want to shout.)			
10	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 욕설을 하고 싶을 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would want to curse.)			
11	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 꾸짖고 싶을 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would want to scold.)			

인하대학교
INHA UNIVERSITY

번호	문항 내용	행동 방식	상황 유형	응답 양식
12	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 고함을 지르고 싶을 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would want to shout.)	Want	Self-to-blame	아니오 (0) 아마도 (1) 예 (2)
13	버스가 정류장에서 나를 지나친다. 나는 욕설을 할 것이다. (A bus fails to stop for me. I would curse.)	Do	Other-to-blame	아니오 (0) 아마도 (1) 예 (2)
14	버스가 정류장에서 나를 지나친다. 나는 꾸짖을 것이다. (A bus fails to stop for me. I would scold.)			
15	버스가 정류장에서 나를 지나친다. 나는 고함을 지를 것이다. (A bus fails to stop for me. I would shout.)			
16	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 욕설을 할 것이다. (I miss a train because the clerk gave me faulty information. I would curse.)			
17	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 꾸짖을 것이다. (I miss a train because the clerk gave me faulty information. I would scold.)			
18	직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 고함을 지를 것이다. (I miss a train because the clerk gave me faulty information. I would shout.)			
19	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 욕설을 할 것이다. (The grocery store closes just as I am about to enter. I would curse.)		Self-to-blame	
20	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 꾸짖을 것이다. (The grocery store closes just as I am about to enter. I would scold.)			
21	내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 고함을 지를 것이다. (The grocery store closes just as I am about to enter. I would shout.)			
22	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 욕설을 할 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would curse.)			
23	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 꾸짖을 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would scold.)			
24	마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 고함을 지를 것이다. (The operator disconnects me when I used up my last 10 cents for a call. I would shout.)			

인하대학교
INHA UNIVERSITY

2. 분석 방법

1) 설명적 부분점수모형

본 연구에서는 설명적 부분점수모형을 활용하여 언어적 공격성 데이터의 문항 및 응답 데이터를 분석하고 각 문항의 단계 난도를 추정하기 위해서 R(4.3.1) 프로그램을 사용하였으며, 통합개발환경으로는 R Studio(2023.06.0)를 사용하였다. 설명적 부분점수모형은 Rasch 계열의 확장 모형을 구현할 수 있는 eRm(Mair et al., 2024) 패키지를 활용하여 분석하였다.

앞서 밝혔듯, 언어적 공격성 데이터의 문항은 다분 문항으로, '아니오(0), 아마도(1), 예(2)' 의 세 가지 응답 범주로 구성되어 있다. 또한, 각 문항은 행동 방식과 상황 유형, 행동 유형의 세 가지 문항 특성으로 구성되어 있다. 따라서, 설명적 부분점수모형에서 각 문항 특성을 설명적 부분점수모형에 통합하기 위해서 각 특성에 대해 더미 코딩(dummy coding)을 적용하였다. 각 문항 특성에서 기준(reference)으로 설정된 값은 다음과 같다. 먼저, 행동 방식에서는 Want, 상황 유형 특성에서는 Self-to-blame, 행동 유형 특성에서는 고함(Shout)을 기준으로 설정하여 분석하였다.

2) 머신러닝 모형

본 연구의 목적은 랜덤 포레스트, 그래디언트 부스팅의 머신러닝 모형과 설명적 부분점수모형을 활용하여 다분 문항 및 응답 데이터를 분석하고 문항 난도 추정의 정확성을 파악하고 비교하는 데에 있다. 이를 위해 데이터 분석에서 Python(3.10.12) 프로그래밍 언어를 사용하였고, 통합개발환경으로는

인하대학교
INHA UNIVERSITY

Colaboratory를 사용하였다. 본 연구에서 사용한 주요 패키지로는 데이터 전처리 및 변환을 위한 pandas(2.2.2), 머신러닝 모형 구축 및 훈련, 성능 평가를 위해 sklearn(1.6.0), 분석 결과 시각화를 위해 matplotlib(3.8.0)을 활용하였다.

머신러닝 모형을 구축할 때에는 모형 훈련 데이터뿐만 아니라, 테스트 데이터에 대해서도 모형이 좋은 예측 성능을 가지도록 하는 것이 매우 중요하다. 이때, 훈련 데이터에서의 모형의 예측 성능에 비해 테스트 데이터에서의 예측 성능이 현저히 낮은 과적합(overfitting) 현상이 발생하지 않도록 모형을 구축하고 훈련해야 한다. 이와 같은 과적합 문제를 방지하기 위해서 일반적으로 훈련 데이터에 교차검증(cross-validation, CV)을 적용하여 모형을 구축한 후, 모형을 테스트 데이터에 적용하여 과적합을 최소화하고 모형을 타당화한다(유진은, 2021). 주로 교육학 영역에서는 훈련 데이터 세트의 규모가 작아 실제 분포를 포착하기 어렵고, 모형이 편향되어 있을 확률이 높기 때문에 k-겹 교차검증(k-fold cross-validation)을 실시한다(Romero et al., 2010). 교차검증은 과적합을 최소화하고 모형을 타당화하기 위한 방법으로, 교차검증을 실시할 때 훈련 데이터를 다시 검증 데이터로 분리하게 된다.

본 연구에서는 다분 문항에서의 피험자 응답 반응 예측 정확성을 탐색 및 설명적 부분점수모형과 비교하기 위해 생성한 데이터를 7:3의 비율로 훈련 데이터와 테스트 데이터로 무선 분할하였다. 또한, 본 연구에서 사용한 랜덤 포레스트 모형 및 그래디언트 부스팅 모형과 같이 트리 기반의 머신러닝 모형을 훈련할 때 일반적으로 권장되는 기준(Breiman, 2001)에 따라 10겹 교차검증(10-fold cross validation)을 수행하였다.

머신러닝 모형을 활용하여 문항 난도를 추정하는 데 있어서 추정 정확성을 높이기 위해 RandomizedSearchCV를 사용하여 각 모형에서 최적의 임계치가 도출되는 하이퍼파라미터를 탐색한 후 해당 하이퍼파라미터로 설정된 모형을 분석에 활용하였다. 다음의 <표 3.2.1>는 본 연구에서 적용한 머신러닝 모형의 하이퍼파라미터의 요소와 범위를 정리한 것으로, 랜덤 포레스트 모형을 활용하여 데이터를 분석한 선행 연구(조수빈, 2023; Choi. 2024; Park et al., 2023)

인하대학교
INHA UNIVERSITY

와 같이 결정 트리의 개수(n_estimators), 리프 노드의 최소 샘플 수(min_samples_leaf), 각 결정 트리의 최대 깊이(max_depth), 각 노드를 분할할 때의 최소 샘플 수(min_sample_split)의 하이퍼파라미터(hyperparameter)의 범위를 설정하였다. 또한, 그래디언트 부스팅 모형에서는 각 결정 트리의 최대 깊이(max_depth), 결정 트리의 개수(n_estimators), 학습률(learning_rate)의 하이퍼파라미터 범위를 설정하여 최적의 하이퍼파라미터를 탐색하였다.

<표 3.2.1> 머신러닝 모형의 하이퍼파라미터 요소 및 범위

모형 구분	하이퍼파라미터
랜덤 포레스트	리프 노드의 최소 샘플 수(min_samples_leaf): 1, 2, 5
	결정 트리의 개수(n_estimators): 25, 50, 100, 200
	각 결정 트리의 최대 깊이(max_depth): 3, 6, 9
	각 노드 분할 시의 최소 샘플 수(min_sample_split): 2, 5, 10
그래디언트 부스팅	각 결정 트리의 최대 깊이(max_depth): 3, 6, 9
	결정 트리의 개수(n_estimators): 25, 50, 100, 200
	학습률(learning_rate): 0.001, 0.01, 0.1, 0.2

이러한 과정을 통해 도출한 각 모형의 하이퍼파라미터는 다음의 <표 3.2.2>와 같으며, 본 연구에서는 해당 하이퍼파라미터를 적용한 모형을 활용하여 문항 및 응답 데이터를 분석하였다.

<표 3.2.2> 각 머신러닝 모형의 하이퍼파라미터 선정 결과

모형 구분	하이퍼파라미터
랜덤 포레스트	리프 노드의 최소 샘플 수(min_samples_leaf): 1
	결정 트리의 개수(n_estimators): 200
	각 결정 트리의 최대 깊이(max_depth): 6
	각 노드 분할 시의 최소 샘플 수(min_sample_split): 2
그래디언트 부스팅	각 결정 트리의 최대 깊이(max_depth): 9
	결정 트리의 개수(n_estimators): 100
	학습률(learning_rate): 0.1

인하대학교
INHA UNIVERSITY

3. 평가 준거

본 연구에서는 다분 문항으로 구성된 검사에서 머신러닝 모형과 설명적 부분점수모형 간의 문항 난도를 추정하는 데 있어서 정확성을 비교하고자 하였다. 따라서, 각 문항의 단계 난도 추정치와 실제 단계 난도와의 상관계수, 평균제곱오차(mean squared error, MSE)를 통해 각 모형의 추정 정확성을 비교하였다.

1) 모수 추정치와 실제 모수 간 상관

$$r = \rho(\beta_{ik}, \widehat{\beta_{ik}}) = \frac{cov(\sigma_{ik}, \widehat{\sigma_{ik}})}{\sigma_{ik}\widehat{\sigma_{ik}}} \tag{3.3.1}$$

식(3.3.1)은 머신러닝 모형과 설명적 부분점수모형에서 추정한 전체 검사 문항의 단계 난도와 본 연구에서 실제 문항의 단계 난도(참값)로 상정한 부분점수모형의 전체 문항의 단계 난도 추정치와의 상관계수를 나타낸 것이다. 위 식에서 β_{ik}는 문항 i의 각 단계 k의 난도를 의미하며, $\widehat{\beta_{ik}}$는 각 모형이 추정한 문항의 단계 난도 추정치를 의미한다. 상관계수(r)는 $-1 \leq r \leq 1$의 범위로 산출되며, 1에 가까울수록 모형의 추정치와 실제 값의 상관이 높다고 해석할 수 있다. 따라서, 상관계수가 높을수록 각 모형의 추정치가 실제 값과 유사하다고 볼 수 있다.

인하대학교
INHA UNIVERSITY

2) 평균제곱오차

회귀모형을 비롯한 머신러닝 모형에서 종속변수가 연속 변수일 경우, 모형의 예측 정확성을 평가하기 위해 대표적으로는 RMSE, 또는 평균제곱오차(mean squared error, MSE)를 활용한다(김형관, 유진은, 2020; 정혜원, 박소영, 2021). 본 연구에서 종속변수는 다분 문항의 단계 난도로, 이는 연속 변수에 해당한다. 따라서, 머신러닝 모형과 설명적 부분점수모형의 문항 난도 추정 정확성을 비교하고 평가하기 위한 지표로서 평균제곱오차를 활용하였으며 이는 식(3.3.2)과 같이 산출된다.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2 \qquad (3.3.2)$$

식(3.3.2)에서 n은 모형의 추정 횟수, y_i는 실제 값, $\hat{y_i}$는 모형의 추정치를 의미하며, 모형이 추정한 단계 난도와 실제 단계 난도 값 간의 차이를 활용하여 예측의 오차를 평가할 수 있다. 평균제곱오차는 그 값이 0에 가까울수록 모형의 예측 오차가 작다는 것을 나타내며, 상대적인 예측 정확성을 평가할 수 있는 지표라고 할 수 있다(서지범, 강남화, 2023).

인하대학교
INHA UNIVERSITY

Ⅳ. 연구 결과

1. 모형별 난도 추정 결과

본 연구는 다분 문항 유형의 검사에서 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅)과 설명적 부분점수모형 간 문항 난도 추정의 정확성을 분석하고 비교하는 데 목적을 두고 있다. 이에 따라, 언어적 공격성을 측정하는 문항과 응답 반응 데이터에 각 모형을 적용하여 각 문항의 난도를 추정한 결과는 다음과 같다. 이때, 부분점수모형과 설명적 부분점수모형은 문항 모수 및 피험자 능력 모수를 추정하는 것을 목적으로 개발된 모형임에 따라, 언어적 공격성 데이터에 대한 각 모형 설계의 적합성을 분석하였다. 또한, 설명적 부분점수모형은 문항 특성의 효과를 추정할 수 있는 모형임에 따라 언어적 공겨성 데이터 내 검사 문항의 특성이 각 문항의 단계 난도에 미치는 효과를 추정한 결과를 제시하였다.

1) 부분점수모형

본 연구에서는 언어적 공격성 데이터에 대해 설명적 부분점수모형과 랜덤 포레스트 모형, 그래디언트 부스팅 모형이 각 문항의 단계 난도를 추정하고 추정 결과의 정확성을 비교하기 위해 부분점수모형(이하 ‘PCM’)으로 추정한 문항의 단계 난도를 실제 문항의 단계 난도, 즉 참값이라고 상정하였다. 이에 따라, R(4.3.1) 프로그램의 mirt 패키지를 사용하여 부분점수모형을 설계하고 언어적 공격성 데이터의 24개 문항에 대해 각 문항의 단계 난도를 추정하였으며 그 결과는 다음의 <표 4.1.1>과 같다.

인하대학교
INHA UNIVERSITY

<표 4.1.1> 부분점수모형의 문항별 단계 난도

문항 번호	1단계 난도 추정치(δ_{i1})	2단계 난도 추정치(δ_{i2})
1	-0.42	**-0.08**
2	0.13	0.15
3	0.32	0.94
4	**-0.97**	-0.03
5	-0.03	0.21
6	0.50	0.59
7	-0.13	1.00
8	0.82	1.87
9	1.49	2.48
10	-0.56	0.66
11	0.66	1.16
12	1.28	1.31
13	-0.53	0.18
14	0.14	0.56
15	1.15	1.20
16	-0.18	0.18
17	0.46	0.90
18	1.62	1.55
19	0.41	1.68
20	1.51	2.21
21	**2.76**	**3.08**
22	-0.23	0.75
23	0.65	1.33
24	1.99	2.07
평균(표준편차)	0.54 (0.89)	1.08 (0.82)

Note. 소수점 셋째 자리에서 반올림하였음.

인하대학교
INHA UNIVERSITY

부분점수모형의 각 문항의 단계 난도 추정 결과, 피험자가 각 문항에 대해 '아마도(1)' 라고 응답하는 것의 어려운 정도를 의미하는 1단계 난도의 평균은 0.54이며 4번 문항('직원이 잘못된 정보를 주어서 기차를 놓친다. 나는 욕설을 하고 싶을 것이다.')의 1단계 난도가 -0.97로 가장 낮았다. 반면, 1단계 난도가 가장 높은 문항은 21번 문항('내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 고함을 지를 것이다.')으로, 1단계 난도 추정치는 2.76으로 나타났다.

피험자가 각 문항에 대해 '예(2)' 라고 응답하는 것의 어려운 정도를 의미하는 2단계 난도의 평균은 1.08로, 1단계의 평균 난도에 비해 전반적으로 높게 나타났다. 전체 검사 문항에서 2단계 난도가 가장 낮은 문항은 1번 문항('버스가 정류장에서 나를 지나친다. 나는 욕설을 하고 싶을 것이다.')으로, 2단계 난도 추정치는 -0.08이었다. 반면에, 2단계 난도가 가장 높은 문항은 1단계와 마찬가지로 21번 문항으로, 2단계 난도 추정치는 3.08로 나타났다.

다음으로, 본 연구에서 설계한 부분점수모형이 언어적 공격성 데이터의 문항 및 응답 반응을 분석하기에 적합한 정도를 확인하기 위해 AIC(Akaike information criterion), BIC(Baysian information criterion) 적합도 지수를 산출하였다. 그 결과, 부분점수모형의 AIC는 12737.75, BIC는 13131.26로 나타났다.

2) 설명적 부분점수모형

본 연구에서는 설명적 부분점수모형을 설계하고 언어적 공격성 데이터의 24개 문항에 대해 각 문항 특성(행동 방식, 상황 유형, 행동 유형)이 문항의 단계 난도에 미치는 효과를 추정하였으며, 그 결과는 다음의 <표 4.1.2>와 같다.

인하대학교
INHA UNIVERSITY

<표 4.1.2> 설명적 부분점수모형의 문항 특성 효과

문항 특성		문항 특성 효과 추정치	표준 오차(SE)	유의확률(p)
상수(절편)	ω_{01}	1.42	0.09	$<.001$
	ω_{02}	1.77	0.12	$<.001$
행동 방식 (Do)	ω_{Do1}	0.54	0.06	$<.001$
	ω_{Do2}	0.35	0.07	$<.001$
상황 유형 (Other-to-blame)	$\omega_{Other\,1}$	-0.69	0.06	$<.001$
	$\omega_{Other\,2}$	-0.97	0.08	$<.001$
행동 유형 (Curse)	$\omega_{Curse\,1}$	-1.68	0.08	$<.001$
	$\omega_{Curse\,2}$	-0.93	0.10	$<.001$
행동 유형 (Scold)	$\omega_{Scold\,1}$	-0.80	0.07	$<.001$
	$\omega_{Scold\,2}$	-0.50	0.10	$<.001$

상술한 바와 같이, 언어적 공격성의 검사 문항에서 1단계 난도는 '아마도(1)' 라고 답하는 것이 '아니오(0)' 라고 응답하는 것보다 더 어려운 정도를 나타내며, 2단계 난도는 '예(2)' 라고 답하는 것이 '아마도(1)' 라고 답하는 것보다 더 어려운 정도를 의미한다. <표 4.1.2>와 같이 설명적 부분점수모형에서 절편(ω_{01}, ω_{02})을 포함한 모든 문항 특성 효과 추정치(ω)는 유의수준 0.01에서 통계적으로 유의미한 것으로 나타났다.

언어적 공격성 검사 문항의 특성은 '행동 방식, 상황 유형, 행동 유형' 의 세 가지로 구성되어 있으며, 각 문항 특성이 1단계 단계 난도에 미치는 효과는 다음과 같다. 먼저, 다른 문항 특성이 일정하다고 가정할 때 행동 방식에서 실제로 공격적 반응을 보이는 것(이하 'Do')은 공격적으로 반응하고 싶어 하는 것(이하 'Want')에 비해 0.54 로짓(logit)만큼 어렵다고 해석할 수 있다($\omega_{Do1} = 0.54$). 또한, 상황 유형에서 타인을 질책하는 상황(이하 'Other-to-blame')은 자신을 탓하는 상황(이하 'Self-to-blame')에 비해 0.69 로짓만큼 쉽다고 해석할 수 있다($\omega_{Other\,1} = -0.69$). 행동 유형에서 고함을 지르는 것(이하 'Shout')과 비교했을 때, 욕설(이하 'Curse')은 1.68 로짓

인하대학교
INHA UNIVERSITY

만큼 쉬웠으며($\omega_{Curse\,1} = -1.68$), Shout에 응답하는 것에 비해 꾸짖는 행동(이하 'Scold')은 0.80 로짓만큼 쉬운 것으로 나타났다($\omega_{Scold\,1} = -0.80$).

2단계 난도에 대해서는 다른 특성이 일정하다고 가정할 때, 행동 방식에서 Do는 Want에 동의하는 것에 비해 0.35 로짓만큼 어렵다고 할 수 있으며($\omega_{Do2} = 0.35$), 상황 유형에서 Other-to-blame은 Self-to-blame보다 0.97 로짓만큼 쉬운 것으로 나타났다($\omega_{Other\,2} = -0.97$). 또한, 행동 유형에서 Curse는 Shout에 비해 0.93 로짓만큼 쉽고($\omega_{Curse\,2} = -0.93$), Scold는 Shout에 비해 0.5 로짓만큼 쉬운 것으로 나타났다($\omega_{Scold\,2} = -0.5$).

설명적 부분점수모형에서 각 문항의 단계별 난도는 각 문항 특성의 단계별 효과의 가중합으로 계산될 수 있다. 예를 들어, 1번 문항('버스가 정류장에서 나를 지나친다. 나는 욕설을 하고 싶을 것이다.')의 1단계 난도($\widehat{\delta_{11}}$)는 1단계 절편($\omega_{01} = 1.42$)과 해당 문항의 특성 효과($\omega_{Want1} = 0.00$, $\omega_{Other\,1} = -0.69$, $\omega_{Curse\,1} = -1.68$)를 합한 것과 같다. 이러한 과정을 통해 설명적 부분점수모형에서 산출한 각 문항의 단계별 난도는 다음의 <표 4.1.3>과 같다.

설명적 부분점수모형의 각 문항의 단계 난도 추정 결과, 1단계 난도의 평균은 0.52, 표준편차는 0.81이었으며, 1번과 4번 문항의 1단계 난도가 -0.95로 가장 낮았다. 반면, 1단계 난도가 가장 높은 문항은 21번과 24번 문항으로, 1단계 난도 추정치는 1.96으로 나타났다. 또한, 2단계 난도의 평균은 0.98로 부분점수모형과 마찬가지로 1단계의 평균 난도에 비해 전반적으로 높게 나타났다. 전체 검사 문항에서 2단계 난도가 가장 낮은 문항은 1번과 4번 문항으로, 2단계 난도 추정치는 -0.13이었다. 반면에, 2단계 난도가 가장 높은 문항은 1단계와 마찬가지로 21번과 24번 문항으로, 2단계 난도 추정치는 2.12로 나타났다.

인하대학교
INHA UNIVERSITY

<표 4.1.3> 설명적 부분점수모형의 문항별 단계 난도

문항 번호	1단계 난도 추정치($\widehat{\delta_{i1}}$)	2단계 난도 추정치($\widehat{\delta_{i2}}$)
1	**-0.95**	**-0.13**
2	-0.07	0.3
3	0.73	0.8
4	**-0.95**	-0.13
5	-0.07	0.3
6	0.73	0.8
7	-0.26	0.84
8	0.62	1.27
9	1.42	1.77
10	-0.26	0.84
11	0.62	1.27
12	1.42	1.77
13	-0.41	0.22
14	0.47	0.65
15	1.27	1.15
16	-0.41	0.22
17	0.47	0.65
18	1.27	1.15
19	0.28	1.19
20	1.16	1.62
21	**1.96**	**2.12**
22	0.28	1.19
23	1.16	1.62
24	**1.96**	**2.12**
평균(표준편차)	0.52 (0.81)	0.98 (0.64)

Note. 소수점 셋째 자리에서 반올림하였음.

인하대학교
INHA UNIVERSITY

마지막으로, 설명적 부분점수모형이 언어적 공격성 데이터를 분석하는 데 있어서 적합한 모형인지 여부를 파악하기 위해 AIC와 BIC 적합도 지수를 산출하였으며 이를 부분점수모형의 AIC, BIC 지수와 비교한 결과는 다음의 <표 4.1.4>와 같다.

<표 4.1.4> 설명적 부분점수모형과 부분점수모형의 모형 적합도

구분	부분점수모형	설명적 부분점수모형
AIC	12737.75	12865.21
BIC	13131.26	12954.14
N_{par}	49	11

Note. 소수점 셋째 자리에서 반올림하였음, N_{par} = 추정된 모수의 개수

<표 4.1.4>에서 볼 수 있듯이 PCM의 AIC 값은 12737.75로, 설명적 부분점수모형(이하 'LPCM')의 AIC 값(12865.21)보다 낮았다. 이는 LPCM이 PCM에 비해 추정한 모수의 개수가 적어, 보다 간결한 모형임에도 불구하고 PCM에 비해 모형의 적합성이 낮음을 의미한다. 그러나, BIC에서는 LPCM의 BIC 값이 12954.14로, PCM의 BIC 값(13131.26)보다 낮게 나타나며 AIC와는 상반된 결과가 도출되었다. 이는 AIC보다 BIC에서 추정된 모수의 개수가 증가할수록 부여하는 벌점(penalty term)이 더 많다는 점을 고려했을 때, LPCM에서 추정한 모수의 개수가 PCM보다 작기 때문에 BIC가 더 낮게 나타났다고 이해할 수 있다(Kuha, 2004; Wagenmakers & Farrell, 2004).

2) 랜덤 포레스트 모형

랜덤 포레스트 모형을 활용하여 각 문항의 단계 난도를 추정한 결과는 <표 4.1.5>와 같다. 1단계 난도의 평균은 0.47, 표준편차는 0.52였으며, 13번 문항('버스가 정류장에서 나를 지나친다. 나는 욕설을 할 것이다.')의 1단계 난도가 -0.34로 가장 낮은 것으로 나타났다. 반면, 1단계 난도가 가장 높은 문항

인하대학교
INHA UNIVERSITY

은 20번 문항('내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 꾸짖을 것이다.')으로, 1단계 난도 추정치는 1.25로 나타났다. 2단계 난도의 평균은 1.02, 표준편차는 0.55로 1단계의 평균 난도에 비해 전반적으로 높게 나타났다. 전체 검사 문항에서 2단계 난도가 가장 낮은 문항은 1번 문항으로, 2단계 난도 추정치는 -0.21이었다. 반면에, 2단계 난도가 가장 높은 문항은 20번 문항으로, 2단계 난도 추정치는 2.01로 나타났다. 이러한 랜덤 포레스트 모형의 문항별 단계 난도 추정치의 추이를 확인하기 위해 분석 결과를 시각화한 결과는 다음의 [그림 4.1.1]과 같다.

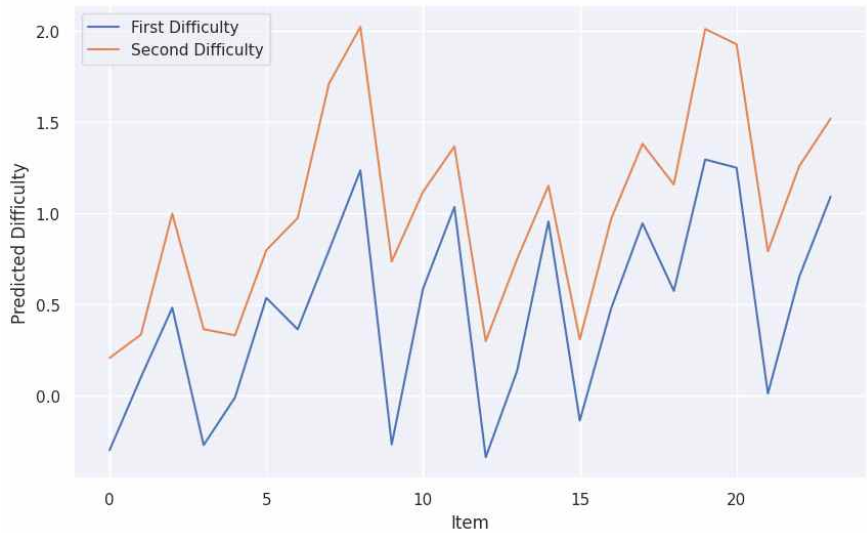

[그림 4.1.1] 랜덤 포레스트 모형의 문항별 단계 난도 추정치 변화

인하대학교
INHA UNIVERSITY

<표 4.1.5> 랜덤 포레스트 모형의 문항별 단계 난도

문항 번호	1단계 난도 추정치($\widehat{\delta_{i1}}$)	2단계 난도 추정치($\widehat{\delta_{i2}}$)
1	-0.30	**0.21**
2	0.10	0.33
3	0.48	1.00
4	-0.27	0.36
5	-0.01	0.33
6	0.54	0.80
7	0.36	0.97
8	0.80	1.71
9	1.23	2.02
10	-0.27	0.74
11	0.59	1.12
12	1.03	1.37
13	**-0.34**	0.30
14	0.14	0.75
15	0.95	1.15
16	-0.14	0.31
17	0.48	0.97
18	0.94	1.38
19	0.57	1.16
20	**1.29**	**2.01**
21	1.25	1.93
22	0.01	0.79
23	0.65	1.26
24	1.09	1.52
평균(표준편차)	0.47 (0.52)	1.02 (0.55)

Note. 소수점 셋째 자리에서 반올림하였음.

인하대학교
INHA UNIVERSITY

더불어, 본 연구에서 실제 단계 난도로 상정한 PCM의 문항별 단계 난도와 랜덤 포레스트 모형의 문항별 단계 난도 간의 관계를 파악하기 위해 이를 시각화한 결과는 다음의 [그림 4.1.2]와 같다.

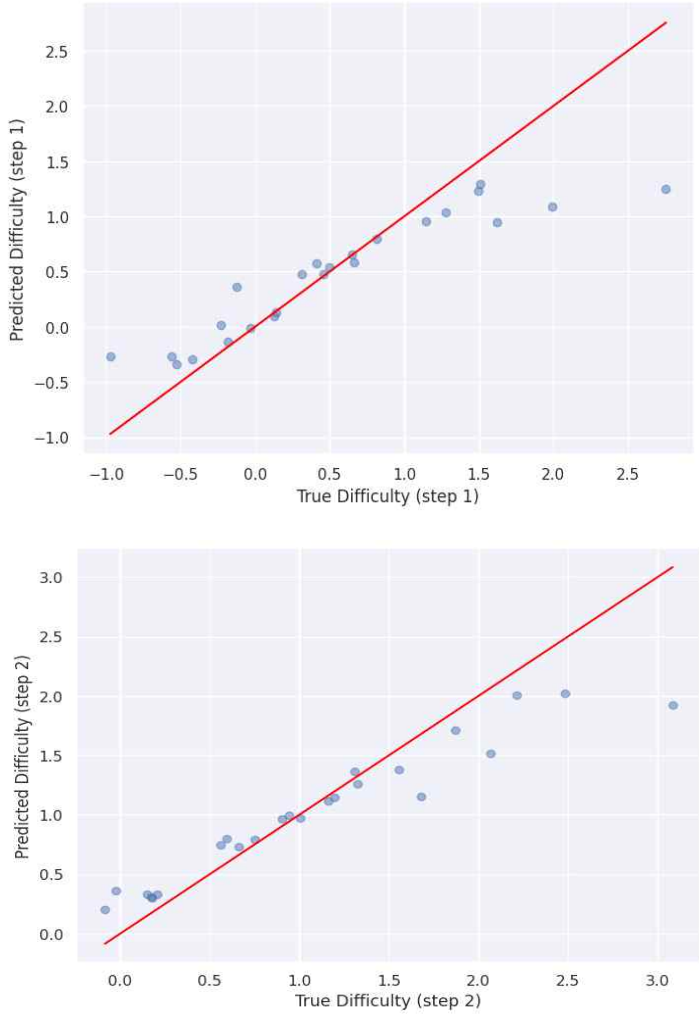

[그림 4.1.2] 랜덤 포레스트 모형의 단계 난도 추정치 분포(위: 1단계, 아래: 2단계)

인하대학교
INHA UNIVERSITY

3) 그래디언트 부스팅 모형

다음으로, 그래디언트 부스팅 모형을 활용하여 각 문항의 단계 난도를 추정한 결과는 <표 4.1.6>과 같다. 1단계 난도의 평균은 0.50, 표준편차는 0.70이었으며, 10번 문항('마지막 동전을 사용했는데, 전화 연결이 끊긴다. 나는 욕설을 하고 싶을 것이다.')의 1단계 난도가 -0.56으로 가장 낮았다. 반면, 1단계 난도가 가장 높은 문항은 20번 문항('내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 꾸짖을 것이다.')으로, 1단계 난도 추정치는 1.51로 나타났다. 2단계 난도의 평균은 1.03, 표준편차는 0.75로 1단계의 평균 난도에 비해 전반적으로 높게 나타났다. 전체 검사 문항에서 2단계 난도가 가장 낮은 문항은 1번 문항으로, 2단계 난도 추정치는 -0.08이었다. 반면에, 2단계 난도가 가장 높은 문항은 9번 문항('내가 가게에 들어가려고 하니, 영업시간이 종료된다. 나는 고함을 지르고 싶을 것이다.')으로, 2단계 난도 추정치는 2.48로 나타났다. 이러한 그래디언트 부스팅 모형의 문항별 단계 난도 추정치의 추이를 확인하기 위해 분석 결과를 시각화한 결과는 다음의 [그림 4.1.3]과 같다.

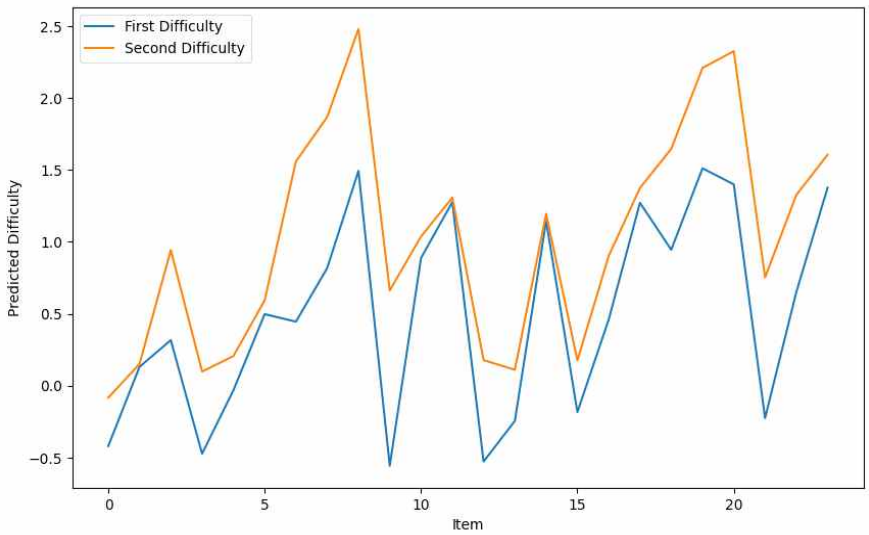

[그림 4.1.3] 그래디언트 부스팅 모형의 문항별 단계 난도 추정치 변화

인하대학교
INHA UNIVERSITY

<표 4.1.6> 그래디언트 부스팅 모형의 문항별 단계 난도

문항 번호	1단계 난도 추정치($\widehat{\delta_{i1}}$)	2단계 난도 추정치($\widehat{\delta_{i2}}$)
1	-0.42	**-0.08**
2	0.13	0.15
3	0.32	0.94
4	-0.47	0.10
5	-0.03	0.21
6	0.50	0.59
7	0.44	1.56
8	0.82	1.87
9	1.49	**2.48**
10	**-0.56**	0.66
11	0.89	1.04
12	1.28	1.31
13	-0.53	0.18
14	-0.25	0.11
15	1.15	1.20
16	-0.18	0.18
17	0.46	0.90
18	1.27	1.37
19	0.95	1.65
20	**1.51**	2.21
21	1.40	2.33
22	-0.23	0.75
23	0.65	1.33
24	1.38	1.61
평균(표준편차)	0.50 (0.70)	1.03 (0.75)

Note. 소수점 셋째 자리에서 반올림하였음.

인하대학교
INHA UNIVERSITY

더불어, 본 연구에서 실제 단계 난도로 상정한 PCM의 문항별 단계 난도와 그래디언트 부스팅 모형의 문항별 단계 난도 간의 관계를 파악하기 위해 이를 시각화한 결과는 다음의 [그림 4.1.4]와 같다.

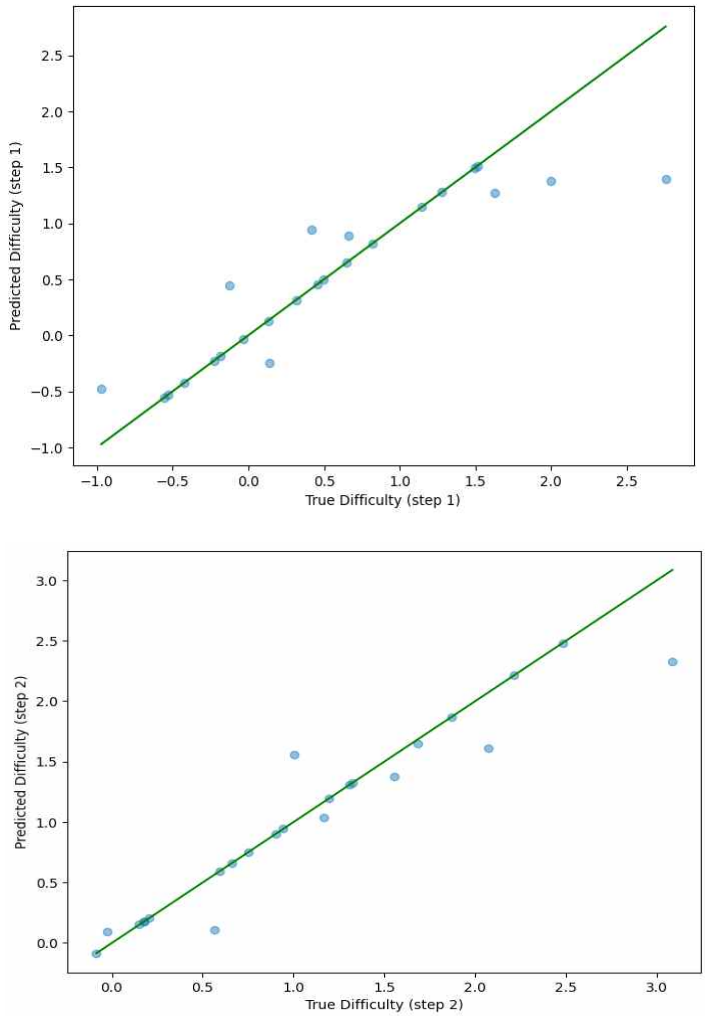

[그림 4.1.4] 그래디언트 부스팅 모형의 단계난도 추정치 분포(위: 1단계, 아래: 2단계)

인하대학교
INHA UNIVERSITY

2. 모형별 문항 난도 추정 정확성 비교

1) 머신러닝 모형과 설명적 부분점수모형 간 추정 정확성 비교

먼저, LPCM과 랜덤 포레스트 모형, 그래디언트 부스팅 모형이 추정한 각 문항의 단계 난도($\widehat{\delta_{i1}}$, $\widehat{\delta_{i2}}$)와 실제 단계 난도(δ_{i1}, δ_{i2}) 간의 상관계수를 분석한 결과는 다음의 <표 4.2.1>과 같다. 각 모형의 단계 난도 추정치와 실제 단계 난도 간의 상관이 높을수록 모형이 각 문항의 단계 난도를 정확히 추정했다고 볼 수 있다. 전반적으로, 1단계와 2단계 난도에서 모든 모형의 상관계수가 0.9 이상으로 높았으며 1단계 난도보다 2단계 난도에서의 상관계수가 높은 것을 확인할 수 있었다. 1단계 난도에서는 LPCM의 상관계수는 0.949, 랜덤 포레스트 모형의 상관계수는 0.934, 그래디언트 부스팅 모형의 상관계수는 0.914로, LPCM이 실제 단계 난도와 가장 높은 상관을 보였다. 반면에, 2단계 난도에서는 랜덤 포레스트 모형의 상관계수가 0.966으로 가장 높았으며, LPCM의 상관계수가 0.952로 가장 낮은 것으로 나타났다.

<표 4.2.1> 모형별 단계 난도 추정치와 실제 난도 간 상관

모형 구분	1단계 난도	2단계 난도
LPCM	0.949	0.952
RF	0.934	0.966
GD	0.914	0.961

Note. LPCM = 설명적 부분점수모형, RF = 랜덤포레스트 모형, GD = 그래디언트 부스팅 모형

모형별 단계 난도 추정치와 실제 단계 난도의 상관 계수 비교 결과를 그래프로 시각화한 결과는 다음의 [그림 4.2.1]과 같다.

인하대학교
INHA UNIVERSITY

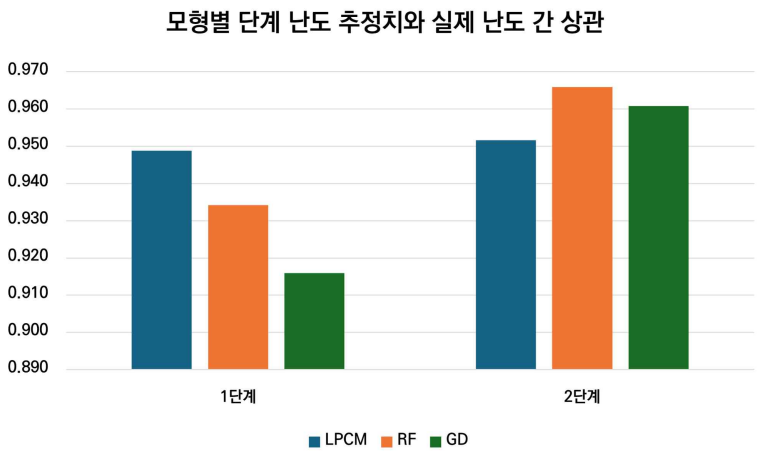

[그림 4.2.1] 모형별 단계 난도 추정치와 실제 난도 간 상관

다음으로, LPCM과 랜덤 포레스트 모형, 그래디언트 부스팅 모형이 추정한 문항별 단계 난도($\widehat{\delta_{i1}}$, $\widehat{\delta_{i2}}$)의 평균제곱오차(MSE)를 분석하여 비교한 결과는 다음의 <표 4.2.2>와 같다. 전반적으로, 1단계와 2단계 난도에 대한 모든 모형의 MSE는 0.2 이하로 나타났으며 랜덤 포레스트 모형과 그래디언트 부스팅 모형의 MSE는 1단계 난도보다 2단계 난도에서 더 낮은 것을 확인할 수 있었다. 1단계 난도에 대해서는 LPCM의 MSE가 0.097로, 다른 머신러닝 모형에 비해 낮았으며, 2단계 난도에서는 그래디언트 부스팅 모형의 MSE가 0.059로 다른 모형에 비해 낮은 것을 확인할 수 있었다.

<표 4.2.2> 모형별 단계 난도 추정치의 평균제곱오차

모형 구분	1단계 난도	2단계 난도
LPCM	0.097	0.117
RF	0.197	0.111
GD	0.142	0.059

Note. LPCM = 설명적 부분점수모형, RF = 랜덤포레스트 모형, GD = 그래디언트 부스팅 모형

모형별 단계 난도 추정치의 MSE 비교 결과를 그래프로 시각화한 결과는 다

인하대학교
INHA UNIVERSITY

음의 [그림 4.2.2]와 같다.

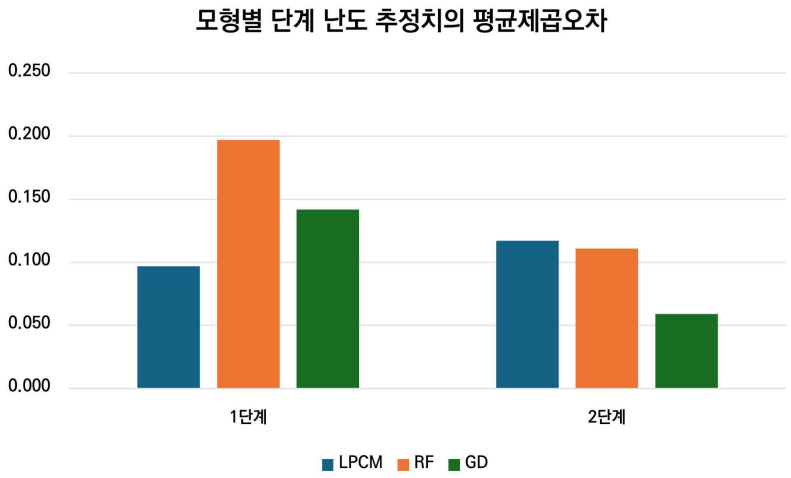

[그림 4.2.2] 모형별 단계 난도 추정치의 평균제곱오차

인하대학교
INHA UNIVERSITY

Ⅴ. 결론 및 논의

1. 연구 결과 및 논의

본 연구는 다분 문항으로 구성된 검사에서 설명적 부분점수모형과 머신러닝 모형(랜덤 포레스트, 그래디언트 부스팅) 간의 문항 난도 추정 정확성을 분석하여 비교하였다. 이를 위해 언어적 공격성(verbal aggression; Vansteelandt & Van Mechelen, 2001) 데이터를 활용하였으며, 벨기에 소재 대학의 심리학과 1학년 학생 316명을 대상으로 수집되었다. 해당 데이터는 좌절감을 유발하는(frustrating) 상황에서 언어적으로 공격적인 반응의 정도를 측정하는 24개의 다분 문항으로 구성되어 있다. 데이터 분석에는 R(4.3.1) 및 Python(3.10.12) 프로그램을 활용하였으며, 최적의 머신러닝 모형을 구축하기 위해 Sklearn의 RandomizedSearchCV 패키지를 활용하여 각 모형에 적합한 하이퍼파라미터를 탐색 및 적용하였다.

이에 따른 본 연구의 결과와 그에 대해 논의할 점은 다음과 같다. 첫째, 설명적 부분점수모형이 부분점수모형에 비해 언어적 공격성 데이터를 분석하는데 있어서 적합한 모형인지 여부를 파악하기 위해 AIC, BIC 지수를 비교한 결과, 설명적 부분점수모형의 BIC 지수가 부분점수모형보다 낮은 것으로 나타났다. 다만, AIC 지수에서는 부분점수모형의 AIC가 12737.75로, 설명적 부분점수모형의 AIC 값(12865.21)보다 낮았다. 이는 설명적 부분점수모형이 부분점수모형에 비해 추정한 모수의 개수가 적어, 간결한 모형임에도 불구하고 모형의 적합성이 낮음을 의미한다. 그러나, BIC에서는 설명적 부분점수모형의 BIC 값이 12954.14로, 부분점수모형의 BIC 값(13131.26)보다 낮게 나타났다는 점을 주목할 만하다. 기본적으로 BIC는 모형에서 추정된 모수의 개수에 대해 더 크게 벌점를 부여하는 반면, AIC는 모수가 많은 모형에 대해 벌점을 비교적 작게

인하대학교
INHA UNIVERSITY

부여하는 경향이 있다(Kuha, 2004). 따라서, 이러한 점을 고려했을 때, 설명적 부분점수모형에서 추정한 모수의 개수가 부분점수모형보다 작기 때문에 BIC가 더 낮게 나타났다고 이해할 수 있다(Kuha, 2004; Wagenmakers & Farrell, 2004). 다시 말해, BIC는 AIC보다 간결한(parsimonious) 모형을 더 선호한다고 해석할 수 있으며 본 연구에서 제시한 <표 4.1.4>에 따르면 기존 부분점수모형에서 추정한 문항 모수는 48개나, 설명적 부분점수모형에서는 10개이므로 설명적 부분점수모형이 더 간결한 모형임을 확인할 수 있었다.

둘째, 설명적 부분점수모형과 랜덤 포레스트 모형, 그래디언트 부스팅 모형의 문항별 단계 난도 추정치와 실제 단계 난도 간의 상관계수를 분석한 결과, 전반적으로 1단계와 2단계 난도에서 모든 모형의 상관계수가 0.9 이상으로 높은 상관을 보였다. 또한, 설명적 부분점수모형과 랜덤 포레스트 모형, 그래디언트 부스팅 모형의 문항별 단계 난도 추정 정확성을 파악하기 위해 각 모형의 평균제곱오차를 비교한 결과, 1단계와 2단계 난도에서 모든 모형의 평균제곱오차가 0.2 미만으로 낮게 나타났다. 이는 머신러닝 모형과 설명적 부분점수모형의 예측 정확성이 우수하고 추정 오차가 적다는 것을 의미한다. 설명적 부분점수모형의 경우, 기존 부분점수모형에 비해 추정한 문항 모수의 개수가 적었음에도 불구하고 높은 추정 정확성을 보였다는 점에서 문항 수가 적은 경우에도 비교적 정확하게 문항 난도를 추정할 수 있다는 가능성이 있다.

본 연구는 다분 문항 유형의 검사에서 문항의 단계 난도를 추정하는 데 있어서 설명적 부분점수모형와 랜덤 포레스트 모형 및 그래디언트 부스팅 모형 간의 정확성을 분석하고 비교함으로써 설명적 부분점수모형의 유용성과 더불어, 머신러닝 모형의 활용 가능성에 대해 탐구하였다. 특히, 설명적 부분점수모형은 기존의 다분 문항반응모형에 비해 적은 수의 문항 모수를 추정하여 각 문항 특성이 단계별로 미치는 효과를 설명하고 비교적 정확하게 예측할 수 있도록 함으로써 방법론적 이점을 제공한다고 할 수 있다. 이러한 측면에서 설명적 부분점수모형은 서답형 문항과 같은 다양한 유형의 다분 문항에서 채점자 점수, 문항 노출 시간, 평가 영역 등의 다양한 특성의 효과를 측정하는 데 활용될 가능성이 있음을 시사한다(Kim & Wilson, 2020).

인하대학교
INHA UNIVERSITY

2. 제언

본 연구의 결과 및 한계점을 바탕으로 한 후속 연구를 위한 제언은 다음과 같다. 첫째, 다양한 검사 조건에서 각 모형의 문항 난도 추정 정확성을 분석하기 위해서 모의실험을 통한 연구를 수행할 필요가 있다. 본 연구에서는 다분 문항으로 구성된 검사에서 머신러닝 모형과 설명적 문항반응모형 간의 문항 난도 추정 정확성을 분석 및 비교하고자 실제 검사에서 사용된 문항 및 응답 반응 자료를 활용하였다. 그러나, 실제 검사가 이루어지는 상황을 반영하기 위해서는 피험자 능력 분포나 문항 수 등의 조건을 다양하게 구성하여 모의실험 데이터를 생성하고 이를 분석하는 것이 의미가 있을 것으로 보인다. 또한, 본 연구에서는 다분 문항으로만 이루어진 검사 데이터를 활용하여 이를 분석하였으나, 이분 문항과 다분 문항이 혼합되어 있는 검사 상황을 고려하여 후속 연구를 진행한다면 더욱 실제적인 평가 상황을 반영할 수 있을 것이다.

둘째, 연구의 범위를 확장하여 다양한 문항반응모형 및 머신러닝 모형, 딥러닝 모형을 활용하여 연구를 수행할 필요성이 있다. 본 연구에서는 다분 문항으로 이루어진 검사에 대해 설명적 문항반응모형 중 하나인 설명적 부분점수 모형과 머신러닝 모형 중에서 앙상블 기법을 적용한 랜덤 포레스트와 그래디언트 부스팅 모형을 선정하여 문항 난도의 추정 정확성을 비교하였다. 그러나, 최근 생성형 인공지능을 비롯하여 인공 신경망, LSTM 모형 등의 다양한 딥러닝 모형이 개발되었고 머신러닝 모형 중에서도 다양한 비지도 학습 모형이 있다는 점을 고려하여 후속 연구를 수행할 필요성이 있다. 따라서, 다양한 모형을 적용하여 다분 문항 검사, 또는 혼합 문항 유형 검사에서의 추정 정확성을 비교한다면 해당 검사 상황에 적합한 모형을 탐색하고 개발하는 데에 도움을 줄 수 있을 것으로 보인다.

인하대학교
INHA UNIVERSITY

참 고 문 헌

강태훈, 김명연(2012). 모의실험 연구를 통한 등급반응모형과 일반화부분점수 모형 비교. 교육평가연구, 25(3), 479-496.

강태훈, 심혜진(2015). 다분문항반응이론에서 두 가지 사후기대추정법을 통한 IRT 능력모수 정확성 비교 연구, 교육방법연구. 27(1), 89-107.

김길재, 김병주(2024). 교육 분야에서의 랜덤포레스트 알고리즘 활용 연구 동향 분석. 미래교육학연구, 37(2), 77-102.

김 선, 반제천(2024). LLTM모형과 LLTM-R모형을 이용한 Rasch 문항난이도 및 문항정답률에 영향을 미치는 요인 탐색: 초등학교 3R’s 셈하기를 중심으로. 교육평가연구, 37(1), 145-174.

김형관, 유진은(2020). ICILS 2018 컴퓨터·정보 소양 예측 변수 탐색: glmmLasso를 통한 다층모형에서의 변수 선택. 교육과학연구, 22(4), 1-21.

문지영, 조명근(2023). 대학생 학업 중단 예방을 위한 기계학습 기반 모형 탐색. 교육평가연구, 36(2), 289-313.

박정(2001). 다분 문항반응이론 모형. 서울: 교육과학사.

서지범, 강남화(2023). 머신러닝과 설명가능한 인공지능 SHAP을 활용한 사범대학 전공생의 전공만족도 및 학업만족도 영향요인 탐색. 과학교육연구지, 47(1), 37-51.

성태제(1997). 문항반응이론: 이분문항반응 모형과 등급반응모형. 정신병리학, 6(2), 212-222.

유진은(2021). AI시대 빅데이터 분석과 기계학습. 학지사.

이지혜, 강동수(2021). 랜덤포레스트를 이용한 프로젝트 초기단계 소프트웨어 기능점수 추정. 정보과학회 컴퓨팅의 실제, 27(1), 41-47.

인하대학교
INHA UNIVERSITY

장필식(2022). 그래디언트 부스팅 기계학습 및 유전 알고리즘을 적용한 증권 트레이딩 전략의 성능 분석. 한국컴퓨터정보학회논문지, 27(11), 147-155.

정혜원, 박소영(2021). 다층자료에 대한 벌점화 회귀모형의 모수추정값과 예측성과 비교 연구. 교육평가연구, 34(1), 183-205.

조수빈(2023). 랜덤포레스트(Random Forest)를 활용한 초·중·고등학생의 정보역량 영향요인 탐색. 학습자중심교과교육연구, 23(20), 905-922.

최세일(2017). 설명적 문항반응이론을 이용한 영어 읽기 시험 자료의 분석. 한국연구재단, 연구보고서.

한정아(2023). 설명 가능한 인공지능을 활용한 청소년의 학업열의 관련 주요 변수 탐색. 교육학연구, 61(6), 323-349.

허주성, 권도형, 김주봉, 한연희, 안채현(2018). 그래디언트 부스팅을 활용한 암호화폐 가격 동향 예측. 정보처리학회논문지: 소프트웨어 및 데이터 공학, 7(10), 387-396.

Andrich, D. A. (1978). A rating formulation for ordered response categories. *Psychometrika, 43*(4), 561-573.

Baghaei, P., & Kubinger, K. D. (2015). Linear Logistic Test Modeling with R. Practical Assessment, *Research & Evaluation, 20*(1).

Bejar, I. I. (1977). An application of the continuous response level model to personality measurement. *Applied Psychological Measurement, 1*(4), 509-521.

Bergner, Y., Droschler, S., Kortemeyer, G., Rayyan, S., Seaton, D.,& Pritchard, D. E. (2012). Model-based collaborative filtering analysis of student response data: Machine-learning item response theory. *International Educational Data Mining Society*.

Breiman, L. (2001). Random Forests. *Machine Learning, 45*(1), 5-32.

인하대학교
INHA UNIVERSITY

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (2017). *Classification and regression trees (eBook).* Boca Raton, Florida: Routledge.

Carleo, G., Cirac, I., Cranmer, K., Daudet, L., Schuld, M., Tishby, N., Vogt-Maranto, L., & Zdeborova, L. (2019). Machine learning and the physical sciences. *Reviews of Modern Physics, 91*(4), 1-39.

Chen, T. (2015). XGBoost: extreme gradient boosting. *R package version 0.4.2, 1*(4).

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the ACM SIGKDD international conference on knowledge discovery and data mining, 13-17-Augu*, 785-794.

Cho, S. J., De Boeck, P., & Lee, W. Y. (2017). Evaluating testing, profile likelihood confidence interval estimation, and model comparisons for item covariate effects in linear logistic test models. *Applied Psychological Measurement, 41*(5), 353-371.

Choi, Y. (2024). Machine learning-base item difficulty prediction model using item text features. *Secondary English Education, 17*(1), 47-66.

Cole, K. L., Turner, R. C., & Gitchel, W. D. (2019). A study of polytomous IRT methods and item wording directionality effects on perceived stress items. *Personality and Individual Differences, 147*, 63-72.

De Boeck, P., Bakker, M., Zwitser, R., Nivard, M., Hofman, A., Tuerlinckx, F., & Partchev, I. (2011). The estimation of item response models with the lmer function from the lme4 package in R. *Journal of Statistical Software, 39*(12), 1-28.

De Boeck, P., & Wilson, M. (Eds.), (2004). *Explanatory item response model: a generalized linear and nonlinear approach.* New York:

인하대학교
INHA UNIVERSITY

Springer-Verlag.

Deng, H., Zhou, Y., Wang, L., & Zhang, C. (2021). Ensembel learning for the early prediction on neonatal jaundice with genetic features. *BMC Medical Informatics and Decision Making. 21*(338), 1-21.

DeMars, C. E. (2010). *Item Response Theory*, New York, NY: Oxford University Press.

Embretson, S. E., & Wetzel, C. D. (1987). Component latent models for paragraph comprehension tests. *Applied Psychological Measurement, 11*, 175-193.

Embreston, S. M., & Reise, S. P. (2000). *Item Reponse Theory for Psychologists*, Mahwah, NJ: Lawrence Erlbaum Associates.

Fernandez-Delgado, M., Cernadas, E., Barro, S., & Amorim, D. (2014). Do we need hundreds of classifiers to solve real world classification problems? *Journal of Machine Learning Research, 15*, 3133-3181.

Fisher, G. H. (1973). The linear logistic test model as an instrument in educational research. *Acta Psychologica, 37*, 359-374.

Fischer, G. H., & Formann, A. K. (1982). Some applications of logistic latent trait models with linear constraints on the parameters. *Applied Psychological Measurement, 4*, 397-416.

Fischer, G. H., & Ponocny, I. (1994). An extension of the partial credit model with an application to the measurement of change. *Psychometrika, 59*, 177-192.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics. 29*(5), 1189-1232.

Gonzalez, O. (2020). Psychometric and machine learning approaches for diagnostic assessment and tests of individual classification.

인하대학교
INHA UNIVERSITY

Psychological Methods, 26(2), 236-254.

Hartzel, J., Agresti, A., & Caffo, B. (2001). Multinomial logit random effects models. *Statistical Modelling, 1*, 81-102.

Hecht, M., Weirich, S., Siegle, T., & Frey, A. (2015). Effects of design properties on parameter estimation in large-scale assessments. *Educational and Psychological Measurement, 75*(6), 1021-1044.

Janssen, R., Schepers, J., & Peres, D. (2004). Models with item and item group predictors. In P. De Boeck & M. Wilson (Eds.), *Explanatory item response models: A generalized linear and nonlinear approach* (pp. 189-212). New York: NY: Springer.

Jiao, H., & Lissitz, R. (2020). What hath the coronavirus brought to assessment? Unprecedented challenges in educational assessment in 2020 and years to come. *Educational Measurement, Issues and Practice, 39*(3), 45-48.

Kim, J., & Wilson, M. (2020). Polytomous items explanatory item response theory models. *Educational and Psychological Measurement, 80*(4), 726-755.

Kuha, J. (2004). AIC and BIC: Comparisons of assumtions and performance. *Sociological Methods & Research, 33*, 188-229.

Loe, B., S., Sun, L., Simonfy, F., & Doebler, P. (2018). Evaluating an automated number series item generator using linear logistic test models. *Journal of Intelligence, 6*(20).

Lord, F. M., & Novick, M. R. (1968). *Statistical Theories of Mental Test Scores*. Reading, MA: Addison-Wesley.

Mair P., Hatzinger R., Maier M. J. (2024). *eRm: Extended Rasch Modeling (1.0-6) [Computer software manual]*. Available from https://cran.r-p

인하대학교
INHA UNIVERSITY

roject.org/web/packages/eRm/index.html

Masters, G. N. (1982). A Rasch model for partial credit scoring. *Psychometrika, 47*(2), 149-174.

Masters, G. N. (1988). The analysis of partial credit scoring. *Applied Measurement in Education, 1*(4), 279-297.

Masters, G. N., & Wright, B. D. (1997). The partial credit model. In W. J. van der Linden & R. K. Hambleton (Eds.), *Handbook of modern item response theory* (pp. 101-121). New York, NY: Springer.

Muraki, E. (1992). A generalized partial credit model: Application of an EM algorithm. *Applied Psychological Measurement, 16*, 159-176.

Muraki, E., & Muraki, M. (2016). Generalized partial credit model. In W. J. van der Linden (Ed.), *Handbook of Item Response Theory, Volume One* (pp. 155-166). Boca Raton, FL: CRC Press.

NVIDIA Korea. (2018. 09. 03.). 딥러닝 지도학습, 자율학습, 지도/자율학습. 강화학습의 차이점은 무엇일까?. URL: https://blogs.nvidia.co.kr/blog/supervised-unsupervised-learning/ (검색일: 2024. 11. 20)

Ostini, R., & Nering, M. L. (2006). *Polytomous Item Response Theory Models*. Thousand Oaks, CA: Sage.

Park, J. Y., Dedja, K., Pliakos, K., Kim, J., Joo, S., Cornillie, F., Vens, C., & Van den Noortgate, W. (2022). Comparing the prediction performance of item response theory and machine learning methods, on item responses for educational assessments. *Behavior Research Methods*, *55*, 2109-2124.

Pliakos, K., Joo, S., Park, J. Y., Cornillie, F., Vens, C., & Van den Noortgate, W. (2019). Integrating machine learning into item response theory for addressing the cold start problem in adaptive learning systems.

인하대학교
INHA UNIVERSITY

Computers and Education, 137, 91-103.

Poinstingl, H. (2009). The linear logistic test model(LLTM) as the methodological foundation of item generating rules for a new verbal reasoning test. *Psychology Science Quarterly, 51*(2), 123-134.

Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning, 1*(1), 81-106.

Rasch, G. (1960). *Probabilistic Models for Some Intelligence and Attainment Tests.* Copenhagen, Denmark: Paedagogiske Institute.

Rijmen, F., Tuerlinckx, F., De Boeck, P., & Kuppens, P. (2003). A nonlinear mixed model framework for item response theory. *Psychological Methods, 8*, 185-205.

Rose, N. Nagy, G., Nagengast, B, Frey A., & Becker, M. (2019). Modeling multiple item context effects with generalized linear mixed models. *Frontiers in Psychology, 10*(248).

Romero, C., Ventura, S., Pechenizkiy, M., & Baker, R. S. J. d. (Eds.). (2010). Handbook of Educational Data Mining (1st ed.) . CRC Press.

Rief, M. (2012). Applying a construction rational to a rule based designed questionnaire using the Rasch model and LLTM. *Psychological Test and Assessment Modeling, 54*, 73-89.

Samejima, F. (1969). Estimation of latent ability using a response pattern of graded scores. *Psychometrika Monograph Supplement, 17.*

Schonlau, M., Zou, R. Y. (2020). The random forest algorithm for statistical learning. *The Stata Journal, 20*(1), 3-29.

Shmueli, G. (2010). To explain or to predict? *Statistical Science, 25*(3), 289-310.

인하대학교
INHA UNIVERSITY

Thissen, D., & Steinberg, L. (1986). A taxonomy of item-response models. *Psychometrika, 51*, 567-577.

Tuerlinckx, F., & Wang, W. C. (2004). Models for polytomous data. In De Boeck, P. & Wilson, M. (Eds.), *Explanatory item response models: A generalized linear and nonlinear approach* (pp. 75-109). New York, NY: Springer-Verlag.

Vansteelandt, K., & Van Mechelen, I. (2001). Formal models for contextualized personality psychology. *Doctoral dissertation*, KU Leuven, Flanders, Belgium.

Wagenmakers, E. J., & Farrell, S. (2004). AIC model selection using Akaike weights. *Psychonomic Bulletin & Review, 11*, 192-196.

Witten, I. H., Frank, E., & Hall, M. A. (2011). *Data Mining: Practical machine learning tools and techniques*. Morgan Kaufmann Publishers Inc.

Wolpert, D. H., & Macready, W. G. (1997). No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation, 1*(1), 67-82.

Zheng, X., & Rabe-Hesketh, S. (2007). Estimating parameters of dichotomous and ordinal item response models with gllamm. *Stata Journal, 7*, 313-333.

인하대학교
INHA UNIVERSITY

ABSTRACT

Comparison of Polytomous Item Difficulty Estimation Accuracy Between Explanatory Partial Credit Model and Machine Learning Models

Haneul, Lee(Inha University)

To more accurately assess and predict students' learning outcomes, research and the development of models leveraging background factors of examinees and item characteristics for analyzing assessment results have been continuously conducted. In particular, the explanatory item response model (EIRM) has demonstrated its utility by incorporating examinee and item characteristics, as well as their interaction effects, into the model to provide a comprehensive interpretation of assessment results. Meanwhile, machine learning, as a data-driven approach capable of efficient and accurate predictive algorithms, shows potential for application in educational assessment, particularly in analyzing data such as item difficulty and examinee responses. Consequently, recent studies have explored integrating machine learning models with item response theory (IRT) or comparing their estimation outcomes. However, most of these studies have been limited to dichotomous item formats, and comparisons of estimation accuracy between EIRM and machine learning models remain relatively scarce.

Regarding this, this study aimed to analyze and compare the accuracy of item difficulty estimation using the step difficulty explanatory linear partial credit model (LPCM) and machine learning models (random forest and gradient boosting) in assessments composed of polytomous items. By evaluating the performance of these two approaches based on polytomous

인하대학교
INHA UNIVERSITY

item response data, this study sought to identify the strengths and limitations of each model. To this end, data from a verbal aggression assessment were analyzed, and the correlation between estimated and true item difficulty, as well as mean squared error (MSE), was calculated to compare the estimation accuracy of the two models.

The findings of this study are as follows. First, analyzing the correlation between the step difficulty estimates of the LPCM, random forest, and gradient boosting models and the true step difficulty values revealed that all models demonstrated high correlations above 0.9 for both the first and second step difficulties. Additionally, a comparison of the MSE for step difficulty estimation accuracy across the three models showed that the MSE for all models remained below 0.2 for both steps, indicating excellent predictive accuracy and minimal estimation error for the machine learning models and LPCM. Notably, despite requiring fewer item parameters than the traditional partial credit model, the LPCM demonstrated high estimation accuracy, suggesting its potential for accurately estimating item difficulty even when the number of items is limited.

Through this study, the applicability and predictive accuracy of EIRM and machine learning models for estimating and predicting item difficulty in assessments with polytomous items were explored and compared. The findings provide practical insights into selecting appropriate models for predicting and estimating item difficulty under polytomous assessment conditions.

Keywords: Polytomous Item Response Model, Explanatory Item Response Model, Step Difficulty Explanatory Linear Partial Credit Model, Machine Learning